

Gate Retrieval-Augmented Forecasting による 書籍需要予測

1. はじめに

出版物は、個々の販売規模が小さく品目数が多いという多品種少量生産の性質をもつ。こうした多様な出版物の流通を支えるため、出版業界では再販売価格維持制度と委託販売制度が広く用いられている。前者は出版社が定価を定めて小売店に定価での販売を求める制度であり、価格競争による淘汰から多様な出版物を守る [1]。後者は、小売店が売れ残った在庫を出版社へ返品できる委託仕入れの制度であり、小売店の在庫リスクを抑える一方で、返本を構造的に生み出す。需要に基づかない発注や配本は、この返本をさらに増大させる。返本の増加は物流コストや流通効率の面で出版業界全体の課題となっており [2]、返本率の低減には需要に即した配本が不可欠である。したがって、書籍の販売冊数を適切に予測することは、出版流通の効率化における重要な課題である。

一般に、書籍の需要予測は、過去の販売冊数に基づく時系列予測問題として位置づけられる。しかし多品種少量生産という特性上、需要の多くはゼロや少数にとどまる一方で、初版発行やイベントなどにより突発的な需要増加が生じる。通常の予測モデルはこうした需要を平坦に予測しやすく、単一系列の履歴だけでは稀にしか起こらないスパイクのパターンを学習しにくい。

時系列予測問題に対し、自然言語処理の Retrieval-Augmented Generation (RAG) [3] を時系列予測へ拡張した Retrieval-Augmented Forecasting (以下, RAF) が提案されている [4]。RAF は、予測対象の直近の変動パターンに類似する過去の部分系列 (以下, 参照ウィンドウ) をデータベースから検索し、予測モデルへの追加情報として利用する。これにより類似事例を系列横断的に活用できるため、予測対象系列のみを用いる単一系列モデルでは捉えにくい情報を補うことができる。しかしながら従来の RAF は、参照ウィンドウを予測対象の直近区間に時間軸方向へ連結して入力するため、主に二つの問題を抱える。第一に、参照ウィンドウと直近区間では値の水準や端部の変化が必

ずしも一致せず、両者の接続点に不連続が生じる可能性がある。第二に、近傍探索は相対的な類似順位で検索結果を選ぶため、予測に十分関連しない参照ウィンドウであっても一律に取り込まれてしまう。

上記の議論を鑑み、本研究では従来の RAF の持つ問題を解決し、書籍の販売冊数を高精度に予測する手法の構築を目的とする。このために、上記の問題に対処したゲート付き融合型 RAF である GateRAF を提案する。GateRAF では、ローカルコンテキストと各参照ウィンドウを同一のエンコーダで独立に処理するマルチストリームエンコードを導入し、入力系列の接合に伴う不連続性を排除する。さらに、ローカル要約ベクトルと各参照パッチとの関連度をスカラーゲートによって評価することで、予測対象との関連性が低い参照情報の混入を動的に抑制する。

提案手法の有効性を、経営科学系研究部会連合協議会が主催する令和 7 年度データ解析コンペティションより提供された書籍 POS データを用いた実験により検証する。実験を通じて、GateRAF が従来手法に対して予測精度を改善すること、平常時の過大予測の抑制とスパイク近傍の予測の時間的な改善にそれぞれ寄与することを示す。

2. 準備

2.1 問題設定

本研究では、経営科学系研究部会連合協議会が主催する令和 7 年度データ解析コンペティションより提供いただいた書籍 POS データを使用する。本データは 2024 年の 1 年間にわたる全国 35 店舗分の書籍・雑誌の販売実績であり、約 20 万書名・約 400 万件の販売記録から構成される。各記録は販売日、店舗、書名、販売冊数等の情報を持つ。

前述の通り、書籍の販売冊数は、平常時には少数にとどまることが多い一方、イベントなどに起因して短期間だけ販売冊数が急増する場合がある。以下では、このような一時的な需要増加をスパイクと呼ぶ。需要を過小に見積もればスパイクが発生した際に機会損失が生じ、逆に過大に見積もれば在庫や返本の増加につながる。したがって本研究では、平常時の少数需要とス

パイクが混在する販売冊数を、過不足なく予測することを課題とする。予測の対象は、書名ごとに全店舗の販売冊数を日単位で合算した時系列であり、目的変数は将来の各日における販売冊数そのものとする。本研究で観測する販売冊数は、POS上に記録された実際販売量である。いま、需要を消費者が購入を希望する量と定義すれば、在庫切れなどにより需要が販売冊数を上回る可能性が存在する。しかしながら、対象データには在庫情報が存在せず、潜在的な需要を直接観測することはできない。そこで販売冊数を需要の代理指標として用い、本論文における需要予測は販売冊数の予測を指すものとする。その際、書籍の販売特性を踏まえ、需要を平均的に均して予測するのではなく、平常時とスパイクが混在する需要構造に対応できる予測を目指す。

2.2 関連研究

スパイク需要の捕捉と少数系列からの学習に関連する手法は、主に時系列予測の基盤手法、間欠・突発需要予測、検索拡張型予測に分けられる。

時系列予測の基盤手法としては、PatchTST [5] などの Transformer ベースの深層学習手法、確率的予測手法である DeepAR [6] や TFT [7]、大規模事前学習基盤モデルである Chronos [8] が代表的な手法として挙げられる。また、間欠・突発需要予測についても数多くの研究が存在し、Croston 法 [9] が基準手法として広く参照されている。また、系列に生じる急激な変化を扱う手法として変化点検知がある。変化点検知は、観測された系列から変化の発生時点を検出する手法であり、たとえばオンライン変化点検知 [19] は、観測が得られるたびに変化点の事後確率を更新することで、変化を逐次的に検出する。書籍のスパイクも系列に生じる急激な変化の一種であり、変化点検知はその発生を捉える手段となりうる。

RAG [3] を時系列予測へ拡張した RAF は、予測対象のローカルコンテキストに類似した過去のウィンドウを検索データベースから取得し、予測に活用する手法である。これにより、単一系列からは捕捉が困難な稀なスパイクパターンを、系列横断的に参照できる。代表的な手法として、Chronos [8] を基盤とし、検索した参照ウィンドウをローカルコンテキストへ時間軸方向に連結して、一つの拡張シーケンスとしてエンコードする ProtoRAF [4] がある。また、TS-RAG [10] や TimeRAF [11] では、それぞれ潜在空間での融合や Channel Prompting によって、検索情報の活用方法を改善している。

3. 従来手法

提案手法の基礎となる ProtoRAF [4] は、参照ウィンドウを以下の手順で取得する。まず、学習データの系列を長さ L のウィンドウに区切り、各ウィンドウを $\mathbf{w}_i \in \mathbb{R}^L$ として過去のウィンドウ集合 $\mathcal{D} = \{\mathbf{w}_i\}_{i=1}^N$ を構成する。ただし、 N をウィンドウ数とする。また、予測対象の直近 L 時点をローカルコンテキスト $\mathbf{x} \in \mathbb{R}^L$ とおく。ProtoRAF による予測では、 $\mathbf{x}$ と $\mathcal{D}$ の各ウィンドウ $\mathbf{w}_i$ を互いに標準化したもとので比較する。すなわち、 $\mathbf{x}$ を標準化した $\tilde{\mathbf{x}}$ と、 $\mathbf{w}_i$ を標準化した $\tilde{\mathbf{w}}_i$ の距離 $d(\tilde{\mathbf{x}}, \tilde{\mathbf{w}}_i)$ を算出し、このうち距離の小さい上位 K 件を参照ウィンドウ $\mathbf{r}_k \in \mathbb{R}^L$ ($k = 1, \dots, K$) として取得する：

$$\{\mathbf{r}_k\}_{k=1}^K = \text{Top-}K_{\min} \underset{\mathbf{w}_i \in \mathcal{D}}{d(\tilde{\mathbf{x}}, \tilde{\mathbf{w}}_i)} \quad (1)$$

ここで、 $\text{Top-}K_{\min}$ は距離 d が小さい順に上位 K 件を選ぶ操作であり、その計算には近傍検索を用いる。なお本研究では、距離 d として、標準化後のウィンドウ間の二乗ユークリッド距離

$$d(\tilde{\mathbf{x}}, \tilde{\mathbf{w}}_i) = \sum_{t=1}^L (\tilde{x}_t - \tilde{w}_{i,t})^2 \quad (2)$$

を用いる。ここで $\tilde{x}_t$ と $\tilde{w}_{i,t}$ は、それぞれ $\tilde{\mathbf{x}}$ と $\tilde{\mathbf{w}}_i$ の第 t 要素を表す。この距離は標準化後の系列に対して定義されるため、系列の水準や振幅の違いを除いた変動の形状の類似度を測ることになる。また、 $\tilde{\mathbf{x}}$ と $\tilde{\mathbf{w}}_i$ はいずれも平均 0、分散 1 に標準化されているため、式 (2) の距離は、 $\mathbf{x}$ と $\mathbf{w}_i$ のピアソン相関係数 r_i を用いて $2L(1 - r_i)$ と書ける。したがって、距離 d の代わりに相関係数や標準化後の系列に対するコサイン類似度を用いても、取得される参照ウィンドウは変わらない。

また、データリークを防ぐためウィンドウ集合 $\mathcal{D}$ は予測時点より前のウィンドウのみで構成する。この検索は $\mathcal{D}$ の中で相対的に類似した上位 K 件を返すため、予測対象に真に似た事例があるか否かによらず、常に K 件が選出される。

図 1 に示すように、ProtoRAF はローカルコンテキスト $\mathbf{x}$ の前方に参照ウィンドウ $\mathbf{r}_1, \dots, \mathbf{r}_K$ をそのまま連結して拡張コンテキスト $\mathbf{x}^{\text{proto}} \in \mathbb{R}^{(K+1)L}$ を構成し、これを単一系列としてエンコーダに入力してパッチ表現 $H^{\text{proto}} \in \mathbb{R}^{(K+1)P \times D}$ を得る。パッチ数を P 、エンコーダの埋め込み次元を D とすると、こ

れらは以下のように表される：

$$\mathbf{x}^{\text{proto}} = \text{Concat}(\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_K, \mathbf{x}) \quad (3)$$

$$H^{\text{proto}} = \text{Encode}(\mathbf{x}^{\text{proto}}) \quad (4)$$

ここで $\text{Concat}(\cdot)$ は、与えられたベクトルまたは行列を行方向（時間軸方向）に連結する操作を表す。また H^{proto} は、 $\mathbf{x}^{\text{proto}}$ をパッチごとに区切って各パッチを D 次元ベクトルへ変換し、これら $(K+1)P$ 個のベクトルを行方向に積み上げた $(K+1)P \times D$ の行列である。このエンコーダ $\text{Encode}(\cdot)$ は、入力系列をその平均と標準偏差で標準化してからパッチ表現へ変換する [14]。ProtoRAF では、この標準化に用いる平均と標準偏差を、ローカルコンテキストだけでなく参照ウィンドウまで連結した $\mathbf{x}^{\text{proto}}$ 全体から計算する。

ProtoRAF は、参照ウィンドウとローカルコンテキストを 1 本の系列として連結する構造に起因して、接合部の不連続性と無関係な参照ウィンドウの混入という 2 つの問題を持つ。前者について、 $\mathbf{x}^{\text{proto}}$ では性質の異なる参照ウィンドウとローカルコンテキストが結合されるため、その境界で値の水準や形状が大きく異なりうる。エンコーダはこの不自然な結合を、データに実際に起きた変化と区別できないまま学習し、予測精度を低下させる。加えて、この連結は標準化の基準にも影響を及ぼす。エンコーダは平均と標準偏差を $\mathbf{x}^{\text{proto}}$ 全体から計算するため、大きく外れた観測値を含む参照ウィンドウが混在すると、ローカルコンテキストが本来とは異なるスケールで標準化される。後者について、前述の通り ProtoRAF は、予測対象に似た事例があるか否かによらず常に上位 K 件を返す。そのため、似た事例が乏しい場合には、関連の薄いウィンドウまで参照として連結される。ProtoRAF はこれらをローカルコンテキストと区別せず一括で符号化するため、無関係な情報も予測に取り込まれ、精度が低下する可能性が存在する。

4. 提案手法

4.1 概要

前述の通り、ProtoRAF には接合部の不連続性と無関係な参照ウィンドウの混入という問題が存在する。提案手法では、ProtoRAF の 2 つの問題がいずれも参照ウィンドウとローカルコンテキストを単一の系列として一括で符号化することに起因する点に着目し、これらをそれぞれ独立に符号化し、予測に役立つ参照だけを選んで組み合わせることで改善を図る。具体的には、マルチストリームエンコードとゲート機構の 2 つ

を ProtoRAF に導入する。マルチストリームエンコードは、ローカルコンテキストと各参照ウィンドウを個別に標準化し、共通のエンコーダで独立に符号化を行う。これにより、系列の連結境界をデータの変化と取り違える問題と、スケール差の影響を抑える。ゲート機構は、ローカルコンテキストとの関連性に応じて各参照への寄与を調整し、関連性の低い参照が予測に与える影響を抑制する。¹以下では提案手法を GateRAF と呼ぶこととし、その概要を図 2 に示す。

4.2 マルチストリームエンコードとゲート機構

GateRAF は次の 5 つのステップから構成される。

Step 1) ローカルコンテキストのエンコード

Step 2) 参照ウィンドウの独立エンコード

Step 3) ローカル要約ベクトルの計算

Step 4) ゲートの計算

Step 5) ゲート付き融合

Step 1 ではローカルコンテキストだけを符号化し、参照ウィンドウに影響されない標準化の基準を確保する。まず、予測対象のローカルコンテキスト $\mathbf{x}$ だけをエンコーダに入力し、そのパッチ表現 $H^{\text{loc}} \in \mathbb{R}^{P \times D}$ を式 (5) より得る：

$$H^{\text{loc}} = \text{Encode}(\mathbf{x}) \quad (5)$$

ここではローカルコンテキスト $\mathbf{x}$ のみを入力し、その平均と標準偏差で標準化するため、参照ウィンドウに含まれるスパイクの影響を受けない。

Step 2 では各参照ウィンドウを独立に符号化し、連結による接合部の作成を回避する。すなわち、各参照ウィンドウ $\mathbf{r}_k$ をローカルコンテキストと同じエンコーダで個別に符号化し、参照ブロック $H_k^{\text{ret}} \in \mathbb{R}^{P \times D}$ を得る：

$$H_k^{\text{ret}} = \text{Encode}(\mathbf{r}_k) \quad (6)$$

これにより連結部分が生じず、接合部の不連続性も避けられる。この段階では各参照を独立なブロック H_k^{ret} として保持し、ローカルコンテキストとも他の参照とも結合しない。

Step 3 ではローカルコンテキストの表現を 1 本のベ

¹距離 d の選択は、取得される参照ウィンドウそのものを変えるため、予測結果に影響し得る。一方で、Cross-RAG [12] のように各参照の出力を予測対象との関連度に応じて重み付けして統合する枠組みでは、類似尺度を変えても予測精度がほとんど変化しないことが報告されている。ゲート機構も同様に各参照ウィンドウのパッチ表現を予測対象との関連度に応じて重み付けすることから、本研究では式 (2) の距離を用いるものとし、距離尺度の違いによる性能評価は今後の課題とする。




図 1 ProtoRAF のアーキテクチャ概要




図 2 GateRAF (提案手法) のアーキテクチャ概要

クトルにまとめ、参照の基準とする。 H^{loc} をパッチ方向に平均プーリングし、ローカル要約ベクトル $\bar{h}^{\text{loc}} \in \mathbb{R}^D$ を次の通り得る：

$$\bar{h}^{\text{loc}} = \text{Pool}(H^{\text{loc}}) \quad (7)$$

ここで $\text{Pool}(\cdot)$ はパッチ方向の平均プーリングを表す。

Step 4 では各参照パッチを予測にどれだけ反映させるかを、ローカルコンテキストとの関連の強さに応じて決める。具体的には、Step 3 で得たローカル要約ベクトル $\bar{h}^{\text{loc}}$ と、各参照ブロックの第 p パッチ $\mathbf{h}_{k,p}^{\text{ret}} \in \mathbb{R}^D$ を多層パーセプトロン GateMLP に入力し、両者の関連の強さを 0 から 1 の値 $g_{k,p}$ として出力する：

$$g_{k,p} = \text{GateMLP}(\bar{h}^{\text{loc}}, \mathbf{h}_{k,p}^{\text{ret}}) \quad (8)$$

$g_{k,p}$ は参照パッチの重みであり、1 に近いほどその参照を予測に強く反映し、0 に近いほど影響を抑える。関連の薄い参照を自動的に弱めることで、無関係なウィンドウの混入を防ぐことを意図する。また、無関係な参照に影響を受けないよう、ゲートは学習の初期にはほぼ閉じた状態、すなわち出力が 0 に近い状態から始まるよう初期化する。これにより、モデルはまず信頼できるローカルコンテキストに基づいて予測を学習し、役立つ参照だけを学習の進行とともに取り込む。

Step 5 ではゲートで重み付けした参照表現をローカルコンテキストの表現と統合し、予測に用いる。まず、各参照ブロック H_k^{ret} の各パッチに、対応する重み $g_{k,p}$ を掛け、重み付き参照ブロック $\tilde{H}_k^{\text{ret}} \in \mathbb{R}^{P \times D}$ を得る。次に、ローカル表現と重み付けした全参照ブロックを結合して融合表現 $H^{\text{gate}} \in \mathbb{R}^{(1+K)P \times D}$ とする：

$$\tilde{H}_k^{\text{ret}} = \mathbf{g}_k \odot H_k^{\text{ret}} \quad (9)$$

$$H^{\text{gate}} = \text{Concat}(H^{\text{loc}}, \tilde{H}_1^{\text{ret}}, \dots, \tilde{H}_K^{\text{ret}}) \quad (10)$$

ここで $\mathbf{g}_k = (g_{k,1}, \dots, g_{k,P})^\top$ は参照ブロック k の各パッチのゲート値を並べたベクトルであり、 $\odot$ は各パッチ p の表現全体に同じ重み $g_{k,p}$ を掛ける演算を表す。関連の薄い参照ほど重みが小さくなるため、無関係なウィンドウの混入が抑えられる。参照表現とローカル表現を結合するのは Step 5 のみであり、それまでは互いに干渉しない。

4.3 予測

最後に、融合表現 H^{gate} から将来の販売冊数を予測する。 H^{gate} には、ローカルコンテキストとゲートで重み付けした参照の情報がまとめられている。これをデコーダに渡して各分位点の予測を出力し、符号化の際に施した標準化を元に戻す。分位点の集合を Q 、予測する日数を F 、標準化したスケールを元に戻す操作

表 1 各手法の推論時間（括弧内は Baseline に対する比）

モデル	推論時間 [ms]
GateRAF	69.9 (2.86)
Multi-RAF	70.1 (2.87)
ProtoRAF	60.1 (2.46)
Baseline	24.4 (1.00)

を RevNorm とすると、予測値 $\hat{Y} \in \mathbb{R}^{|Q| \times F}$ は以下のように表される：

$$\hat{Y} = \text{RevNorm}(\text{Decode}(H^{\text{gate}}), \mu, \sigma) \quad (11)$$

ここで μ, σ はローカルコンテキスト x から計算した平均と標準偏差である。また、 $\hat{Y}$ の第 (q, f) 要素は、予測起点から f 日先の 1 日における販売冊数について、 Q の第 q 番目の分位点に対応する予測値を表す。すなわち、 $\hat{Y}$ の各要素は特定の 1 日の販売冊数であり、複数日にわたる累計ではない。

4.4 計算コスト

提案手法は処理を 5 つのステップに分けるが、これは参照ウィンドウとローカルコンテキストを独立に符号化するための構成であり、逐次的な処理を追加するものではない。Step 1 と Step 2 のエンコードは互いに独立に実行でき、Step 3 から Step 5 はパッチ表現に対する要素ごとの積と多層パーセプトロンの適用にとどまる。

計算量の観点では、ProtoRAF がパッチ数 $(K+1)P$ の単一系列を符号化するのに対し、提案手法はパッチ数 P の系列を $K+1$ だけ符号化する。そのためエンコーダの自己注意の計算量は、ProtoRAF の $\mathcal{O}((K+1)^2 P^2 D)$ に対し、提案手法では $\mathcal{O}((K+1)P^2 D)$ となり、参照の連結に伴う二次的な増加は生じない。ゲート機構が追加する計算量は $\mathcal{O}(KPD^2)$ であり、エンコーダ全体と比べて小さい規模にとどまる。また、参照ウィンドウの検索に要する計算は両手法で共通である。

実際に、5.3 節で述べる実験設定 ($L = 128, K = 3$) のもとで、同一の計算機の GPU 上でバッチサイズ 16 の同一の入力を与え、各手法の推論時間を 30 回測定して平均した結果を表 1 に示す。GateRAF の推論時間は ProtoRAF の約 1.16 倍であり、自己注意の計算量の大小とは逆になった。これは、本実験ではパッチ数が小さく、推論時間の大半を全結合層の計算が占めるためと考えられる。

5. 実験

5.1 実験概要

提案手法 GateRAF が書籍の需要予測に有効であるかを検証する。このため、平常時のわずかな需要から突発的なスパイクまでを含めた予測全体の精度が、従来手法と比べて向上するか確認を行う。加えて、GateRAF を構成する 2 つの工夫、すなわちマルチストリームエンコードとゲート機構が、予測のどの側面をそれぞれ改善するかを切り分ける。

このため、過去の類似事例を一切参照しない基盤モデルそのものである Baseline、参照ウィンドウを入力系列にそのまま連結する従来手法 ProtoRAF、Baseline にマルチストリームエンコードを加えた Multi-RAF、さらにゲート機構を加えた提案手法 GateRAF の 4 手法によりその性能比較を行う。ProtoRAF と Multi-RAF の比較からマルチストリームエンコードの寄与が、Multi-RAF と GateRAF の比較からゲート機構の寄与を把握することが可能となる。

以上の枠組みのもとで、予測精度の算出（実験 1）、スパイクの大きさと発生頻度による予測精度（実験 2）、時間近接性（実験 3）、予測区間幅の比較（実験 4）、代表系列の事例分析（実験 5）の 5 つの実験を行う。

5.2 データ整形

本研究では書名ごとの需要推移を予測対象とする。まず店舗間の差異を捨象し、同一の書名・日付に対する販売冊数を全店舗にわたって合算することで、POS 販売冊数の時系列を構築した。すなわち本研究における POS 販売冊数とは、本データに含まれる各店舗の販売記録を、同一書名・同一日付で合算した販売冊数である。その上で、予測に適した系列を得るため、以下の前処理を施した。第一に、年間総販売冊数が 366 冊に満たない、すなわち一日あたり平均でおよそ 1 冊に満たない書籍は、予測に必要な販売実績の情報量を欠くため除外した。第二に、巻数違いなど同一作品をシリーズ単位へ統合し、一つの需要系列として扱うものとした。第三に、販売記録の存在しない日を欠測ではなくゼロ需要とみなして補完し、全書名と全日付を網羅する完全パネルデータを構築した。以上により、最終的に約 40 万件のデータを得た。前処理後に分析対象となった書名は 1,157 点であり、これに対象期間である 366 日を掛けた 423,462 件を分析対象とした。

得られたデータでは、POS 販売冊数の平均が約 3.68 冊であるのに対し標準偏差は 13.65 冊と大きく、さらにゼロ販売日の割合が 42.9%に達する。これは、平常

時の間欠的なゼロ需要と突発的なスパイク需要が混在するという、本研究が対象とする需要構造を端的に表している。

5.3 実験設定

比較する4手法は、時系列予測の基盤モデルをファインチューニングすることで構築した。基盤モデルには Chronos [8] の軽量・高速版である ChronosBolt を用いた。ファインチューニングには、モデル全体ではなく少数の追加パラメータのみを調整する DoRA [15] を用い、追加パラメータの規模を定めるランクは事前の予備実験により8とした。なお事例分析(実験5)では、古典的な比較対象として、時系列を傾向・季節性・休日効果の和へ分解する加法モデル Prophet [16] を併せて用いるものとした。

データは、各系列の終盤64日分を評価用とし、残りを9対1の割合で学習用と検証用に分割した。予測時には、対象系列の直近 $L = 128$ 日分を切り出してローカルコンテキストとし、これを基に続く $F = 64$ 日分の販売冊数を予測する。参照ウィンドウは、1回の予測ごとにローカルコンテキストと形の似たものを上位 $K = 3$ 件まで検索して用いる。 $K = 3$ は、ローカルコンテキストと参照ウィンドウを連結した長さ $(K+1)L$ が、Chronos の入力長である512時点に収まる最大の件数である。ChronosBolt の入力長は2048時点であり、 K を15まで増やすことができる。しかし、ProtoRAF の原論文 [4] は Chronos を基盤モデルとしているため、Chronos を基盤モデルとする場合にも同じ設定で比較できるよう、 $K = 3$ を採用した。このときの類似度は、式 (2) に示した標準化後のウィンドウ間の二乗ユークリッド距離により測るものとし、近傍検索の実装には Faiss [13] を用いた。

予測値は単一の値ではなく分位点として出力する。分位点 τ は予測を幅をもって表すための水準であり、たとえば $\tau = 0.5$ は中央の予測値を、 $\tau = 0.1$ と $\tau = 0.9$ はそれぞれ予測の下限と上限を表す。上側と下側の分位点の差は予測の幅を表し、幅が広いほど将来の予測が難しく、不確実性が高いことを意味する。本研究では $\tau \in \{0.1, 0.5, 0.9\}$ を出力し、学習にはこれら3つの分位点に対するピンボール損失 [17] を用いる。

予測精度の基本指標としては、実績と予測の平均絶対誤差(以下、MAE)と二乗平均平方根誤差(以下、RMSE)を分位点ごとに用いる。

実験1では、全系列・全予測期間を対象に、分位点ごとの MAE と RMSE を算出し、予測全体の精度を比較する。

実験2では、需要の大きさによって各手法の性能がどう変化するかを確認する。このため、各時点の実績値をその系列の平均と標準偏差で標準化した z スコアへ変換する。 z スコアは、その時点の需要が系列の平常水準からどれだけ離れているかを表し、負であれば平常より低い需要を、正で大きいほど強い急増を意味する。この z スコアの大小で時点を区分し、区分ごとに分位点別の MAE と RMSE を集計する。なお、以下では需要が平常を大きく下回る $z < -1$ の区分を静穏域、需要が急増した z の大きい区分をスパイク域と呼ぶこととする。 z スコアはその時点の需要が平常水準からどれだけ離れているかを表すため、 z スコアによる区分はスパイクの大きさによる評価にあたる。実験2ではこれに加えて、スパイクの発生頻度による層別も行う。評価期間の64日のうち z スコアが2を超えた時点の数を発生頻度とし、書名を区分する。大きさによる区分が個々の需要の水準に着目するのに対し、発生頻度による区分は系列ごとのスパイクの現れやすさに着目するものである。なお、評価期間中に一度もスパイクが生じなかった25書名は、発生頻度による層別の対象とならないため除外し、残る1,132書名を対象とする。

ここで用いる平均および標準偏差は、各系列の評価期間、すなわち予測対象となる64日間の実績値に基づいて算出したものである。この z スコアは、予測終了後に予測誤差を需要水準別に層別化して評価するための指標であり、モデルの学習および推論には使用していない。一方、予測時の標準化にはローカルコンテキストから算出した平均および標準偏差のみを用いている。したがって、評価期間の実績値に関する情報がモデルの学習または推論に流入することはない。なお、実験3および実験4で用いる z スコアについても、同様の方法により算出している。

実験3では、 $\tau = 0.5$ の予測を対象に、予測したスパイクと実際のスパイクが時間的にどれだけ近いかを評価する。各系列について、実績値の z スコアが2を超える日を実スパイクの日とし、 $\tau = 0.5$ の予測値を同じ平均と標準偏差で標準化した値が2を超える日を予測スパイクの日とする。系列 j の実スパイクの日の集合を A_j 、予測スパイクの日の集合を $\hat{A}_j$ とし、実スパイクと一致しなかった予測スパイクの日の集合 $E_j = \hat{A}_j \setminus A_j$ を誤検知、予測できなかった実スパイクの日の集合 $M_j = A_j \setminus \hat{A}_j$ を見逃しと呼ぶ。誤検知の日 $\hat{a} \in E_j$ には最も近い実スパイクの日 $a^*(\hat{a}) \in A_j$ を対応させ、見逃しの日 $a \in M_j$ には最も近い予測ス

パイクの日 $\hat{a}^*(a) \in \hat{A}_j$ を対応させて、時間差を次のように定める：

$$\Delta_E(\hat{a}) = a^*(\hat{a}) - \hat{a}, \quad (12)$$

$$\Delta_M(a) = a - \hat{a}^*(a) \quad (13)$$

ここで、前後に同じ距離の候補がある場合は、日付の早い方を対応させる。以下では、両者をまとめて Δ と書く。 Δ は予測が実スパイクより前なら正、後なら負となり、 $|\Delta|$ が小さいほど時間的に近く捉えられていることを意味する。

Δ は、相手のスパイクが存在する場合にのみ定まる。そのため集計は、実スパイクと予測スパイクがともに 1 つ以上ある系列の集合 $\mathcal{J}$ に限る。 Δ は $-5 \sim +5$ 日の範囲で集計し、両端は $\Delta \leq -5$ と $\Delta \geq +5$ にまとめる。 Δ の区分 B に含まれる誤検知の割合は、

$$\frac{\sum_{j \in \mathcal{J}} \sum_{\hat{a} \in E_j} \mathbf{1}[\Delta_E(\hat{a}) \in B]}{\sum_{j \in \mathcal{J}} |E_j|} \quad (14)$$

により求める。ここで $\mathbf{1}[\cdot]$ は、条件を満たすとき 1、満たさないとき 0 をとる関数である。見逃しの割合も同様に、 M_j と Δ_M を用いて求める。一致した日は誤検知にも見逃しにも含めないため、 $\Delta = 0$ の割合は定義上 0 となる。

たとえば、ある系列で実スパイクが 20 日目、予測スパイクが 17 日目と 25 日目にあるとき、誤検知の Δ は $20 - 17 = +3$ と $20 - 25 = -5$ 、見逃しの Δ は $20 - 17 = +3$ となる。なお、この Δ の分布は、相手のスパイクが存在する系列における誤りに限った分布であり、全系列の誤検知数・見逃し数とは分母が異なる。

実験 4 では、上側分位点 $\tau = 0.9$ と下側分位点 $\tau = 0.1$ の予測値の差を予測区間の幅とし、その幅が実際の需要変動と対応するかをみる。全時点を予測区間の幅の順に十分位へ分け、区分ごとに実績の z スコアの平均を求める。

実験 5 では、平均的な指標では捉えられない個々の挙動を確認するため、現れ方の異なる代表的な 2 系列を取り上げ、 $\tau = 0.5$ の予測を実績と重ねて比較する。

以上の各実験について、どのような結果が得られれば提案手法の有用性が支持されるかを以下に示す。

実験 1 では、まず中央値 ($\tau = 0.5$) の MAE と RMSE により、全評価時点における点予測の誤差を比較する。これらが従来手法より小さければ、予測全体の精度が改善したといえる。上側・下側の分位点 ($\tau = 0.9, 0.1$) の MAE と RMSE は、実績値との乖離を示す補助的

な指標として扱い、これらが小さいことのみから分位点の予測が適切であるとは判断しない。

実験 2 では、実績の z スコアによる区分と、系列ごとのスパイクの発生頻度による区分のそれぞれで誤差を比較する。スパイク域で誤差が小さく、かつ静穏域で誤差が増えていなければ、スパイクの捕捉と平常時の精度が両立しているといえる。ただし、発生頻度による改善幅の違いのみから、参照の検索やゲート機構の寄与を特定するものではない。

実験 3 では、全系列における検出の件数、適合率および再現率と、 Δ の分布を併せて確認する。予測スパイク数の違いを踏まえたうえで、 $|\Delta|$ の小さい割合が従来手法より高ければ、予測したスパイクが従来手法よりも実際のスパイクの近くに寄っているといえる。

実験 4 では、予測区間の幅の十分位ごとに、実績の z スコアの平均と標準偏差、およびスパイクの割合を比較する。幅の広い区分ほどこれらの値が大きければ、予測区間の幅が大きな需要変動と対応しているといえる。ただし、これのみから予測区間の妥当性や個々のスパイクの予測が実証されるわけではない。

実験 5 では、代表的な 2 系列について、予測の過大・過小や需要の変化への反応を確認する。需要が減衰する系列で過大な予測が抑えられ、急増する系列で予測が立ち上がっていれば、実験 1 から実験 4 の定量的な結果を個々の系列でも具体的に確認できたといえる。ただし、個別の系列の結果のみから一般的な性能を結論づけるものではない。

5.4 実験結果と考察

5.4.1 実験 1：予測精度の算出

全系列・全予測期間を対象に、分位点ごとの MAE と RMSE で予測全体の精度を比較した結果を表 2 に示す。GateRAF は 6 指標中 5 指標で最小の誤差を示し、従来手法の ProtoRAF・Baseline を全分位点で下回った。改善は中央・上側の分位点で大きく、たとえば $\tau = 0.9$ の RMSE は約 27 から約 13 へと半減している。構成要素ごとにみると、参照を単に連結する ProtoRAF は Baseline とほぼ変わらず、連結だけでは精度が改善していない。マルチストリームエンコーダを加えた Multi-RAF で中央・上側の誤差が大きく下がる一方、下側 ($\tau = 0.1$) はわずかに悪化しており、ゲート機構を加えた GateRAF で下側の誤差が改善していることがわかる。

この分位点ごとの寄与の違いは、2 つの工夫が異なる問題に対処していることを示唆する。Baseline の上側分位点が高いのは、スパイクの発生時点を単一

表 2 各モデルおよび分位点レベルにおける MAE および RMSE の比較

モデル	分位点					
	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE
GateRAF	3.6339	13.5293	2.7452	12.2025	5.0136	13.3030
Multi-RAF	3.7766	13.6118	2.8117	12.2594	4.9745	13.3570
ProtoRAF	3.6604	13.7593	3.0467	12.9622	6.8549	27.0196
Baseline	3.6501	13.7476	3.0460	12.9603	6.8512	27.0050

系列からは判別できず、モデルがその発生に備えて上側分位点を恒常的に高く見積もるためと考えられる。Multi-RAF では、類似局面の参照事例が、同様の局面でスパイクが起きたか否かの証拠を与えるため、平常局面では上側分位点を下げられる。一方、ProtoRAF が Baseline とほぼ同等にとどまることは、参照を時間軸方向に連結するだけでは参照情報がほとんど活用されないことを示す。また、関連の薄い参照が混入すると本来低いはずの下側分位点が高い値へ引き上げられるが、ゲート機構がそうした参照を弱めるため、下側の誤差が改善したと解釈できる。また、参照件数 K に対する感度を確認するため、 K を 1, 3, 5, 7 に変えて GateRAF を学習し直し、学習時と同じ K で予測した。 $\tau = 0.5$ の MAE は 2.735~2.746 であり、 K による変動は 0.4% 以内にとどまった。一方、 $\tau = 0.9$ の MAE は $K = 1$ の 4.94 から $K = 7$ の 5.18 へ増加した。検索される参照ウィンドウは互いに似た波形であることが多いため、 K を増やしても新たな情報はほとんど加わず、参照に由来する寄与だけが増えて上側分位点が押し上げられたと考えられる。

5.4.2 実験 2：スパイクの大きさや発生頻度による予測精度

需要の大きさを表す z スコアの区分ごとに MAE と RMSE を集計し、需要水準による精度の違いを比較した結果を表 3 に示す。GateRAF の改善は、需要が平常を下回る静穏域で最も大きい。とりわけ ProtoRAF は、上側分位点 ($\tau = 0.9$) を実需の大きさによらず高く出力する。そのため、実需の低い静穏域では予測が実績を大きく上回り、 $\tau = 0.9$ の RMSE は他モデルの 3 倍近くに達する。この傾向は静穏域に限らず、実需が中程度までの区分にわたって続く。これに対し、マルチストリームエンコードを加えるとこの上側の過大予測が解消され、さらにゲート機構が静穏域の下側分位点 ($\tau = 0.1$) の誤差を下げていることがわかる。

一方、スパイク域でも、GateRAF の中央値 ($\tau = 0.5$) の MAE は全モデル中で最小であった。すなわち、静穏域での過大予測の抑制がスパイクの見逃しを招くことはなく、平常時の精度とスパイクの捕捉が両立でき

ていると考えられる。

なお、各区分に含まれる時点数は表 3 の最上段に示す通りであり、最も時点数の少ない $z > 3$ の区分にも 1,433 時点（全時点の 1.9%）が含まれる。ただし、同じ系列内の観測は互いに独立ではなく、また RMSE は誤差を二乗して平均するため、誤差の大きい少数の時点に値が大きく左右される。そのため、時点数のみから各区分における誤差の推定が安定しているとは判断できず、各区分の結果は、このような標本の構成を踏まえて解釈する必要がある。

z スコアによる区分はスパイクの大きさによる評価にあたるため、表 3 がスパイクの大きさ別の結果に該当する。これに加えて、5.3 節で述べた発生頻度により層別した結果を表 4 に示す。

発生頻度別に、ProtoRAF に対する GateRAF の MAE の改善率、すなわち ProtoRAF の MAE に対して GateRAF の MAE が減少した割合をみる。表 4 の分位点 $\tau = 0.5$ の段で GateRAF と ProtoRAF の MAE を比べると、改善率は、発生頻度が 1 回から 5 回の書名では約 7~11% であるのに対し、6 回以上の書名では約 35% に達する。分位点 $\tau = 0.9$ の段ではこの傾向がより明瞭で、改善率は発生頻度が 1 回の書名での約 3% から、6 回以上の書名での約 54% まで増大する。これは、参照を連結する ProtoRAF がスパイクの多い系列ほど上側分位点を過大に出力するのに対し、提案手法ではこれが抑えられるためと考えられる。

次に、スパイクの高さをどの程度再現できているかを確認する。時点 t の実績値を y_t 、分位点 τ の予測値を $\hat{y}_t$ 、その時点の z スコアを z_t とする。評価対象の時点を、 $z_t > 2$ となるスパイクの時点の集合 $\mathcal{T}_{\text{spike}} = \{t \mid z_t > 2\}$ と、 $z_t < 0$ となる平常時の時点の集合 $\mathcal{T}_{\text{normal}} = \{t \mid z_t < 0\}$ に分ける。そのうえで、それぞれの集合に含まれる時点に限って、予測値の平均を実績値の平均で割った捕捉率 C_{spike} , C_{normal} を

次により求める：

$$\begin{aligned} C_{\text{spike}} &= \frac{\sum_{t \in \mathcal{T}_{\text{spike}}} \hat{y}_t}{\sum_{t \in \mathcal{T}_{\text{spike}}} y_t}, \\ C_{\text{normal}} &= \frac{\sum_{t \in \mathcal{T}_{\text{normal}}} \hat{y}_t}{\sum_{t \in \mathcal{T}_{\text{normal}}} y_t} \end{aligned} \quad (15)$$

捕捉率が 100% を下回れば実績の平均より低い予測を、上回れば高い予測を出していることを意味する。なお、 $\tau = 0.1$ の予測値は負となる場合があるが、本評価では予測値を 0 で切り捨てずにそのまま用いた。そのため、平常時の $\tau = 0.1$ の捕捉率は負の値をとることがある。

スパイクの時点と平常時における捕捉率を表 5 に示す。スパイクの時点における提案手法の C_{spike} は $\tau = 0.5$ で 27.1%, $\tau = 0.9$ で 56.9% であり、ProtoRAF の 21.4%, 53.3% を上回るが、いずれも 100% を大きく下回る。一方、平常時の C_{normal} は 100% を超え、提案手法は $\tau = 0.5$ で 115.0%, $\tau = 0.9$ で 405.3% であるのに対し、ProtoRAF は 139.6%, 554.3% である。すなわち提案手法は、従来手法と比べて C_{spike} が高く、 C_{normal} が低い。上側分位点を一律に広げているのではなく、スパイクの時点で選択的に予測の水準と幅を高めている。Multi-RAF もほぼ同等であり、この性質は主にマルチストリームエンコードによる。

以上より、提案手法の寄与はスパイクの高さの再現ではなく、立ち上がりの時期と不確実性の提示にある。販売冊数は在庫が尽きた時点で頭打ちとなるため学習データ自体が高さを過小に含み、またスパイクの契機は受賞や映像化といった外生的な事象にあるため、販売履歴のみから高さを決めることは原理的に難しい。高さの再現は本研究の限界である。

この限界の要因は、本研究の予測が販売履歴のみに基づいており、受賞や映像化、メディアでの紹介、SNS 上での話題化といった外生的な契機を十分に扱えないことにある。そこで今後は、出版社や分類などの書籍属性を用いて参照ウィンドウの検索を条件付ける拡張と、外部から収集した事象の情報を共変量として統合する拡張が考えられる。前者は、本研究で用いたデータに含まれる情報のみで実現できる。一方、後者については、本研究で用いた基盤モデル ChronosBolt が単変量の系列のみを入力とするため、共変量を取り込む機構を新たに設ける必要がある。また、将来の情報の混入を避けるため、予測時点ですでに観測できる事象の情報のみを用いて評価することが求められる。

5.4.3 実験 3：時間近接性

表 6(a) に、全系列における実スパイク数、予測スパイク数、的中数、誤検知数および見逃し数と、予測スパイクを 1 つ以上出した書名の数を示す。ここでの中数は、実スパイクと同じ日に予測スパイクを出した件数である。あわせて、予測スパイク数に対する的中数の割合である適合率と、実スパイク数に対する的中数の割合である再現率を示す。さらに、予測スパイクと実スパイクの日の差が 1 日以内または 3 日以内であれば的中とみなした場合の適合率と再現率も示す。日付の完全一致で評価すると、GateRAF の適合率は 10.34%、再現率は 2.79% であり、ProtoRAF の 5.34%、1.95% を上回る。前後 3 日以内のずれを許すと、GateRAF の適合率は 23.09%、再現率は 4.11% となり、ProtoRAF の 15.65%、2.68% との差はさらに広がる。なお、適合率はいずれの許容幅でも Multi-RAF が GateRAF をわずかに上回る一方、再現率はいずれの許容幅でも GateRAF が最も高い。ただし、再現率はずれを許してもいずれの手法でも 5% 未満であり、実スパイクの大半は見逃されている。これは、実スパイクが生じた 1,132 書名に対し、予測スパイクを 1 つ以上出した書名が 70~81 書名に限られるためである。したがって、提案手法は予測したスパイクと実際のスパイクとの時間的な対応を改善しているものの、スパイクそのものの検出には大きな限界が残る。

予測したスパイクと実際のスパイクが時間的にどれだけ近いかを、誤検知と見逃しの Δ の分布として集計した結果を表 6(b) に示す。この分布は、最も近い相手のスパイクを定めるため、実スパイクと予測スパイクがともに 1 つ以上ある系列のみを対象とする。分母は (a) の誤検知数・見逃し数とは一致せず、誤検知で 440~680 件、見逃しで 141~162 件に限られる。特に、予測スパイクを 1 件も出さなかった系列の見逃しは、(a) の見逃し数には含まれるが、(b) の分布には含まれない。また、対象の系列はモデルによって異なるため、(b) の分布のみから全系列における予測の時期の精度を判断することはできない。GateRAF は誤検知・見逃しのいずれでも、実際のスパイクから大きく外れた誤り ($|\Delta| \geq 5$) の割合が ProtoRAF より低く（誤検知で 75.9% に対し 68.8%、見逃しで 77.8% に対し 64.8%）、逆に 3 日以内で対応づく割合が高い（誤検知で 20.4% に対し 26.1%、見逃しで 18.8% に対し 30.2%）。すなわち、GateRAF の誤りは ProtoRAF と比べて実際のスパイクの近くに寄っている。ただし、GateRAF でも誤検知・見逃しの 6 割以上は実際のスパイクから 5 日以上離れており、時間的な対応の改善

表 3 系列内 z スコアビン別の MAE および RMSE.													
モデル	<-1		-1-0		0-1		1-2		2-3		>3		
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	
時点数	3,381		46,775		14,144		6,054		2,261		1,433		
$\tau = 0.1$													
GateRAF	0.85	2.88	1.57	4.57	5.15	10.44	7.64	16.52	14.72	39.32	28.08	63.94	
Multi-RAF	1.03	3.01	1.71	4.67	5.29	10.55	7.81	16.64	14.84	39.68	28.24	63.94	
ProtoRAF	0.89	3.09	1.47	4.39	5.31	10.77	7.98	17.19	15.45	40.54	28.58	64.37	
Baseline	0.89	3.08	1.46	4.38	5.30	10.76	7.97	17.18	15.44	40.51	28.56	64.35	
$\tau = 0.5$													
GateRAF	1.84	3.15	1.21	3.78	3.32	8.39	5.35	13.84	11.28	35.30	24.76	61.12	
Multi-RAF	1.94	3.23	1.26	3.77	3.40	8.39	5.48	13.92	11.47	35.98	24.84	61.00	
ProtoRAF	2.66	6.21	1.40	5.13	3.54	9.25	5.80	14.56	12.42	36.57	26.26	62.31	
Baseline	2.66	6.21	1.40	5.14	3.54	9.24	5.80	14.56	12.41	36.55	26.25	62.29	
$\tau = 0.9$													
GateRAF	6.19	9.70	4.52	9.50	4.57	9.39	4.68	11.33	8.39	30.16	18.81	55.93	
Multi-RAF	6.27	9.64	4.46	9.43	4.53	9.41	4.65	11.40	8.57	31.39	18.73	55.86	
ProtoRAF	9.48	29.11	6.57	27.12	6.11	24.45	5.01	13.12	9.56	33.12	20.74	58.00	
Baseline	9.49	29.17	6.56	27.09	6.11	24.46	5.02	13.12	9.56	33.15	20.72	57.99	

注：同じ値が並ぶ箇所は小数第 3 位で比較した ($\tau = 0.1 \cdot z > 3$ の RMSE は GateRAF が 63.944, Multi-RAF が 63.941, $\tau = 0.5 \cdot 0-1$ の RMSE は GateRAF が 8.389, Multi-RAF が 8.391)。

表 4 スパイクの発生頻度により層別した MAE および RMSE (太字は各分位点・各発生頻度における最小値)

モデル	発生頻度 [回]											
	1		2		3		4		5		6 以上	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
対象書名数	104		253		337		264		102		72	
分位点 $\tau = 0.1$												
GateRAF	2.10	8.55	4.04	13.62	3.53	10.56	3.61	13.15	4.15	18.90	4.92	22.71
Multi-RAF	2.27	8.63	4.22	13.71	3.65	10.57	3.68	13.07	4.34	19.12	5.07	23.10
ProtoRAF	2.08	8.56	4.10	14.09	3.55	10.62	3.67	13.25	4.31	19.47	4.70	22.88
Baseline	2.07	8.56	4.09	14.08	3.54	10.61	3.66	13.24	4.29	19.45	4.67	22.85
分位点 $\tau = 0.5$												
GateRAF	1.61	8.17	3.06	11.59	2.70	9.67	2.85	12.31	3.24	17.20	2.92	20.23
Multi-RAF	1.65	8.17	3.15	11.71	2.78	9.66	2.87	12.22	3.32	17.19	2.99	20.71
ProtoRAF	1.80	8.32	3.29	12.20	2.90	9.81	3.10	12.46	3.53	18.04	4.49	24.35
Baseline	1.80	8.32	3.29	12.21	2.90	9.81	3.09	12.46	3.52	18.03	4.49	24.34
分位点 $\tau = 0.9$												
GateRAF	4.53	11.97	5.17	11.73	4.63	10.64	4.69	12.27	5.68	18.18	7.56	24.26
Multi-RAF	3.84	9.80	5.14	11.93	4.66	10.63	4.67	12.26	5.82	18.73	7.81	25.12
ProtoRAF	4.65	11.66	6.34	13.70	5.65	11.44	6.12	13.58	10.50	44.15	16.40	82.56
Baseline	4.65	11.67	6.34	13.70	5.65	11.45	6.12	13.58	10.45	43.83	16.40	82.71

表 5 スパイクの時点と平常時における捕捉率 [%]						
モデル	スパイクの時点 (C_{spike})			平常時 (C_{normal})		
	$\tau = 0.1$	$\tau = 0.5$	$\tau = 0.9$	$\tau = 0.1$	$\tau = 0.5$	$\tau = 0.9$
GateRAF	11.7	27.1	56.9	6.2	115.0	405.3
Multi-RAF	11.1	26.7	56.2	−0.1	116.9	403.3
ProtoRAF	8.9	21.4	53.3	13.0	139.6	554.3
Baseline	8.9	21.5	53.3	13.9	139.8	553.9

は相対的なものとどまる。

この違いは各手法の予測の出方を反映していると考えられる。ProtoRAF はスパイクが過ぎた後も高い予測を出し続けるため、誤検知が実際のスパイクより後方へ偏る。マルチストリームエンコードはこの過大予測を抑え、誤検知を実際のスパイク近傍へ引き戻す。ただしマルチストリームエンコードだけでは、予測を立

ち上げてもその位置が実スパイクからずれやすく、見逃しは ProtoRAF と同程度となっている。ここにゲート機構が加わることで、スパイク近傍に予測のピークが絞られ、見逃したスパイクに最も近い予測スパイクが実際のスパイクの近くに寄る (見逃しの $|\Delta| \geq 5$ の割合は Multi-RAF の 71.7% に対し GateRAF では 64.8%) と考えられる。結果として、GateRAF の誤り

表 6 スパイクの検出結果と、 Δ 日ごとの誤検知および見逃しの割合

(a) 全系列における検出結果

モデル	実スパイク数	予測スパイク数	件数			予測を出した書名数	適合率 [%]			再現率 [%]		
			的中数	誤検知数	見逃し数		一致	± 1 日	± 3 日	一致	± 1 日	± 3 日
GateRAF	3,694	996	103	893	3,591	81	10.34	16.87	23.09	2.79	3.47	4.11
Multi-RAF	3,694	841	97	744	3,597	72	11.53	18.19	24.97	2.63	3.22	3.68
ProtoRAF	3,694	1,348	72	1,276	3,622	71	5.34	10.09	15.65	1.95	2.33	2.68
Baseline	3,694	1,353	71	1,282	3,623	70	5.25	9.90	15.37	1.92	2.27	2.63

(b) Δ 日ごとの誤検知および見逃しの割合 (実スパイクと予測スパイクがともにある書名のみ)

モデル	≤ -5	-4	-3	-2	-1	+0	+1	+2	+3	+4	$\geq +5$
誤検知											
GateRAF	0.381	0.020	0.025	0.041	0.078	0.000	0.055	0.031	0.031	0.031	0.307
Multi-RAF	0.459	0.016	0.030	0.041	0.070	0.000	0.057	0.032	0.027	0.030	0.239
ProtoRAF	0.665	0.022	0.025	0.028	0.050	0.000	0.044	0.029	0.028	0.015	0.094
Baseline	0.667	0.022	0.025	0.028	0.050	0.000	0.043	0.028	0.028	0.015	0.093
見逃し											
GateRAF	0.253	0.012	0.043	0.043	0.086	0.000	0.068	0.037	0.025	0.037	0.395
Multi-RAF	0.263	0.000	0.033	0.033	0.072	0.000	0.072	0.026	0.020	0.026	0.454
ProtoRAF	0.403	0.014	0.007	0.007	0.035	0.000	0.062	0.042	0.035	0.021	0.375
Baseline	0.411	0.014	0.007	0.007	0.035	0.000	0.057	0.043	0.035	0.021	0.369

は従来手法と比べて実際のスパイクの近くに寄っており、GateRAF は発生日を正確に当てにくい突発需要において、備えるべき時期の目安を従来手法よりの確に与える点で有用と考えられる。なお、2.2 節で述べた変化点検知を用いれば、スパイクの発生を観測から検出できる。しかし、検出はスパイクが始まった後の観測に基づくため、検出後に対応できるのはスパイクの 2 日目以降に限られる。 z スコアが 2 を超える時点が連続する区間を 1 回のスパイクとして数えると、評価期間には全書名で 2,896 回のスパイクが生じており、そのうち 79.5% が 1 日で終了し、94.9% が 2 日以内に収まる。このため、スパイクの初日に検出して翌日から対応できたとしても、対応が間に合うのはスパイクの時点全体の 21.6%、販売冊数では 30.4% にとどまる。ただし、3 日以上続く 147 回のスパイクでは、検出後の対応が一定の効果をもつと考えられる。これに対し GateRAF は、スパイクを観測する前に、過去の類似事例から需要の立ち上がりを予測に反映できる。したがって、変化点検知は提案手法を置き換えるものではなく、長く続くスパイクへの対応や、系列を局面ごとに区切って参照ウィンドウの検索範囲を限定するといった形で、提案手法と組み合わせて用いることが考えられる。この組み合わせの検討は今後の課題とする。

5.4.4 実験 4：予測区間幅の比較

予測区間の幅ごとに実績の z スコアの平均を求め、区間幅と実際の需要変動との対応を調べた結果を図 3 に示す。GateRAF と Multi-RAF では、予測区間の幅が広い区分ほど実績の z スコアの平均が高く、幅の

広い区間ほど実際のスパイクの時点を多く含む傾向がある。一方 ProtoRAF では、この対応がほとんどみられない。各十分位における実績値の z スコアの標準偏差と、スパイク ($z > 2$) に該当する観測値の割合を表 7 に示す。GateRAF では、標準偏差が最も狭い区分の 0.60 から最も広い区分の 1.25 へ概ね大きくなり、スパイクの割合も 1.4% から 9.9% へ増加する。一方 ProtoRAF では標準偏差が 0.87~1.12、スパイクの割合が 3.6%~7.4% の範囲にとどまり、区分による違いが小さいことがわかる。すなわち GateRAF の広い予測区間は実際にスパイクの時点を相対的に多く含んでおり、区間幅と需要変動の対応は平均だけでなく分布としても確認できる。ただし最も広い区分でもスパイクの割合は 9.9% であり、区間が広いことが直ちにスパイクの発生を意味するわけではない。

この対応が GateRAF と Multi-RAF でほぼ一致することから、区間幅と需要変動の連動は主にマルチストリームエンコードによるスケールの安定化によると考えられる。標準化の基準を正したことで、連結による歪みで頭打ちとなっていた上側分位点、実際の需要変動へ応答できるようになったと解釈できる。稀に発生し予測の難しいスパイクにおいて、不確実性を区間の幅として示せることは、スパイクの到来を事前に示唆する手がかりとして意義をもつと言える。

5.4.5 実験 5：代表系列の事例分析

現れ方の異なる代表的な 2 系列について、各手法の $\tau = 0.5$ の予測を実績と重ねて比較した結果を図 4 に示す。このうち、図 4(a) に示す書籍 A は、高い需要が時

表 7 予測区間幅の十分位ごとの実績 z スコアの標準偏差とスパイクの割合

モデル	予測区間幅の十分位									
	1	2	3	4	5	6	7	8	9	10
実績 z スコアの標準偏差										
GateRAF	0.60	0.80	0.92	0.92	0.91	0.87	0.96	1.09	1.22	1.25
Multi-RAF	0.70	0.85	0.89	0.89	0.91	0.88	0.95	1.08	1.19	1.26
ProtoRAF	0.91	0.87	0.93	0.91	0.95	0.96	0.99	1.07	1.10	1.12
Baseline	0.91	0.88	0.93	0.91	0.94	0.96	0.99	1.07	1.10	1.12
スパイク ($z > 2$) の割合 [%]										
GateRAF	1.4	2.8	4.1	4.2	3.9	3.3	4.6	6.9	8.7	9.9
Multi-RAF	2.3	3.7	3.8	3.9	3.5	3.4	4.4	7.0	8.0	10.0
ProtoRAF	4.8	3.6	4.3	4.1	4.2	4.3	4.9	5.9	6.5	7.4
Baseline	4.8	3.7	4.3	4.0	4.1	4.3	4.9	5.9	6.4	7.4




図 3 予測区間の幅ごとの実績 z スコア平均

間とともに減衰する系列である。GateRAF は実績の減衰にほぼ沿って予測を下げるのに対し、ProtoRAF・Baseline は需要が下がった後も高い予測を維持している。これは、ProtoRAF が連結系列全体で標準化するため予測のスケールが過大なまま保たれるためであると考えられ、標準化を局所化する GateRAF ではこの高止まりが避けられている。


図 4(b) に示す書籍 B は、平常はほぼゼロの需要が突発的に急増する系列である。GateRAF と Multi-RAF は販売冊数の急増に合わせて予測値も上昇しているのに対し、ProtoRAF, Baseline はほぼゼロのまま反応せず、加法モデルの Prophet も構造上この急増を表現できていない。GateRAF, Multi-RAF 共に同様の傾向が見られることから、スパイクの捕捉は主にマルチストリームエンコードの働きによると考えられる。ただし書籍 B では、予測の上昇は実績の急増に比べて小さく、スパイクの水準までは再現できていない。なお、スパイクの時点だけに限った評価は表 3 の z スコアが 2 以上の区分に、スパイクの位置のずれの評価は表 6 に示している。また、スパイクの高さの再現と上側分位点による被覆については 5.4.2 項で述べた通りである。

これら 2 例は、いずれもマルチストリームエンコードの効果、すなわち標準化の局所化による過大予測の抑制と、参照の個別取り込みによる他系列スパイクの捕捉を示している。ゲート機構の寄与はこれとは異なり、実験 1・2 の平常時（下側分位点・静穏域）の精度向上と、実験 3 のスパイク近傍への時間的な絞り込みに現れる。


6. 返本と機会損失の観点からの評価

以下では、予測誤差が出版流通にもたらす損失を、返本と販売機会の損失という実務的な観点から評価する。需要を上回る入荷は売れ残りとなって返本を生み、過剰な返本は出版流通全体の課題となっている。一方で、需要のスパイクに見合う入荷ができなければ機会損失が生じる。そこで、各手法が予測した販売冊数をそのまま入荷量とみなし、提案手法 GateRAF が返本と販売機会の損失をどの程度抑えられるかを、他手法との比較により見積もる。MAE や RMSE といった精度指標は、予測の良し悪しを数値としては示すものの、それが出版流通の現場でどれだけの負担や損失につながるかを直接には表さない。そこで以下では、予測精度の違いを返本と機会損失という実務的な指標へと結び付けることで、提案手法が出版流通の効率化にもたらす意義を明らかにする。なお本評価は、発注リードタイムや在庫の繰り越しといった実際の流通過程を含まない簡易的なシミュレーションであり、損失量そのものではなく手法間の相対的な差を把握することを目的とする。比較対象には、基盤モデルそのものである Baseline に加え、古典的な予測手法である SARIMA [18] と Prophet [16] を用いる。

評価指標は、過剰入荷 O 、返本率 R 、機会損失 U の 3 つである。評価対象とする全書名について、評価期間である $F = 64$ 日にわたり、時点 t の実際の販売冊



(a) 書籍 A



(b) 書籍 B

図 4 各系列における予測と実績の比較

数を y_t , 予測した販売冊数の中央値 ($\tau = 0.5$) を $\hat{y}_t$ とし, $\hat{y}_t$ をその時点の入荷量とみなす. **ただし, 入荷量は負とならないため, 予測値が負の場合は入荷量を 0 とし, 以下の $\hat{y}_t$ はこの入荷量を表すものとする.** 入荷量が実際の販売を上回った分を売れ残りとして合計したものが過剰入荷 O であり, これがそのまま返本となる. 一方, 入荷量が実際の販売に届かなかった分を合計したものが機会損失 U である. 返本率 R は, 実際の総販売冊数 $S = \sum_t y_t$ と過剰入荷の和に対し, 過剰入荷が占める割合とする. 以上をまとめると, 3 つ

の指標は次のように表される.

$$O = \sum_t \max(\hat{y}_t - y_t, 0) \quad (16)$$

$$U = \sum_t \max(y_t - \hat{y}_t, 0) \quad (17)$$

$$R = \frac{O}{S + O} \quad (18)$$

返本率 R が高いほど返品にともなう物流の負担が大きく, 機会損失 U が大きいほど, 入荷が需要に満たず, 本来得られたはずの販売機会を多く逸失していることを意味する.

入荷量に中央値 ($\tau = 0.5$) を用いたのは, 過剰量と不足量を等重みで評価する対称な絶対損失に対応する

表 8 入荷量に用いる分位点 τ を変えた場合の過剰入荷、機会損失 [冊] および返本率 [%]									
モデル	$\tau = 0.1$			$\tau = 0.5$			$\tau = 0.9$		
	過剰入荷	機会損失	返本率	過剰入荷	機会損失	返本率	過剰入荷	機会損失	返本率
GateRAF	4,073	247,628	1.37	41,182	161,450	12.33	296,482	74,763	50.31
Baseline	4,271	255,962	1.44	57,383	168,070	16.39	428,864	78,453	59.43
SARIMA	4,315	268,777	1.45	124,588	145,498	29.85	657,493	70,737	69.19
Prophet	219,753	220,035	42.87	331,922	176,414	53.13	910,309	106,388	75.66

表 9 予測値 ($\tau = 0.5$) を入荷量とみなした場合の返本率と過不足の金額 (本体価格による換算)

モデル	返本率	金額 [万円]	
		過剰入荷	機会損失
GateRAF	12.33%	3,173	12,009
Baseline	16.39%	4,401	12,377
SARIMA	29.85%	9,361	10,840
Prophet	53.13%	23,170	13,280

ためである。観測数で割った平均損失は MAE に一致し、その期待値を最小化する予測は条件付き中央値となる。実際の費用が非対称である場合には、別の分位点が適切となる。すなわち、欠品 1 冊あたりの費用を c_u 、売れ残り 1 冊あたりの費用を c_o とすると、期待費用を最小にする入荷量は $c_u / (c_u + c_o)$ 分位点となる。たとえば $\tau = 0.9$ は欠品の費用が売れ残りの 9 倍である場合に、 $\tau = 0.1$ は売れ残りの費用が欠品の 9 倍である場合に対応する。

また、表 8 に $\tau = 0.1, 0.5, 0.9$ とした際の各手法の過剰入荷、機会損失および返本率を示す。評価した $\tau = 0.1, 0.5, 0.9$ のいずれにおいても、GateRAF は Baseline に比べて過剰入荷冊数と機会損失冊数の双方が少なかった。したがって、Baseline に対する改善は、中央値を入荷量とする場合だけでなく、下側分位点を用いて入荷を抑える場合と、上側分位点を用いて入荷を増やす場合にも確認された。また、GateRAF の過剰入荷冊数と返本率は、3 水準すべてで表 8 の比較手法中最小であった。GateRAF の返本率は、 $\tau = 0.1$ で 1.37%、 $\tau = 0.5$ で 12.33%、 $\tau = 0.9$ で 50.31% であり、分位点の選択によって返本率が大きく変わることがわかる。一方、SARIMA との比較では、 $\tau = 0.5$ および 0.9 で GateRAF の機会損失冊数が多かった。このため、SARIMA に対しては、過剰入荷冊数と機会損失冊数の双方を同時に削減したわけではないことに注意されたい。

以下では $\tau = 0.5$ を入荷量とみなした場合について詳しくみる。返本率と、過剰入荷および機会損失を本体価格により金額に換算した値を表 9 に示す。

まず、参照を用いない Baseline との比較から、提案手法の効果を確認する。GateRAF は Baseline に対し、返本率を 16.4% から 12.3% へ下げ、機会損失も

168,070 から 161,450 へと同時に減らした。予測精度の改善が、売れ残りと売り逃しの双方の削減として現れている。次に古典的手法と比較すると、GateRAF の返本率は SARIMA の 29.9%、Prophet の 53.1% を大きく下回る。過剰入荷の冊数で比較しても、GateRAF は SARIMA の約 3 分の 1、Prophet の約 8 分の 1 にとどまる。一方で機会損失は SARIMA が最小であり、GateRAF はこれを約 11% 上回る 161,450 冊であった。

返本と機会損失は、本来両立の難しい指標である。売り逃しを減らそうとして入荷を増やせば、売れ残りが増えて返本が増大するためである。SARIMA は入荷量を多めに見積もることで機会損失を最小に抑えるが、過剰入荷は GateRAF の約 3 倍に達し、返本率も GateRAF の 2 倍を超える。これに対し GateRAF は、機会損失の増加を最小手法である SARIMA に対して約 11% にとどめつつ、返本を大幅に抑えている。返本の抑制が出版流通全体の課題であることを踏まえると、GateRAF は販売機会の損失を低い水準に保ったまま返本を抑えており、実務上望ましい特性を備えていることが示唆された。これらを本体価格を用いて金額に換算すると、GateRAF の過剰入荷は 3,173 万円分、機会損失は 1 億 2,009 万円分となる。Baseline と比べると、GateRAF の過剰入荷は 1,228 万円分、機会損失は 368 万円分少なく、合わせて約 1,596 万円分少ない。この約 1,596 万円は、評価対象とした 1,157 書名の 64 日間における本体価格ベースの売上 2 億 1,369 万円の約 7.5% にあたる。ただし、返本は返品として精算され、機会損失による実際の逸失は粗利に相当する部分であるため、これらの金額は実際の損失額ではなく、過不足の規模を本体価格で表したものである。

また、返本は書店から取次・出版社への返品であり、往復の輸送と在庫の再処理を伴う。GateRAF は Baseline に対し返本を 16,201 冊減らしており、その分の物流コストが低減可能となる。加えて、委託販売制度のもとでは売れ残りの在庫リスクを出版社が負うため、過剰入荷の抑制はそのリスクの軽減を可能とする。GateRAF は機会損失も同時に 6,620 冊減らしており、欠品を増やさずに実現可能であることからその有効性を示すことができたと言える。

7. おわりに

本研究では、平常時とスパイクが混在する書籍の需要予測を目的に、GateRAF を提案した。GateRAF は、従来の RAF がもつ接合部の不連続性をマルチストリームエンコードによって構造的に取り除き、無関係な参照の混入をゲート機構によって動的に抑制する。実験の結果、GateRAF は全体の予測精度で ProtoRAF と Baseline を上回り、2 つの機構が予測の異なる側面を改善することを確認した。

今後の課題として、複数の距離尺度を比較し、距離尺度の選択が予測精度に与える影響を検証すること、形状以外の観点も取り入れた類似尺度、参照を組み合わせたゲート機構の検討、受賞や映像化、SNS 上での話題化といった外生的な契機の情報を参照ウィンドウの検索条件や共変量として取り込む拡張などが挙げられる。

参考文献

- [1] 日本書籍出版協会, 「再販制度」, <https://www.jbpa.or.jp/resale/>, 2001 (2026 年 6 月 26 日閲覧)。
- [2] 全国出版協会・出版科学研究所, 『出版指標年報 2024 年版』, 全国出版協会, 2024。
- [3] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-T. Yih, T. Rocktäschel, S. Riedel and D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [4] K. Tire, E. O. Taga, M. E. Ildiz and S. Oymak, “Retrieval Augmented Time Series Forecasting,” arXiv:2411.08249, 2024.
- [5] Y. Nie, N. H. Nguyen, P. Sinthong and J. Kalagnanam, “A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,” in *Proceedings of the International Conference on Learning Representations*, 2023.
- [6] D. Salinas, V. Flunkert, J. Gasthaus and T. Januschowski, “DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks,” *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.
- [7] B. Lim, S. Ö. Arık, N. Loeff and T. Pfister, “Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting,” *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [8] A. F. Ansari, L. Stella, C. Turkmen, X. Zhang, P. Mercado, H. Shen, O. Shchur, S. S. Rangapuram, S. P. Arango, S. Kapoor, J. Zschiegner, D. C. Maddix, H. Wang, M. W. Mahoney, K. Torkkola, A. G. Wilson, M. Bohlke-Schneider and Y. Wang, “Chronos: Learning the Language of Time Series,” arXiv:2403.07815, 2024.
- [9] J. D. Croston, “Forecasting and Stock Control for Intermittent Demands,” *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972.
- [10] K. Ning, Z. Pan, Y. Liu, Y. Jiang, J. Y. Zhang, K. Rasul, A. Schneider, L. Ma, Y. Nevmyvaka and D. Song, “TS-RAG: Retrieval-Augmented Generation based Time Series Foundation Models are Stronger Zero-Shot Forecaster,” arXiv:2503.07649, 2025.
- [11] H. Zhang, C. Xu, Y.-F. Zhang, Z. Zhang, L. Wang, J. Bian and T. Tan, “TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting,” arXiv:2412.20810, 2024.
- [12] S. Lee, J. Lee, J. Seo, S. Yoo, M. Kim, T. Y. Lim, D. Kang, H. Choi, S. Lee and W. Ahn, “Cross-RAG: Zero-Shot Retrieval-Augmented Time Series Forecasting via Cross-Attention,” arXiv:2603.14709, 2026.
- [13] J. Johnson, M. Douze and H. Jégou, “Billion-Scale Similarity Search with GPUs,” *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535–547, 2019.
- [14] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi and J. Choo, “Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift,” in *Proceedings of the International Conference on Learning Representations*, 2022.
- [15] S.-Y. Liu, C.-Y. Wang, H. Yin, P. Molchanov, Y.-C. F. Wang, K.-T. Cheng and M.-H. Chen, “DoRA: Weight-Decomposed Low-Rank Adaptation,” in *Proceedings of the International Conference on Machine Learning*, 2024.
- [16] S. J. Taylor and B. Letham, “Forecasting at Scale,” *The American Statistician*, vol. 72, no. 1, pp. 37–45, 2018.
- [17] R. Koenker and G. W. Bassett, “Regression Quantiles,” *Econometrica*, vol. 46, no. 1, pp. 33–50, 1978.
- [18] G. E. P. Box and G. M. Jenkins, *Time Series Analysis: Forecasting and Control*, Holden-Day, 1970.
- [19] R. P. Adams and D. J. C. MacKay, “Bayesian Online Change-point Detection,” arXiv:0710.3742, 2007.