

返本率を低減して効率化が必要かある？
ここでは需要予測に関すること、
下図は、需要予測が求められること。
提案手法が何か、それは何を解決して、
何かに応答のAPI、という感じの文法。
背景
↓
従来の手法とその
同様の点
↓
かいつぱく
↓
で、ある
↓
で、あるで、あること
↓
実行
↓
また、これは流れて
あること。
コンパで提供された
データによる実験を行う。
また、これは流れて
あること。
これに「準備」
と、2.1に同様の
2.2に使用データ
2.3に関連研究と
してどうだろうか？
前々から
つながらない
いし
なにか
返本率とか
ってこと？
それ
どうして？
～、～という
言い換えより、
何となくあるのは
わかるけど...
もう少し平易に
して、わかりやすく。
これって、なに？
何となくある？
上のRAFを
一掃？

GRAF: Gate Retrieval-Augmented Forecasting による突発需要の予測

奈良原 俊誠, 斎藤 陽, 橋本 朋樹

1. はじめに

文字・活字文化の振興において、書籍や雑誌は基本的な文化資産であり、国家の文化水準を維持・向上させる上で極めて重要な役割を担っている。この役割を保障するための仕組みが、再販売価格維持制度である [1, 2]。同制度は出版社が定価を決定し、小売店に定価販売を義務付けるものであり、仮に価格競争が導入された場合に淘汰される多様な出版物を保護している。こうした多品種少量生産という特性に対応するため、出版業界では委託販売制度が広く採用されている [3]。これは出版社が書店に販売を委託し、売れ残った場合に返本できる仕組みであるが、返本率は半数に達する書籍もあり業界全体の深刻な課題となっている [4]。返本率を低減し出版流通の効率化を図るためには、適切な需要予測が極めて重要である。本研究で対象とする書籍は、多品種少量生産の特性を持つ時系列データの需要予測には、2つの課題がある。第1の課題は、突発的な需要スパイクが予測で無視されやすい点である。初版の発行や各種イベントに起因する急激な需要増加に対し、全体の誤差を最小化するように学習された一般的なモデルは、少数の突出した需要とゼロが頻出する需要を平均化してしまい、平坦な予測に陥りやすい。さらに、過去に類を見ない稀な事象では予測性能が著しく低下する。第2の課題は、データが限られた特定の系列では十分な学習が行えず、スパイクを正確に予測できない点である。

これらの課題を解決するアーキテクチャとして、自然言語処理分野の RAG [16] を時系列予測へ拡張した Retrieval-Augmented Forecasting (RAF) が近年提案されている [10-12]。RAF はインデックスから形状が類似した他系列のウィンドウを取得して予測に活用することで、単一系列では学習困難なスパイクパターンを横断的に参照できる点に強みがある。しかし既存のコンテキスト拡張型 RAF [10] には、接合部の不連続性と無関係な参照系列の無条件混入という構造的課題がある (第2節)。

そこで本稿では、これらの問題を解消するゲート付き融合型 RAF である GateRAF を提案する。第2節で関連研究を整理し、第3節でデータの概観を示す。第4節で提案手法 GateRAF を示し、第5節で実験結果、第6節でスパイク特性に着目した詳細分析を示した後、第7節で総括する。

2. 関連研究

時系列予測 PatchTST [13] 等の Transformer ベースの深層学習手法、確率的予測手法の DeepAR [14] や TFT [15]、M5 コンペティション [6] で実用性が検証された大規模事前学習基盤モデル ChronosBolt [9] が代表的な手法として挙げられる。しかしいずれも単一系列のみを用いるため、希少スパイクの捕捉と少数系列からの学習という本研究の課題が残る。

間欠・突発需要予測 間欠需要の予測は OR および供給連鎖管理で古くから研究されており、Croston 法 [7] が基準手法として広く参照される。深層学習では深層更新過程に基づく確率フレームワーク [8] が間欠・希薄な時系列を統一的にモデル化する。しかし初版発行やイベント起因の稀なスパイクは過去データに類例が少なく、単独系列モデルでは予測精度が著しく低下しやすい。

Retrieval-Augmented Forecasting RAG [16] を時系列予測へ拡張した RAF は、類似系列のウィンドウを検索して予測に活用することで稀なスパイクパターンを横断的に参照できる。Tire et al. [10] は Chronos を基盤として参照ウィンドウをローカルコンテキストへ時間軸方向に連結するコンテキスト拡張型 RAF を提案したが、接合部の不連続性と無関係系列の無条件混入という構造的課題が存在する。TS-RAG [11] および TimeRAF [12] はそれぞれ潜在空間での融合や Channel Prompting によりこの問題を回避する。本稿の GateRAF はコンテキスト拡張型 RAF の枠組み

を踏襲しつつ、Multi Stream エンコードと Gate 機構によって不連続性とノイズ混入の双方を構造的に解消する。

3. データ

本研究では、経営科学系研究部会連合協議会が主催する令和7年度データ解析コンペティションの書籍 POS データを使用する。本データは 2024 年の 35 店舗分の書籍・雑誌販売実績（約 400 万件、約 20 万書名）であり、店舗の違いを捨象して日付・書名単位に集約した POS 販売冊数を分析対象とする。

7年間総販売冊数が366冊未満の書籍を除外し、書名を作品シリーズ単位へ統合した上で、全日分のゼロ補完を施した結果、約40万件の完全パネルデータを得た。POS販売冊数の平均は約3.68冊（標準偏差13.65冊）、ゼロ販売日の割合は42.9%であり、需要の間欠性とスパイクの混在が顕著である。

4. 提案手法

本節では、まず両手法に共通する時系列検索器を定式化する。次に、ベースラインとなる従来のコンテキスト拡張型 RAF である ProtoRAF を説明し、その構造的な問題点を指摘する。最後に、それらの問題点を解消するために Multi Stream エンコードと Gate 機構を導入した提案手法、ゲート付き融合型 RAF（以下、GateRAF）を提示する。

4.1 時系列検索器

ローカルコンテキスト $x \in \mathbb{R}^L$ (L はウィンドウ長) の z スコア正規化形状に基づき, 訓練データの全ウィンドウを格納した検索データベース $\mathcal{D}$ から過去の系列に限定して上位 K 件の参照ウィンドウを取得する:

$$\{r_k\}_{k=1}^K = \text{Retrieve}(x, \mathcal{D}), \quad r_k \in \mathbb{R}^L \quad (1)$$

ここで Retrieve は FAISS による近傍検索 [18] を表す。

4.2 ProtoRAF:従来のコンテキスト拡張型RAF

$x \in \mathbb{R}^L$ をローカルコンテキスト, $\{r_k\}_{k=1}^K \subset \mathbb{R}^L$ を参照ウィンドウとする. ProtoRAF は参照ウィンドウをローカルコンテキストの前方に連結した拡張コンテキストを単一シーケンスとして一括エンコードする (図 1):

$$x^{\text{proto}} = [r_1 \parallel \cdots \parallel r_K \parallel x] \in \mathbb{R}^{(K+1)L} \quad (2)$$

$$\begin{aligned} (H^{\text{proto}}, \mu, \sigma) &= \text{Encode}(x^{\text{proto}}), \\ H^{\text{proto}} &\in \mathbb{R}^{(K+1)P \times D} \end{aligned} \quad (3)$$

ここで P はパッチ数, D はエンコーダの埋め込み次元であり, インスタンス正規化 [17] パラメータ (μ, σ) は x^{proto} 全体の統計量から推定される.

4.3 コンテキスト拡張型 RAF の問題点

ProtoRAF には構造に起因する 2 つの問題点がある。

問題 1：接合部の不連続性 各 r_k と x は独立した系列に由来するため、連結点においてスケールや形状の異なる系列が直接接合される．エンコーダはこの不連続点を実際の系列変化として学習してしまい、表現が歪んで予測精度が低下する．

問題 2：無関係な系列の無条件混入 近傍探索は相対的な順位を返すに過ぎず、絶対的な類似度が低い系列も等しく x^{proto} に連結される。これによりエンコーダがノイズを学習するリスクがあり、さらにインスタンス正規化パラメータ (μ, σ) が歪んでローカルコンテキストを誤ったスケールで処理してしまう。 4 と似た

4.4 提案手法：ゲート付き融合型 RAF

GateRAF は問題 1 に対して Multi Stream エンコード (x と各 r_k を同一エンコーダで独立にエンコード), 問題 2 に対してスカラーゲート $g_i \in (0, 1)$ による参照パッチの動的抑制 (Gate 機構) を導入する. ゲートの初期バイアスを -1 とし, 学習初期は検索情報をほぼ遮断した状態から出発する.

ステップ 1: ローカルコンテキストのエンコード

$$(H^{\text{loc}}, \mu, \sigma) = \text{Encode}(x), \quad H^{\text{loc}} \in \mathbb{R}^{P \times D} \quad (4)$$

(μ, σ) は x のみから推定されるため、参照ウィンドウに汚染されないローカルスケールで処理できる（問題 2 の部分解消）。

ステップ 2: 参照ウィンドウの独立エンコード (Multi

Stream) 各 r_k を同一エンコーダで独立にエンコードし、接合部を生じさせない (問題 1 の解消). 各 r_k の正規化統計はエンコーダ内部にのみ使用し, 逆正規化にはステップ 1 の (μ, σ) のみを用いる:

$$H_k^{\text{ret}} = \text{Encode}(r_k) \in \mathbb{R}^{P \times D} \quad (5)$$

$$H^{\text{ret}} = [H_1^{\text{ret}} \parallel \cdots \parallel H_K^{\text{ret}}] \in \mathbb{R}^{KP \times D} \quad (6)$$




図1 ProtoRAF のアーキテクチャ概要. K 件の参照ウィンドウとローカルコンテキスト x を時間軸方向に連結し、単一シーケンスとしてエンコードする。




図2 GateRAF (提案手法) のアーキテクチャ概要. ローカルコンテキストと各参照ウィンドウを独立にエンコードし、GateMLP によるスカラーゲートで関連度の低い参照パッチを動的に抑制する。

ステップ 3: ローカル要約ベクトルの計算 $H^{loc} \in \mathbb{R}^{P \times D}$ をパッチ方向に平均プーリングし、ローカル要約ベクトルを得る:

$$\bar{h}^{loc} = \text{Pool}(H^{loc}) \in \mathbb{R}^D \quad (7)$$

ここで $\text{Pool}(\cdot)$ はパッチ方向の平均プーリングを表す。

ステップ 4: ゲートの計算 固定クエリ $\bar{h}^{loc}$ と参照パッチ H_i^{ret} から、2 層 MLP (Linear $\rightarrow$ SiLU $\rightarrow$ Linear $\rightarrow$ Sigmoid) により各パッチの有用度をスカラー $g_i \in (0, 1)$ で評価する:

$$g_i = \text{GateMLP}(\bar{h}^{loc}, H_i^{ret}) \in (0, 1), \quad i = 1, \dots, KP \quad (8)$$

出力層のバイアスを -1 で初期化することで、学習初期はゲートがほぼ閉じた状態 ($g_i \approx 0$) から出発する。

ステップ 5: ゲート付き融合 ゲートベクトル $\mathbf{g} = [g_1, \dots, g_{KP}]^T$ を各参照パッチに乘じ (問題 2 の解消), ローカル隠れ状態と結合して融合表現を得る:

$$\tilde{H}^{ret} = \mathbf{g} \odot H^{ret} \in \mathbb{R}^{KP \times D} \quad (9)$$

$$H^{gate} = [H^{loc} \parallel \tilde{H}^{ret}] \in \mathbb{R}^{(1+K)P \times D} \quad (10)$$

ここで $\odot$ は行方向にブロードキャストした要素積を表す。

ステップ 6: デコードと予測 ローカルコンテキストのパッチ埋め込み E_{in} をクエリ, H^{gate} をキー・バリューとしてデコードし、各分位点の予測値を出力する (図 2):

$$O = \text{Decode}(E_{in}, H^{gate}) \quad (11)$$

$$\hat{Y} = \text{RevNorm}(\text{OutputProj}(O), \mu, \sigma) \in \mathbb{R}^{|Q| \times F} \quad (12)$$

ここで Q は分位点集合, F は予測ホライズン長, $\text{RevNorm}(\cdot, \mu, \sigma)$ は逆インスタンス正規化 $z \mapsto z \cdot \sigma + \mu$ を表す.

4.5 アーキテクチャの構造的解釈

共有エンコーダによるゲート計算の妥当性 ゲート MLP が $[\bar{h}^{\text{loc}} \| H_i^{\text{ret}}]$ から適合度を計算するには, 両ベクトルが同一の表現空間に属することが前提となる. ステップ 1・2 で同一パラメータのエンコーダを共有することで, $\bar{h}^{\text{loc}}$ と H_i^{ret} はともに同一値域に属し, ゲートによる意味的な比較が保証される. ProtoRAF のように連結系列を一括エンコードした場合, インスタンス正規化パラメータが連結系列全体の統計量に依存するため, ゲート機構を後付けしても適合度計算の前提が崩れる. Multi-Stream エンコードはゲート機構の意味的妥当性をアーキテクチャとして保証するための設計上の要件でもある.

5. 実験結果

本節では, 提案手法 GateRAF の有効性を検証する. まず第 5.1 節で実験設定を示し, 続く 2 節では全体的な予測精度と代表書名の予測挙動を示す. より詳細な分析は第 6 節で行う.

5.1 実験設定

比較手法 全手法は ChronosBolt [9] を DoRA [20] でファインチューニングしたものである. **Baseline** は検索機構を持たない基準手法, **ProtoRAF** は参照ウィンドウをローカルコンテキストへ時間軸方向に連結する従来型 RAF (第 4.2 節), **Multi-RAF** は GateRAF からゲート機構を除いた手法である. ProtoRAF→Multi-RAF の比較で Multi Stream エンコードの寄与を, Multi-RAF→GateRAF の比較で Gate 機構の効果を段階的に検証する. 共通設定は LoRA [19] ランク $r = 8$, $K = 3$, $L = 128$, $F = 64$, ピンボール損失 [21] である.

5.2 全体的な予測精度

表 1 に, 全書名・全予測期間を対象とした MAE および RMSE を示す. ProtoRAF は Baseline とほぼ同等の精度にとどまっており, 参照ウィンドウを時間軸方向へ単純連結するアプローチは予測改善に寄していない.

Multi Stream エンコードの効果 (ProtoRAF → Multi-RAF) : $\tau = 0.5$ で MAE が 7.7%, $\tau = 0.9$ では MAE が 27.4%・RMSE が 50.6%と大幅に改善し

た. ProtoRAF は参照系列のスパイクが正規化統計量を歪めるため上位分位点の予測が過大に上振れるが, 独立エンコードはこの正規化汚染を根本的に排除する. 一方 $\tau = 0.1$ では MAE がわずかに悪化しており, Multi Stream の寄与は中・上位分位点に集中している.

Gate 機構の効果 (Multi-RAF → GateRAF)

: $\tau = 0.1$ で MAE が 3.8%, $\tau = 0.5$ で 2.4%改善した. 主な効果は低分位点の静穏域 (第 6.1 節) と時間近接性 (第 6.2 節) に現れている.

5.3 書名別事例分析

以下では, スパイクの発生パターンが異なる 2 書名を取り上げ, 各モデルの予測挙動を具体的に示す (図 3).

ぼっち・ざ・ろっく! 予測期間冒頭に実績が急増 (z スコア最大 3.6) した後, 急速に減衰するパターンを示す (図 3a). GateRAF (MAE= 2.39) は減衰ペースを正確に追従したが, ProtoRAF および Baseline は減衰を捉えられず終始高水準の予測を維持した (MAE= 7.81).

デラックスクロスワード 予測期間中盤 (約 20 日目前後) に急増するパターンを示す (図 3b, z スコア最大 5.8). GateRAF (MAE= 1.59) および Multi-RAF (MAE= 1.88) はスパイクを検出できているのに対し, ProtoRAF および Baseline は予測値がほぼゼロに張り付いたままスパイクを全く捉えられなかった (ProtoRAF MAE= 2.96). 2 書名の分析から, Multi Stream エンコードがスパイク検出精度を向上させ, Gate 機構が文脈に応じた選択的な参照を実現するという, 2 つの機構の補完的な効果が確認された.

6. 分析

本節では, 第 5 節の全体精度を踏まえ, スパイク強度・時間近接性・予測区間幅の観点から多角的に分析する.

6.1 スパイク強度別の予測精度


各時点の実績値を系列内 z スコアでピン分けし, スパイク強度ごとの予測誤差を比較した (表 2). $\tau = 0.5$ の MAE において GateRAF はすべての z スコア帯で Baseline を上回り, 静穏域 ($z < -1$) では約 31%の誤差削減を実現した. $\tau = 0.9$ の静穏域では ProtoRAF の RMSE が GateRAF の約 3 倍に達しており, 一括正規化による統計量の歪みが平坦な需要帯においても過大予測を誘発することが確認できる. Gate 機構の寄与は低分位点の静穏域に現れ, $\tau = 0.1$ の静穏域にお

図表は必ず本文で言及
内容を説明する!!




表 1 各モデルおよび分位点レベルにおける MAE および RMSE の比較.

モデル	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE
GateRAF	3.6339	13.5293	2.7452	12.2025	5.0136	13.3030
Multi-RAF	3.7766	13.6118	2.8117	12.2594	4.9745	13.3570
ProtoRAF	3.6604	13.7593	3.0467	12.9622	6.8549	27.0196
Baseline	3.6501	13.7476	3.0460	12.9603	6.8512	27.0050



(a) ぼっち・ざ・ろっく!



(b) デラックスクロスワード

図 3 各書名における全モデルの予測比較 ($\tau = 0.5$). 赤実線は GateRAF, 青破線は Multi-RAF, 緑点線は ProtoRAF, 橙一点鎖線は Baseline であり, 黒実線は実績を表す.

表 2 系列内 z スコアビン別の MAE および RMSE.

モデル	<-1		-1-0		0-0.5		0.5-1		1-1.5		1.5-2		2-3		>3	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
$\tau = 0.1$																
GateRAF	0.85	2.88	1.57	4.57	4.65	9.48	5.98	11.86	7.18	15.81	8.42	17.66	14.72	39.32	28.08	63.94
Multi-RAF	1.03	3.01	1.71	4.67	4.77	9.56	6.15	12.00	7.36	15.92	8.59	17.80	14.84	39.68	28.24	63.94
ProtoRAF	0.89	3.09	1.47	4.39	4.77	9.79	6.20	12.22	7.51	16.47	8.79	18.36	15.45	40.54	28.58	64.37
Baseline	0.89	3.08	1.46	4.38	4.76	9.77	6.19	12.21	7.50	16.45	8.78	18.35	15.44	40.51	28.56	64.35
$\tau = 0.5$																
GateRAF	1.84	3.15	1.21	3.78	2.96	7.32	3.92	9.90	4.94	13.12	6.05	14.98	11.28	35.30	24.76	61.12
Multi-RAF	1.94	3.23	1.26	3.77	3.01	7.29	4.03	9.95	5.07	13.14	6.19	15.17	11.47	35.98	24.84	61.00
ProtoRAF	2.66	6.21	1.40	5.13	3.14	8.22	4.22	10.73	5.39	13.82	6.50	15.74	12.42	36.57	26.26	62.31
Baseline	2.66	6.21	1.40	5.14	3.13	8.22	4.22	10.73	5.39	13.82	6.50	15.75	12.41	36.55	26.25	62.29
$\tau = 0.9$																
GateRAF	6.19	9.70	4.52	9.50	4.47	8.98	4.74	10.04	4.56	10.64	4.89	12.42	8.39	30.16	18.81	55.93
Multi-RAF	6.27	9.64	4.46	9.43	4.41	8.92	4.73	10.18	4.51	10.65	4.88	12.59	8.57	31.39	18.73	55.86
ProtoRAF	9.48	29.11	6.57	27.12	6.33	24.03	5.75	25.13	4.79	11.83	5.39	15.07	9.56	33.12	20.74	58.00
Baseline	9.49	29.17	6.56	27.09	6.33	24.02	5.75	25.16	4.80	11.83	5.39	15.08	9.56	33.15	20.72	57.99

いて GateRAF は Multi-RAF に対し MAE を 17.5% (1.03 $\rightarrow$ 0.85) 改善している.

6.2 時間近接性

誤分類時点と最近傍の実際スパイク時点との時間的距離 (Δ 日) を分析した ($\tau = 0.5$, 図 4, 5). 系列内 z スコアが 2.0 以上となる時点スパイクとして定義した. 誤検知 (FP) のうちノイズ的な誤検知 ($|\Delta| \geq 10$) の割合は, ProtoRAF の 59.1% に対して GateRAF は 49.6% と低く, GateRAF の誤検知の多くは実際スパイクに近接した「タイミングのズレ」によるものである. 見逃し (FN) でも同様に, GateRAF はスパイク付近で予測を上方修正する挙動が見られる. Gate 機構がローカル文脈に類似した参照パッチのみを選択的に透過させることで, 無関係な参照の混入を時間軸上でも抑制している.

6.3 予測区間幅の比較

予測区間幅 ($\tau_{0.9} - \tau_{0.1}$) を等頻度ビンに分割し, 各

ビンの系列内 z スコア平均を算出した (図 6). GateRAF および Multi-RAF は, 区間幅が広がるにつれて z スコアが単調に上昇 ($-0.34 \rightarrow +0.32$) しており, 広い予測区間がスパイク発生日に集中している. 一方, ProtoRAF の傾きはほぼ平坦 ($-0.06 \rightarrow +0.14$) であり, 一括正規化による統計量の歪みが区間幅と実需変動の連動性を失わせている. GateRAF と Multi-RAF の校正挙動がほぼ同一であることから, この効果は主に Multi Stream エンコードによる正規化スケールの安定化に起因することがわかる.

7. おわりに

本研究では, 多品種少量生産という特性を持つ出版販売データに対する需要予測, 特に突発的なスパイク需要の捕捉を目的として, ゲート付き融合型 RAF である GateRAF を提案した. GateRAF は, 既存のコンテキスト拡張型 RAF が抱える 2 つの構造的課題,

※参考文献は生順に
 順番に




図4 誤検知 (FP) の Δ 日分布 ($\tau = 0.5$): スパイクは系列内 z スコアが 2.0 以上の時点として定義した. 各 FP 予測日について, 最近傍の実際スパイクまでの符号付き距離のヒストグラム. 外側ビン ($|\Delta| \geq 10$) は付近 10 日以内に実際スパイクが存在しないケースを表す.




図5 見逃し (FN) の Δ 日分布 ($\tau = 0.5$): スパイク定義は図4と同様. 各 FN 実際スパイク日について, 最近傍の予測スパイクまでの符号付き距離のヒストグラム.

すなわち参照ウィンドウの連結に起因する時系列の接合部不連続性と, 無関係な参照系列の無条件混入を, Multi Stream エンコードと Gate 機構という独立した設計上の工夫によってそれぞれ解消する.

数値実験の結果, GateRAF は全体的な予測精度において ProtoRAF および Baseline を上回ることが確認された. アブレーション分析から, Multi Stream エンコードと Gate 機構がそれぞれ異なる側面で予測性能に寄与していることが示された. 前者は正規化歪みを根本的に解消することで分位点予測の安定化に主として貢献し, 後者は静穏域の過検知低減と時間的精度の改善を通じてその効果を補完する.

出版流通における返本率の低減という実用的な観点




図6 予測区間幅 ($q_{0.9} - q_{0.1}$) を等頻度 10 ビンに分割した際の実績値 z スコア平均. 傾きが正であるほど, 区間幅の広い時点に実際スパイクが集中していることを示す.

から, 本研究の枠組みが需要予測の精度向上と業界全体の効率化に貢献することを期待する.

謝辞

参考文献

- [1] 日本書籍出版協会, 「再販制度」, <https://www.jbpa.or.jp/resale/>, 2001.
- [2] 清田義昭, 「再販売価格維持制度の現状と問題点」, 出版研究, vol. 32, pp. 161–166, 2002.
- [3] 下村昭夫, 「日本における出版産業の現状と課題」, 出版研究, vol. 35, pp. 95–102, 2005.
- [4] 全国出版協会・出版科学研究所, 『出版指標年報 2024 年版』, 全国出版協会, 2024.
- [5] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser and I. Polosukhin, “Attention Is All You Need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [6] S. Makridakis, E. Spiliotis and V. Assimakopoulos, “M5 Accuracy Competition: Results, Findings, and Conclusions,” *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022.
- [7] J. D. Croston, “Forecasting and Stock Control for Intermittent Demands,” *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972.
- [8] A. C. Turkmen, T. Januschowski, Y. Wang and A. T. Cemgil, “Forecasting Intermittent and Sparse Time Series: A Unified Probabilistic Framework via Deep Renewal Processes,” *PLOS ONE*, vol. 16, no. 11, e0259764, 2021.
- [9] A. F. Ansari, L. Stella, C. Turkmen, X. Zhang, P. Mercado, H. Shen, O. Shchur, S. S. Rangapuram, S. P. Arango, S. Kapoor, J. Zschiegner, D. C. Maddix, H. Wang, M. W. Mahoney, K. Torkkola, A. G. Wilson, M. Bohlke-Schneider and Y. Wang, “Chronos: Learning the Language of Time Series,” arXiv:2403.07815, 2024.
- [10] K. Tire, E. O. Taga, M. E. Ildiz and S. Oy-

- mak, “Retrieval Augmented Time Series Forecasting,” arXiv:2411.08249, 2024.
- [11] K. Ning, Z. Pan, Y. Liu, Y. Jiang, J. Y. Zhang, K. Rasul, A. Schneider, L. Ma, Y. Nevmyvaka and D. Song, “TS-RAG: Retrieval-Augmented Generation based Time Series Foundation Models are Stronger Zero-Shot Forecaster,” arXiv:2503.07649, 2025.
- [12] H. Zhang, C. Xu, Y.-F. Zhang, Z. Zhang, L. Wang, J. Bian and T. Tan, “TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting,” arXiv:2412.20810, 2024.
- [13] Y. Nie, N. H. Nguyen, P. Sinthong and J. Kalagnanam, “A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,” in *Proceedings of the International Conference on Learning Representations*, 2023.
- [14] D. Salinas, V. Flunkert, J. Gasthaus and T. Januschowski, “DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks,” *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.
- [15] B. Lim, S. Ö. Arık, N. Loeff and T. Pfister, “Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting,” *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [16] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-T. Yih, T. Rocktäschel, S. Riedel and D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [17] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi and J. Choo, “Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift,” in *Proceedings of the International Conference on Learning Representations*, 2022.
- [18] J. Johnson, M. Douze and H. Jégou, “Billion-Scale Similarity Search with GPUs,” *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535–547, 2019.
- [19] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang and W. Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” in *Proceedings of the International Conference on Learning Representations*, 2022.
- [20] S.-Y. Liu, C.-Y. Wang, H. Yin, P. Molchanov, Y.-C. F. Wang, K.-T. Cheng and M.-H. Chen, “DoRA: Weight-Decomposed Low-Rank Adaptation,” in *Proceedings of the International Conference on Machine Learning*, 2024.
- [21] R. Koenker and G. W. Bassett, “Regression Quantiles,” *Econometrica*, vol. 46, no. 1, pp. 33–50, 1978.