

Gate Retrieval-Augmented Forecasting による 突発需要の予測

奈良原 俊誠, 齋藤 陽, 橋本 朋樹, 三川 健太

1. はじめに

文字・活字文化の振興において、書籍や雑誌は基本的な文化資産であり、国家の文化水準を維持・向上させる上で極めて重要な役割を担っている。この役割を保障するための仕組みが再販売価格維持制度である [1, 2]。同制度は出版社が定価を決定し、小売店に定価販売を義務付けるものであり、仮に価格競争が導入された場合に淘汰される多様な出版物を保護している。多様な出版物が保護された結果からなる多品種少量生産という特性に対応するため、出版業界では委託販売制度が広く採用されている [3]。これは出版社が書店に販売を委託し、売れ残った場合に返本できる仕組みである。しかしながら、需要に基づかない発注や配本が行われた場合、書店から出版社に対する過剰な返本が発生し、物流網の圧迫や出版流通の観点から業界全体の深刻な課題となっている [4]。そのため、返本率を低減し出版流通の効率化を図るためには、適切な需要予測が重要である。

書籍の需要予測は過去の販売冊数の推移を扱う時系列予測として位置づけられるが、本研究対象とする書籍のように多品種少量生産の特性を持つ時系列データの需要予測には、突発的な需要が予測で無視されやすいという点、データが限られた特定の系列の予測が困難であるという点の2つの課題がある。前者は、全体の誤差を最小化するように学習された一般的なモデルが、頻出するゼロ需要と少数の突出した需要を平均化してしまい、初版の発行や各種イベントに起因する急激な需要増加に対しても平坦な予測に陥りやすいという問題である。後者は、新刊や販売実績の少ない書籍のように、蓄積されたデータ量が限られた系列において、モデルが需要の変動パターンを十分に学習できず、結果として突発的なスパイク需要を正確に予測することが困難になるという問題である。

これらの課題を解決するアーキテクチャとして、自然言語処理分野の RAG [5] を時系列予測へ拡張した Retrieval-Augmented Forecasting (RAF) が提案さ

れている [6, 7, 8]。RAF は、直近の需要変動に類似した過去のデータを検索・取得して予測に活用する仕組みであり、従来の単一系列モデルの限界を直接的に打破する強みを持つ。全体の誤差最小化に伴い予測値がゼロ需要に引きずられて平坦化するという問題に対しては、過去のデータを直接参照することで突発的な需要スパイクのパターンを的確に捉えることが可能となる。さらに、蓄積されたデータ量が乏しく単独では需要の変動パターンを十分に学習できない系列であっても、他系列の類似事例を横断的に参照することで予測を補完できる。しかし、検索したデータをローカル系列の文脈としてそのまま連結する従来の RAF (コンテキスト拡張型 RAF) [6] には、接合部の不連続性と無関係な参照系列の無条件混入という構造的問題がある。

そこで本稿では、これらの2つの問題を構造的に解消するゲート付き融合型 RAF である GateRAF を提案する。GateRAF は、ローカルコンテキストと各参照ウィンドウを同一のエンコーダで独立にエンコードする Multi Stream エンコードによって接合部の不連続性を根本的に排除し、ローカル要約ベクトルと各参照パッチとの関連度をスカラーゲート $g \in (0, 1)$ で評価する Gate 機構によって無関係な参照の無条件混入を動的に抑制する。提案手法の有効性を、経営科学系研究部会連合協議会が主催する令和7年度データ解析コンペティションで提供いただいた書籍 POS データを用いた実験により、アブレーション分析を通じて定量的に検証する。

2. 準備

2.1 問題設定

2.2 使用データ

本研究では、経営科学系研究部会連合協議会が主催する令和7年度データ解析コンペティションより提供いただいた書籍 POS データを使用する。本データは2024年の1年間にわたる全国35店舗分の書籍・雑誌の販売実績であり、約20万書名・約400万件の販売記録から構成される。各記録は販売日、店舗、書名、販

実験の章へ

売冊数等の情報を持つ。

本研究では書名ごとの需要推移を予測対象とするため、まず店舗間の差異を捨象し、同一の書名・日付に対する販売冊数を全店舗にわたって合算することで POS 販売冊数の時系列を構築した。その上で、予測対象として適した系列を得るために以下の前処理を施した。第一に、年間総販売冊数が 366 冊（1 日あたり平均 1 冊）に満たない書籍は、販売実績が乏しく予測に必要な情報量を欠くため除外した。第二に、巻数違い等の同一作品を作品シリーズ単位へ統合し、一つの需要系列として扱った。第三に、販売記録の存在しない日を欠測ではなくゼロ需要とみなして補完し、全書名・全日付を網羅する完全パネルデータを構築した。以上の処理により、最終的に約 40 万件のデータを得た。

得られたデータでは、POS 販売冊数の平均が約 3.68 冊、標準偏差 13.65 冊と平均に対して分散が大きく、さらにゼロ販売日の割合が 42.9%に達する。このことは、平常時の間欠的なゼロ需要と突発的なスパイク需要が混在するという、本研究が対象とする需要構造を端的に表している。

2.3 関連研究

本研究の課題である突発的なスパイク需要の捕捉と少数系列からの学習に関連する既存研究を、時系列予測の基盤手法、間欠・突発需要予測、検索拡張型予測 (RAF) の 3 つの観点から整理する。

時系列予測の基盤手法としては、PatchTST [9] 等の Transformer ベースの深層学習手法、確率的予測手法の DeepAR [10] や TFT [11]、M5 コンペティション [12] で実用性が検証された大規模事前学習基盤モデル ChronosBolt [13] が代表的手法として挙げられる。また間欠・突発需要予測は既に数多くの研究が存在しており、Croston 法 [14] が基準手法として広く参照される。

RAG [5] を時系列予測へ拡張した RAF は、予測対象のローカルコンテキストに類似した過去のウィンドウを検索データベースから取得し、それを予測に活用することで、単一系列モデルでは捕捉が困難な稀なスパイクパターンを系列横断的に参照できる。代表的な手法として Fire et al. [6] は、Chronos を基盤として検索した参照ウィンドウをローカルコンテキストへ時間軸方向に連結し、拡張した単一系列モデルとして一括エンコードするコンテキスト拡張型 RAF を提案した。ただしこの単純連結には後述の構造的な問題があり、TS-RAG [7] および TimeRAF [8] はそれぞれ潜在空間での融合や Channel Prompting によりこれを回避

2 (2)

ここまで 2.1 へ
+ 図 1 設定を

$r_k \in \mathbb{R}^L$, $k=1, \dots, K$ ってこと?
だとしたら上の + がよい。
にのみ参照、ほかにはないでいいからいい)

する。本稿では、このコンテキスト拡張型 RAF をベースライン (以下、ProtoRAF) として位置づけ、以下にその定式化と構造的な問題点を整理する。

ProtoRAF では、 $x \in \mathbb{R}^L$ をローカルコンテキスト (L はウィンドウ長)、 $\{r_k\}_{k=1}^K \subset \mathbb{R}^L$ を検索された参照ウィンドウとし、参照ウィンドウをローカルコンテキストの前方に連結した拡張コンテキストを単一系列ケンスとして一括エンコードする (図 1):

$$\begin{aligned} x^{\text{proto}} &= [r_1 \parallel \dots \parallel r_K \parallel x] \in \mathbb{R}^{(K+1)L} \quad (1) \\ H^{\text{proto}}, \mu, \sigma &= \text{Encode}(x^{\text{proto}}), \\ H^{\text{proto}} &\in \mathbb{R}^{(K+1)P \times D} \quad (2) \end{aligned}$$

ここで P はパッチ数、 D はエンコーダの埋め込み次元であり、インスタンス正規化 [15] パラメータ (μ, σ) は x^{proto} 全体の統計量から推定される。

この ProtoRAF には、接合部の不連続性 (問題 1) と無関係な系列の無条件混入 (問題 2) という、構造に起因する 2 つの問題点がある。問題 1 は、各 r_k と x を単一系列ケンスとして一括エンコードすることに起因する。連結点においてスケールや形状の異なる系列が直接接合されるため、エンコーダはこの不連続点を実際の系列変化として学習してしまい、表現が歪んで予測精度が低下する。加えて、インスタンス正規化パラメータ (μ, σ) が参照系列を含む連結系列全体から推定されるため、ローカルコンテキストが本来のスケールから外れて処理されるという正規化汚染も併発する。問題 2 は、近傍探索が相対的な順位を返すに過ぎないために生じる。絶対的な類似度が低い無関係な系列も等しく x^{proto} に連結されるため、エンコーダがそのノイズを学習し、予測精度が低下する。本稿の GateRAF は、これら 2 つの問題を Multi Stream エンコードと Gate 機構によって構造的に解消する (第 3 節)。

3. 提案手法

第 2 節で述べた ProtoRAF の 2 つの問題は、参照ウィンドウとローカルコンテキストを単一系列ケンスとして一括エンコードする構造そのものに根ざしている。特に、インスタンス正規化の統計量が連結系列全体から推定されるため、参照パッチを重み付けするゲート機構を後付けするだけでは正規化の汚染を取り除けず、問題を本質的に解決できない。したがって、符号化の方式自体を見直す必要がある。そこで本研究では、ゲート付き融合型 RAF (以下、GateRAF) を提案する。GateRAF は、ローカルコンテキストと各参照ウィンド

オペレーションズ・リサーチ

論文でこのように言っていない。
端的に言うこと。

(XT, ProtoRAF)

どう解決するか先に書くかも
ベター。

図 1 に
～を示す。
へように
ちゃんと言
する
 $x = x_1$
 $x \neq x_2$
して
与えること。

前者
同様の原因から
始めのほうから
どういう図なのか
から始めること

全然おかし
なことをい
っている。

どこでこれを
説明しているの?
で、何か同様の
もの?
もっとちゃんと
説明しよう。

提案手法で

これで
読んでもは
わかってるかな?
「自然な言葉」
ではなく
普遍的に理解
できる言葉で
説明しよう。
(他も)

もう少し小さくてもいい。




図 1 ProtoRAF のアーキテクチャ概要




図 2 GateRAF (提案手法) のアーキテクチャ概要

ここの部分は原則不要。

ウを同一エンコーダで独立に符号化する Multi Stream エンコードによって接合部の不連続性(問題1)と正規化統計量の汚染を構造的に排除し、さらにローカル文脈との関連度に応じて各参照パッチをスカラーゲートで動的に抑制する Gate 機構によって無関係な系列の混入(問題2)を防ぐ。以下では、まず両手法が共通して用いる時系列検索器を定式化し、続いて GateRAF の各構成要素を順に述べる。

3.1 時系列検索器

ローカルコンテキスト $\mathbf{x} \in \mathbb{R}^L$ (L はウィンドウ長) の z スコア正規化形状に基づき、訓練データの全ウィンドウを格納した検索データベース D から過去の系列に限定して上位 K 件の参照ウィンドウを取得する:

$$\{\mathbf{r}_k\}_{k=1}^K = \text{Retrieve}(\mathbf{x}, D), \quad \mathbf{r}_k \in \mathbb{R}^L \quad (3)$$

ここで Retrieve は FAISS による近傍検索 [16] を表す。

3.2 Multi Stream エンコードとゲート付き融合

GateRAF は、問題 1 に対して Multi Stream エンコードを、問題 2 に対してスカラーゲート $g_{k,p} \in (0, 1)$ による参照パッチの動的抑制 (Gate 機構) を導入する

手法である。その順伝播は、(i) ローカルコンテキストと各参照ウィンドウを同一エンコーダで独立に符号化し、(ii) ローカル側の要約ベクトルを基準として各参照パッチの有用度をゲートで評価し、(iii) ゲートで重み付けした参照表現をローカル表現と融合する、という流れからなる(図 2)。以下、融合表現 H^{Gate} を得るまでの手続きを 5 つのステップに分けて述べ、続いてそれを用いた予測を示す。なお、ゲートの出力層バイアスを -1 で初期化することで、学習初期は検索情報をほぼ遮断した状態から出発する。

開始

ステップ 1: ローカルコンテキストのエンコード ローカルコンテキスト $\mathbf{x}$ を単独でエンコードし、パッチ系列の隠れ状態 H^{loc} と正規化統計量 (μ, σ) を得る:

$$(H^{\text{loc}}, \mu, \sigma) = \text{Encode}(\mathbf{x}), \quad H^{\text{loc}} \in \mathbb{R}^{P \times D} \quad (4)$$

(μ, σ) は $\mathbf{x}$ のみから推定されるため、参照ウィンドウに汚染されないローカルスケールで処理でき、ProtoRAF で生じていた正規化汚染が解消される。

みせん、とかいいはい。

(3) 3

ここにかいてある文が、次第からワード文になっっていないダメ。

これ

これも前と同様

protoRAF と何が違うのか？ ちゃんと書く

どうゆうこと？

はいステップ1が始まる

Step 1) ~
" 2) ~
:

こいつ後で Step 1 では ~, Step 2 では ... a だけ m p f o

こいつをどうやら、
少くとも
こ前にちゃんと理由と
解決策をのべておく
必要アリ。

※何ともいっているけど、事実上列だけ絶対にはダメ。何のために行っているのか？
 変数は先に宣言するのが原則。宣言してあげてから日 説明がきこえなくてマズい。
 これもダメ。ダメではないけどあまりきれいではない。

ステップ 2: 参照ウィンドウの独立エンコード (Multi Stream) 各 r_k を同一エンコーダで独立にエンコードし、接合部を生じさせない (問題 1 の解消)。各 r_k の正規化統計はエンコーダ内部にのみ使用し、逆正規化にはステップ 1 の (μ, σ) のみを用いる:

$$H_k^{\text{ret}} = \text{Encode}(r_k) \in \mathbb{R}^{P \times D}, k = 1, \dots, K \quad (5)$$

この段階では各参照を独立なブロック H_k^{ret} として保持し、ローカルコンテキストとも他の参照とも結合しない。

ステップ 3: ローカル要約ベクトルの計算 $H^{\text{loc}} \in \mathbb{R}^{P \times D}$ をパッチ方向に平均プーリングし、ローカル要約ベクトルを得る:

$$\bar{h}^{\text{loc}} = \text{Pool}(H^{\text{loc}}) \in \mathbb{R}^D \quad (6)$$

ここで $\text{Pool}(\cdot)$ はパッチ方向の平均プーリングを表す。

ステップ 4: ゲートの計算 各参照ブロック H_k^{ret} の第 p パッチ $h_{k,p}^{\text{ret}} \in \mathbb{R}^D$ について、固定クエリ $\bar{h}^{\text{loc}}$ との適合度を 2 層 MLP (Linear $\rightarrow$ SiLU $\rightarrow$ Linear $\rightarrow$ Sigmoid) によりスカラー $g_{k,p} \in (0, 1)$ で評価する:

$$g_{k,p} = \text{GateMLP}(\bar{h}^{\text{loc}}, h_{k,p}^{\text{ret}}) \in (0, 1), \quad k = 1, \dots, K, p = 1, \dots, P \quad (7)$$

出力層のバイアスを -1 で初期化することで、学習初期はゲートがほぼ閉じた状態 ($g_{k,p} \approx 0$) から出発する。

ステップ 5: ゲート付き融合 各参照ブロックをそのゲート $g_k = [g_{k,1}, \dots, g_{k,P}]^T$ で重み付けし (問題 2 の解消)、最後にローカル隠れ状態と全参照ブロックをまとめて結合して融合表現を得る:

$$\tilde{H}_k^{\text{ret}} = g_k \odot H_k^{\text{ret}} \in \mathbb{R}^{P \times D} \quad (8)$$

$$H^{\text{gate}} = [H^{\text{loc}} \parallel \tilde{H}_1^{\text{ret}} \parallel \dots \parallel \tilde{H}_K^{\text{ret}}] \in \mathbb{R}^{(1+K)P \times D} \quad (9)$$

ここで $\odot$ はパッチごとのスカラー倍 (行方向へのブロードキャスト) を表す。参照表現とローカル表現の結合は、この最終段で初めて行われる。

3.3 予測

ローカルコンテキストのパッチ埋め込み E_{in} をクエリ、 H^{gate} をキー・バリューとしてデコードし、各分位点の予測値を出力する (図 2):

$$O = \text{Decode}(E_{\text{in}}, H^{\text{gate}}) \quad (10)$$

4 (4)

$$\hat{Y} = \text{RevNorm}(\text{OutputProj}(O), \mu, \sigma) \in \mathbb{R}^{|Q| \times F} \quad (11)$$

ここで Q は分位点集合、 F は予測ホライズン長、 $\text{RevNorm}(\cdot, \mu, \sigma)$ は逆インスタンス正規化 $z \mapsto z \cdot \sigma + \mu$ を表す。

3.4 共有エンコーダによるゲート計算の妥当性

ゲート MLP が $[\bar{h}^{\text{loc}} \parallel h_{k,p}^{\text{ret}}]$ から適合度を計算するには、両ベクトルが同一の表現空間に属することが前提となる。ステップ 1・2 で同一パラメータのエンコーダを共有することで、 $\bar{h}^{\text{loc}}$ と $h_{k,p}^{\text{ret}}$ はともに同一値域に属し、ゲートによる意味的な比較が保証される。ProtoRAF のように連結系列を一括エンコードした場合、インスタンス正規化パラメータが連結系列全体の統計量に依存するため、ゲート機構を後付けしても適合度計算の前提が崩れる。Multi-Stream エンコードはゲート機構の意味的妥当性をアーキテクチャとして保証するための設計上の要件でもある。

4. 実験

本節では、提案手法 ~~GateRAF~~ の有効性を検証する。具体的には、GateRAF が突発的なスパイク需要を含む需要全体の予測精度を改善するか、また Multi Stream エンコードと Gate 機構が予測のどの側面にそれぞれ寄与するかを明らかにすることを目的とする。この目的のため、検索機構を持たない Baseline に各要素を段階的に加えるアブレーション (Baseline $\rightarrow$ ProtoRAF $\rightarrow$ Multi-RAF $\rightarrow$ GateRAF) を実施し、全書名を対象とした分位点予測精度、代表書名におけるスパイク追従挙動、さらにスパイク強度、時間近接性、予測区間幅の観点から多角的に評価する。

4.1 実験条件

全手法は ChronosBolt [13] を DoRA [17] でファインチューニングしたものである。Baseline は検索機構を持たない基準手法、ProtoRAF は参照ウィンドウをローカルコンテキストへ時間軸方向に連結する従来型 RAF (第 2.3 節)、Multi-RAF は GateRAF からゲート機構を除いた手法である。ProtoRAF $\rightarrow$ Multi-RAF の比較で Multi Stream エンコードの寄与を、Multi-RAF $\rightarrow$ GateRAF の比較で Gate 機構の効果を段階的に検証する。共通設定は LoRA [18] ランク $r = 8$, $K = 3$, $L = 128$, $F = 64$, ピンボール損失 [19] である。

この部分も検討はあり。主がわかりにくい。

何をいっているのか オペレーションズ・リサーチからはいし、ビジネスからいっているから。何をいっているのか どちらからはい。ここでもっと説明してほしい。

何にかかっている
 右辺?
 左辺?
 表はわからない。

← 又左側不要。(なぜとある?)

?

ここに必要はない?

→ ため、～へ実行
 実行。

実行しては

→ 何コレ?

何のこと?

分位点の設定は?

?
 アタリマシイ?

↑

?

4.2. 実用性向上

まだ全体像、
わかんない。

家で
かきとるけど
値の範囲が広い。

いぼりていなくて
つかない。

4.2.1

4.2 全体的な予測精度

表 1 に、全書名・全予測期間を対象とした MAE および RMSE を示す。ProtoRAF は Baseline とほぼ同等の精度にとどまっており、参照ウィンドウを時間軸方向へ単純連結するアプローチは予測改善に寄与していない。

Multi Stream エンコードの効果 (ProtoRAF → Multi-RAF) : $\tau = 0.5$ で MAE が 7.7%, $\tau = 0.9$ では MAE が 27.4%・RMSE が 50.6% と大幅に改善した。ProtoRAF は参照系列のスパイクが正規化統計量を歪めるため上位分位点の予測が過大に上振れるが、独立エンコードはこの正規化汚染を根本的に排除する。一方 $\tau = 0.1$ では MAE がわずかに悪化しており、Multi Stream の寄与は中・上位分位点に集中している。

Gate 機構の効果 (Multi-RAF → GateRAF) : $\tau = 0.1$ で MAE が 3.8%, $\tau = 0.5$ で 2.4% 改善した。主な効果は低分位点の静穏域 (第 4.4 節) と時間近接性 (第 4.5 節) に現れている。

4.3 書名別事例分析

前節で示した全体指標は平均的な精度の改善を表すが、各モデルが個々の突発スパイクをどの程度追従できるかという挙動までは明らかにしない。そこで本節では、スパイクの発生パターンが異なる代表的な 2 書名を取り上げ、予測値の時系列を可視化して各モデルの挙動を具体的に比較する (図 3)。これにより、Multi Stream エンコードと Gate 機構がスパイク追従の挙動にどのように寄与するかを定性的に確認する。

ぼっち・ざ・ろっく! 予測期間冒頭に実績が急増 (z スコア最大 3.6) した後、急速に減衰するパターンを示す (図 3a)。GateRAF (MAE= 2.39) は減衰ペースを正確に追従したが、ProtoRAF および Baseline は減衰を捉えられず終始高水準の予測を維持した (MAE= 7.81)。

デラックスクロスワード 予測期間中盤 (約 20 日前後) に急増するパターンを示す (図 3b, z スコア最大 5.8)。GateRAF (MAE= 1.59) および Multi-RAF (MAE= 1.88) はスパイクを検出できているのに対し、ProtoRAF および Baseline は予測値がほぼゼロに張り付いたままスパイクを全く捉えられなかった (ProtoRAF MAE= 2.96)。2 書名の分析から、Multi Stream エンコードがスパイク検出精度を向上させ、Gate 機構が文脈に応じた選択的な参照を実現するという、2 つの機構の補完的な効果が確認された。

4.4 スパイク強度別の予測精度

各時点の実績値を系列内 z スコアでビン分けし、スパイク強度ごとの予測誤差を比較した (表 2)。 $\tau = 0.5$ の MAE において GateRAF はすべての z スコア帯で Baseline を上回り、**静穏域 ($z < -1$)** では約 31% の誤差削減を実現した。 $\tau = 0.9$ の静穏域では ProtoRAF の RMSE が GateRAF の約 3 倍に達しており、一括正規化による統計量の歪みが平坦な需要帯においても過大予測を誘発することが確認できる。 Gate 機構の寄与は低分位点の静穏域に現れ、 $\tau = 0.1$ の静穏域において GateRAF は Multi-RAF に対し MAE を 17.5% (1.03 → 0.85) 改善している。 以上は静穏域での改善が中心であるが、高スパイク域 ($z > 2$) においても GateRAF は $\tau = 0.5$ の MAE で全モデル中最良であり、Baseline に対し $z:2-3$ 帯で 9.1% (12.41 → 11.28), $z > 3$ 帯で 5.7% (26.25 → 24.76) の誤差を削減している。 これにより、提案手法が静穏域の過検知抑制と突発スパイクの捕捉を両立していることが確認できる。

4.5 時間近接性

誤分類時点と最近傍の実際スパイク時点との時間的距離 (Δ 日) を分析した ($\tau = 0.5$, 図 4, 5)。 系列内 z スコアが 2.0 以上となる時点をスパイクとして定義した。 誤検知 (FP) のうちノイズ的な誤検知 ($|\Delta| \geq 10$) の割合は、ProtoRAF の 59.1% に対して GateRAF は 49.6% と低く、GateRAF の誤検知の多くは実際スパイクに近接した **タイミングのズレ** によるものである。 見逃し (FN) でも同様に、GateRAF はスパイク付近で予測を上方修正する挙動が見られる。 Gate 機構がローカル文脈に類似した参照パッチのみを選択的に透過させることで、無関係な参照の混入を時間軸上でも抑制している。

4.6 予測区間幅の比較

予測区間幅 ($\tau_{0.9} - \tau_{0.1}$) を等頻度ビンに分割し、各ビンの系列内 z スコア平均を算出した (図 6)。 GateRAF および Multi-RAF は、区間幅が広がるにつれて z スコアが単調に上昇 ($-0.34 \rightarrow +0.32$) しており、広い予測区間がスパイク発生日に集中している。 一方、ProtoRAF の傾きはほぼ平坦 ($-0.06 \rightarrow +0.14$) であり、一括正規化による統計量の歪みが区間幅と実需変動の連動性を失わせている。 GateRAF と Multi-RAF の校正挙動がほぼ同一であることから、この効果は主に Multi Stream エンコードによる正規化スケールの安定化に起因することがわかる。 この結果は、GateRAF が点予測の精度向上にとどまらず、需要が急増しやすい時点ほど予測区間を広げる、すなわち不確実性を実

これもダメ。

これ、
いいけど?
マシな A を
に A を
よって 12?

どう
なん?

これも。



図 6 より、
ちゃんと
言える。
(他も)

これ、2026 年 12 月
定性評価を
含んでいる。

⇒ どちらも「当たってないじゃん」
と思われると思う。

表 1 各モデルおよび分位点レベルにおける MAE および RMSE の比較

モデル	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE
GateRAF	3.6339	13.5293	2.7452	12.2025	5.0136	13.3030
Multi-RAF	3.7766	13.6118	2.8117	12.2594	4.9745	13.3570
ProtoRAF	3.6604	13.7593	3.0467	12.9622	6.8549	27.0196
Baseline	3.6501	13.7476	3.0460	12.9603	6.8512	27.0050



(a) ぼっち・ざ・ろっく!

(b) デラックスクロスワード

図 3 各書名における全モデルの予測比較 ($\tau = 0.5$). 赤実線は GateRAF, 青破線は Multi-RAF, 緑点線は ProtoRAF, 橙一点鎖線は Baseline であり, 黒実線は実績を表す.

表 2 系列内 z スコアビン別の MAE および RMSE

モデル	<-1		-1-0		0-0.5		0.5-1		1-1.5		1.5-2		2-3		>3	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
$\tau = 0.1$																
GateRAF	0.85	2.88	1.57	4.57	4.65	9.48	5.98	11.86	7.18	15.81	8.42	17.66	14.72	39.32	28.08	63.94
Multi-RAF	1.03	3.01	1.71	4.67	4.77	9.56	6.15	12.00	7.36	15.92	8.59	17.80	14.84	39.68	28.24	63.94
ProtoRAF	0.89	3.09	1.47	4.39	4.77	9.79	6.20	12.22	7.51	16.47	8.79	18.36	15.45	40.54	28.58	64.37
Baseline	0.89	3.08	1.46	4.38	4.76	9.77	6.19	12.21	7.50	16.45	8.78	18.35	15.44	40.51	28.56	64.35
$\tau = 0.5$																
GateRAF	1.84	3.15	1.21	3.78	2.96	7.32	3.92	9.90	4.94	13.12	6.05	14.98	11.28	35.30	24.76	61.12
Multi-RAF	1.94	3.23	1.26	3.77	3.01	7.29	4.03	9.95	5.07	13.14	6.19	15.17	11.47	35.98	24.84	61.00
ProtoRAF	2.66	6.21	1.40	5.13	3.14	8.22	4.22	10.73	5.39	13.82	6.50	15.74	12.42	36.57	26.26	62.31
Baseline	2.66	6.21	1.40	5.14	3.13	8.22	4.22	10.73	5.39	13.82	6.50	15.75	12.41	36.55	26.25	62.29
$\tau = 0.9$																
GateRAF	6.19	9.70	4.52	9.50	4.47	8.98	4.74	10.04	4.56	10.64	4.89	12.42	8.39	30.16	18.81	55.93
Multi-RAF	6.27	9.64	4.46	9.43	4.41	8.92	4.73	10.18	4.51	10.65	4.88	12.59	8.57	31.39	18.73	55.86
ProtoRAF	9.48	29.11	6.57	27.12	6.33	24.03	5.75	25.13	4.79	11.83	5.39	15.07	9.56	33.12	20.74	58.00
Baseline	9.49	29.17	6.56	27.09	6.33	24.02	5.75	25.16	4.80	11.83	5.39	15.08	9.56	33.15	20.72	57.99




図 4 誤検知 (FP) の Δ 日分布 ($\tau = 0.5$): スパイクは系列内 z スコアが 2.0 以上の時点として定義した. 各 FP 予測日について, 最近傍の実需スパイクまでの符号付き距離のヒストグラム. 外側ビン ($|\Delta| \geq 10$) は付近 10 日以内に実際スパイクが存在しないケースを表す.

際の需要変動に整合させて出力できることを意味する. 予測区間が実需のスパイクと連動することは, どの時点で需要変動に備えるべきかを示す指標となり, 発注量の調整や安全在庫の確保を通じて返本率の低減という本研究の目的にも資する. 一方, 区間幅が実需と連動しない ProtoRAF の予測区間は, こうした実務的な示唆を与えない.

5. おわりに

本研究では, 多品種少量生産という特性を持つ出版販売データに対する需要予測, 特に突発的なスパイク需要の捕捉を目的として, ゲート付き融合型 RAF である GateRAF を提案した. GateRAF は, 既存のコンテキスト拡張型 RAF が抱える 2 つの構造的問題, すなわち参照ウィンドウの連結に起因する時系列の接合部不連続性と, 無関係な参照系列の無条件混入を, Multi Stream エンコードと Gate 機構という独立した

前もいたけど
ここに文をゆかいにい




図5 見逃し (FN) の Δ 日分布 ($\tau = 0.5$): スパイク定義は図4と同様. 各FN 実際スパイク日について, 最近傍の予測スパイクまでの符号付き距離のヒストグラム.




図6 予測区間幅 ($q_{0.9} - q_{0.1}$) を等頻度 10 ビンに分割した際の実績値 z スコア平均. 傾きが正であるほど, 区間幅の広い時点に実際スパイクが集中していることを示す.

設計上の工夫によってそれぞれ解消する.

数値実験の結果, GateRAF は全体的な予測精度において ProtoRAF および Baseline を上回ることが確認された. アブレーション分析から, Multi Stream エンコードと Gate 機構がそれぞれ異なる側面で予測性能に寄与していることが示された. 前者は正規化歪みを根本的に解消することで分位点予測の安定化に主として貢献し, 後者は静穏域の過検知低減と時間的精度の改善を通じてその効果を補完する.

出版流通における返本率の低減という実用的な観点から, 本研究の枠組みが需要予測の精度向上と業界全体の効率化に貢献することを期待する.

謝辞 —

2026 年月号

参考文献

- [1] 日本書籍出版協会, 「再販制度」, <https://www.jbpa.or.jp/resale/>, 2001.
- [2] 清田義昭, “再販売価格維持制度の現状と問題点”, 出版研究, vol. 32, pp. 161–166, 2002.
- [3] 下村昭夫, “日本における出版産業の現状と課題”, 出版研究, vol. 35, pp. 95–102, 2005.
- [4] 全国出版協会・出版科学研究所, 『出版指標年報 2024 年版』, 全国出版協会, 2024.
- [5] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-T. Yih, T. Rocktäschel, S. Riedel and D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [6] K. Tire, E. O. Taga, M. E. Ildiz and S. Oymak, “Retrieval Augmented Time Series Forecasting,” arXiv:2411.08249, 2024.
- [7] K. Ning, Z. Pan, Y. Liu, Y. Jiang, J. Y. Zhang, K. Rasul, A. Schneider, L. Ma, Y. Nevmyvaka and D. Song, “TS-RAG: Retrieval-Augmented Generation based Time Series Foundation Models are Stronger Zero-Shot Forecaster,” arXiv:2503.07649, 2025.
- [8] H. Zhang, C. Xu, Y.-F. Zhang, Z. Zhang, L. Wang, J. Bian and T. Tan, “TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting,” arXiv:2412.20810, 2024.
- [9] Y. Nie, N. H. Nguyen, P. Sinthong and J. Kalagnanam, “A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,” in *Proceedings of the International Conference on Learning Representations*, 2023.
- [10] D. Salinas, V. Flunkert, J. Gasthaus and T. Januschowski, “DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks,” *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.
- [11] B. Lim, S. Ö. Arik, N. Loeff and T. Pfister, “Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting,” *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [12] S. Makridakis, E. Spiliotis and V. Assimakopoulos, “M5 Accuracy Competition: Results, Findings, and Conclusions,” *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022.
- [13] A. F. Ansari, L. Stella, C. Turkmen, X. Zhang, P. Mercado, H. Shen, O. Shchur, S. S. Rangapuram, S. P. Arango, S. Kapoor, J. Zschiegner, D. C. Maddix, H. Wang, M. W. Mahoney, K. Torkkola, A. G. Wilson, M. Bohlke-Schneider and Y. Wang, “Chronos: Learning the Language of Time Series,” arXiv:2403.07815, 2024.
- [14] J. D. Croston, “Forecasting and Stock Control for Intermittent Demands,” *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972.
- [15] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi and J. Choo, “Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift,” in *Proceedings of the International Conference on Learning Representations*, 2022.

ありがとうございます。

- [16] J. Johnson, M. Douze and H. Jégou, “Billion-Scale Similarity Search with GPUs,” *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535–547, 2019.
- [17] S.-Y. Liu, C.-Y. Wang, H. Yin, P. Molchanov, Y.-C. F. Wang, K.-T. Cheng and M.-H. Chen, “DoRA: Weight-Decomposed Low-Rank Adaptation,” in *Proceedings of the International Conference on Machine Learning*, 2024.
- [18] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang and W. Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” in *Proceedings of the International Conference on Learning Representations*, 2022.
- [19] R. Koenker and G. W. Bassett, “Regression Quantiles,” *Econometrica*, vol. 46, no. 1, pp. 33–50, 1978.