

Gate Retrieval-Augmented Forecasting による 突発需要の予測

奈良原 俊誠, 齋藤 陽, 橋本 朋樹, 三川 健太

1. はじめに

出版物は、個々の販売規模が小さく、品目数が多いという多品種少量生産の性質を保有する。このような特性のもと、出版流通では再販売価格維持制度と委託販売制度が用いられている。再販売価格維持制度では、出版社が定価を決定し、小売店に定価での販売を求める制度であり、価格競争によって流通が難しくなるであろう多様な出版物を支えている [1]。また、~~いまだに販売制度で~~ ^{は師社や取次} 近傍探索が相対的な順位を返すため関連度の低い一方、需要に基づかない発注や配本は過剰な返本を ^{書店に} 参照窓も一律に繋げてしまうことに起因する。そこで招く。返本の増加は物流コストや流通効率の面で出版 ^{本を返す} 本研究では、これらの2つの問題を構造的に解消す。業界全体の課題となっており [2]、返本率の低減には需 ^{書店の} ゲート付き融合型 RAF である GateRAF を提案する。要に即した配本の判断が不可欠であると言える。従っ ^{店に} GateRAF は、ローカルコンテキストと各参照ウィン ^で ドウを同一のエンコーダで独立にエンコードするマル ^{を小売店} チストリームエンコードによって接合部の不連続性を ^{返本率を} 根本的に排除し、ローカル要約ベクトルと各参照パッ ^{制度を} チとの関連度をスカラーゲートで評価するゲート機構によって無関係な参照の無条件混入を動的に抑制する。本研究の目的は、書籍の将来の販売冊数を予測すること、すなわち書籍の需要予測である。とりわけ、平常時の需要を過大に見積もらず、かつ短期間に需要が急増する時期を見落とさずに予測することを目指す。この目的のもとで提案手法の有効性を、経営科学系研究部会連合協議会が主催する令和7年度データ解析コンペティションより提供いただいた書籍 POS データを用いた実験により検証する。

一般に、書籍の需要予測は過去の販売冊数に基づく時系列予測問題として位置づけられる。しかし、多品種少量生産という特性上、需要の多くがゼロ、または少数に集中する一方で、初版の発行やイベントなどにより突発的な需要増加が発生する。これにより、通常 ^と の予測モデルでは需要の山を平坦に予測してしまう可能性 ^{がある}。加えて、新刊や販売実績の少ない書籍では利用可能なデータが限られてしまうため、各タイトル固有の需要変動を学習することが難しい。このため、これらの課題を解決する方法として、自然言語処理分野 ^の RAG [3] を時系列予測へ拡張した Retrieval-Augmented Forecasting (RAF) が提案されている [4]。RAF は、直近の需要変動に類似した過去のデータを検索 ^し 取得して予測に活用する仕組みにより、従来の単一系列モデルの限界を直接的に打破する強みを持つ。1点目の問題である予測値の平坦化に対しては、過去のデータを直接参照することで突発的な需要スパイクのパターンを的確に捉えることを可能にする。さらに、

これらの課題を解決する方法として、自然言語処理分野 ^の RAG [3] を時系列予測へ拡張した Retrieval-Augmented Forecasting (RAF) が提案されている [4]。RAF は、直近の需要変動に類似した過去のデータを検索 ^し 取得して予測に活用する仕組みにより、従来の単一系列モデルの限界を直接的に打破する強みを持つ。1点目の問題である予測値の平坦化に対しては、過去のデータを直接参照することで突発的な需要スパイクのパターンを的確に捉えることを可能にする。さらに、

ならはら しゅんせい, さいとう はる, はしもと ともし, みかわ けんた

東京都市大学メディア情報学部情報システム学科
〒224-0015 神奈川県横浜市中区牛久保西 3-3-1

2026 年月号

2点目の問題である蓄積されたデータ量が乏しく需要の変動パターンを十分に学習できない場合でも、他系列の類似事例を横断的に参照することで予測を補完できる。しかし、予測する系列の直近データに検索した参照窓をそのまま繋げる従来の RAF には、つなぎ目が不連続になることと、関係の薄い参照窓まで区別なく混入してしまう問題がある。これらの問題は、参照窓を時間軸上で直近データに直接繋げていること、お ^り 近傍探索が相対的な順位を返すため関連度の低い参照窓も一律に繋げてしまうことに起因する。そこで本研究では、これらの2つの問題を構造的に解消す。GateRAF は、ローカルコンテキストと各参照ウィンドウを同一のエンコーダで独立にエンコードするマルチストリームエンコードによって接合部の不連続性を根本的に排除し、ローカル要約ベクトルと各参照パッチとの関連度をスカラーゲートで評価するゲート機構によって無関係な参照の無条件混入を動的に抑制する。本研究の目的は、書籍の将来の販売冊数を予測すること、すなわち書籍の需要予測である。とりわけ、平常時の需要を過大に見積もらず、かつ短期間に需要が急増する時期を見落とさずに予測することを目指す。この目的のもとで提案手法の有効性を、経営科学系研究部会連合協議会が主催する令和7年度データ解析コンペティションより提供いただいた書籍 POS データを用いた実験により検証する。

2. 準備

2.1 問題設定

本研究では、経営科学系研究部会連合協議会が主催する令和7年度データ解析コンペティションより提供いただいた書籍 POS データを使用する。本データは2024年の1年間にわたる全国35店舗分の書籍・雑誌の販売実績であり、約20万書名・約400万件の販売記録から構成される。各記録は販売日、店舗、書名、販売冊数等の情報を持つ。

前述の通り、書籍の販売冊数は、平常時には少数に

すごく回りにくい言い方だし。
 実験でその内容と合致している
 ようにかく必要がある。
 何を予測する内容に落とし込んで
 どう
 いるのか、端的に記述しよう。

とどまることが多い一方、イベントなどに起因して短期間だけ販売冊数が急増する場合がある。以下では、このような一時的な需要増加をスパイクと呼ぶ。スパイクを見落としてしまうと、機会損失が発生する一方、過大に予測した場合、在庫の増加や返本の増加につながる。したがって、本研究では、スパイクの発生時期と規模を適切に予測するとともに、平常時の需要を誤ってスパイクと判断しないことを課題とする。

上記の議論のもと、本研究では書籍一点ごとの将来の販売冊数を過去の実績に基づいて予測する。ただし、書籍の販売特性を考慮し、日々の販売冊数を平均的に予測するのではなく、短期間に需要が急増する時期を捉えることを重視する。

2.2 関連研究

本研究の課題である突発的なスパイク需要の捕捉と少数系列からの学習に関連する既存研究を、時系列予測の基盤手法、間欠・突発需要予測、検索拡張型予測の3つの観点から整理する。

時系列予測の基盤手法としては、PatchTST [5] 等の Transformer ベースの深層学習手法、確率的予測手法の DeepAR [6] や TFT [7]、大規模事前学習基盤モデル Chronos [8] が代表的手法として挙げられる。また、間欠・突発需要予測は既に数多くの研究が存在し ~~しており~~、Croston 法 [9] が基準手法として広く参照される。

RAG [3] を時系列予測へ拡張した RAF は、予測対象のローカルコンテキストに類似した過去のウィンドウを検索データベースから取得し、それを予測に活用することで、単一系列モデルでは捕捉が困難な稀なスパイクパターンを系列横断的に参照できる。代表的な手法として Chronos [8] を基盤として検索した参照ウィンドウをローカルコンテキストへ時間軸方向に連結し、拡張した単一系列として一括エンコードする ProtoRAF が存在する [4]。ただしこの連結方法には接合部の不連続性と無関係な参照ウィンドウの混入という2つの構造的問題があり、TS-RAG [10] や TimeRAF [11] ではそれぞれ潜在空間での融合や Channel Prompting により改善を試みている。

ProtoRAF は参照ウィンドウを次のように取得する。まず、系列を長さ L のウィンドウに区切って扱い、学習データから過去のウィンドウ集合 $\mathcal{D} = \{w_i\}_{i=1}^N$ を作成する。いま、予測対象のローカルコンテキストを $x \in \mathbb{R}^L$ とおく。ProtoRAF による予測では、 x と $\mathcal{D}$ の各ウィンドウ w_i を比較する。この際、入力データの規模の違いを考慮するため、標準化したベクトル

と士で距離を測る。すなわち、 x を標準化した $\tilde{x} \in \mathbb{R}^L$ と、 w_i を標準化した $\tilde{w}_i \in \mathbb{R}^L$ の距離 $d(\tilde{x}, \tilde{w}_i)$ を算出し、このうち距離の小さい上位 K 件を参照ウィンドウ $r_k \in \mathbb{R}^L$ ($k = 1, \dots, K$) として取得する：

$$\{r_k\}_{k=1}^K = \text{Top-}K \underset{w_i \in \mathcal{D}}{d(\tilde{x}, \tilde{w}_i)} \quad (1)$$

ここで、 $\text{Top-}K_{\min}$ は距離 d が小さい順に上位 K 件を選ぶ操作であり、その計算には近傍検索 [12] を用いる。また、データリークを防ぐためウィンドウ集合 $\mathcal{D}$ は予測時点より前のウィンドウのみで構成する。この検索ではウィンドウ集合 $\mathcal{D}$ の中で相対的に類似した K 件を返すのみであり、常に K 件が選出されることに注意されたい。

図1に示すように、ProtoRAF はこのローカルコンテキスト x の前方に参照ウィンドウ $r_1, \dots, r_K$ をそのまま連結し、拡張コンテキストを単一系列として一括エンコードする。バッチ数を P 、エンコーダの埋め込み次元を D とすると、以下のように表される：

$$x^{\text{proto}} = (r_1^T, r_2^T, \dots, r_K^T, x^T)^T \in \mathbb{R}^{(K+1)L} \quad (2)$$

$$H^{\text{proto}} = \text{Encode}(x^{\text{proto}}) \in \mathbb{R}^{(K+1)P \times D} \quad (3)$$

x^{proto} は参照ウィンドウをローカルコンテキストの前方に時間軸方向で連結した拡張コンテキストである。 H^{proto} はこれをエンコーダで符号化した表現であり、 x^{proto} をバッチごとに区切り、各バッチを1つのベクトルにして並べたものである。エンコーダが標準化 [13] に用いる平均と標準偏差は、ローカルコンテキストだけでなく参照ウィンドウまで連結した x^{proto} 全体から計算される。

このProtoRAFには、参照ウィンドウとローカルコンテキストを1本の系列につなぐという構造そのものに起因して、接合部の不連続性、無関係な参照ウィンドウの混入という2つの問題が生じる。前者は、連結した系列の継ぎ目をエンコーダが系列に実際に起きた値の変化と取り違えてしまう問題である。ProtoRAF は性質の異なる参照ウィンドウとローカルコンテキストを1本の長い系列としてつなぐため、その境目では値の水準や形が大きく食い違う。エンコーダはこの不自然な段差を、データに実際に起きた変化と区別できないまま学習してしまい、予測精度の低下を引き起こす可能性がある。また、この連結は標準化の基準もずらす。すなわち、ローカルコンテキストが本来のスケールから外れて処理される。

こういうのは
 今回でいいよ
 理由は
 あり？
 ↑
 直感で
 つまみつかう。

?
 これは
 H^{proto} も
 ベクトル化して
 ↑
 ここへ Encode
 させよう
 式(4)に
 関係する
 1つあり




図 1 ProtoRAF のアーキテクチャ概要




図 2 GateRAF (提案手法) のアーキテクチャ概要

後者は、関連の薄い参照ウィンドウまでが予測にそのまま持ち込まれてしまう問題である。前述の通り、検索は予測対象とよく似た事例があるかどうかに関わらず、常に上位 K 件を返す。そのため、似た事例が乏しい予測対象に対しても、関係の薄いウィンドウが参照ウィンドウとして連結されてしまう。ProtoRAF はこれらをローカルコンテキストと区別せずまとめてエンコードするため、無関係なウィンドウの情報まで取り込み、予測精度の低下を引き起こす。

3. 提案手法

3.1 概要

前述の通り、ProtoRAF には接合部の不連続性と無関係な参照ウィンドウの混入という問題が存在する。提案手法である GateRAF は、ProtoRAF の 2 つの問題がいずれも参照ウィンドウとローカルコンテキストを ~~一本の系列につないで~~ から一括で符号化することに由来する点に着目し、この符号化の流れ自体を見直すことで両者を解決する。具体的には、ローカルコンテキストと各参照ウィンドウをそれぞれ独立に符号化し、予測へ役立つ参照だけを選んで組み合わせる。GateRAF はこの考え方を 2 つの機構により実現する。1 つ目はマルチストリームエンコードであり、ローカルコンテキストと各参照ウィンドウを個別に標準化し、共通のエンコーダで独立に符号化する。これにより、

系列の連結境界をデータの変化と取り違える問題と、スケール差の影響を抑える。2 つ目はゲート機構であり、ローカルコンテキストとの関連性に応じて各参照に寄与を調整し、関連性の低い参照が予測に与える影響を抑制する。GateRAF の全体像を図 2 に示す。

3.2 マルチストリームエンコードとゲート付き融合

GateRAF は次の 5 つのステップから構成される。

- Step 1) ローカルコンテキストのエンコード
- Step 2) 参照ウィンドウの独立エンコード
- Step 3) ローカル要約ベクトルの計算
- Step 4) ゲートの計算
- Step 5) ゲート付き融合

Step 1 ではローカルコンテキストだけを符号化し、参照ウィンドウに影響されない標準化の基準を確保する。まず、予測対象のローカルコンテキスト x だけをエンコーダに入力し、そのパッチ表現 H^{loc} を得る：

$$H^{loc} = \text{Encode}(x), \quad H^{loc} \in \mathbb{R}^{P \times D} \quad (4)$$

ここで Encode は基盤モデルのエンコーダであり、入力系列をその平均と標準偏差で標準化し、パッチ表現に変換する。ローカルコンテキスト x だけを入力するため、自身の平均と標準偏差を利用することから、参照ウィンドウに含まれるスパイクの影響を受けない。

Step 2 では各参照ウィンドウを別々に符号化し、連結による接合部の作成を回避する。各参照ウィンドウ

r_k をローカルコンテキストと同じエンコーダで個別に符号化し、参照ブロック H_k^{ret} を得る：

$$H_k^{\text{ret}} = \text{Encode}(r_k), H_k^{\text{ret}} \in \mathbb{R}^{P \times D} \quad (5)$$

式 (5) を用いることで連結部分を作らず、接合部の不連続性が生じない。この段階では各参照を独立なブロック H_k^{ret} として保持し、ローカルコンテキストとも他の参照とも結合しない。

Step 3 ではローカルコンテキストの表現を 1 本のベクトルにまとめ、参照の基準とする。 H^{loc} をパッチ方向に平均プーリングし、ローカル要約ベクトル $\bar{h}^{\text{loc}}$ を得る：

$$\bar{h}^{\text{loc}} = \text{Pool}(H^{\text{loc}}), \bar{h}^{\text{loc}} \in \mathbb{R}^D \quad (6)$$

ここで $\text{Pool}(\cdot)$ はパッチ方向の平均プーリングを表す。

Step 4 では各参照パッチを予測にどれだけ反映させるかを、ローカルコンテキストとの関連の強さに応じて決める。具体的には、ステップ 3 で得たローカル要約ベクトル $\bar{h}^{\text{loc}}$ と、各参照ブロックの第 p パッチ $h_{k,p}^{\text{ret}} \in \mathbb{R}^D$ を多層パーセプトロン GateMLP に入力し、両者の関連の強さを 0 から 1 の値 $g_{k,p}$ として出力する：

$$g_{k,p} = \text{GateMLP}(\bar{h}^{\text{loc}}, h_{k,p}^{\text{ret}})$$

$g_{k,p}$ は参照パッチの重みであり、1 に近いほどその参照を予測に強く反映し、0 に近いほど影響を抑える。関連の薄い参照を自動的に弱めることで、無関係なウィンドウの混入を防ぐのが狙いである。また、無関係な参照に引きずられないよう、ゲートは学習の初期にはほぼ閉じた状態、すなわち出力が 0 に近い状態から始まるよう初期化する。これにより、モデルはまず信頼できるローカルコンテキストに基づいて予測を学習し、役立つ参照だけを学習の進行とともに取り込んでいく。

Step 5 ではゲートで重み付けした参照表現をローカルコンテキストの表現と統合し、予測に用いる。まず、各参照ブロック H_k^{ret} の各パッチに、対応する重み $g_{k,p}$ を掛け、重み付き参照ブロック $\tilde{H}_k^{\text{ret}} \in \mathbb{R}^{P \times D}$ を得る。次に、ローカル表現と重み付けした全参照ブロックを結合して融合表現 $H^{\text{gate}} \in \mathbb{R}^{(1+K)P \times D}$ とする：

$$\tilde{H}_k^{\text{ret}} = g_k \odot H_k^{\text{ret}} \quad (8)$$

$$H^{\text{gate}} = [H^{\text{loc}}, \tilde{H}_1^{\text{ret}}, \dots, \tilde{H}_K^{\text{ret}}] \quad (9)$$

ここで $g_k = [g_{k,1}, \dots, g_{k,P}]^T$ は参照ブロック k の各パッチのゲート値を並べたベクトルであり、 $\odot$ は各パッチ p の表現全体に同じ重み $g_{k,p}$ を掛ける演算を表

す。関連の薄い参照ほど重みが小さくなるため、無関係なウィンドウの混入が抑えられる。参照表現とローカル表現を結合するのはこの最終段だけであり、それまでは互いに干渉しない。

3.3 予測

最後に、融合表現 H^{gate} から将来の販売冊数を予測する。 H^{gate} には、ローカルコンテキストと、ゲートで重み付けした参照の情報がまとめられている。これをデコーダに渡して各分位点の予測を出力し、符号化の際に施した標準化を元に戻す。分位点の集合を Q 、予測する日数を F 、標準化したスケールを元に戻す操作を RevNorm とすると、予測値 $\hat{Y} \in \mathbb{R}^{|Q| \times F}$ は以下のように表される：

$$\hat{Y} = \text{RevNorm}(\text{Decode}(H^{\text{gate}}), \mu, \sigma) \quad (10)$$

ここで μ, σ はローカルコンテキスト x から計算した平均と標準偏差である。

4. 実験

提案手法が需要予測、とりわけ突発的なスパイク需要の捕捉に有効であるかを検証する。検証では次の 2 つの問いに答える。1 つ目は、平常時のわずかな需要から突発的なスパイクまでを含めた予測全体の精度が、従来手法と比べて実際に向上するののかという問いである。2 つ目は、GateRAF を支える 2 つの工夫、すなわち各ウィンドウを別々に符号化するマルチストリームエンコードと、関連の薄い参照を弱めるゲート機構が、それぞれ予測のどの側面を改善しているのかという問いである。

これらの問いに答えるため、時系列予測の基盤モデルに提案手法の構成要素の一つずつ加えていく比較を行う。比較するのは、過去の類似事例を一切参照しない基盤モデルそのものである Baseline、参照ウィンドウを入力系列にそのままつなぐ従来手法 ProtoRAF、Baseline にマルチストリームエンコードを加えた Multi-RAF、Multi-RAF にゲート機構を加えた提案手法 GateRAF の 4 手法である。

4.1 データ整形

本研究では書名ごとの需要推移を予測対象とするため、まず店舗間の差異を捨象し、同一の書名・日付に対する販売冊数を全店舗にわたって合算することで POS 販売冊数の時系列を構築した。その上で、予測対象として適した系列を得るために以下の前処理を施した。第一に、年間総販売冊数が 366 冊、すなわち一日あたり平均 1 冊に満たない書籍は販売実績が著しく予測に

このおぼろげでどんな実かんしているか
イメージいつくかな？
もうぐたい的にどんな実かん
しているのの示せろ(読み手か
イメージでまじ) こと意識しやう。

必要な情報量を欠くため除外した。第二に、巻数違い等の同一作品を作品シリーズ単位へ統合し、一つの需要系列として扱った。巻数の違いは販売管理上の区別にすぎず、需要の対象としては同一の作品とみなすべきと考えたためだ。第三に、販売記録の存在しない日を欠測ではなくゼロ需要とみなして補完し、全書名と全日付を網羅する完全パネルデータを構築した。以上の処理により、最終的に約 40 万件のデータを得た。

得られたデータでは、POS 販売冊数の平均が約 3.68 冊、標準偏差 13.65 冊と平均に対して分散が大きく、さらにゼロ販売日の割合が 42.9%に達する。このことは、平常時の間欠的なゼロ需要と突発的なスパイク需要が混在するという、本研究が対象とする需要構造を端的に表している。

4.2 実験条件

比較する Baseline, ProtoRAF, Multi-RAF, GateRAF の 4 手法は、いずれも膨大な時系列データであらかじめ学習された予測モデル、すなわち時系列予測の基盤モデルをファインチューニングして用いた。基盤モデルには Chronos [8]、具体的にはその軽量かつ高速な版である ChronosBolt を用いた。ファインチューニングには、モデル全体ではなく少数の追加パラメータだけを調整する DoRA [14] を使い、その追加パラメータの規模を定めるランクを 8 とした。

データは、各系列の末尾 $F = 64$ 日分を評価用に取り分け、残りを 9 対 1 の割合で学習用と検証用に分けた。予測では、対象とする系列の直近 $L = 128$ 日分を切り出してローカルコンテキストとし、これをもとに続く $F = 64$ 日分の販売冊数を予測する。参照ウィンドウは、1 回の予測ごとに、ローカルコンテキストと形の似たものを上位 $K = 3$ 件まで検索して用いる。

予測値は 1 つの値ではなく、分位点として出力する。分位点とは、予測を 1 つの値だけでなく幅をもって表すための水準である。たとえば 0.5 は中央の予測値を表し、0.1 と 0.9 はそれぞれ予測の下限と上限を表す。そして、上側の分位点と下側の分位点の差が予測の幅を表しており、この幅が広いほど将来の予測がしにくく、不確実性が高いことを意味する。本研究では 3 つの分位点 $\tau \in \{0.1, 0.5, 0.9\}$ を出力し、学習には、これら 3 つの分位点を同時に当てる行うピンボール損失 [15] を用いる。

提案手法の有効性を、以下の 5 つの実験で検証する。

実験 1) 予測精度の算出

実験 2) スパイク強度別の予測精度

実験 3) 時間近接性

実験 4) 予測区間幅の比較

実験 5) 書名別事例分析

実験 1 の予測精度の算出では、平常時の小さな値から突発的なスパイクまでを含めた、予測全体の精度を比較する。全系列と全予測期間を対象に、実績と予測の平均絶対誤差と二乗平均平方根誤差を分位点ごとに算出する。以下ではそれぞれを MAE, RMSE と記す。結果を表 1 に示す。

実験 2 のスパイク強度別の予測精度では、値が平常にとどまっているのか急増しているのかによる難しさの違いをとらえる。そのために、各系列について実績値からその系列の平均を引き、標準偏差で割ることで、平常時の水準からどれだけ離れているかを表す値へ変換する。以下ではこの値を z スコアと呼ぶ。この z スコアの大きさを時点を区分し、区分ごとに MAE と RMSE を集計する。結果を表 2 に示す。なお、 z スコアが -1 を下回る、値が平常を大きく下回って穏やかな時点を静穏域と呼ぶ。

実験 3 の時間近接性では、予測したスパイクと実際のスパイクがどれだけ近い時点に現れるかを調べる。スパイクの予測では、その正確な日付を当てることは難しいものの、スパイクの起こる時期をおおまかにでも示せれば意味があると考えられるためである。まず $\tau = 0.5$ の予測を対象に、評価データ内で z スコアが 2.0 以上となる時点をスパイクと定める。次に 2 種類の z を測る。予測ではスパイクとしたが近くに実際のスパイクがない場合を誤検知と呼び、予測したスパイクから最も近い実際のスパイクまでの日数 Δ を求める。実際にはスパイクが起きたのに近くで予測できていない場合を見逃しと呼び、実際のスパイクから最も近い予測したスパイクまでの日数 Δ を求める。表 3 に、誤検知は予測したスパイクの総数、見逃しは実際のスパイクの総数に占める Δ の度数を示す。 Δ が小さいほど時間的に近い位置で予測できていることを意味する。

実験 4 の予測区間幅の比較では、予測の幅が実際に値の跳ね上がる時点とどれだけ対応しているかを調べる。前述のとおり、高い分位点 $\tau = 0.9$ と低い分位点 $\tau = 0.1$ の予測値の差は、その時点で見込んだ値のばらつきの幅を表す。以下では、この幅を予測区間の幅と呼ぶ。全時点を予測区間の幅の順に並べて 10 個のグループに分け、グループごとに実績の z スコアの平均を求める。幅が広いグループほど z スコアの平均も大きい右上がりの関係であれば、モデルは値が急増する時点でこそ幅を広げており、不確実性を実際の値

の変動に合わせてられていることになる。結果を図 3 に示す。

実験 5 の書名別事例分析では、各モデルが個々のスパイクにどう反応するかを調べる。これまでの指標は平均的な精度を表すものであり、個々のスパイクへの反応までは分からないためである。そこで、スパイクの現れ方が異なる代表的な 2 つの系列を取り上げ、 $\tau = 0.5$ の予測値の時系列を実績と重ねて比較する。その様子を図 4 に示す。図中では、黒の実線が実績、赤の実線が GateRAF、青の破線が Multi-RAF、緑の点線が ProtoRAF、橙の一点鎖線が Baseline の予測を表す。

4.3 実験結果と考察

4.3.1 実験 1：予測精度の算出

表 1 が示すように、全体として提案手法 GateRAF は多くの指標で最も誤差が小さく、とくに中央 ($\tau = 0.5$) と上側 ($\tau = 0.9$) で従来手法を上回った。ProtoRAF は Baseline とほぼ同じ誤差にとどまり、 $\tau = 0.5$ の MAE はともに 3.05、 $\tau = 0.9$ の RMSE はともに 27.0 程度であった。Multi-RAF では誤差が大きく下がり、 $\tau = 0.5$ の MAE は 3.05 から 2.81 へ、 $\tau = 0.9$ の MAE は 6.85 から 4.97 へ、RMSE は 27.02 から 13.36 へ改善した一方で、下側 ($\tau = 0.1$) の MAE は 3.66 から 3.78 へわずかに悪化した。GateRAF では低い分位点を中心に誤差が下がり、 $\tau = 0.1$ の MAE は 3.78 から 3.63 へ、 $\tau = 0.5$ は 2.81 から 2.75 へ改善したのに対し、 $\tau = 0.9$ の MAE は 4.97 から 5.01 とほぼ同水準であった。

ProtoRAF の誤差が Baseline とほぼ変わらないことは参照ウィンドウを単純に連結するだけでは予測が改善しないことを示している。誤差の低下は、各参照ウィンドウを独立に符号化する Multi-RAF を導入してはじめて生じる。また、Multi-RAF による改善は中央から上側の分位点に集中している。これは改善が標準化の基準のずれの解消によることを示唆する。ProtoRAF は標準化の平均と標準偏差を参照ウィンドウまで含めて計算するため、大きなスパイクを含む参照が混じるとローカルコンテキストが過大なるケールで標準化され、上側分位点が上振れしていたとみられる。

ローカルコンテキストを単独で標準化する Multi-RAF では、このずれが生じにくい。一方、~~手側の~~ $\tau = 0.1$ では Multi-RAF はわずかに悪化している。マルチストリームエンコードは標準化の基準のずれを正すのみで、無関係な参照ウィンドウの混入には対処しないため、この問題が下側分位点に残る。低い需要を見積も

る $\tau = 0.1$ では、混入した無関係な参照が予測を押し上げて誤差となる。ゲート機構を加えた GateRAF はこれらの参照を関連度に応じて弱めるため、 $\tau = 0.1$ の誤差が改善する。このようにマルチストリームエンコードとゲート機構は、異なる分位点の誤差を下げることで精度に寄与している。

4.3.2 実験 2：スパイク強度別の予測精度

表 2 が示すように、静穏域では、 $\tau = 0.5$ の MAE と $\tau = 0.9$ の RMSE が ProtoRAF から Multi-RAF への段階で大きく下がる。 $\tau = 0.5$ の MAE は ProtoRAF の 2.66 から Multi-RAF の 1.94、GateRAF の 1.84 へと下がり、GateRAF が全モデル中で最も小さい。 $\tau = 0.9$ の RMSE も ProtoRAF の 29.11 から Multi-RAF の 9.64 へ大きく下がり、GateRAF も 9.70 とほぼ同水準である。なお、ProtoRAF のこの突出は静穏域に限られ、 z スコアが 1 を超える帯では 11.83 まで縮んで他モデルとの差はほぼ消える。これに対し $\tau = 0.1$ の MAE は、Multi-RAF の 1.03 から GateRAF の 0.85 へと、ゲート機構を加えた段階で下がった。一方、 z スコアが 2 を上回る帯でも、 $\tau = 0.5$ の MAE は GateRAF が全モデル中で最も小さい。 z スコアが 2 から 3 の帯では Baseline の 12.41 から 11.28 へ、3 を超える帯では 26.25 から 24.76 へと下がっている。

GateRAF の改善は静穏域で特に大きく現れる。マルチストリームエンコードは上側分位点の過大予測をこの帯で大きく抑え、ゲート機構は下側分位点の誤差をこの帯で下げる。前項で述べたように、両機構はいずれも平常時の過大な予測を正すものであり、その効果が静穏域に強く出たためと考えられる。こうしたスパイクへの反応の抑制は突発的な需要の見逃しを招くおそれがあるが、 z スコアが大きいスパイク帯でも GateRAF の MAE は全モデル中で最も小さく、改善がみられる。したがって、提案手法は平常時の過大な予測を抑えつつ、突発的なスパイクの捕捉も両立できていると考えられる。

4.3.3 実験 3：時間近接性

表 3 について、まず誤検知について述べる。近くにある実際のスパイクが見当たらないノイズ的な誤り、すなわち $|\Delta| \geq 10$ の割合は、ProtoRAF が 59.1%、Multi-RAF が 48.9%、GateRAF が 49.6% である。ProtoRAF のこの誤りは $\Delta = -10$ 側に 54.4% と偏っており、Multi-RAF では 28.9% へ下がる。 Δ が 3 日以内の誤検知は、ProtoRAF が 20.4%、GateRAF が 26.1% である。次に見逃しについて述べる。 $|\Delta| \geq 10$

表 1 各モデルおよび分位点レベルにおける MAE および RMSE の比較

モデル	分位点					
	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE
GateRAF	3.6339	13.5293	2.7452	12.2025	5.0136	13.3030
Multi-RAF	3.7766	13.6118	2.8117	12.2594	4.9745	13.3570
ProtoRAF	3.6604	13.7593	3.0467	12.9622	6.8549	27.0196
Baseline	3.6501	13.7476	3.0460	12.9603	6.8512	27.0050

表 2 系列内 z スコアビン別の MAE および RMSE

モデル	<-1		-1-0		0-0.5		0.5-1		1-1.5		1.5-2		2-3		>3	
	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE	MAE	RMSE
$\tau = 0.1$																
GateRAF	0.85	2.88	1.57	4.57	4.65	9.48	5.98	11.86	7.18	15.81	8.42	17.66	14.72	39.32	28.08	63.94
Multi-RAF	1.03	3.01	1.71	4.67	4.77	9.56	6.15	12.00	7.36	15.92	8.59	17.80	14.84	39.68	28.24	63.94
ProtoRAF	0.89	3.09	1.47	4.39	4.77	9.79	6.20	12.22	7.51	16.47	8.79	18.36	15.45	40.54	28.58	64.37
Baseline	0.89	3.08	1.46	4.38	4.76	9.77	6.19	12.21	7.50	16.45	8.78	18.35	15.44	40.51	28.56	64.35
$\tau = 0.5$																
GateRAF	1.84	3.15	1.21	3.78	2.96	7.32	3.92	9.90	4.94	13.12	6.05	14.98	11.28	35.30	24.76	61.12
Multi-RAF	1.94	3.23	1.26	3.77	3.01	7.29	4.03	9.95	5.07	13.14	6.19	15.17	11.47	35.98	24.84	61.00
ProtoRAF	2.66	6.21	1.40	5.13	3.14	8.22	4.22	10.73	5.39	13.82	6.50	15.74	12.42	36.57	26.26	62.31
Baseline	2.66	6.21	1.40	5.14	3.13	8.22	4.22	10.73	5.39	13.82	6.50	15.75	12.41	36.55	26.25	62.29
$\tau = 0.9$																
GateRAF	6.19	9.70	4.52	9.50	4.47	8.98	4.74	10.04	4.56	10.64	4.89	12.42	8.39	30.16	18.81	55.93
Multi-RAF	6.27	9.64	4.46	9.43	4.41	8.92	4.73	10.18	4.51	10.65	4.88	12.59	8.57	31.39	18.73	55.86
ProtoRAF	9.48	29.11	6.57	27.12	6.33	24.03	5.75	25.13	4.79	11.83	5.39	15.07	9.56	33.12	20.74	58.00
Baseline	9.49	29.17	6.56	27.09	6.33	24.02	5.75	25.16	4.80	11.83	5.39	15.08	9.56	33.15	20.72	57.99

相対的に変化量は小さく、

ものの割合は、ProtoRAF が 54.1%，Multi-RAF が 52.7%，GateRAF が 41.4% である。△ が 3 日以内の見逃しは、ProtoRAF が 18.8%，GateRAF が 30.2% である。

誤検知が実際のスパイクから離れて出るのは、予測を高く出すぎているためと見れる。ProtoRAF はスパイクが過ぎ去った後も高い予測を出し続けるため、スパイクから離れた時点で誤検知しており、表でも $\Delta = -10$ 側に偏っている。過大な予測を抑える Multi-RAF では、高い予測がスパイクの近くだけに限られ、誤検知も実際のスパイクの近くに集まる。見逃しが予測スパイクから離れて生じるのは、スパイクの近くで予測を高くできていないためである。ProtoRAF や Multi-RAF はスパイクの近くで予測を高くできず、近くに予測の山がないまま見逃している。スパイクの近くで予測を高くできる GateRAF では、たとえ見逃しても近くに予測の山を伴い、表でも △ の小さい側に多い。GateRAF の誤りは、スパイクと関係のない時点で突然生じるのではなく、実際のスパイクから数日のずれに収まるものが多い。スパイクの正確な日付を当てるのが難しい突発需要の予測では、需要に備えるべき時期をおおまかにでも示せることに意味があると考えられる。

4.3.4 実験 4：予測区間幅の比較

図 3 が示すように、GateRAF と Multi-RAF では予測区間の幅が広がるにつれて z スコアの平均が -0.34 から $+0.32$ へと一貫して上昇しており、広い予測区間が実際のスパイク発生時点に集中していることがわか

る。一方、ProtoRAF では -0.06 から $+0.14$ までとほとんど変化せず、予測区間の幅が実需の変動とほとんど連動していない。

以上の結果は、予測区間の幅が単なる出力のばらつきではなく、需要が変動しやすい時点を示す手がかかりとして機能していることを示唆する。この傾向は GateRAF と Multi-RAF ではほぼ一致しており、当該の連動は主にマルチストリームエンコードによるスケールの安定化に起因すると考えられる。すなわち、標準化の基準を正したことで、系列の連結による歪みで頭打ちとなっていた上側分位点、実際の需要変動に応答できる状態へ回復したものと解釈できる。まれで予測の難しいスパイクを対象とする本研究において、不確実性を区間の幅として表現できることは、スパイクの到来を事前に示す手がかかりとして意義をもつ。

4.3.5 実験 5：書名別事例分析

書籍 A この系列は、予測期間の冒頭で実績が急増し、系列内 z スコアが最大 3.6 に達したのち、急速に減衰するパターンを示す。図 4(a) を見ると、GateRAF はこの減衰にほぼ沿って予測を下げ、MAE は 2.39 にとどまった。一方 ProtoRAF と Baseline は、実績が下がっても高い予測を維持し続け、MAE は 7.81 と大きい。これは、ProtoRAF が連結系列全体から標準化を行うに予測のスケールが高止まりし、需要が落ち着いたあとも過大な予測から抜け出せないことを表していると考えられる。標準化の基準をローカルコンテクス

〜〜 :
言葉で
修正はウ。
(0.1, 0.5, 0.9)
33)

paragraph はつかひはい!!! いまより
書籍 A とかから
入らはい。
ちゃんと
リード文を
つくこと。

スノース

表 3 Δ 日ごとの誤検知および見逃しの割合

モデル	-10	-9	-8	-7	-6	-5	-4	-3	-2	-1	0	+1	+2	+3	+4	+5	+6	+7	+8	+9	+10
誤検知																					
GateRAF	0.289	0.012	0.014	0.033	0.014	0.018	0.020	0.025	0.041	0.078	0.000	0.055	0.031	0.031	0.031	0.025	0.016	0.027	0.014	0.018	0.207
Multi-RAF	0.350	0.018	0.020	0.045	0.011	0.014	0.016	0.030	0.041	0.070	0.000	0.057	0.032	0.027	0.030	0.020	0.020	0.030	0.014	0.016	0.139
ProtoRAF	0.544	0.021	0.024	0.029	0.024	0.024	0.022	0.025	0.028	0.050	0.000	0.044	0.029	0.028	0.015	0.012	0.012	0.010	0.006	0.007	0.047
Baseline	0.543	0.021	0.024	0.030	0.025	0.025	0.022	0.025	0.028	0.050	0.000	0.043	0.028	0.028	0.015	0.012	0.010	0.010	0.006	0.007	0.047
見逃し																					
GateRAF	0.179	0.000	0.006	0.043	0.000	0.025	0.012	0.043	0.043	0.086	0.000	0.068	0.037	0.025	0.037	0.037	0.012	0.093	0.019	0.000	0.235
Multi-RAF	0.191	0.013	0.007	0.046	0.007	0.000	0.000	0.033	0.033	0.072	0.000	0.072	0.026	0.020	0.026	0.007	0.013	0.066	0.013	0.020	0.336
ProtoRAF	0.319	0.000	0.007	0.042	0.014	0.021	0.014	0.007	0.007	0.035	0.000	0.062	0.042	0.035	0.021	0.021	0.035	0.069	0.014	0.014	0.222
Baseline	0.326	0.000	0.007	0.043	0.014	0.021	0.014	0.007	0.007	0.035	0.000	0.057	0.043	0.035	0.021	0.021	0.028	0.071	0.014	0.014	0.220




図 3 予測区間の幅ごとの実績 z スコア平均

トだけから取る GateRAF は、この高止まりを避けられている。

書籍 B この系列は、予測期間の中盤にあたる 20 日目前後で実績が急増し、系列内 z スコアが最大 5.8 に達するパターンを示す。図 4(b) より、GateRAF と Multi-RAF はこの急増に合わせて予測を立ち上げており、MAE はそれぞれ 1.59, 1.88 である。対して ProtoRAF と Baseline は予測値がほぼゼロのまま動かず、スパイクをまったく捉えられなかった。ProtoRAF の MAE は 2.96 である。Multi-RAF の段階ですでに検出できていることから、このスパイクの予兆は、参照ウィンドウを個別に符号化して取り込むマルチストリームエンコードによって引き出されていると解釈できる。参照を持たない Baseline はもとより、参照を単純に連結するだけの ProtoRAF でも、取得した類似事例のスパイクが予測に現れていない。

以上の 2 例は、いずれもマルチストリームエンコードの働きを端的に表している。すなわち、標準化の基準をローカルコンテキストに限ることで過大な予測の高止まりを防ぎ、参照ウィンドウを個別に取り込むことで他系列のスパイクを予測に反映させる、という 2 つの働きである。これらの例で GateRAF と Multi-RAF の挙動がほぼ重なることは、スパイクへの追従そのものが主にマルチストリームエンコードによって実現さ

れていることを裏づけており、ゲート機構の寄与は、全体指標で見たとおり平常時の予測の調整という別の側面に現れると考えられる。

5. おわりに


本研究では、突発的なスパイク需要の予測を目的に、ゲート付き融合型 RAF である GateRAF を提案した。GateRAF は、従来の RAF がもつ接合部の不連続性と無関係な参照の混入という 2 つの問題を、マルチストリームエンコードとゲート機構によって解消する。実験の結果、GateRAF は全体の予測精度で ProtoRAF と Baseline を上回り、2 つの機構が予測の異なる側面を改善することを確認した。

今後の課題は 3 点である。第一に、参照の検索が波形の形状の類似のみに基づく点であり、形状以外の観点も取り入れた類似尺度を検討したい。第二に、ゲート機構が各参照に強弱をつけるにとどまる点であり、参照を組み合わせで新たな表現を作る統合も考えられる。第三に、ゲート機構の調整に学習を要する点であり、追加学習なしで使えるゼロショット化も有望である。


謝辞 貴重なデータを提供していただいた XXX 社名入りたい XXX を始め、データ解析コンペティション関係者の皆様にお礼申し上げます。

参考文献

- [1] 日本書籍出版協会、「再販制度」, <https://www.jbpa.or.jp/resale/>, 2001.
- [2] 全国出版協会・出版科学研究所、『出版指標年報 2024 年版』, 全国出版協会, 2024.
- [3] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-T. Yih, T. Rocktäschel, S. Riedel and D. Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” in *Advances in Neural Information Processing Systems*, vol. 33, pp. 9459–9474, 2020.
- [4] K. Tire, E. O. Taga, M. E. Ildiz and S. Oymak, “Retrieval Augmented Time Series Forecasting,” arXiv:2411.08249, 2024.
- [5] Y. Nie, N. H. Nguyen, P. Sinthong and J. Kalagnanam, “A Time Series is Worth 64 Words: Long-term Forecasting with Transformers,” in *Pro-*



(a) 書籍 A



(b) 書籍 B

図 4 各系列における予測と実績の比較

- ceedings of the International Conference on Learning Representations, 2023.
- [6] D. Salinas, V. Flunkert, J. Gasthaus and T. Januschowski, “DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks,” *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020.
- [7] B. Lim, S. Ö. Arik, N. Loeff and T. Pfister, “Temporal Fusion Transformers for Interpretable Multi-Horizon Time Series Forecasting,” *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021.
- [8] A. F. Ansari, L. Stella, C. Turkmen, X. Zhang, P. Mercado, H. Shen, O. Shchur, S. S. Rangapuram, S. P. Arango, S. Kapoor, J. Zschiegner, D. C. Maddix, H. Wang, M. W. Mahoney, K. Torkkola, A. G. Wilson, M. Bohlke-Schneider and Y. Wang, “Chronos: Learning the Language of Time Series,” arXiv:2403.07815, 2024.
- [9] J. D. Croston, “Forecasting and Stock Control for Intermittent Demands,” *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972.
- [10] K. Ning, Z. Pan, Y. Liu, Y. Jiang, J. Y. Zhang, K. Rasul, A. Schneider, L. Ma, Y. Nevmyvaka and D. Song, “TS-RAG: Retrieval-Augmented Generation based Time Series Foundation Models are Stronger Zero-Shot Forecaster,” arXiv:2503.07649, 2025.
- [11] H. Zhang, C. Xu, Y.-F. Zhang, Z. Zhang, L. Wang, J. Bian and T. Tan, “TimeRAF: Retrieval-Augmented Foundation Model for Zero-Shot Time Series Forecasting,” arXiv:2412.20810, 2024.
- [12] J. Johnson, M. Douze and H. Jégou, “Billion-Scale Similarity Search with GPUs,” *IEEE Transactions on Big Data*, vol. 7, no. 3, pp. 535–547, 2019.
- [13] T. Kim, J. Kim, Y. Tae, C. Park, J.-H. Choi and J. Choo, “Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift,” in *Proceedings of the International Conference on Learning Representations*, 2022.
- [14] S.-Y. Liu, C.-Y. Wang, H. Yin, P. Molchanov, Y.-C. F. Wang, K.-T. Cheng and M.-H. Chen, “DoRA: Weight-Decomposed Low-Rank Adaptation,” in *Proceedings of the International Conference on Machine Learning*, 2024.
- [15] R. Koenker and G. W. Bassett, “Regression Quantiles,” *Econometrica*, vol. 46, no. 1, pp. 33–50, 1978.