

事例研究 [論文]

最適モデル多分木による価格需要曲線の推定

菊池 明飛, 伊熊 大貴, 板山 咲穂, 上原 祐輝, 武井 柊悟, 竹内 崇貴,
深谷 悠人, 柳 智也, 椎名 萌, 守屋 恵瑠萌, 池田 春之介, 高野 祐一

1. はじめに

多くの企業にとって、販売商品の価格と需要の関係を理解することは有益である。価格と需要の関係を理解することで、売上や利益を最大化するための商品価格の決定、ブランド形成のための商品特性の理解、特売品の販売促進による集客施策などに活用できる。価格と需要の定量的な関係を示す価格需要曲線の推定は、特に商品価格の設定において重要である [1-3]。

価格需要曲線の形状として、線形、積乗型、魅力型、ゲーテンベルク型などのさまざまな関数利用されるが、価格と需要の真の関係を探索するためには形状を制約しない表現力の高いモデルが必要となる [1]。商品需要の予測では、回帰スプライン、サポートベクトル回帰、ニューラルネットワークなどの非線形回帰モデルが利用されている [4]。価格最適化における需要予測では、線形回帰が利用されることが多いが [5-8]、近年は決定木に基づく手法も利用されている [9, 10]。

ニューラルネットワークなどのブラックボックス型の機械学習モデルは高い表現力をもつが、一方で予測結果の解釈性が低く、差別や信頼性などの問題を生じる可能性が指摘されている [11]。特にリスクの大きな意思決定では、ブラックボックス型の機械学習モデルではなく、解釈可能な機械学習モデルを利用することが推奨されている [12]。

解釈性を保ちつつ表現力にも優れた回帰手法として、決定木分析が広く用いられている [13]。代表的な回帰手法として、各葉ノードの平均値を予測値とする CART

(Classification and Regression Tree)[14] や、各葉ノードで任意の回帰モデルを推定するモデル木 [15] が提案されている。また、最近の研究では、すべての分岐と回帰モデルを同時に最適化する最適決定木も提案されている [16]。一方で、これらの手法は二分木に基づくため、同じ分岐特徴量が繰り返し利用されるような深い木が作成される可能性があり、結果として解釈性が損なわれる。

この問題に対処するため、一つの分枝ノードから複数のノードへの分岐が可能な多分木を、整数最適化技術を利用して最適化する手法が提案されており、最適多分木と呼ばれている [17]。この最適多分木は、多くの分類問題に対して二分木に基づく手法よりも高い予測精度を示しており、回帰問題への拡張も可能である。

本研究では、経営科学系研究部会連合協議会主催の令和 5 年度データ解析コンペティションで提供された飲料の購買データを利用する。このデータに対して、多分木を用いて解釈性の高い価格需要曲線を推定することを目標とする。本研究では、最適多分木 [17] をモデル木に拡張した最適モデル多分木を利用し、さらに最適化問題の規模を縮小して計算を高速化する方法を提案する。

本論文の 2 節では、本研究で分析するデータについて説明する。提供データの概要と実施した前処理の内容を説明し、商品名の分散表現に基づく商品クラスタを独自に作成する。

本論文の 3 節では、最適モデル多分木を用いた価格需要曲線の推定手法を説明する。多分木の構築に用いる特徴グラフを導入し、多分木を最適化する問題を基数制約付き集合分割問題として定式化する。さらに、最適化問題の制約式と決定変数を削減し、最適化計算を効率化する方法を提示する。

本論文の 4 節では、提案手法の推定精度と計算時間を既存手法と比較し、その有効性を実証する。また、推定された価格需要曲線について考察し、モデル木との差異も検証する。

きくち はるか, いくま だいき, いたやま さほ,
うへはら ゆうき, たけい しゅうご, たけうち しゅうき,
ふかや ゆうと, やなぎ ともや, しいな もえ,
もりや えりも, いけだ しゅんのすけ
筑波大学大学院システム情報工学研究群
〒 305-8573 茨城県つくば市天王台 1-1-1
たかの ゆういち
筑波大学システム情報系
〒 305-8573 茨城県つくば市天王台 1-1-1
受付 24.6.29 採択 24.10.16

2. 分析データ

本節では、提供データの概要と分析データの作成について説明する。

2.1 提供データの概要

本研究では、経営科学系研究部会連合協議会が主催する令和5年度データ解析コンペティションにおいて、日本経済新聞社から提供されたデータ（日経POSデータ）を利用した。このデータには、2013年7月から2022年6月までの10年間にわたるスーパーマーケットでの飲料製品の週次販売履歴が記録されている。

各レコードには、首都圏・近畿・全国の3地域における週ごとのSKU (Stock Keeping Unit) の集計結果が記録されており、全体では約1,800万のレコードが存在する。本研究では以下のデータ項目を使用した。

- 販売地域：首都圏，近畿，全国
- 商品大分類：コーヒー飲料，野菜ジュースなど
- 商品小分類：ペットボトル入りコーヒー飲料，缶コーヒー飲料など
- 商品名：メーカー・容器・容量の情報を含む名称
- 対象店舗数：当該商品を販売する店舗の数
- 販売容量：当該商品の各週の販売量の合計値 [mL]
- 販売金額：当該商品の各週の販売金額の合計値
- 日付：当該商品が販売された年，月，週

本研究では、販売地域「首都圏」の大分類「コーヒー飲料」「野菜ジュース」「果汁100%飲料」を分析対象とした。

2.2 前処理

価格需要曲線の推定では、

$$\text{mL 価格} := \frac{\text{販売金額}}{\text{販売容量}}$$

によって1mLあたりの価格を算出し、価格は以下のように各商品の最頻値で正規化した値とした。

$$\text{価格} := \frac{\text{mL 価格}}{\text{各商品の mL 価格の最頻値}} \quad (1)$$

需要は以下のように1店舗あたりの販売容量を算出し、商品ごとに標準化して数値の規模を調整した。

$$\text{需要} := \frac{\text{販売容量}}{\text{対象店舗数}} \quad (\text{商品ごとに標準化}) \quad (2)$$

また、販売の月，季節，容器，容量に関するカテゴリ特徴量を以下のように作成した。

- 月：1月，2月，…，12月
- 季節：春（3～5月），夏（6～8月），秋（9～11月），冬（12～2月）

表1 商品クラスターの番号と名称

番号	名称
1	G ブランドコーヒー
2	紙パックアイスコーヒー
3	中容量ブラックコーヒー
4	「プレミアム」コーヒー
5	ペットボトルカフェオレ
6	ボトル缶ラテ
7	U 社缶コーヒー
8	U 社 900 mL コーヒー
9	缶 185 g コーヒー
10	缶コーヒー
11	紙パック 1 L コーヒー
12	野菜+果汁ジュース
13	「1 日分」野菜ジュース
14	トマトジュース
15	T ブランドジュース
16	紙パック 1 L ジュース
17	フルーツ果汁 100%ジュース
18	紙パック 100%ジュース
19	W ブランドジュース
20	その他

- 容器：缶，瓶，ペットボトル，その他（紙パック，パウチなど）
- 容量：0.4 L 未満，0.4 L 以上～0.6 L 未満，0.6 L 以上～1 L 未満，1 L 以上～2 L 未満，2 L 以上，その他（粉末など）

2.3 商品クラスターの作成

提供データでは、商品の大部分類や小分類と比較して多数の詳細な商品名が存在し、これらの情報を利用することで精度の向上が期待できる。一方で、商品名を分岐に使用すると分岐後の各葉ノードにおける事例数が少なくなり、回帰モデルの推定精度が低下する可能性がある。そこで本研究では、商品名の分散表現を用いてクラスター分析を実行し、小分類よりも詳細な商品カテゴリを独自に作成した。

提供データの商品名を fastText モデル [18] に入力して 100 次元の分散表現（数値ベクトル）に変換し、得られた分散表現に K 平均法を適用して商品クラスターを作成した。複数のクラスター数で結果を確認し、クラスターの解釈性を考慮してクラスター数は 20 に設定した。また、帰属する商品名から各クラスターに名称を付与した（表 1）。

商品名にはメーカー・容器・容量などの情報が含まれているため、表 1 からそれらに基づくクラスターが作成されていることがわかる。




図 1 特徴グラフの例




図 2 図 1 の太線のパスから得られる多分木

3. 最適モデル多分木

本節では、モデル多分木の最適化問題の定式化と、その計算を高速化する方法について説明する。

3.1 特徴グラフ

多分木の構築では、図 1 に示すような特徴グラフを利用する。図 1 では、3 種類の特徴量（季節、大分類、容器）に対して、各特徴量のカテゴリがノードとして表現されている。また、 $S_{\text{特徴量}}$ はその特徴量を分岐に利用しないことを表す Skip ノードである。特徴グラフでは、隣り合う特徴量間で全ノードの組合せに有向エッジがつながれている。この特徴グラフ上で、Source ノード（始点）から Sink ノード（終点）へのすべてのパスの集合を $\mathcal{P}$ とする。

特徴グラフからパスの部分集合を選択することで、多分木が構築できる。たとえば、図 1 の太線のパス

- Source $\rightarrow$ 春 $\rightarrow$ $S_{\text{大分類}}$ $\rightarrow$ $S_{\text{容器}}$ $\rightarrow$ Sink
- Source $\rightarrow$ 夏 $\rightarrow$ コーヒー $\rightarrow$ $S_{\text{容器}}$ $\rightarrow$ Sink
- Source $\rightarrow$ 夏 $\rightarrow$ 野菜 $\rightarrow$ $S_{\text{容器}}$ $\rightarrow$ Sink
- Source $\rightarrow$ 夏 $\rightarrow$ 果汁 $\rightarrow$ $S_{\text{容器}}$ $\rightarrow$ Sink
- Source $\rightarrow$ 秋 $\rightarrow$ $S_{\text{大分類}}$ $\rightarrow$ $S_{\text{容器}}$ $\rightarrow$ Sink
- Source $\rightarrow$ 冬 $\rightarrow$ $S_{\text{大分類}}$ $\rightarrow$ $S_{\text{容器}}$ $\rightarrow$ Sink

を選択すると、図 2 の多分木が得られる。

3.2 定式化

本研究では、文献 [17] で提案された最適多分木の定式化を、モデル木に拡張して利用する。

データセットに含まれる全事例（レコード）の集合を $\mathcal{I}$ とし、事例 $i \in \mathcal{I}$ が特徴グラフのパス $p \in \mathcal{P}$ に該当するとき 1、そうでないとき 0 をとる定数を a_{ip} とする。また、パス $p \in \mathcal{P}$ に該当する事例集合を $\mathcal{I}_p \subseteq \mathcal{I}$ とし、式 (1) の価格を説明変数、式 (2) の需要を目的変数とした場合の事例集合 $\mathcal{I}_p$ に対する回帰の残差二乗和を ξ_p とする。

パス $p \in \mathcal{P}$ を選択するとき 1、そうでないとき 0 をとる決定変数を z_p とし、 $\mathbf{z} := (z_p)_{p \in \mathcal{P}}$ と定義する。選択するパスの上限数を表すパラメータを γ とするとき、モデル多分木を最適化する問題は、以下のように基数制約付き集合分割問題として定式化できる。

$$\underset{\mathbf{z}}{\text{minimize}} \quad \sum_{p \in \mathcal{P}} \xi_p z_p, \quad (3)$$

$$\text{subject to} \quad \sum_{p \in \mathcal{P}} a_{ip} z_p = 1 \quad (\forall i \in \mathcal{I}), \quad (4)$$

$$\sum_{p \in \mathcal{P}} z_p \leq \gamma, \quad (5)$$

$$\mathbf{z} \in \{0, 1\}^{|\mathcal{P}|}. \quad (6)$$

式 (3) の目的関数は選択したパスにおける残差二乗和の合計を表す。式 (4) はすべての事例が選択されたパスの一つに該当することを表し、式 (5) は選択するパスの上限数制約、式 (6) は決定変数 $\mathbf{z}$ の 0-1 制約である。

3.3 問題規模の縮小

最適化問題 (3)–(6) の制約式と決定変数は以下のように削減し、計算を効率化することができる。

まず、図 1 の特徴グラフを用いて、制約式 (4) の本数を削減する方法を説明する。Skip ノードを含まないパス

- $p: \text{Source} \rightarrow \text{春} \rightarrow \text{コーヒー} \rightarrow \text{缶} \rightarrow \text{Sink}$

を考える。このパスに該当する事例の集合 $\mathcal{I}_p$ をさらに細かく分割するパスは存在しないため、これらの事例はまとめて扱うことができ、集合 $\mathcal{I}_p$ に対応する複数の制約式 (4) は 1 本に集約することができる。

同様に図 1 の特徴グラフを用いて、決定変数 $\mathbf{z}$ を削減する方法を説明する。上記のパス p に加えて、以下のパスを考える。

- $q_1: \text{Source} \rightarrow \text{春} \rightarrow \text{コーヒー} \rightarrow \text{ペットボトル} \rightarrow \text{Sink}$
- $q_2: \text{Source} \rightarrow \text{春} \rightarrow \text{コーヒー} \rightarrow \text{その他} \rightarrow \text{Sink}$
- $q_3: \text{Source} \rightarrow \text{春} \rightarrow \text{コーヒー} \rightarrow S_{\text{容器}} \rightarrow \text{Sink}$

このとき、対象となる商品が販売されていないなどの理由から、パス q_1, q_2 に該当する事例が存在しないと仮定する。このとき、パス p とパス q_3 に該当する事例集合は一致する。したがって、パス q_1, q_2 は削除し、パス p, q_3 は一つのパスに集約することができ、決定変数 z を削減することができる。

4. 数値実験

本節では数値実験の結果を報告し、提案手法の有効性を検証する。

4.1 実験設定

価格需要曲線の推定では、式 (1) で定義した価格を説明変数、式 (2) で定義した需要を目的変数として用いた。多分木の分岐特微量として、大分類（コーヒー飲料、野菜ジュース、果汁 100% 飲料）、小分類（13 種類）、商品クラス（表 1）、商品名（230 種類）、月、季節、容器、容量を用いた（詳細は 2 節）。商品は 1 年以上継続して毎週 100 個以上の販売履歴がある商品を抽出した。抽出後の事例数は 56,496 件であり、そのうち 39,547 件（70%）を訓練データ、16,949 件（30%）をテストデータにランダムに分割した。

数値実験では以下の手法の性能を比較する。

- **提案手法**：最適モデル多分木（最適化問題 (3)–(6)）
- **提案手法（商品クラス無）**：商品クラスを分岐特微量から除外した場合の最適モデル多分木（最適化問題 (3)–(6)）
- **モデル木**：モデル木 [15]（葉ノードの回帰モデルで予測する二分木）
- **CART**：回帰木 [14]（葉ノードに該当する事例の目的変数の平均値で予測する二分木）
- **商品別回帰**：商品名（230 種類）ごとに回帰

CART 以外の手法では、回帰モデルとして K 近傍法（近傍サイズ： $K = 20$ ）を用いた。

実験には Apple M1 Pro（10 スレッド、3.2 GHz）、16 GB メモリを搭載した MacBook を用いた。最適化問題 (3)–(6) の求解には Gurobi Optimizer¹ 11.0.0 を用いた。モデル木は GitHub で公開されている Python 言語のプログラム² を改変して実装した。CART と K 近傍法は Python 言語の scikit-learn ライブラリを用いて実行した。

決定木の各葉ノードの最小事例数は 100 と設定し、木の深さの上限値は 1, 2, 4, 6, 8, 10 とした。ただし、分岐特微量は 8 種類であるため提案手法の木の深

表 2 問題規模縮小の前後の事例数、パス数、計算時間（秒）

木の深さ の上限値	縮小前 (事例数：39,547)		縮小後 (事例数：2,261)	
	パス数	計算時間	パス数	計算時間
1	214	18.6	214	20.3
2	1,761	33.8	853	21.2
4	11,392	214.5	1,813	56.2
6	16,197	348.6	1,813	75.3
8	16,353	355.5	1,813	78.0

さの最大値は 8 であるが、二分木に基づく他の手法ではより深い木を作成することが可能である。提案手法において選択するパスの上限数は $\gamma = 600$ とした。

価格需要曲線の推定精度の評価指標として、テストデータに対する予測値と実測値の二乗平均平方根誤差 (RMSE: Root Mean Square Error) と相関係数を用いる。

4.2 各手法の性能比較

まず、3.3 節で説明した問題規模縮小の効果を検証する。問題規模縮小の前後の木の深さに対する事例数、パス数、計算時間（秒）の結果を表 2 に示す。事例数は木の深さに依存せず、縮小前と比較して縮小後の事例数は 94% 程度減少した。パス数と計算時間の削減割合は木が深くなるにつれて大きくなり、木の深さが 8 の場合には計算時間は縮小前の 78% 程度減少した。

図 3 に各手法の RMSE、図 4 に各手法の相関係数の結果を示す。提案手法はすべての木の深さで最も推定精度が優れている。特に、木を深くせずに高い推定精度を達成していることから、高い解釈性も実現している。商品クラスを分岐特微量から除外した場合には推定精度が低下しており、商品クラスの分岐特微量としての有用性が示唆される。商品別回帰と比較すると、提案手法は多分木に基づいて適切に商品を集約することで高精度の価格需要曲線を推定することができ、実際に木の深さが 4 以上の場合に RMSE を約 16% 減少させ、相関係数を 2 倍程度まで増加させている。このように、最適モデル多分木は高い解釈性と推定精度の両立を実現している。

図 5 に各手法の計算時間の結果を示す。提案手法は CART や商品別回帰と比較すると計算に時間がかかるが、モデル木より高速に計算することができ、木の深さが 8 の場合でも計算時間は 100 秒程度であった。

4.3 価格需要曲線の推定結果

木の深さが 3 の場合に得られた最適モデル多分木の一部を図 6 に示す。容量・季節・月・商品クラスに

¹ <https://www.gurobi.com/>

² <https://github.com/ankonzoid/LearningX>




図 3 木の深さに対する RMSE




図 5 木の深さに対する計算時間 (秒)




図 4 木の深さに対する相関係数

よって商品が分岐されており、二分木では実現できない複数ノードへの分岐が含まれる。

図 6 の太線のパスに対する価格需要曲線の推定結果を図 7 に示す。図 7 の各図の点はパスに該当する訓練データの事例であり、実線は得られた価格需要曲線を表す。図 7(b)–(d) では比較のために図 7(a) の価格需要曲線を破線で表示している。以降では図 7(a) の「季節：夏，容量：0.4 L 未満，商品クラスタ：17（フルーツ果汁 100% ジュース）」の結果と比較しながら、図 7(b)–(d) の結果を考察する。

図 7(b) は図 7(a) の季節を夏から冬に変更した場合の結果である。曲線の形状は類似しているが全体的に下に移動しており、夏と比較すると冬の需要は小さいことが示唆される。

図 7(c) は図 7(a) の容量を 0.4 L 未満から 0.6 L 以上～1 L 未満に変更した場合の結果である。容量が 0.4 L 未満の場合には価格を最頻値より高くするにつれて需要が大きく減少し、容量が 0.6 L 以上～1 L 未満の場合には価格を最頻値より低くするにつれて需要が大きく

増加する傾向があり、需要が大きく変化する価格帯は容量によって異なることが示唆される。

図 7(d) は図 7(a) の商品クラスタを 17（フルーツ果汁 100% ジュース）から 12（野菜+果汁ジュース）に変更した場合の結果である。野菜+果汁ジュースは価格需要曲線が比較的平坦になっており、フルーツ果汁 100% ジュースと比較すると価格弾力性が小さいことが示唆される。

4.4 モデル木との差異の検証

各葉ノードに該当する事例集合の類似度に基づいて、最適モデル多分木とモデル木の差異を検証する。最適モデル多分木とモデル木において、葉ノードの集合をそれぞれ P^* , Q^* とし、各葉ノードに該当する事例の集合をそれぞれ $\mathcal{I}_p$ ($p \in P^*$), $\mathcal{J}_q$ ($q \in Q^*$) とする。このとき、最適モデル多分木の各葉ノード $p \in P^*$ に対して、モデル木の葉ノード $q \in Q^*$ に対する Jaccard 係数, Dice 係数, Simpson 係数の最大値を以下のように定義する。

$$J_{\max}(p) := \max_{q \in Q^*} \frac{|\mathcal{I}_p \cap \mathcal{J}_q|}{|\mathcal{I}_p \cup \mathcal{J}_q|},$$

$$D_{\max}(p) := \max_{q \in Q^*} \frac{2|\mathcal{I}_p \cap \mathcal{J}_q|}{|\mathcal{I}_p| + |\mathcal{J}_q|},$$

$$S_{\max}(p) := \max_{q \in Q^*} \frac{|\mathcal{I}_p \cap \mathcal{J}_q|}{\min\{|\mathcal{I}_p|, |\mathcal{J}_q|\}}.$$

ここで、 $J_{\max}(p) \leq D_{\max}(p) \leq S_{\max}(p)$ の関係が成立することに注意されたい。

最適モデル多分木（木の深さ：8）とモデル木（木の深さ：10）について、事例数が多い 50 個の葉ノード $p \in P^*$ の Jaccard 係数, Dice 係数, Simpson 係数の最大値を図 8 に示す。多くの葉ノードで Jaccard 係数と Dice 係数の最大値は 1 より小さく、最適モデル多




図6 構築した深さ3の最適モデル多分木の一部




図7 価格需要曲線の推定結果

分木とモデル木による事例の分岐には異なる部分が多いといえる。一方で、多くの葉ノードでSimpson係数の最大値が1に近づいていることから、最適モデル多分木とモデル木では包含関係が成立するような事例集合の組合せが多く存在することもわかる。

5. おわりに

本研究では、解釈性に優れた多分木を用いて、飲料の価格と需要の関係を表す価格需要曲線を推定した。価

格需要曲線の推定には、最適多分木 [17] をモデル木に拡張した最適モデル多分木を利用した。さらに、推定精度を向上させるために、分岐特徴量として商品クラスを作成し、最適化計算を高速化するために、最適化問題の制約式と決定変数を削減する方法を提案した。

数値実験の結果、商品クラスの分岐特徴量としての有用性を示した。また、問題規模の縮小により事例数、パス数、計算時間を削減できることを確認し、特に木の深さの値が大きい場合に計算時間が大幅に削減さ




図8 最適モデル多分木とモデル木による事例集合間の類似度

れた。また、提案手法である最適モデル多分木は、二分木構造に基づく CART [14] やモデル木 [15] よりもすべての木の深さで優れた推定精度を示した。特に、提案手法は木を深くせずに高い推定精度を示しており、高い解釈性と推定精度の両立を実現した。また、価格需要曲線の推定結果を考察し、季節・容量・商品クラスタの観点から価格需要曲線の特性を分析した。また、最適モデル多分木とモデル木の差異を検証し、事例の分岐に異なる部分が多いことを確認した。

本研究では、特徴量の各カテゴリ（「春」「夏」「秋」「冬」など）に分岐する多分木を扱ったが、「春・夏」「秋・冬」のようなカテゴリの部分集合への分岐を扱うことは今後の課題となる。今後の研究の方向性として、商品間の交差弾力性の推定 [19] への拡張や、適切な価格範囲の推定 [20, 21] および複数商品の価格設定 [22] への応用などが考えられる。

謝辞 貴重なデータを提供していただいたデータ解析コンペティション関係者の皆様に御礼申し上げます。

参考文献

[1] 杉田善弘, 上田隆穂, 守口剛, 『プライシング・サイエンスー価格の不思議を探るー』, 同文館出版, 2005.
 [2] K. T. Talluri and G. J. van Ryzin, *The Theory and Practice of Revenue Management*, Springer, 2004.
 [3] R. L. Phillips, *Pricing and Revenue Optimization*, Stanford University Press, 2021.
 [4] R. Fildes, S. Ma and S. Kolassa, “Retail forecasting: Research and practice,” *International Journal of Forecasting*, **38**, pp. 1283–1318, 2022.
 [5] S. Ito and R. Fujimaki, “Optimization beyond prediction: Prescriptive price optimization,” In *Proceed-*

ings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 1833–1841, 2017.

[6] S. Ito and R. Fujimaki, “Large-scale price optimization via network flow,” *Advances in Neural Information Processing Systems*, **29**, pp. 3855–3863, 2016.
 [7] M. Hamzei, A. Lim and J. Xu, “Robust price optimization of multiple products under interval uncertainties,” *Journal of Revenue and Pricing Management*, **21**, pp. 442–454, 2022.
 [8] 池田春之介, 朝倉希美, 西村直樹, 高野祐一, “構造的正則化処方分析による旅行パックの価格最適化,” オペレーションズ・リサーチ: 経営の科学, **68**, pp. 485–490, 2023.
 [9] K. J. Ferreira, B. H. A. Lee and D. Simchi-Levi, “Analytics for an online retailer: Demand forecasting and price optimization,” *Manufacturing & Service Operations Management*, **18**, pp. 69–88, 2016.
 [10] S. Ikeda, N. Nishimura, N. Sukegawa and Y. Takano, “Prescriptive price optimization using optimal regression trees,” *Operations Research Perspectives*, **11**, 10029, 2023.
 [11] R. Guidotti, A. Monreale, S. Ruggieri, F. Turini, F. Giannotti and D. Pedreschi, “A survey of methods for explaining black box models,” *ACM Computing Surveys*, **51**, Article No. 93, 2018.
 [12] C. Rudin, “Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead,” *Nature Machine Intelligence*, **1**, pp. 206–215, 2019.
 [13] V. G. Costa and C. E. Pedreira, “Recent advances in decision trees: An updated survey,” *Artificial Intelligence Review*, **56**, pp. 4765–4800, 2023.
 [14] W. Y. Loh, “Classification and regression trees,” *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, **1**, pp. 14–23, 2011.
 [15] J. R. Quinlan, “Learning with continuous classes,” In *Proceedings of the 5th Australian Joint Conference on Artificial Intelligence*, **92**, pp. 343–348, 1992.
 [16] D. Bertsimas and J. Dunn, *Machine Learning Under a Modern Optimization Lens*, Dynamic Ideas,

- 2019.
- [17] S. Subramanian and W. Sun, “Scalable optimal multiway-split decision trees with constraints,” In *Proceedings of the AAAI Conference on Artificial Intelligence*, **37**, pp. 9891–9899, 2023.
 - [18] P. Bojanowski, E. Grave, A. Joulin and T. Mikolov, “Enriching word vectors with subword information,” *Transactions of the Association for Computational Linguistics*, **5**, pp. 135–146, 2017.
 - [19] M. Levy, D. Grewal, P. K. Kopalle and J. D. Hess, “Emerging trends in retail pricing practice: Implications for research,” *Journal of Retailing*, **80**, pp. xiii–xxi, 2004.
 - [20] S. Ikeda, N. Nishimura and S. Umetani, “Operating range estimation for price optimization,” In *Proceedings of the 2023 IEEE International Conference on Data Mining Workshops (ICDMW)*, pp. 31–36, 2023.
 - [21] S. Ikeda, N. Nishimura and S. Umetani, “Interpretable price bounds estimation with shape constraints in price optimization,” *The Review of Socionetwork Strategies*, <https://doi.org/10.1007/s12626-024-00176-0>, 2024.
 - [22] W. Soon, “A review of multi-product pricing models,” *Applied Mathematics and Computation*, **217**, pp. 8149–8165, 2011.