

査読結果に対する回答書

この度は、私どもの拙稿をご査読並びに非常に有益なご助言を頂きまして、誠にありがとうございました。

ご指摘頂きました箇所を中心に論文全体に対する検討を行い、加筆・修正を致しました。以下に、頂きましたコメントとその回答を記載させて頂きます。また、論文中の修正・追記箇所には査読者#A のご指摘に対する修正箇所は青色の文字、査読者#B のご指摘に対する修正箇所は赤色の文字で示させて頂いております。大変恐縮ではございますが、ご確認の程、何卒宜しくお願い申し上げます。

受付番号：DACR07-3

タイトル：Gate Retrieval-Augmented Forecasting による書籍需要予測

【査読者#A から頂いたコメント】

距離関数 d の選択が結果に与える影響について言及していただきたい。また、本研究の実験において具体的にどの距離関数を用いたのかを本文中に明記する必要があると思われる。

【著者の回答】

ご指摘ありがとうございました。距離関数の定義を本文に記載しておりませんでした。

用いた距離は、標準化後のローカルコンテキストと各ウィンドウとの二乗ユークリッド距離です。具体的には、ローカルコンテキストとウィンドウ集合の各ウィンドウをそれぞれ平均 0、標準偏差 1 にそろえた上で、各時点の差を二乗して合計した値を距離としております。この距離が小さい上位 K 件を探す処理には、近傍検索のライブラリである Faiss を用いております。

距離の選択は取得される参照ウィンドウそのものを変えるため、予測結果に影響し得ると考えております。本研究の距離は標準化後の系列に対するものであり、需要の水準や振幅の違いを無視して変動の形状だけで参照を選びます。そのため、需要規模の近さを重視する場合には標準化を行わない距離が、時間軸のずれを許容して形状を照合する場合には動的時間伸縮法が適する可能性があります。一方で本研究では距離を固定しており、複数の尺度を比較した検証には至っておりません。

ただし、参照を関連度に応じて重み付けして統合する枠組みでは、類似尺度をコサイン類似度・ユークリッド距離・相関係数と変えても 7 つのデータセットの平均 MSE が 0.191~0.194 とほとんど変化しないことが報告されております (S. Lee et al., "Cross-RAG: Zero-Shot Retrieval-Augmented Time Series Forecasting via Cross-Attention," arXiv:2603.14709, 2026)。本研究のゲート機構も同様に関連度で参照を重み付けするため、距離の選択による影響は限定的と考えており、比較は今後の課題といたします。

以上を、3. 従来手法と 5.3 実験設定に追記いたしました。

新原稿 p.2 右カラム, 3. 従来手法 (記載の追加) :

なお本研究では、距離 d として標準化後のウィンドウ間の二乗ユークリッド距離を用いる。この距離は標準化後の系列に対して定義されるため、系列の水準や振幅の違いを除いた変動の形状の類似度を測ることになる。

新原稿 p.5 左カラム, 5.3 実験設定 (記載の追加):

このときの類似度は二乗ユークリッド距離により測るものとし, 近傍検索の実装には Faiss[12] を用いた.

【査読者#A から頂いたコメント】

Top-K における K の設定方法について, 結果に対する感度を検討する必要があると考える. 例えば, K を変化させた感度分析や追加実験を行うことで, 提案手法の頑健性を示すことができるのではないか.

【著者の回答】

ご指摘ありがとうございます. K の感度を確認しておりませんでした.

学習済みのモデルに対し, 推論時の K を 1 から 8 まで変えて予測精度を比較いたしました. 結果は下表の通りです.

K	分位点					
	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE
1	3.5978	13.5063	2.7533	12.2612	4.8157	13.0221
2	3.6140	13.5152	2.7496	12.2316	4.9177	13.1424
3*	3.6339	13.5293	2.7452	12.2025	5.0136	13.3030
5	3.6565	13.5242	2.7445	12.1581	5.1744	13.5542
8	3.6846	13.5361	2.7548	12.1453	5.3636	13.9132

中央値 ($\tau = 0.5$) の MAE は $K = 1$ から 8 まで 2.745~2.755 で, 変動は 0.4% 以内でした. ゲート機構が関連の薄い参照を弱めるため, 参照件数を増やしても予測が乱れないためと考えております. 一方, 上側分位点 ($\tau = 0.9$) は K が増えるほど誤差が大きくなり, $K = 1$ の 4.82 に対し $K = 8$ では 5.36 でした.

なお, これは推論時のみ K を変えたもので, K 別の再学習は行っておりません. 学習時の K は 3 であるため, $\tau = 0.9$ の悪化は, 学習時より多くの参照を与えたことの影響と切り分けられておりません. K 別に学習し直した感度分析は今後の課題とさせていただきます.

関連する報告として, 参照を関連度に応じて重み付けして統合する Cross-RAG では, 参照件数を 2 件から 14 件まで変えても平均 MSE が 0.1944 から 0.1927 までしか変化しない一方, 重み付けを行わない手法では非単調に変動することが示されております (S. Lee et al., arXiv:2603.14709, 2026). 本研究のゲート機構も同種の役割を果たすため, K に対する頑健性は整合する結果と考えております.

【査読者#A から頂いたコメント】

提案手法では処理を 5 つのステップに分割していることから, 従来手法と比較して計算コストが増加する可能性があるように見受けられる. 提案手法と従来手法の計算量, 学習時間, あるいは予測時間について比較または考察があると, 本手法の実用性を評価しやすくなると思う.

【著者の回答】

ご指摘ありがとうございます. 計算コストに関する記載がありませんでした.

まず、5つのステップへの分割は、参照ウィンドウとローカルコンテキストを独立に符号化するための構成であり、逐次的な処理の追加を意味するものではございません。Step 1 と Step 2 のエンコードは互いに独立に実行でき、Step 3 から Step 5 はパッチ表現に対する要素ごとの積と多層パーセプトロンの適用にとどまります。

計算量の観点では、従来手法 ProtoRAF がパッチ数 $(K+1)P$ の単一系列を符号化するのに対し、提案手法は長さ P の系列を $K+1$ 本符号化いたします。そのためエンコーダの自己注意の計算量は、ProtoRAF の $O((K+1)^2P^2D)$ に対し提案手法では $O((K+1)P^2D)$ となり、参照の連結に伴う二次的な増加は生じません。一方で、提案手法は各参照を独立した系列として扱うため、系列ごとに区切りの要素が付き、処理する要素の数はその分だけ増加いたします。また、ゲート機構が追加する計算量は $O(KPD^2)$ であり、エンコーダ全体と比べて小さい規模です。なお、参照ウィンドウの検索に要する計算は両手法で完全に共通であり、本実験の条件では1予測あたり0.20ミリ秒と、モデルの順伝播に対して無視できる水準でした。

その上で、同一の計算機の GPU 上で同一の入力を与え、各手法の推論時間を実測いたしました。PyTorch を用い、予備の実行を行ったうえで30回測定した平均を示しております。結果は下表の通りです（バッチサイズ16, $L=128$, $K=3$, 括弧内は Baseline に対する比）。

モデル	推論時間 [ms]
GateRAF	69.9 (2.86)
Multi-RAF	70.1 (2.87)
ProtoRAF	60.1 (2.46)
Baseline	24.4 (1.00)

提案手法は従来手法 ProtoRAF に対し、推論で約1.16倍の時間を要します。この増分は参照を独立に符号化することによるものであり、ゲート機構自体による増分は、Multi-RAF との差から1%未満（測定誤差の範囲内）にとどまっております。また、参照数 K を1から8まで変化させて測定したところ、両手法の比はおよそ1.16から1.18でほぼ一定であり、5つのステップへの分割によって計算量の増え方が悪化するものではないことを確認いたしました。

【査読者#A から頂いたコメント】

販売冊数に生じるスパイクの大きさや発生頻度について、さらなる考察が必要であるように思われる。書籍の売上は、さまざまな契機によって一時的に大きく増加する可能性があるが、その頻度や規模によって予測の難易度も異なると考えられる。例えば、スパイクの頻度や大きさごとに予測性能を評価することで、提案手法がどのような状況で有効であるかをより明確にできるのではないかな。

【著者の回答】

ご指摘ありがとうございます。スパイクの現れ方による評価が不足しておりました。

大きさにつきましては表2が該当いたしますが、これは時点単位の区分であり、書籍ごとに現れ方が異なるという観点は捉えられておりませんでした。

そこで、評価期間の64日のうちzスコアが2.0以上となった時点の数を発生頻度、系列内のzスコアの最大値を最大規模とし、系列単位で層別した評価を追加いたしました。なお、一度もスパイクが生じなかった25書名は層別の対象とならないため除外し、残る1,132書名を対象としております。

改善率は、発生頻度別に 1 回から 5 回では約 7~11%であるのに対し、6 回以上では約 35%に達します。スパイクが頻繁に現れる系列で提案手法の優位が特に大きく、これは同種の変動が過去に複数回生じている系列ほど、検索によって有用な参照ウィンドウが得られやすいためと解釈しております。最大規模別では 2~3 で約 19%, 3~5 で約 9%, 5 以上で約 6%であり、いずれの区分でも提案手法の MAE が最小でした。なお、スパイクの大きさにつきましては表 2 が時点単位の評価として該当いたしますので、最大規模別の結果は表には載せず、本文で 1 文触れるにとどめております。

以上を実験 2 の考察に追記し、発生頻度別の結果を表 3 として掲載いたしました。

新原稿 p.6 左~右カラム, 5.4.2 実験 2 (記載の追加):

表 2 が時点単位でのスパイクの強度別の評価であるのに対し、書籍ごとにスパイクの現れ方が異なることを踏まえ、系列単位でスパイクの発生頻度により層別した評価を行う。評価期間の 64 日のうち z スコアが 2.0 以上となった時点の数を発生頻度とし、書名を区分した。なお、評価期間中に一度もスパイクが生じなかった 25 書名は、スパイクに関する層別の対象とならないため除外し、残る 1,132 書名を対象とした。結果を表 3 に示す。

発生頻度別にみると、GateRAF の ProtoRAF に対する MAE の改善率は、1 回から 5 回では約 7~11%であるのに対し、6 回以上では約 35%に達する。すなわち、スパイクが頻繁に現れる系列で提案手法の優位が特に大きい。これは、同種の変動が過去に複数回生じている系列ほど、検索によって有用な参照が得られやすいためと解釈できる。なお、系列内の z スコアの最大値により層別した場合も、いずれの区分で GateRAF の MAE が最小であった。

(表 3「スパイクの発生頻度により層別した MAE と RMSE」を追加)

【査読者#A から頂いたコメント】

目的変数 Y が具体的に何を表しているのかを、本文中で明記する必要があると考える。例えば、ある時点における販売冊数そのものなのか、一定期間内の販売冊数なのかを明確にいただきたい。

【著者の回答】

ご指摘ありがとうございました。目的変数の定義を本文に記載しておりませんでした。

本研究の目的変数は、書名ごとに全店舗の販売冊数を日単位で合算した値であり、将来の各日における販売冊数そのものです。一定期間の累計ではございません。予測値の各要素も、予測起点から数えた特定の 1 日の販売冊数にあたります。

以上を 2.1 節と 4.3 節に明記いたしました。

新原稿 p.2 左カラム, 2.1 問題設定 (記載の追加):

予測の対象は、書名ごとに全店舗の販売冊数を日単位で合算した時系列であり、目的変数は将来の各日における販売冊数そのものである。すなわち、一定期間の累計販売冊数ではなく、1 日単位の販売冊数を予測の対象とする。

新原稿 p.4 右カラム, 4.3 予測 (記載の追加):

また、 $\hat{Y}$ の第 (q, f) 要素は、予測起点から f 日先の 1 日における販売冊数について、 Q の第 q 番目の分位点に対応する予測値を表す。すなわち $\hat{Y}$ の各要素は特定の 1 日の販売冊数であり、複数日にわたる累計ではない。

【査読者#A から頂いたコメント】

本論文における「需要」の定義を明確にしていきたい。本研究で直接観測されているのは販売冊数であり、潜在的な需要そのものとは必ずしも一致しないと考えられる。販売冊数、販売冊数の予測値、および需要の関係を整理した上で、用語を定義することが望ましい。

【著者の回答】

ご指摘ありがとうございます。「需要」と販売冊数を区別せずに用いておりました。

本研究が実務上目指しているのは、需要に見合う量を入荷することです。入荷が需要に届かなければ機会損失が生じ、需要を上回れば売れ残って返本になります。第 6 章で評価しているのはまさにこの過不足であり、本来予測したいのは需要そのものです。

しかし、実際に観測できるのは販売された冊数だけです。売り切れた日には販売冊数が入荷量で頭打ちになり、そのとき本当はいくつ売れたはずだったのかは記録に残りません。本研究の POS データには在庫や入荷の情報が含まれないため、この頭打ちがどの程度生じているのかを確かめることもできません。

そこで、販売冊数を需要の観測可能な代理指標として扱い、「需要予測」は販売冊数の予測を指すものと定義いたしました。この扱いには限界もございます。学習に用いる販売冊数自体が売り切れによって過小に記録されている可能性があり、その場合、モデルはスパイク時の水準を実際より低く学習することになります。図 4 の書籍 B で実績の水準を再現できていないことにも、この影響が含まれている可能性があると考えております。

以上を 2.1 節に明記いたしました。

新原稿 p.2 左カラム, 2.1 問題設定（記載の追加）：

本研究で観測できるのは実際に販売された冊数であり、これを販売冊数と呼ぶ。消費者が買いたいと考えた量である需要は、在庫切れがあれば販売冊数を上回るが、本研究の POS データには在庫情報がないため観測できない。そこで販売冊数を需要の代理指標とし、需要予測は販売冊数の予測を指すものとする。

【査読者#A から頂いたコメント】

図 4 では、書籍 A および B について予測値と実績値の比較が示されている。従来手法と比較して予測精度が改善していることは確認できる一方で、少なくとも図からはスパイクそのものを十分に予測できているとは判断しにくい。本研究ではスパイクへの対応が重要な目的の一つであると理解しているため、スパイク発生時に限定した予測性能の評価や、定量的な指標を追加するなど、提案手法の有効性を補足する分析があるとよい。

【著者の回答】

ご指摘ありがとうございます。図 4 だけではスパイクへの対応が分かりにくく、失礼いたしました。

スパイク時だけに限った評価は、改訂稿の表 2 に含まれております。表 2 は各時点を z スコアで区分したもので、2 以上の区分がスパイクの時点にあたります。この区分でも提案手法の MAE が最小です。また表 4 は、予測したスパイクが実際のスパイクからどれだけずれているかを見たもので、こちらもスパイクに絞った指標です。

図 4 の書籍 B については、ご指摘の通りスパイクの高さまでは予測できておりません。スパイク時の実績が平均 25 冊であるのに対し、提案手法の予測は 9 冊にとどまります。ただし従来手法 ProtoRAF は 1 冊未満とほとんど反応しておらず、提案手法は少なくとも需要が立ち上がったことは捉えております。書籍 A では、スパイク時の誤差が提案手法 2.4 冊、ProtoRAF 7.5 冊で、実績に

ほぼ沿った予測ができております。

以上を踏まえ、実験5の考察に、書籍Bで水準を再現できていないことと、スパイク時の評価は表2と表4にあることを追記いたしました。

新原稿 p.8 右カラム, 5.4.5 実験5（記載の追加）：

ただし書籍Bでは、予測の上昇は実績の急増に比べて小さく、スパイクの水準までは再現できていない。なお、スパイクの時点だけに限った評価は表2のzが2以上の区分に、スパイクの位置のずれの評価は表4に示している。

【査読者#Aから頂いたコメント】

第6節では返本および機会損失について議論されているが、そこで示された改善が実社会においてどの程度のインパクトを持つのかを、より明確に示していただきたい。可能であれば、返本冊数や機会損失冊数だけでなく、金額換算した効果やリスクの大きさなどを示すことで、提案手法の実務的な意義がより理解しやすくなると考える。

【著者の回答】

ご指摘ありがとうございます。冊数のみでは実務上の規模が伝わりにくい構成でした。

データに含まれる本体価格で金額に換算いたしました。GateRAFの過剰入荷は3,173万円、機会損失は1億2,052万円で、Baselineと比べ合わせて約1,560万円の損失を抑えられております（評価対象は1,157書名の64日分、本体価格ベースの売上2億1,369万円）。

あわせて、はじめに述べた物流コストと在庫リスクの観点からの意味づけも加えました。返本は書店から取次・出版社への返品であり往復の輸送を伴いますが、GateRAFはBaselineに対し返本を16,201冊減らしております。また委託販売制度のもとで売れ残りの在庫リスクを負うのは出版社であるため、過剰入荷の抑制はそのリスクの軽減にあたります。機会損失も同時に6,073冊減っており、欠品を増やさずにこれを実現しております。

以上を、表5の金額列と6章の考察2段落として追記いたしました。

新原稿 p.8 右カラム, 表5（金額列の追加）：

冊数の3列に加え、過剰入荷と機会損失を本体価格で換算した金額〔万円〕の2列を追加。

新原稿 p.9 右カラム, 6. 返本と機会損失の観点からの評価（記載の追加）：

これらを本体価格で金額に換算すると、GateRAFの過剰入荷は3,173万円、機会損失は1億2,052万円となる。Baselineと比べると返本が1,228万円、機会損失が332万円減り、合わせて約1,560万円の損失を抑えられている。評価対象は1,157書名の64日分（本体価格ベースの売上2億1,369万円）であり、返本の抑制が金額でも相応の規模になることがわかる。

返本は書店から取次・出版社への返品であり、往復の輸送と在庫の再処理を伴う。GateRAFはBaselineに対し返本を16,201冊減らしており、その分の物流が不要になる。また委託販売制度のもとでは売れ残りの在庫リスクを出版社が負うため、過剰入荷の抑制はそのリスクの軽減にあたる。GateRAFは機会損失も同時に6,073冊減らしており、欠品を増やさずにこれを実現している。

【査読者#Aから頂いたコメント】

図表中の文字が小さく、一部が読み取りにくい。文字サイズやレイアウトを調整し、視認性を改善

していただきたい。

【著者の回答】

ご指摘ありがとうございました。表の文字が小さく、読み取りにくくなっておりました。

表 2 から表 5 の文字を大きくし、本文とほぼ同じ大きさにいたしました。表 2 は z スコアの区分を 1 刻みに、表 3 は発生頻度による層別のみに、表 4 は Δ の範囲を ± 5 日にまとめ、表 5 は紙面の幅いっぱいに配置しております。また、図 2 を拡大いたしました。

【査読者#A から頂いたコメント】

オンライン変化点検知など、時系列データにおける急激な構造変化を検出する手法も比較対象となり得るように思われる。これらの手法を比較対象に含めることが適切でない場合には、その理由について考察があるとよい。

【著者の回答】

ご指摘ありがとうございました。変化点検知を比較対象としない理由を、以下にご説明いたします。

変化点検知は、観測された系列に変化が生じたかを判定する検出の手法で、出力は変化点の位置や確率です。一方、本研究は予測期間の観測を一切用いずに、直近 128 日から続く 64 日の販売冊数を分位点として出力する予測の問題です。出力の形式が異なるため、MAE や RMSE、返本や機会損失といった本研究の指標で並べて比較することができません。

また、オンライン変化点検知は変化が始まった後の観測から検知するため、検知には遅れが伴います。本データのスパイクは数日で収まるものが多く、仮に逐次観測できる設定であっても、検知できた時点ではスパイクが過ぎており、事前に備えるという目的には合いません。

一方で、変化点検知を予測手法の部品として使う余地はあると考えております。系列を局面ごとに区切り、参照ウィンドウの検索範囲や直近区間を現在の局面に限定するという使い方です。この点は今後の課題とさせていただきます。

【査読者#A から頂いたコメント】

本研究では主として販売冊数の時系列情報を用いて予測していると理解している。一方で、書籍の突発的な売上増加には、SNS 上での話題化、ドラマ化・映画化、本屋大賞等の受賞やノミネート、メディアでの紹介など、外生的な要因が大きく関与すると思われる。これらの情報を共変量として利用する可能性について、今後の課題を含めて考察していただきたい。

【著者の回答】

ご指摘の通りです。本研究は販売冊数の時系列のみを用いており、外生的な要因は扱っておりません。提供いただいたデータにも、SNS での話題化や映像化、受賞といった情報は含まれておらず、販売実績のほかは出版社、著者名、分類、本体価格といった書籍属性のみでした。

一方で、提案手法は外生的な要因を間接的に取り込んでいる面があると考えております。外生的な契機で生じたスパイクは、過去に同じような契機を受けた他の書籍にも現れております。提案手法はその変動パターンを系列横断的に検索して参照するため、外生変数を直接観測しなくても、類似した立ち上がり方を予測に反映できます。実験 3 で提案手法の誤りが実際のスパイクの近傍に集中することは、その現れと考えております。

今後の課題としては、段階的に 3 つを考えております。第一に、データに含まれる書籍属性を参照ウィンドウの検索条件に加え、同じ分類や著者の系列に絞って参照する方法です。これは現在の

データのままで実現できます。第二に、受賞や映像化、メディア紹介の日付を外部から収集し、それらの日からの経過日数などを共変量として与える方法です。第三に、モデル側の対応です。本研究の基盤モデルは単変量であり共変量を直接扱えないため、共変量を扱える基盤モデルへの拡張が必要になります。

以上のうち、今後の課題として7章に追記いたしました。

新原稿 p.10 左カラム, 7. おわりに (記載の追加) :

また、受賞や映像化、メディアでの紹介といった外生的な契機を共変量として扱う拡張も課題である。本研究で用いた基盤モデルは単変量であり共変量を直接扱えないため、共変量を扱える基盤モデルへの拡張や、出版社や分類などの書籍属性を参照ウィンドウの検索条件に加える方法が考えられる。

以上のように、頂きましたコメントに対しまして入念な推敲を重ね、論文の加筆・修正を致しましたので、ご確認の程、何卒宜しくお願い申し上げます。

【査読者#B から頂いたコメント】

実験 1~5 について、各実験が提案手法のどの側面を検証するためのものかは本文中で述べられているものの、実験結果の報告前の段階で、「どのような結果が得られれば提案手法の有用性が支持されるのか」がやや読み取りづらいです。たとえば、実験 1 では全体的な予測精度、実験 2 では需要水準別の誤差特性、実験 3 ではスパイク予測の時間的近接性、実験 4 では予測区間幅と需要変動の対応、実験 5 では代表系列における挙動確認を意図していると理解しました。各実験の目的と期待される結果の解釈を実験設定の段階で簡潔に整理すると、結果の読み取りがより容易になると考えられます。

【著者の回答】

ご指摘ありがとうございました。各実験の結果をどう読めばよいかを、結果の報告前に述べておりませんでした。

ご理解の通りの意図で各実験を設けております。そこで 5.3 実験設定の各実験の説明に、どのような結果が得られれば提案手法が支持されるのかを1文ずつ加えました。

新原稿 p.5~6, 5.3 実験設定 (記載の追加) :

実験 1 : いずれの分位点でも従来手法より MAE と RMSE が小さければ、予測全体の精度が改善したといえる。

実験 2 : スパイク域で誤差が小さく、かつ静穏域でも誤差が増えていなければ、スパイクの捕捉と平常時の精度が両立しているといえる。あわせて系列ごとのスパイクの多さでも層別し、スパイクが多く現れる系列ほど改善が大きければ、過去の類似事例の参照が効いているといえる。

実験 3 : $|Δ|$ の小さい割合が従来手法より高ければ、予測したスパイクが実際のスパイクの近くに集まっているといえる。

実験 4 : 幅の広い区分ほど実績のzスコアが高ければ、予測の不確実性が実際の需要変動に対応しているといえる。

実験 5 : 需要が減衰する系列で過大な予測が抑えられ、急増する系列で予測が立ち上がっている、2つの工夫がそれぞれ意図した通りに働いているといえる。

【査読者#B から頂いたコメント】

実験 2：各 z スコアの区分に含まれる観測数はどの程度でしょうか？特に $z > 3$ のようなスパイク域は時点数が少ない可能性があるため、そこでの MAE/RMSE がどれくらい安定しているかに疑義が生じます。各区分の観測数などを併記すると、表 2 の解釈可能性が高まると考えられます。

【著者の回答】

ご指摘ありがとうございます。各区分に含まれる時点数を示しておりませんでした。

評価の対象は 1,157 書名の 64 日分、計 74,048 時点です。時点数は、 -1 未満が 3,381 時点、 $-1 \sim 0$ が 46,775 時点、 $0 \sim 1$ が 14,144 時点、 $1 \sim 2$ が 6,054 時点、 $2 \sim 3$ が 2,261 時点、 3 以上が 1,433 時点です。

ご指摘の通り、上側の区分ほど時点数は少なくなります。ただし最も少ない $z > 3$ の区分にも 1,433 時点が含まれており、平均をとる標本としては十分な数と考えております。この区分の中央値 ($\tau = 0.5$) の MAE は、GateRAF が 24.76、その 95%信頼区間の幅は ± 2.89 です。

また、同じ時点どうしを対応させて手法間の差をとると、ProtoRAF と GateRAF の MAE の差は 1.50 (95%信頼区間の幅 ± 0.23) となり、区間は 0 をまたぎません。他の区分でも同様に、GateRAF の MAE が最も小さいという関係は、区間の幅の範囲で入れ替わることはございません。

以上を踏まえ、表 2 に各区分の時点数を示す行を追加し、本文にもその旨を記載いたしました。

新原稿 p.7, 表 2 (記載の追加)：

各区分の時点数を示す行を最上段に追加。

新原稿 p.6 右カラム, 5.4.2 実験 2 (記載の追加)：

なお、各区分に含まれる時点数は表 2 の最上段に示す通りである。最も時点数の少ない $z > 3$ の区分にも 1,433 時点 (全時点の 1.9%) が含まれており、区分ごとの比較に足る標本数が確保されている。

【査読者#B から頂いたコメント】

実験 2 では、各時点の実績値を「その系列全体の平均と標準偏差」で標準化した z スコアに基づいて時点を区分していると説明されています。一方で、時系列予測において評価期間を含む全期間の統計量を前処理やモデルの入力に用いる場合、将来情報の利用、すなわち data leakage と誤解される可能性があると思われます。本実験では、当該 z スコアはモデルの学習・推論に用いられるものではなく、予測後に需要水準別の誤差を確認するための事後的な層別指標であると理解しました。この理解でよい場合、 z スコアの算出に用いた期間、および当該 z スコアがモデルの学習・推論には用いられていないことを本文中で明示するとよいと思われます。

【著者の回答】

ご指摘の通りです。この z スコアは、予測を終えた後に誤差を需要水準別に集計するための指標であり、モデルの学習にも推論にも用いておりません。

算出に用いた期間は、各書名の評価期間、すなわち予測対象の 64 日です。この 64 日の実績値から書名ごとに平均と標準偏差を求め、各時点の実績値を標準化しております。実験 3 でスパイクを定義する際の z スコア、実験 4 で集計する z スコアも同じものです。

モデル側では将来の情報を用いておりません。入力の標準化は直近 128 日のローカルコンテキスト

トの平均と標準偏差のみで行っており、参照ウィンドウの検索も、予測起点より前に終わるウィンドウに限っております。学習に用いる予測対象の期間も、評価期間と重ならないようにしております。

以上を、5.3 実験設定の実験 2 の説明に明記いたしました。

新原稿 p.5 右カラム, 5.3 実験設定 (記載の追加) :

ここでの平均と標準偏差は、各系列の評価期間、すなわち予測対象の64日の実績値から算出したものである。このzスコアは、予測を終えた後に誤差を需要水準別に集計するための層別指標であり、モデルの学習および推論には一切用いていない。予測に用いる標準化はローカルコンテキストの平均と標準偏差のみによるため、評価期間の情報が予測に流入することはない。実験3および実験4で用いるzスコアについても同様である。

【査読者#8 から頂いたコメント】

実験3: 表3の解釈について確認させてください。本文では、予測した各スパイクについて最も近い実スパイクとの時間差を求めたものを「誤検知」、実際の各スパイクについて最も近い予測スパイクとの時間差を求めたものを「見逃し」として集計していると理解しました。この理解に基づく、たとえば誤検知における GateRAF の $\Delta = -10$ の値は、「GateRAF が予測スパイクとした時点のうち、最も近い実スパイクよりも 10 日以上後方に位置したものの割合」を示している、という理解でよろしいでしょうか。「誤検知」および「見逃し」の割合の具体的な計算方法が本文からやや読み取りづらいため、可能であれば数式または簡単な例を用いて説明していただけると、表3の解釈が容易になると思われます。

【著者の回答】

ご理解の通りです。 Δ は実スパイクの日から予測スパイクの日を引いた値ですので、誤検知の Δ が負であることは、予測したスパイクが最も近い実スパイクより後にあることを意味します。

ただし、割合の分母について 1 点補足いたします。分母は予測スパイクとした時点の総数ではなく、そのうち実スパイクと一致しなかったもの、すなわち誤検知の総件数です。実スパイクと一致した予測スパイクは誤検知に含めないため、 $\Delta = 0$ の割合は定義上0となります。見逃しも同様に、予測できなかった実スパイクの総件数を分母としております。

また、改訂稿では表の見やすさを優先し、 Δ を $-5 \sim +5$ 日の範囲にまとめております。前の原稿の $\Delta = -10$ に相当するのは、改訂稿では $\Delta \leq -5$ の列、すなわち実スパイクより 5 日以上後に出された誤検知の割合です。

簡単な例を示します。ある書名で、実スパイクが 20 日目のみ、予測スパイクが 17 日目と 25 日目であったとします。17 日目の予測は実スパイクと一致しないため誤検知で、最も近い実スパイクは 20 日目ですから $\Delta = 20 - 17 = +3$ です。25 日目の予測も誤検知で $\Delta = 20 - 25 = -5$ です。一方、20 日目の実スパイクは予測できていないため見逃しで、最も近い予測スパイクは 17 日目ですから $\Delta = 20 - 17 = +3$ となります。

このように求めた Δ を、実スパイクと予測スパイクがともに 1 つ以上ある書名について全系列分集め、値ごとの件数を誤検知・見逃しそれぞれの総件数で割ったものが表の値です。いずれか一方でも存在しない書名は、最も近い相手が定まらないため対象外としております。

なお、改訂稿では表を 1 つ追加したため、ご指摘の表は表 4 となっております。

以上を、5.3 実験設定に式と例を用いて明記いたしました。

新原稿 p.6 左カラム, 5.3 実験設定 (記載の修正・追加) :

評価では Δ を $-5 \sim +5$ 日の範囲で集計し、 Δ の値ごとの件数を、誤検知・見逃しそれぞれの総件数で割った割合として算出する。

実スパイクの日と予測スパイクの日を記号で置き、誤検知は実スパイクと一致しなかった予測スパイクを、見逃しは予測できなかった実スパイクを対象とすることを式で定義した。誤検知の Δ は最も近い実スパイクの日から予測スパイクの日を引いた値、見逃しの Δ は実スパイクの日から最も近い予測スパイクの日を引いた値である。実スパイクと予測スパイクがともに 1 つ以上ある系列を対象として全系列の Δ をまとめ、値ごとの件数を総件数で割った割合を表 4 に示す。たとえば誤検知の $\Delta = -3$ の値は、実際のスパイクの 3 日後に出された誤検知が、誤検知全体に占める割合を表す。なお、実スパイクと一致した予測スパイクは誤検知に含めず、予測できた実スパイクは見逃しに含めないため、 $\Delta = 0$ の割合は定義上 0 となる。

【査読者#B から頂いたコメント】

実験 3：加えて、表 3 からは誤検知・見逃しの時間的分布は読み取れる一方で、各モデルがどの程度多く予測スパイクを出し、そのうちどの程度が誤検知または見逃しに該当したのかを判断しにくいです。各モデルの予測スパイク数や誤検知数、見逃し数の絶対数を併記することで、実験 3 の解釈可能性が高まると考えられます。

【著者の回答】

ご指摘ありがとうございます。絶対数を示しておりませんでした。

表 4 の右に 2 列を追加いたしました。誤検知の行には予測スパイク数と誤検知数を、見逃しの行には実スパイク数と見逃し数を示しております。GateRAF は予測スパイクの数が ProtoRAF より少ないにもかかわらず、誤検知も見逃しも少なくなっております。

1 点補足いたします。 Δ の割合は、実スパイクと予測スパイクをともに 1 件以上もつ書名だけで集計しております。片方でも無いと最も近い相手が定まらないためです。そのため割合の分母は、表の誤検知数や見逃し数とは一致いたしません。

とくに見逃しについては、予測スパイクを 1 件も出していない書名が対象から外れるため、分母は見逃し数よりかなり小さくなります。この表は、予測が反応した書名においてずれがどの程度かを示すものとご理解いただければ幸いです。

以上を踏まえ、表 4 に絶対数の 2 列を追加し、5.4.3 実験 3 にその説明を記載いたしました。

新原稿 p.8, 表 4 (記載の追加)：

誤検知の行に予測スパイク数と誤検知数、見逃しの行に実スパイク数と見逃し数の 2 列を右端に追加。

新原稿 p.7 右カラム, 5.4.3 実験 3 (記載の追加)：

絶対数は表 4 の右の 2 列に示す。GateRAF は予測スパイクの数が ProtoRAF より少ないにもかかわらず誤検知・見逃しがともに少なく、スパイクの予測がより絞り込まれている。なお Δ の割合は、最も近い相手が定まる系列に限って集計しており、その件数は誤検知が 440~680 件、見逃しが 141~162 件である。

【査読者#B から頂いたコメント】

実験 4 では、予測区間幅の十分位ごとに実績 z スコアの平均を求めることで、予測区間幅と実際の需要変動の対応を確認しており、有用な分析であると感じました。一方で、平均値のみでは、各区

分内のばらつきや外れ値の影響を判断しにくいです。各十分位における実績 z スコアの標準偏差等を補足すると、予測区間幅がスパイク需要と安定的に対応しているかをより判断しやすくなると思われます。

【著者の回答】

ご指摘ありがとうございました。平均だけではばらつきが分からない構成でした。

各十分位について、実績の z スコアの標準偏差と、スパイク (z が 2 より大きい時点) が占める割合を求めました。結果は下表の通りです。

予測区間幅の十分位ごとの、実績値の z スコアの標準偏差とスパイクの割合

十分位	GateRAF		ProtoRAF	
	標準偏差	スパイクの割合	標準偏差	スパイクの割合
1	0.60	1.4%	0.91	4.8%
2	0.80	2.8%	0.87	3.6%
3	0.92	4.1%	0.93	4.3%
4	0.92	4.2%	0.91	4.1%
5	0.91	3.9%	0.95	4.2%
6	0.87	3.3%	0.96	4.3%
7	0.96	4.6%	0.99	4.9%
8	1.09	6.9%	1.07	5.9%
9	1.22	8.7%	1.10	6.5%
10	1.25	9.9%	1.12	7.4%

GateRAF では、区間幅が狭い区分から広い区分へ向かって標準偏差が 0.60 から 1.25 へ大きくなり、スパイクの割合も 1.4% から 9.9% へ増えます。幅の広い区間には、実際にスパイクの時点が多く含まれております。Multi-RAF もほぼ同じ傾向で、標準偏差は 0.70 から 1.26、スパイクの割合は 2.3% から 10.0% です。

一方 ProtoRAF は、標準偏差が 0.87~1.12、スパイクの割合が 3.6%~7.4% と、区分による違いが小さく、区間の幅が需要の変動をあまり反映しておりません。Baseline もほぼ同じです。

なお、広い区分ほど標準偏差が大きくなるのは、その区分にスパイクと平常時が混在するためです。実際、最も広い区分でもスパイクの割合は 9.9% にとどまります。区間が広いことはスパイクの起こりやすい時点であることを示しますが、発生を確定づけるものではないと考えております。

以上を、5.4.4 実験 4 に追記いたしました。

新原稿 p.7 右カラム, 5.4.4 実験 4 (記載の追加):

平均だけでは区分内のばらつきが分からないため、各十分位における実績の z スコアの標準偏差と、スパイク ($z > 2$) が占める割合も求めた。GateRAF では、標準偏差が最も狭い区分の 0.60 から最も広い区分の 1.25 へ大きくなり、スパイクの割合も 1.4% から 9.9% へ増加する。一方 ProtoRAF では標準偏差が 0.87~1.12、スパイクの割合が 3.6%~7.4% の範囲にとどまり、区分による違いが小さい。すなわち GateRAF の広い予測区間は実際にスパイクの時点を多く含んでおり、区間幅と需要変動の対応は平均だけでなく分布としても確認できる。ただし最も広い区分でもスパイクの割合は 9.9% であり、区間が広いことが直ちにスパイクの発生を意味するわけではない。

【査読者#B から頂いたコメント】

第 6 章では、予測値をその時点の入荷量とみなして過剰入荷、返本率、機会損失を算出しており、予測精度を実務的指標に接続する試みとして有用です。一方で、入荷量として予測中央値 $\tau=0.5$ を用いる理由については、もう少し説明があるとよいと思われます。実務上の発注意思決定では、機会損失を重視する場合には上側分位点（例： $\tau=0.9$ ）を用いて欠品を抑える判断が考えられる一方、過剰入荷や返本を重視する場合には下側分位点（例： $\tau=0.1$ ）を用いて入荷量を抑える判断も考えられます。したがって、 $\tau=0.5$ を用いた理由を補足するか、可能であれば $\tau=0.1, 0.5, 0.9$ など複数の分位点を入荷量とみなした場合の過剰入荷・返本率・機会損失を比較する感度分析を加えると、第 6 章の実務的含意がより明確になると考えられます。

【著者の回答】

ご指摘ありがとうございます。中央値を用いた理由を書いておりませんでした。

中央値を用いたのは、返本と機会損失のどちらにも重みを置かない中立的な基準だからです。どちらの損失をどれだけ重くみるかは実務の費用構造によって決まりますが、本研究の目的は手法間の予測精度の差を実務的な指標に写すことにありますので、特定の費用構造を仮定せず、入荷を需要の中心に合わせる場合を基準といたしました。

あわせて、 $\tau=0.1$ 、 $\tau=0.5$ 、 $\tau=0.9$ のそれぞれを入荷量とみなした感度分析を行い、表 5 として掲載いたしました。

$\tau=0.1$ では入荷を絞るため過剰入荷は GateRAF で 4,073 冊まで減りますが、機会損失は 265,006 冊と $\tau=0.5$ の約 1.6 倍になります。逆に $\tau=0.9$ では機会損失が 74,763 冊まで下がる一方で、過剰入荷は 296,482 冊に達します。ご指摘の通り、返本と機会損失のどちらを重視するかで適切な τ は変わります。

参考までに、返本と機会損失を同じ重みで本体価格により金額換算すると、GateRAF の損失の合計は $\tau=0.1$ で 1 億 9,880 万円、 $\tau=0.5$ で 1 億 5,225 万円、 $\tau=0.9$ で 2 億 8,021 万円となり、 $\tau=0.5$ が最小でした。ただし返本の実際の費用は本体価格そのものではなく物流と在庫リスクにあたり、機会損失も本来は利幅にあたりますので、この合計はあくまで目安とお考えいただければ幸いです。

手法間の関係は τ によらず保たれておりました。いずれの τ でも GateRAF の過剰入荷は比較手法の中で最小で、Baseline に対しては過剰入荷と機会損失の双方を同時に下回ります。第 6 章の結論が分位点の選び方に依存しないことを確認できました。

なお、従来の表は冊数と金額の両方を載せておりましたが、冊数は表 5 と重複いたしますので、返本率と金額のみを載せる形に改め、表 6 といたしました。

以上を、6 章に追記いたしました。

新原稿 p.11 左カラム、6. 返本と機会損失の観点からの評価（記載の追加）：

入荷量に中央値を用いたのは、返本と機会損失のどちらにも重みを置かない中立的な基準だからであることを述べ、 $\tau=0.1$ 、 $\tau=0.5$ 、 $\tau=0.9$ を入荷量とみなした場合の比較を加えた。 τ を小さくすると過剰入荷は減るが機会損失が増え、大きくするとその逆になること、いずれの τ でも GateRAF の過剰入荷が最小であり、本章の結論が分位点の選び方に依存しないことを示した。

新原稿 p.10、表 5（新規追加）：

入荷量に用いる分位点 τ を変えた場合の過剰入荷と機会損失を、GateRAF、Baseline、SARIMA、Prophet について示す表を追加。

【査読者#8 から頂いたコメント】

軽微な修正の要求：5.2 節の「POS 販売冊数」という用語について、当該データセットに詳しい読者には理解可能だと思われそうですが、初めて読む読者には、店舗別 POS データを同一書名・同一日付で全店舗合算した販売冊数を指すのか、あるいは別の定義を持つのがやや分かりづらい可能性があります。簡潔に定義を補足するとよいと思われま

【著者の回答】

ご指摘ありがとうございます。定義が読み取りにくい書き方でした。

ご理解の通り、店舗別の POS データを同一の書名・同一の日付で全店舗合算した販売冊数を指します。5.2 データ整形に、その旨を 1 文で明記いたしました。

新原稿 p.5 左カラム, 5.2 データ整形（記載の追加）：

すなわち本研究における POS 販売冊数とは、ある書名のある日について、全店舗の販売冊数を合計した値である。

【査読者#8 から頂いたコメント】

軽微な修正の要求：5.2 節では、年間総販売冊数が 366 冊に満たない書籍の除外、同一作品のシリーズ単位への統合、ゼロ需要日の補完を経て、最終的に約 40 万件のデータを得たと説明されています。一方で、最終的に分析対象となった書名数が明示されていないため、データの規模を把握しにくいです。元データは約 20 万書名・約 400 万件の販売記録から構成されると説明されているため、前処理後に分析対象となった書名数も併記するとよいと思われま

【著者の回答】

ご指摘ありがとうございます。書名数を書いておりませんでした。

前処理後に分析対象となった書名は 1,157 点です。366 日分と合わせて 423,462 件となります。5.2 データ整形に明記いたしました。

新原稿 p.5 左カラム, 5.2 データ整形（記載の追加）：

前処理後に分析対象となった書名は 1,157 点であり、これに 366 日を掛けた 423,462 件が分析対象である。

【査読者#8 から頂いたコメント】

軽微な修正の要求：本文中では過去の類似系列を参照しない基盤モデルを Baseline と呼んでいる一方で、図 3 の凡例では noRAF と表記されています。両者が同一のモデルを指すのであれば、表記を統一したほうがよいと思われま

【著者の回答】

ご指摘ありがとうございます。同一のモデルを指しております。

図 3 の凡例を Baseline に修正し、本文と統一いたしました。

新原稿 p.9 左カラム, 図 3（凡例の修正）：

凡例の「noRAF」を「Baseline」に変更。

以上のように、頂きましたコメントに対しまして入念な推敲を重ね、論文の加筆・修正を致しましたので、ご確認の程、何卒宜しくお願い申し上げます。

以上のように、頂きましたコメントに従って論文全体の加筆・修正をさせて頂くと共に、再度、入念な推敲を重ねました。多くの貴重なご指摘を頂きまして誠にありがとうございました。頂きましたコメントにより、論文全体の大幅な改善に結び付いたと考えております。再度のご依頼となり大変恐縮ではございますが、ご確認の程、何卒宜しくお願い申し上げます。

以上