

日本経営工学会論文誌 編集委員会御中

査読結果に対する回答書

この度は、私どもの拙稿をご査読並びに非常に有益なご助言を頂きまして、誠にありがとうございました。

ご指摘頂きました箇所を中心に論文全体に対する検討を行い、加筆・修正を致しました。以下に、頂きましたコメントとその回答を記載させて頂きます。また、論文中の修正・追記箇所には査読者#A のご指摘に対する修正箇所は青色の文字、査読者#B のご指摘に対する修正箇所は赤色の文字で示させて頂いております。大変恐縮ではございますが、ご確認の程、何卒宜しくお願い申し上げます。

受付番号：DACR07-3

タイトル：Gate Retrieval-Augmented Forecasting による書籍需要予測

【査読者 A から頂いたコメント】

距離関数 d の選択が結果に与える影響について言及していただきたい。また、本研究の実験において具体的にどの距離関数を用いたのかを本文中に明記する必要があると思われる。

【著者の回答】

ご指摘いただきましてありがとうございました。距離関数の定義を本文に記載しておらず、大変失礼いたしました。

まず、距離尺度に対するご質問ですが、本論文では、標準化後のローカルコンテキストと各ウィンドウとの間の二乗ユークリッド距離を距離尺度として使用するものといたしました。具体的には、ローカルコンテキストとウィンドウ集合の各ウィンドウをそれぞれ平均 0、標準偏差 1 と正規化した上で、各時点の差を二乗して合計した値を使用しております。この距離が小さい上位 K 件を採す処理には、近傍検索のライブラリである Faiss を用いております。

また、距離関数の選択が結果に与える影響についてですが、距離の選択は取得される参照ウィンドウそのものを変えるため、予測結果に影響し得ます。本研究の距離は標準化後の系列に対するものであり、需要の水準や振幅の違いを無視して変動の形状だけで参照を選びます。そのため、需要規模の近さを重視する場合には標準化を行わない距離が、時間軸のずれを許容して形状を照合する場合には動的時間伸縮法が適する可能性がございます。一方で本研究では距離を固定しており、複数の尺度を比較した検証には至っておりません。

ただし、参照に関連度に応じて重み付けして統合する枠組みでは、類似尺度をコサイン類似度・ユークリッド距離・相関係数と変えても 7 つのデータセットの平均 MSE が 0.191~0.194 とほとんど変化しないことが報告されております (S. Lee et al., "Cross-RAG: Zero-Shot Retrieval-Augmented Time Series Forecasting via Cross-Attention," arXiv:2603.14709, 2026)。本研究のゲート機構も同様に関連度で参照を重み付けするため、距離の選択による影響は限定的と考えており、比較は今後の課題といたします。

以上を、2.2 関連研究、3. 従来手法、5.3 実験設定に追記いたしました。

新原稿 p.2 左カラム, 2.2 関連研究 (記載の追加) :

また、Cross-RAG [12] は、検索された参照ウィンドウの有用性が一様ではない点に着目し、

予測対象との関連度に応じて参照をクロスアテンションで重み付けする枠組みを提案している。

新原稿 p.2 右カラム, 3. 従来手法（記載の追加）:

なお本研究では、距離 d として、標準化後のウィンドウ間の二乗ユークリッド距離

$$d(\boldsymbol{x}, \boldsymbol{w}_i) = \sum_{t=1}^L (\boldsymbol{x}_t - \boldsymbol{w}_{i,t})^2 \quad (2)$$

を用いる。ここで $\boldsymbol{x}_t$ と $\boldsymbol{w}_{i,t}$ は、それぞれ $\boldsymbol{x}$ と $\boldsymbol{w}_i$ の第 t 要素を表す。この距離は標準化後の系列に対して定義されるため、系列の水準や振幅の違いを除いた変動の形状の類似度を測ることになる。

距離 d の選択は、取得される参照ウィンドウそのものを変えるため、予測結果に影響し得る。たとえば標準化を行わない距離を用いれば系列の水準や振幅の近さが反映され、動的時間伸縮法を用いれば時間軸のずれを許容した照合が行われるため、いずれも式(2)とは異なる参照ウィンドウが取得される。一方で、参照を関連度に応じて重み付けして統合する枠組みでは、類似尺度を変えても予測精度がほとんど変化しないことが報告されている[12]。提案手法のゲート機構も参照の関連度に応じた重み付けを行い、予測対象との関連が薄い参照の寄与を抑制する。したがって、距離 d の選択により取得される参照ウィンドウが変化しても、予測結果への影響は限定的であると考えられる。ただし本研究では距離を式(2)に固定しており、複数の尺度を比較した検証は今後の課題である。

新原稿 p.6 左カラム, 5.3 実験設定（記載の追加）:

このときの類似度は、式(2)に示した標準化後のウィンドウ間の二乗ユークリッド距離により測るものとし、近傍検索の実装には Faiss[13]を用いた。

【査読者#A から頂いたコメント】

Top-K における K の設定方法について、結果に対する感度を検討する必要があると考える。例えば、K を変化した感度分析や追加実験を行うことで、提案手法の頑健性を示すことができるのではないか。

【著者の回答】

ご指摘ありがとうございます。Kの感度を確認しておりませんでした。

学習済みのモデルに対し、推論時のKを 1 から 8 まで変えて予測精度を比較いたしました。なお、本研究では予測を単一の値ではなく分位点として出力しており、 τ はその水準を表します。 $\tau = 0.5$ が中央の予測値、 $\tau = 0.1$ と $\tau = 0.9$ がそれぞれ予測の下限と上限にあたります。結果は下表の通りです。

K	分位点					
	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	MAE	RMSE	MAE	RMSE	MAE	RMSE
1	3.5978	13.5063	2.7533	12.2612	4.8157	13.0221
2	3.6140	13.5152	2.7496	12.2316	4.9177	13.1424
3*	3.6339	13.5293	2.7452	12.2025	5.0136	13.3030
5	3.6565	13.5242	2.7445	12.1581	5.1744	13.5542
8	3.6846	13.5361	2.7548	12.1453	5.3636	13.9132

中央値 ($\tau = 0.5$) の MAE は $K = 1$ から 8 について 2.745～2.755 となり、その変動は 0.4%以内で

Commented [ミ1]: 指摘をもらっているので、本文中にもきちんと記載しよう。

した。ゲート機構が関連の薄い参照を弱め、参照件数を増やしても予測が乱れないためと考えております。一方、上側分位点 ($\tau = 0.9$) は K が増えるほど誤差が大きくなり、 $K = 1$ の 4.82 に対し $K = 8$ では 5.36 でした。

なお、これは推論時のみ K を変えたもので、 K 別の再学習は行っておりません。学習時の K は 3 であるため、 $\tau = 0.9$ の悪化は、学習時より多くの参照を与えたことの影響と切り分けられておりません。 K 別に学習し直した感度分析は今後の課題とさせていただきます。

関連する報告として、参照に関連度に応じて重み付けして統合する Cross-RAG では、参照件数を 2 件から 14 件まで変えても平均 MSE が 0.1944 から 0.1927 までしか変化しない一方、重み付けを行わない手法では非単調に変動することが示されております (S. Lee et al., arXiv:2603.14709, 2026)。本研究のゲート機構も同種の役割を果たすため、 K に対する頑健性は整合する結果と考えております。

Commented [M2]: 予測が乱れないため、とはどういうことか？

Commented [M3]: 何か理由はある？

Commented [M4]: 唐突に出てきてしまっている。何に対する実験なのかもこれだと不明瞭。なので、これをもって整合する、と言われても読み手は意味が理解できない。

【査読者#A から頂いたコメント】

提案手法では処理を 5 つのステップに分割していることから、従来手法と比較して計算コストが増加する可能性があるように見受けられる。提案手法と従来手法の計算量、学習時間、あるいは予測時間について比較または考察があると、本手法の実用性を評価しやすくなると考える。

【著者の回答】

ご指摘ありがとうございます。計算コストについての記載がなく、また「5 つのステップ」という表現が処理の追加を思わせる書き方になっておりました。わかりづらい記載となり、大変失礼いたしました。結論から申し上げますと、提案手法を用いても計算コストが大きく悪化することはありません。エンコーダの自己注意の計算量は参照件数に対して従来手法より緩やかにしか増えず、実測の推論時間でも従来手法 ProtoRAF の約 1.16 倍にとどまります。以下、計算量と実測の順にご説明いたします。

まず、5 つのステップへの分割は説明の便宜上の区分であり、参照ウィンドウとローカルコンテキストを独立に符号化するための構成でございます。したがって、逐次的な処理の追加を意味するものではありません。Step 1 と Step 2 のエンコードは互いに独立であり、同一のエンコーダへまとめて入力することで並列に実行できます。また、Step 3 から Step 5 はバッチ表現に対する要素ごとの積と多層パーセプトロンの適用にとどまり、エンコーダの処理に比べて無視できる規模でございます。

計算量の観点から申し上げますと、提案手法のエンコーダの自己注意の計算量は、従来手法 ProtoRAF より小さくなります。以下では、ローカルコンテキストおよび参照ウィンドウの長さを L 、エンコーダがこれを分割したパッチの数を P 、エンコーダの埋め込み次元を D 、参照ウィンドウの件数を K と表記いたします。ProtoRAF がパッチ数 $(K + 1)P$ の単一系列を符号化するのに対し、提案手法はパッチ数 P の系列を $K + 1$ 本符号化いたします。自己注意の計算量は系列長の二乗に比例するため、ProtoRAF の $O((K + 1)^2 P^2 D)$ に対し提案手法では $O(K(K + 1)P^2 D)$ となり、参照の連結に伴う二次的な増加は生じません。すなわち参照件数 K に対して、ProtoRAF が二乗で増えるのに対し、提案手法は線形にとどまります。また、ゲート機構が追加する計算量は $O(KPD^2)$ であり、エンコーダ全体と比べて小さい規模です。一方で、提案手法は各参照を独立した系列として扱うため、系列ごとに区切りの要素が付き、処理する要素の数はその分だけ増加いたします。なお、参照ウィンドウの検索に要する計算は両手法で完全に共通であり、本実験の条件では 1 予測あたり 0.20 ミリ秒と、モデルの順伝播に対して無視できる水準でした。

その上で、同一の計算機の GPU 上で同一の入力を与え、各手法の推論時間を 30 回測定した平均を示しております。結果は下表の通りです (バッチサイズ 16, $L = 128$, $K = 3$, 括弧内は Baseline

に対する比).

モデル	推論時間 [ms]
GateRAF	69.9 (2.86)
Multi-RAF	70.1 (2.87)
ProtoRAF	60.1 (2.46)
Baseline	24.4 (1.00)

提案手法は従来手法 ProtoRAF に対し、推論で約 1.16 倍の時間を要します. この増分は参照を独立に符号化することによるものであり、ゲート機構自体による増分は、Multi-RAF との差から 1% 未満 (測定誤差の範囲内) にとどまっております. また、参照数 K を 1 から 8 まで変化させて測定したところ、両手法の比はおおよそ 1.16 から 1.18 でほぼ一定であり、5 つのステップへの分割によって計算量の増え方が悪化するものではないことを確認いたしました.

以上を、4.4 計算コストとして本文に追記いたしました.

新原稿 p.5 左カラム, 4.4 計算コスト (節の新設):

提案手法は処理を 5 つのステップに分けるが、これにより計算コストが大きく悪化することはない.

5 つのステップへの分割は、参照ウィンドウとローカルコンテキストを独立に符号化するための構成であり、逐次的な処理を追加するものではない. Step 1 と Step 2 のエンコードは互いに独立に実行でき、Step 3 から Step 5 はパッチ表現に対する要素ごとの積と多層パーセプトロンの適用にとどまる.

計算量の観点では、ProtoRAF がパッチ数 $(K+1)P$ の単一系列を符号化するのにに対し、提案手法はパッチ数 P の系列を $K+1$ 本符号化する. そのためエンコーダの自己注意の計算量は、ProtoRAF の $O((K+1)^2 P^2 D)$ に対し提案手法では $O((K+1) P^2 D)$ となり、参照の連結に伴う二次的な増加は生じない. ゲート機構が追加する計算量は $O(KPD^2)$ であり、エンコーダ全体と比べて小さい規模にとどまる. また、参照ウィンドウの検索に要する計算は両手法で共通である.

【査読者#A から頂いたコメント】

販売冊数に生じるスパイクの大きさや発生頻度について、さらなる考察が必要であるように思われる. 書籍の売上は、さまざまな契機によって一時的に大きく増加する可能性があるが、その頻度や規模によって予測の難易度も異なると考えられる. 例えば、スパイクの頻度や大きさごとに予測性能を評価することで、提案手法がどのような状況で有効であるかをより明確にできるのではないかな.

【著者の回答】

スパイクの現れ方による評価が不足しており、大変失礼いたしました. 貴重なご指摘をいただきまして誠にありがとうございました.

ご指摘いただいた 2 つの観点のうち、スパイクの大きさにつきましては、表 2 の z スコアがその時点の需要が平常水準からどれだけ離れているかを表しており、 z スコアによる区分がスパイクの大きさ別の評価に該当いたします. 一方、発生頻度による評価は行っておりませんでした. そこで、評価期間の 64 日のうち z スコアが 2.0 以上となった時点の数を発生頻度とし、書名を層別した評価を新たに追加いたしました. なお、一度もスパイクが生じなかった 25 書名は層別の対象とな

らないため除外し、残る 1,132 書名を対象としております。結果は下表の通りです。本研究では予測を単一の値ではなく分位点として出力しており、 τ はその水準を表します。 $\tau = 0.5$ が中央の予測値、 $\tau = 0.1$ と $\tau = 0.9$ がそれぞれ予測の下限と上限にあたります。紙面の都合上 MAE のみを示しており、RMSE を含む全体は新原稿の表 3 に掲載しております。

モデル	1	2	3	4	5	6 以上
対象書名数	104	253	337	264	102	72
$\tau = 0.1$						
GateRAF	2.10	4.04	3.53	3.61	4.15	4.92
Multi-RAF	2.27	4.22	3.65	3.68	4.34	5.07
ProtoRAF	2.08	4.10	3.55	3.67	4.31	4.70
Baseline	2.07	4.09	3.54	3.66	4.29	4.67
$\tau = 0.5$						
GateRAF	1.61	3.06	2.70	2.85	3.24	2.92
Multi-RAF	1.65	3.15	2.78	2.87	3.32	2.99
ProtoRAF	1.80	3.29	2.90	3.10	3.53	4.49
Baseline	1.80	3.29	2.90	3.09	3.52	4.49
$\tau = 0.9$						
GateRAF	4.53	5.17	4.63	4.69	5.68	7.56
Multi-RAF	3.84	5.14	4.66	4.67	5.82	7.81
ProtoRAF	4.65	6.34	5.65	6.12	10.50	16.40
Baseline	4.65	6.34	5.65	6.12	10.45	16.40

発生頻度別にみますと、中央値 ($\tau = 0.5$) の MAE の改善率は、1 回から 5 回では約 7~11%であるのに対し、6 回以上では約 35%に達します。上側分位点 ($\tau = 0.9$) ではこの傾向がより明瞭で、改善率は発生頻度とともに約 3%から約 54%まで増大いたします。これは、参照を連結する ProtoRAF がスパイクの多い系列ほど上側分位点を過大に出力するのに対し、提案手法ではこれが抑えられるためと考えております。なお、系列内の z スコアの最大値、すなわち系列ごとのスパイクの最大規模により層別した場合も、いずれの区分で GateRAF の MAE が最小であることを確認しております。

以上を、5.1 実験概要、5.3 実験設定、5.4.2 実験 2 の 3 箇所に追記いたしました。発生頻度別の結果は表 3 として新たに掲載しております。

新原稿 p.5 右カラム、5.1 実験概要（記載の修正）：

以上の枠組みのもとで、予測精度の算出（実験 1）、スパイクの大きさと発生頻度による予測精度（実験 2）、時間近接性（実験 3）、予測区間幅の比較（実験 4）、代表系列の事例分析（実験 5）の 5 つの実験を行う。

新原稿 p.6 右カラム、5.3 実験設定（記載の追加）：

z スコアはその時点の需要が平常水準からどれだけ離れているかを表すため、z スコアによる区分はスパイクの大きさによる評価にあたる。実験 2 ではこれに加えて、スパイクの発生頻度による層別も行う。評価期間の 64 日のうち z スコアが 2.0 以上となった時点の数を発生頻度とし、書名を区分する。大きさによる区分が個々の需要の水準に着目するのに対し、発生頻度に

よる区分は系列ごとのスパイクの現れやすさに着目するものである。なお、評価期間中に一度もスパイクが生じなかった25書名は、発生頻度による層別の対象とならないため除外し、残る1,132書名を対象とする。

新原稿 p.7 右カラム, 5.4.2 実験2 (記載の追加) :

zスコアによる区分はスパイクの大きさによる評価にあたるため、表2がスパイクの大きさ別の結果に該当する。これに加えて、5.3節で述べた発生頻度により層別した結果を表3に示す。発生頻度別にみると、中央値 ($\tau = 0.5$) のMAEの改善率は、1回から5回では約7~11%であるのに対し、6回以上では約35%に達する。上側分位点 ($\tau = 0.9$) ではこの傾向がより明瞭で、改善率は約3%から約54%まで増大する。これは、参照を連結するProtoRAFがスパイクの多い系列ほど上側分位点を過大に出力するのに対し、提案手法ではこれが抑えられるためと考えられる。

(表3「スパイクの発生頻度により層別したMAEおよびRMSE」を新規追加)

【査読者#Aから頂いたコメント】

目的変数Yが具体的に何を表しているのかを、本文中で明記する必要があると考える。例えば、ある時点における販売冊数そのものなのか、一定期間内の販売冊数なのかを明確にしていきたい。

【著者の回答】

ご指摘ありがとうございます。目的変数の定義を本文に記載しておらず誠に申し訳ございません。

本研究の目的変数は、書名ごとに全店舗の販売冊数を日単位で合算した値であり、将来の各日における販売冊数そのものです。従いまして、一定期間の累計ではございません。予測値の各要素も、予測起点から数えた特定の1日の販売冊数にあたります。

以上の点につきまして2.1節と4.3節に明記いたしました。

新原稿 p.2 左カラム, 2.1 問題設定 (記載の追加) :

予測の対象は、書名ごとに全店舗の販売冊数を日単位で合算した時系列であり、目的変数は将来の各日における販売冊数そのものとする。すなわち、一定期間の累計販売冊数ではなく、1日単位の販売冊数を予測の対象とする。

新原稿 p.5 左カラム, 4.3 予測 (記載の追加) :

また、 $\hat{Y}$ の第 (q, f) 要素は、予測起点から f 日先の1日における販売冊数について、 Q の第 q 番目の分位点に対応する予測値を表す。すなわち、 $\hat{Y}$ の各要素は特定の1日の販売冊数であり、複数日にわたる累計ではない。

【査読者#Aから頂いたコメント】

本論文における「需要」の定義を明確にしていきたい。本研究で直接観測されているのは販売冊数であり、潜在的な需要そのものとは必ずしも一致しないと考えられる。販売冊数、販売冊数の予測値、および需要の関係を整理した上で、用語を定義することが望ましい。

【著者の回答】

ご指摘ありがとうございます。需要と販売冊数を区別せずに用いてしまい、余計な混乱を招い

てしまっておりまして、大変失礼いたしました。

本研究が実務上目指しているのは、需要に見合う量を入荷することです。入荷が需要に届かなければ機会損失が生じ、需要を上回れば売れ残って返本になります。第 6 章で評価しているのはこの過不足であり、本来予測したいのは需要そのものとなります。

一方で、実際に観測できる指標は販売された冊数だけとなっております。このため、売り切れた日には販売冊数が入荷量で頭打ちになり、需要に対して十分な量が店舗に存在した場合に何冊売れたはずか、という情報を算出することはできません。本研究の POS データには在庫や入荷の情報が含まれないため、上記の状況が生じているのか否かを確認することはできません。

そこで、販売冊数を需要の観測可能な代理指標として扱い、需要予測は販売冊数の予測を指すものと定義いたしました。しかしながら、学習に用いる販売冊数自体が売り切れによって過小に記録されている可能性があり、モデルはスパイク時の水準を実際より低く学習することになるという限界も存在しております。図 4 の書籍 B で実績の水準を再現できていないことにも、この影響が含まれている可能性があると考えております。

以上を 2.1 節に明記いたしました。

新原稿 p.2 左カラム, 2.1 問題設定 (記載の追加):

本研究で観測できるのは実際に販売された冊数であり、これを販売冊数と呼ぶ。消費者が買いたいと考えた量である需要は、在庫切れがあれば販売冊数を上回るが、本研究の POS データには在庫情報がないため観測できない。そこで販売冊数を需要の代理指標とし、需要予測は販売冊数の予測を指すものとする。

【査読者#A から頂いたコメント】

図 4 では、書籍 A および B について予測値と実績値の比較が示されている。従来手法と比較して予測精度が改善していることは確認できる一方で、少なくとも図からはスパイクそのものを十分に予測できているとは判断しにくい。本研究ではスパイクへの対応が重要な目的の一つであると理解しているため、スパイク発生時に限定した予測性能の評価や、定量的な指標を追加するなど、提案手法の有効性を補足する分析があるとよい。

【著者の回答】

ご指摘ありがとうございます。図 4 だけではスパイクへの対応が分かりづらく、大変失礼いたしました。ご指摘の通り、提案手法はスパイクの高さそのものを当てきれておりません。図 4 の書籍 B では、スパイク時の実績が平均 25 冊であるのに対し、提案手法の予測は 9 冊にとどまります。ただし、従来手法 ProtoRAF は 1 冊未満とほとんど反応しておらず、提案手法は少なくとも需要が立ち上がったこと自体は捉えております。また書籍 A では、スパイク時の誤差が提案手法 2.4 冊、ProtoRAF 7.5 冊であり、実績にほぼ沿った予測ができております。

そこで、スパイクの高さを当てられていないなかで提案手法が何を示すことができているのかを明らかにするため、スパイクの時点に限定した定量的な指標を新たに追加いたしました。算出の手順は次の通りでございます。まず書名ごとに、評価期間 64 日の実績値から平均と標準偏差を求め、各時点の実績値を z スコアへ変換いたします。次に、 z スコアが 2 を超える時点を実際のスパイクの時点と定めます。そのうえで、各分位点の予測値の平均を実績値の平均で割った捕捉率を求めました。時点 t の実績値を y_t 、分位点 τ の予測値を $\hat{y}_{t,\tau}$ 、その時点の z スコアを z_t といたします。スパイクの時点、すなわち $z_t > 2$ となる時点に限り、捕捉率 R を次により求めました。

$$R = \frac{\sum_t y_t}{\sum_t \hat{y}_{t,\tau}}$$

ここで $\sum_t$ は $z_t > 2$ を満たす時点についての和で、 R は τ が 0.1, 0.5, 0.9 のそれぞれについて算出し

ております。平常時、すなわち $z_t < 0$ となる時点についても同じ式で算出し、両者を比較いたしました。 R が100%を下回れば実績の平均より低い予測を、上回れば高い予測を出していることになります。実績値の平均は、スパイクの時点で22.54冊、平常時で1.47冊でございます。結果は下表の通りです。

モデル	スパイク時			平常時		
	$\tau = 0.1$	$\tau = 0.5$	$\tau = 0.9$	$\tau = 0.1$	$\tau = 0.5$	$\tau = 0.9$
GateRAF	11.7%	27.1%	56.9%	6.2%	115.0%	405.3%
Multi-RAF	11.1%	26.7%	56.2%	-0.1%	116.9%	403.3%
ProtoRAF	8.9%	21.4%	53.3%	13.0%	139.6%	554.3%
Baseline	8.9%	21.5%	53.3%	13.9%	139.8%	553.9%

スパイクの時点では、いずれの手法も R が100%を大きく下回っており、実績の水準に届いておりません。中央値($\tau = 0.5$)で提案手法は27.1%、従来手法ProtoRAFは21.4%、上側分位点($\tau = 0.9$)でも提案手法56.9%、ProtoRAF53.3%です。提案手法の方が高い値ではございますが、スパイクの高さそのものを再現できているとはいえません。

着目いただきたいのは平常時との対比でございます。平常時では R が逆に100%を上回り、中央値で提案手法115.0%に対しProtoRAFは139.6%、上側分位点では提案手法405.3%に対しProtoRAFは554.3%です。すなわち従来手法が平常時に実績よりかなり高い予測を出しているのに対し、提案手法はその過大さが小さく抑えられております。スパイクの時点では R が従来手法より高く、平常時では低い。上側分位点を一律に広げて当てにしているのではなく、スパイクの時点を選んで予測の水準と幅を引き上げている、という点は示すことができていると考えております。なお、スパイクの時点のうち実績が $\tau = 0.9$ の予測に収まっていた割合は、提案手法が34.6%、ProtoRAFが29.9%であり、いずれも名目の90%を大きく下回っております。

以上を踏まえますと、提案手法が示すことができているのは、スパイクの高さを当てることではなく、スパイクの生じる時期に予測の水準と幅を選択的に引き上げられている、ということでございます。実務上は、平常時に在庫を積み増すことなく、スパイクの生じる時期に絞って発注を厚くする判断に資するものと考えております。

以上を、5.4.2 実験2の考察に追記いたしました。また5.4.5 実験5の記載にも、スパイクの時点に限定した評価がどこにあるかを明記しております。

新原稿 p.8 左カラム, 5.4.2 実験2 (記載の追加):

次に、スパイクの高さをどの程度再現できているかを確認する。時点 t の実績値を y_t 、分位点 τ の予測値を $\hat{y}_t$ 、その時点の z スコアを z_t とし、 $z_t > 2$ となる時点に限り、予測値の平均を実績値の平均で割った捕捉率 R を次により求める:

$$R = \frac{\sum_t \hat{y}_t}{\sum_t y_t}$$

ここで $\sum_t$ は $z_t > 2$ を満たす時点についての和である。 R が100%を下回れば実績の平均より低い予測を、上回れば高い予測を出していることを意味する。平常時、すなわち $z_t < 0$ となる時点についても同じ式で算出し、両者を比較する。

スパイクの時点における提案手法の R は $\tau = 0.5$ で27.1%、 $\tau = 0.9$ で56.9%であり、ProtoRAFの21.4%、53.3%を上回るが、いずれも100%を大きく下回る。一方、平常時では R が100%を超え、提案手法は $\tau = 0.5$ で115.0%、 $\tau = 0.9$ で405.3%であるのに対し、ProtoRAFは139.6%、554.3%である。すなわち提案手法は、スパイクの時点では R が従来手法より高く、平常時では低い。上側分位点を一律に広げているのではなく、スパイクの時点で選択的に予測の水準と幅

を高めている。Multi-RAF もほぼ同等であり、この性質は主にマルチストリームエンコードによる。

以上より、提案手法の寄与はスパイクの高さの再現ではなく、立ち上がりの時期と不確実性の提示にある。販売冊数は在庫が尽きた時点で頭打ちとなるため学習データ自体が高さを過小に含み、またスパイクの契機は受賞や映像化といった外生的な事象にあるため、販売履歴のみから高さを決めることは原理的に難しい。高さの再現は本研究の限界である。

新原稿 p.10 右カラム, 5.4.5 実験 5 (記載の追加) :

ただし書籍 B では、予測の上昇は実績の急増に比べて小さく、スパイクの水準までは再現できていない。なお、スパイクの時点だけに限った評価は表 2 の z スコアが 2 以上の区分に、スパイクの位置のずれの評価は表 4 に示している。また、スパイクの高さの再現と上側分位点による被覆については 5.4.2 項で述べた通りである。

【査読者#A から頂いたコメント】

第 6 節では返本および機会損失について議論されているが、そこで示された改善が実社会においてどの程度のインパクトを持つのかを、より明確に示していただきたい。可能であれば、返本冊数や機会損失冊数だけでなく、金額換算した効果やリスクの大きさなどを示すことで、提案手法の実務的な意義がより理解しやすくなると思う。

【著者の回答】

ご指摘いただきましてありがとうございます。冊数のみでは実務上の規模が伝わりにくいというご指摘の通りです。大変失礼いたしました。

データに含まれる本体価格を基に金額に換算いたしました。GateRAF の過剰入荷は 3,173 万円、機会損失は 1 億 2,052 万円で、Baseline と比べ合わせて約 1,560 万円の損失を抑えられております。(評価対象は 1,157 書名の 64 日分、本体価格ベースの売上 2 億 1,369 万円)。

ただし、本試算は在庫の繰越を考慮しない日毎に独立であることを仮定したシミュレーションであり、売り上げの半分程度が機会損失となってしまうています。在庫の繰越を考慮していないことから、機会損失は過大に生じてしまうこと、主張したいのは手法間の金額の差であることから、これを追加するものとなりました。

あわせて、はじめに述べた物流コストと在庫リスクの観点からの意味づけも加えました。返本は書店から取次・出版社への返品であり往復の輸送を伴いますが、GateRAF は Baseline に対し返本を 16,201 冊減らしております。また委託販売制度のもとで売れ残りの在庫リスクを負うのは出版社であるため、過剰入荷の抑制はそのリスクの軽減にあたります。機会損失も同時に 6,073 冊減っており、欠品を増やさずにこれを実現しております。

以上を、表 7 の金額列と 6 章の考察 2 段落として追記いたしました。

新原稿 p.11, 表 7 (金額列の追加) :

モデル	返本率	金額 [万円]	
		過剰入荷	機会損失
GateRAF	12.33%	3,173	12,052
Baseline	16.39%	4,401	12,384
SARIMA	29.85%	9,361	11,239
Prophet	53.13%	23,170	23,607

新原稿 p.12 左カラム, 6. 返本と機会損失の観点からの評価（記載の追加）:

これらを本体価格で金額に換算すると、GateRAF の過剰入荷は 3,173 万円、機会損失は 1 億 2,052 万円となる。Baseline と比べると返本が 1,228 万円、機会損失が 332 万円減り、提案手法を用いることで約 1,560 万円の損失を抑えられることが示唆される。評価対象は 1,157 書名の 64 日分（本体価格ベースの売上 2 億 1,369 万円）であり、返本の抑制が金額でも相応の、規模になることがわかる。

また、返本は書店から取次・出版社への返品であり、往復の輸送と在庫の再処理を伴う。GateRAF は Baseline に対し返本を 16,201 冊減らしており、その分の物流コストが低減可能となる。加えて、委託販売制度のもとでは売れ残りの在庫リスクを出版社が負うため、過剰入荷の抑制はそのリスクの軽減を可能とする。GateRAF は機会損失も同時に 6,073 冊減らしており、欠品を増やさずに実現可能であることからその有効性を示すことができた。

【査読者#A から頂いたコメント】

図表中の文字が小さく、一部が読み取りにくい。文字サイズやレイアウトを調整し、視認性を改善していただきたい。

【著者の回答】

ご指摘いただきましてありがとうございました。また、表の文字が小さく、大変申し訳ございませんでした。再度図表の文字サイズを確認し、みやすくなるように全体を修正いたしました。修正後の本文にてご確認いただけると幸いです。

【査読者#A から頂いたコメント】

オンライン変化点検知など、時系列データにおける急激な構造変化を検出する手法も比較対象となり得るように思われる。これらの手法を比較対象に含めることが適切でない場合には、その理由について考察があるとよい。

【著者の回答】

大変貴重なご指摘、誠にありがとうございました。本研究では変化点検知を行わず、RAF をベースとした手法を用いております。その理由を以下に記載させていただきます。

変化点検知は、観測された系列に変化が生じたかを判定する検出の手法であり、その出力は変化点の位置や確率です。一方、本研究は予測期間の観測を一切用いずに、直近 128 日から続く 64 日の販売冊数を分位点として出力する予測の問題です。すなわち、変化点検知が出力する変化点の位置や確率と、本研究が出力する将来 64 日分の販売冊数の分位点とでは、出力の形式そのものが異なります。そのため、MAE や RMSE、返本や機会損失といった本研究の指標で両者を並べて比較することができません。

また、オンライン変化点検知は変化が始まった後の観測から検知するため、検知には遅れが伴い

ます。本データのスパイクは短く、 z スコアが2を超える時点が連続する区間を1回のスパイクと数えますと、評価期間の64日間に全書名で2,896回生じており、そのうち79.5%が1日で終わり、94.9%が2日以内に収まります。最も長いものでも7日でした。仮に逐次観測できる設定であっても、検知できた時点ではスパイクが過ぎており、事前に備えるという目的には合いません。

一方で、変化点検知を予測手法の一部として使う余地はあると考えております。系列を局面ごとに区切り、参照ウィンドウの検索範囲や直近区間を現在の局面に限定するという使い方です。この点は今後の課題とさせていただきます。

以上を、5.1 実験概要に追記いたしました。

新原稿 p.5 右カラム, 5.1 実験概要（記載の追加）：

なお、系列の急激な変化を扱う手法として変化点検知があるが、本研究では比較対象としない。変化点検知は観測から変化の発生を判定する検出の問題であり、出力は変化点の位置や確率であるため、将来の販売冊数を分位点として出力する本研究とは MAE や RMSE で並べて比較できない。また、検知は変化が始まった後の観測に基づくため遅れを伴う。本研究が対象とするスパイクは、需要が平常水準から大きく離れた時点が連続する区間のうち 79.5%が1日、94.9%が2日以内に収まり、最も長いものでも7日である。そのため、検知できた時点ですでにスパイクが過ぎている。一方、変化点検知を参照ウィンドウの検索範囲の限定などに用いる余地はあり、今後の課題である。

【査読者#A から頂いたコメント】

本研究では主として販売冊数の時系列情報を用いて予測していると理解している。一方で、書籍の突発的な売上増加には、SNS 上での話題化、ドラマ化・映画化、本屋大賞等の受賞やノミネート、メディアでの紹介など、外生的な要因が大きく関与すると考えられる。これらの情報を共変量として利用する可能性について、今後の課題を含めて考察していただきたい。

【著者の回答】

大変貴重なご指摘、誠にありがとうございました。販売冊数の履歴だけでは外生的な契機を捉えきれず、データの外から得られる情報を活用することが重要である、というご指摘の通りでございます。提供いただいたデータには、SNS での話題化や映像化、受賞といった情報は含まれておらず、販売実績のほかは出版社、著者名、分類、本体価格といった書籍属性のみでした。そのうえで、現在の手法で補えている点と、今後の対応方針を申し上げます。

まず、提案手法は外生的な要因を間接的に取り込んでいる面がございます。外生的な契機で生じたスパイクは過去に他の書籍にも現れており、提案手法はその変動パターンを系列横断的に検索して参照するためです。実験3で提案手法の誤りが実際のスパイクの近傍に集中することは、その現れと考えております。

しかし、査読者のご指摘の通り、外生的な要因を扱うことはモデルの性能向上に寄与する可能性が高いと考えております。そこで、考えられる方策について、以下の通り考察と今後の課題を追記いたしました。データに含まれる書籍属性を参照ウィンドウの検索条件に加える方法は、現在のデータのままで実現できます。受賞や映像化の日付を外部から収集し、共変量として与える方法も考えられますが、本研究の基盤モデルは単変量であり共変量を直接扱えないため、共変量を扱える基盤モデルへの拡張が必要になります。

以上を、5.4.2 実験2の考察に追記いたしました。

新原稿 p.8 右カラム, 5.4.2 実験2（記載の追加）：

この限界に対しては、外生的な契機を共変量として扱う拡張が考えられる。本研究の基盤モデルは単変量であり共変量を直接扱えないため基盤モデルの拡張を要するが、出版社や分類などの書籍属性を参照ウィンドウの検索条件に加える方法であれば、現在のデータのまま実現できる。

以上のように、頂きましたコメントに対しまして入念な推敲を重ね、論文の加筆・修正を致しましたので、ご確認の程、何卒宜しくお願い申し上げます。

【査読者#B から頂いたコメント】

実験 1~5 について、各実験が提案手法のどの側面を検証するためのものかは本文中で述べられているものの、実験結果の報告前の段階で、「どのような結果が得られれば提案手法の有用性が支持されるのか」がやや読み取りづらいです。たとえば、実験 1 では全体的な予測精度、実験 2 では需要水準別の誤差特性、実験 3 ではスパイク予測の時間的近接性、実験 4 では予測区間幅と需要変動の対応、実験 5 では代表系列における挙動確認を意図していると理解しました。各実験の目的と期待される結果の解釈を実験設定の段階で簡潔に整理すると、結果の読み取りがより容易になると考えられます。

【著者の回答】

ご指摘ありがとうございます。各実験の結果をどう読めばよいかを、結果の報告前に述べておりませんでした。

ご理解の通りの意図で各実験を設けております。そこで 5.3 実験設定の各実験の説明に、どのような結果が得られれば提案手法が支持されるのかを 1 文ずつ加えました。

新原稿 p.6~7, 5.3 実験設定（記載の追加）:

実験 1：いずれの分位点でも従来手法より MAE と RMSE が小さければ、予測全体の精度が改善したといえる。

実験 2：スパイク域で誤差が小さく、かつ静穏域でも誤差が増えていなければ、スパイクの捕捉と平常時の精度が両立しているといえる。あわせて系列ごとのスパイクの多さでも層別し、スパイクが多く現れる系列ほど改善が大きければ、過去の類似事例の参照が効いているといえる。

実験 3：| Δ |の小さい割合が従来手法より高ければ、予測したスパイクが実際のスパイクの近くに集まっているといえる。

実験 4：幅の広い区分ほど実績の z スコアが高ければ、予測の不確実性が実際の需要変動に対応しているといえる。

実験 5：需要が減衰する系列で過大な予測が抑えられ、急増する系列で予測が立ち上がっていれば、2 つの工夫がそれぞれ意図した通りに働いているといえる。

【査読者#B から頂いたコメント】

実験 2：各 z スコアの区分に含まれる観測数はどの程度でしょうか？特に $z > 3$ のようなスパイク域は時点数が少ない可能性があるので、そこでの MAE/RMSE がどれくらい安定しているかに疑義が生じます。各区分の観測数などを併記すると、表 2 の解釈可能性が高まると考えられます。

【著者の回答】

ご指摘いただきまして誠にありがとうございました。時点数を示しておらず、可読性が低い文章となっておりまして、大変失礼いたしました。

当該実験における評価の対象は 1,157 書名の 64 日分、計 74,048 時点です。時点数は、 z スコアが -1 未満の区分が 3,381 時点、 $-1 \sim 0$ が 46,775 時点、 $0 \sim 1$ が 14,144 時点、 $1 \sim 2$ が 6,054 時点、 $2 \sim 3$ が 2,261 時点、 3 以上が 1,433 時点です。

また、ご指摘いただきました通り、 z スコアが 0 を超える範囲では、区分が上になるほど時点数は少なくなります。ただし最も少ない $z > 3$ の区分にも 1,433 時点が含まれており、標本数としては問題ないと考えております。

以上を踏まえ、表 2 に各区分の時点数を示す行を追加し、本文にもその旨を記載いたしました。

新原稿 p.9, 表 2 (記載の追加) :

各区分の時点数を示す行を最上段に追加。なお表 2 につきましては、図表の視認性に関する査読者 #A のご指摘にも併せて対応しており、 z スコアの区分を 1 刻みに統合して列数を減らすとともに、表全体の縮小表示をやめて文字を大きくしております。

新原稿 p.7 右カラム, 5.4.2 実験 2 (記載の追加) :

なお、各区分に含まれる時点数は表 2 の最上段に示す通りである。最も時点数の少ない $z > 3$ の区分にも 1,433 時点 (全時点の 1.9%) が含まれており、区分ごとの比較に足る標本数が確保されている。

【査読者 #B から頂いたコメント】

実験 2 では、各時点の実績値を「その系列全体の平均と標準偏差」で標準化した z スコアに基づいて時点を区分していると説明されています。一方で、時系列予測において評価期間を含む全期間の統計量を前処理やモデルの入力に用いる場合、将来情報の利用、すなわち data leakage と誤解される可能性があると思われます。本実験では、当該 z スコアはモデルの学習・推論に用いられるものではなく、予測後に需要水準別の誤差を確認するための事後的な層別指標であると理解しました。この理解でよい場合、 z スコアの算出に用いた期間、および当該 z スコアがモデルの学習・推論には用いられていないことを本文中で明示するとよいと思われます。

【著者の回答】

大変貴重なご指摘をいただきまして誠にありがとうございました。査読者のご指摘の通り、事後的な層別指標であるという認識となります。この z スコアは、予測を終えた後に誤差を需要水準別に集計するための指標であり、モデルの学習にも推論にも用いておりません。

算出に用いた期間は、各書名の評価期間、すなわち予測対象の 64 日です。この 64 日の実績値から書名ごとに平均と標準偏差を求め、各時点の実績値を標準化しております。実験 3 でスパイクを定義する際の z スコア、実験 4 で集計する z スコアも同じものです。

なお、こちらも確認となりますが、モデル側では将来の情報を用いておりません。入力の標準化は直近 128 日のローカルコンテキストの平均と標準偏差のみで行っており、参照ウィンドウの検索も、予測起点より前に終わるウィンドウに限っております。学習に用いる予測対象の期間も、評価期間と重ならないようにしております。

以上の点につきまして、5.3 実験設定の実験 2 の説明に明記いたしました。

新原稿 p.6 右カラム, 5.3 実験設定 (記載の追加) :

ここでの平均と標準偏差は、各系列の評価期間、すなわち予測対象の 64 日の実績値から算出し

たものである。この z スコアは、予測を終えた後に誤差を需要水準別に集計するための層別指標であり、モデルの学習および推論には一切用いていない。予測に用いる標準化はローカルコンテキストの平均と標準偏差のみによるため、評価期間の情報が予測に流入することはない。実験3および実験4で用いる z スコアについても同様である。

【査読者#Bから頂いたコメント】

実験3：表3の解釈について確認させてください。本文では、予測した各スパイクについて最も近い実スパイクとの時間差を求めたものを「誤検知」、実際の各スパイクについて最も近い予測スパイクとの時間差を求めたものを「見逃し」として集計していると理解しました。この理解に基づく、たとえば誤検知における GateRAF の $\Delta = -10$ の値は、「GateRAF が予測スパイクとした時点のうち、最も近い実スパイクよりも10日以上後方に位置したものの割合」を示している、という理解でよろしいでしょうか。「誤検知」および「見逃し」の割合の具体的な計算方法が本文からやや読み取りづらいため、可能であれば数式または簡単な例を用いて説明していただけると、表3の解釈が容易になると思われます。

【著者の回答】

はじめに1点お断りいたします。改訂稿ではスパイクの発生頻度別の評価を表3として新たに追加したため、ご指摘いただきました表3は、改訂稿では表4に繰り下がっております。以下では改訂稿の番号で申し上げます。

ご理解の通りです。 Δ は実スパイクの日から予測スパイクの日を引いた値ですので、誤検知の Δ が負であることは、予測したスパイクが最も近い実スパイクより後にあることを意味します。

ただし、割合の分母について1点補足させていただきますと、分母は予測スパイクとした時点の総数ではなく、そのうち実スパイクと一致しなかったもの、すなわち誤検知の総件数となります。実スパイクと一致した予測スパイクは誤検知に含めないため、 $\Delta = 0$ の割合は定義上0となります。見逃しも同様に、予測できなかった実スパイクの総件数を分母としております。読み取りづらい内容となっておりますので、大変申し訳ありませんでした。

改訂稿では別の査読者からいただきましたご指摘に対応するため、表の見やすさを優先し、 Δ を $-5 \sim +5$ 日の範囲にまとめております。前の原稿の $\Delta = -10$ に相当するのは、改訂稿では $\Delta \leq -5$ の列、すなわち実スパイクより5日以上後に出された誤検知の割合です。

算出方法を具体的に示すため、簡単な例を記載させていただきます。ある書名について、実スパイクが20日目のみに観測され、予測スパイクが17日目と25日目に観測されたとします。17日目の予測は実スパイクと一致しないため誤検知となり、最も近い実スパイクは20日目となることから $\Delta = 20 - 17 = +3$ と計算することができます。同様に、25日目の予測についても誤検知であり、 $\Delta = 20 - 25 = -5$ です。一方、20日目の実スパイクは正しく予測できていないため見逃しとなり、最も近い予測スパイクは17日目となることから $\Delta = 20 - 17 = +3$ と計算を行うことができます。

このように求めた Δ を、実スパイクと予測スパイクがともに1つ以上ある書名について全系列分集め、 Δ ごとの件数を誤検知・見逃しそれぞれの総件数で割ったものが表の値となります。いずれか一方でも存在しない書名は、最も近い相手スパイクが定まらないため対象外としております。

以上を、5.3 実験設定に式と例を用いて明記いたしました。

新原稿 p.6 右カラム, 5.3 実験設定（記載の修正・追加）：

予測した各スパイクについては最も近い実スパイクとの時間差を、実際の各スパイクについては最も近い予測スパイクとの時間差を符号付きの日数 Δ として求める。前者の分布を誤検知、後者の分布を見逃しと呼ぶ。

ある系列において、実スパイクの日を a 、予測スパイクの日を $\hat{a}$ と表す。実スパイクと一致した予測スパイクは誤検知に含めず、予測できた実スパイクは見逃しに含めない。誤検知については予測スパイクの日 $\hat{a}$ に最も近い実スパイクの日 a をとり、見逃しについては実スパイクの日 a に最も近い予測スパイクの日 $\hat{a}$ をとって、いずれも

$$\Delta = a - \hat{a}$$

とする。 Δ は予測が実スパイクより前なら正、後なら負となり、 $|\Delta|$ が小さいほど時間的に近く捉えられていることを意味する。なお、実スパイクと予測スパイクがともに 1 つ以上ある系列のみを対象とする。

評価では Δ を $-5 \sim +5$ 日の範囲で集計し（両端は $|\Delta| \geq 5$ としてまとめる）、 Δ の値ごとの件数を、誤検知・見逃しそれぞれの総件数で割った割合として算出する。

【査読者#8 から頂いたコメント】

実験 3：加えて、表 3 からは誤検知・見逃しの時間的分布は読み取れる一方で、各モデルがどの程度多く予測スパイクを出し、そのうちの程度が誤検知または見逃しに該当したのかを判断しにくいです。各モデルの予測スパイク数や誤検知数、見逃し数の絶対数を併記することで、実験 3 の解釈可能性が高まると考えられます。

【著者の回答】

ご指摘ありがとうございます。絶対数を示しておらず、大変失礼いたしました。なお、ご指摘いただきました表 3 は、改訂稿では表 4 に繰り下がっております。

表 4 右側に 2 列を追加いたしました。誤検知の行には予測スパイク数と誤検知数を、見逃しの行には実スパイク数と見逃し数を示しております。GateRAF は予測スパイクの数が ProtoRAF より少ないにもかかわらず、誤検知も見逃しも少なくなっております。

1 点補足いたします。 Δ の割合は、実スパイクと予測スパイクをともに 1 件以上もつ書名だけで集計しております。片方でも無いと最も近い相手が定まらないためです。そのため割合の分母は、表の誤検知数や見逃し数とは一致いたしません。とくに見逃しについては、予測スパイクを 1 件も出していない書名が対象から外れるため、分母は見逃し数よりかなり小さくなります。この表は、予測が反応した書名においてずれがどの程度かを示すものとご理解いただければ幸いです。

以上を踏まえ、表 4 に絶対数の 2 列を追加し、5.4.3 実験 3 にその説明を記載いたしました。表 4 は下表の通りです。

新原稿 p.9, 表 4（記載の追加）:

モデル	≤ -5	-4	-3	-2	-1	$+0$	$+1$	$+2$	$+3$	$+4$	$\geq +5$		
誤検知												予測スパイク数	誤検知数
GateRAF	0.381	0.020	0.025	0.041	0.078	0.000	0.055	0.031	0.031	0.031	0.307	996	893
Multi-RAF	0.459	0.016	0.030	0.041	0.070	0.000	0.057	0.032	0.027	0.030	0.239	841	744
ProtoRAF	0.665	0.022	0.025	0.028	0.050	0.000	0.044	0.029	0.028	0.015	0.094	1,348	1,276
Baseline	0.667	0.022	0.025	0.028	0.050	0.000	0.043	0.028	0.028	0.015	0.093	1,353	1,282
見逃し												実スパイク数	見逃し数
GateRAF	0.253	0.012	0.043	0.043	0.086	0.000	0.068	0.037	0.025	0.037	0.395	3,694	3,591
Multi-RAF	0.263	0.000	0.033	0.033	0.072	0.000	0.072	0.026	0.020	0.026	0.454		3,597
ProtoRAF	0.403	0.014	0.007	0.007	0.035	0.000	0.062	0.042	0.035	0.021	0.375		3,622
Baseline	0.411	0.014	0.007	0.007	0.035	0.000	0.057	0.043	0.035	0.021	0.369		3,623

新原稿 p.8 右カラム, 5.4.3 実験 3 (記載の追加):

絶対数は表 4 の右の 2 列に示す. GateRAF は予測スパイクの数が ProtoRAF より少ないにもかかわらず誤検知・見逃しがともに少なく, スパイクの予測がより絞り込まれている. なおΔの割合は, 最も近い相手が定まる系列に限って集計しており, その件数は誤検知が 440~680 件, 見逃しが 141~162 件である.

【査読者#8 から頂いたコメント】

実験 4 では, 予測区間幅の十分位ごとに実績 z スコアの平均を求めることで, 予測区間幅と実際の需要変動の対応を確認しており, 有用な分析であると感じました. 一方で, 平均値のみでは, 各区分内のばらつきや外れ値の影響を判断しにくいです. 各十分位における実績 z スコアの標準偏差等を補足すると, 予測区間幅がスパイク需要と安定的に対応しているかをより判断しやすくなると思われます.

【著者の回答】

ご指摘ありがとうございます. ご指摘の通り, ばらつきを記載しておらず, 実験の有効性を適切に表現できておりませんでした. 大変失礼いたしました.

各十分位について, 実績の z スコアの標準偏差と, スパイク (z スコアが 2 より大きい時点) が占める割合を求めました. 結果は下表の通りです.

予測区間幅の十分位ごとの, 実績値の z スコアの標準偏差とスパイクの割合				
十分位	GateRAF		ProtoRAF	
	標準偏差	スパイクの割合	標準偏差	スパイクの割合
1	0.60	1.4%	0.91	4.8%
2	0.80	2.8%	0.87	3.6%
3	0.92	4.1%	0.93	4.3%
4	0.92	4.2%	0.91	4.1%
5	0.91	3.9%	0.95	4.2%
6	0.87	3.3%	0.96	4.3%
7	0.96	4.6%	0.99	4.9%
8	1.09	6.9%	1.07	5.9%
9	1.22	8.7%	1.10	6.5%
10	1.25	9.9%	1.12	7.4%

GateRAF では, 区間幅が狭い区分から広い区分へ向かって標準偏差が 0.60 から 1.25 へ大きくなり, スパイクの割合も 1.4%から 9.9%へ増えます. 幅の広い区間には, 実際にスパイクの時点が多く含まれております. Multi-RAF もほぼ同じ傾向で, 標準偏差は 0.70 から 1.26, スパイクの割合は 2.3%から 10.0%です.

一方 ProtoRAF は, 標準偏差が 0.87~1.12, スパイクの割合が 3.6%~7.4%と, 区分による違いが小さく, 区間の幅が需要の変動をあまり反映しておりません. Baseline もほぼ同じです.

なお, 広い区分ほど標準偏差が大きくなるのは, その区分にスパイクと平常時が混在するためです. 実際, 最も広い区分でもスパイクの割合は 9.9%にとどまります. 区間が広いことはスパイクの起こりやすい時点であることを示しますが, 発生を確定づけるものではないと考えております.

以上を, 5.4.4 実験 4 に追記いたしました.

新原稿 p.10 左カラム, 5.4.4 実験 4 (記載の追加):

平均だけでは区分内のばらつきが分からないため、各十分位における実績の z スコアの標準偏差と、スパイク ($z > 2$) が占める割合も求めた。GateRAF では、標準偏差が最も狭い区分の 0.60 から最も広い区分の 1.25 へ大きくなり、スパイクの割合も 1.4% から 9.9% へ増加する。一方 ProtoRAF では標準偏差が 0.87~1.12、スパイクの割合が 3.6%~7.4% の範囲にとどまり、区分による違いが小さい。すなわち GateRAF の広い予測区間は実際にスパイクの時点を多く含んでおり、区間幅と需要変動の対応は平均だけでなく分布としても確認できる。ただし最も広い区分でもスパイクの割合は 9.9% であり、区間が広いことが直ちにスパイクの発生を意味するわけではない。

【査読者#8 から頂いたコメント】

第 6 章では、予測値をその時点の入荷量とみなして過剰入荷、返本率、機会損失を算出しており、予測精度を実務的指標に接続する試みとして有用です。一方で、入荷量として予測中央値 $\tau = 0.5$ を用いる理由については、もう少し説明があるとよいと思われます。実務上の発注意思決定では、機会損失を重視する場合には上側分位点 (例: $\tau = 0.9$) を用いて欠品を抑える判断が考えられる一方、過剰入荷や返本を重視する場合には下側分位点 (例: $\tau = 0.1$) を用いて入荷量を抑える判断も考えられます。したがって、 $\tau = 0.5$ を用いた理由を補足するか、可能であれば $\tau = 0.1, 0.5, 0.9$ など複数の分位点を入荷量とみなした場合の過剰入荷・返本率・機会損失を比較する感度分析を加えると、第 6 章の実務的含意がより明確になると考えられます。

【著者の回答】

大変貴重なご指摘をいただき、誠にありがとうございました。中央値を用いた理由の記載がなく、大変失礼いたしました。

過剰入荷と機会損失を同一単価、等重みで合算した場合、その損失は $\sum_t \max(y_t - y_t, 0) + \sum_t \max(y_t - y_t, 0) = \sum_t |y_t - y_t|$ となり、MAE に一致します。この点から、 $\tau = 0.5$ を用いるものとなりました。

また、ご指摘いただきました通り、 τ の値を変化させた場合、どのような結果となるのかという点を明確にするため、 $\tau = 0.1$ 、 $\tau = 0.5$ 、 $\tau = 0.9$ のそれぞれを入荷量とみなした感度分析を行い、表 6 として追記するものといたしました。 $\tau = 0.1$ では入荷を絞るため過剰入荷は GateRAF で 4,073 冊まで減りますが、機会損失は 265,006 冊と $\tau = 0.5$ の約 1.6 倍になります。逆に $\tau = 0.9$ では機会損失が 74,763 冊まで下がる一方で、過剰入荷は 296,482 冊に達します。ご指摘の通り、返本と機会損失のどちらを重視するかで適切な τ は変わります。

また、 τ を変化させた感度分析の結果ですが、手法間の関係は τ によらず保たれておりました。いずれの τ でも GateRAF の過剰入荷は比較手法の中で最小で、Baseline に対しては過剰入荷と機会損失の双方を同時に下回ることが明らかとなり、提案手法の有効性を改めて示すことができました。

なお、従来の表は冊数と金額の両方を載せておりましたが、冊数は表 6 と重複いたしますので、返本率と金額のみを載せる形に改め、表 7 といたしました。

以上を、6 章に追記いたしました。

新原稿 p.11 左カラム, 6. 返本と機会損失の観点からの評価 (記載の追加):

入荷量に中央値 ($\tau = 0.5$) を用いたのは、返本と機会損失のどちらにも重みを置かない中立的な基準だからである。どちらの損失をどれだけ重くみるかは実務の費用構造によって異なるため、本研究では特定の費用構造を仮定せず、入荷を需要の中心に合わせる場合を基準とした。

τ の選び方による違いを表 6 に示す. $\tau = 0.1$ では入荷を絞るため過剰入荷は GateRAF で 4,073 冊まで減るが, 機会損失は 265,006 冊と $\tau = 0.5$ の約 1.6 倍になる. 逆に $\tau = 0.9$ では機会損失が 74,763 冊まで下がる一方, 過剰入荷は 296,482 冊に達する. 手法間の関係は τ によらず保たれる. いずれの τ でも GateRAF の過剰入荷は比較手法の中で最小であり, Baseline に対しては過剰入荷と機会損失の双方を同時に下回る. すなわち以下の結果は, 入荷量にどの分位点を用いるかに依存しない.

新原稿 p.12, 表 6 (新規追加):

モデル	$\tau = 0.1$		$\tau = 0.5$		$\tau = 0.9$	
	過剰入荷	機会損失	過剰入荷	機会損失	過剰入荷	機会損失
GateRAF	4,073	265,006	41,182	162,098	296,482	74,763
Baseline	4,271	266,008	57,383	168,171	428,864	78,453
SARIMA	4,315	642,766	124,588	150,440	657,493	70,746
Prophet	219,753	917,871	331,923	317,997	910,309	185,874

【査読者#B から頂いたコメント】

軽微な修正の要求: 5.2 節の「POS 販売冊数」という用語について, 当該データセットに詳しい読者には理解可能だと思われますが, 初めて読む読者には, 店舗別 POS データを同一書名・同一日付で全店舗合算した販売冊数を指すのか, あるいは別の定義を持つのがやや分かりづらい可能性があります. 簡潔に定義を補足するとよいと思われます.

【著者の回答】

ご指摘ありがとうございます. 読者にとって定義が読み取りにくい記載となり, 大変申し訳ございませんでした. ご指摘の通り, POS 販売冊数は店舗別の POS データを同一の書名・同一の日付で全店舗合算した販売冊数を指します. 5.2 データ整形に, その旨を追記するものといたしました.

新原稿 p.5 右カラム, 5.2 データ整形 (記載の追加):

すなわち本研究における POS 販売冊数とは, ある書名のある日について, 全店舗の販売冊数を合計した値である.

【査読者#B から頂いたコメント】

軽微な修正の要求: 5.2 節では, 年間総販売冊数が 366 冊に満たない書籍の除外, 同一作品のシリーズ単位への統合, ゼロ需要日の補完を経て, 最終的に約 40 万件のデータを得たと説明されています. 一方で, 最終的に分析対象となった書名数が明示されていないため, データの規模を把握しにくいです. 元データは約 20 万書名・約 400 万件の販売記録から構成されると説明されているため, 前処理後に分析対象となった書名数も併記するとよいと思われます.

【著者の回答】

ご指摘いただきましてありがとうございます. 書名数を書いておらず, 大変失礼いたしました. ご指摘いただきました書名数ですが, 前処理後に分析対象となった書名は 1,157 点でございます. これに 366 日を掛けた 423,462 件が分析対象となります. 5.2 データ整形に明記いたしました.

新原稿 p.5 右カラム, 5.2 データ整形（記載の追加）:

前処理後に分析対象となった書名は 1,157 点であり、これに 366 日を掛けた 423,462 件が分析対象である。

【査読者#8 から頂いたコメント】

軽微な修正の要求：本文中では過去の類似系列を参照しない基盤モデルを Baseline と呼んでいる一方で、図 3 の凡例では noRAF と表記されています。両者が同一のモデルを指すのであれば、表記を統一したほうがよいと思われます。

【著者の回答】

ご指摘ありがとうございました。内容が統一されておらず、大変失礼いたしました。
図 3 の凡例を Baseline に修正し、本文と統一するものといたしました。

新原稿 p.10 左カラム, 図 3（凡例の修正）:

凡例の「noRAF」を「Baseline」に変更。

以上のように、頂きましたコメントに対しまして入念な推敲を重ね、論文の加筆・修正を致しましたので、ご確認の程、何卒宜しくお願い申し上げます。

以上のように、頂きましたコメントに従って論文全体の加筆・修正をさせて頂くと共に、再度、入念な推敲を重ねました。多くの貴重なご指摘を頂きまして誠にありがとうございました。頂きましたコメントにより、論文全体的大幅な改善に結び付いたと考えております。再度のご依頼となり大変恐縮ではございますが、ご確認の程、何卒宜しくお願い申し上げます。

以上