データ解析コンペ経過発表
第1週

Team A
斎藤陽
奈良原俊誠
橋本智樹

目次

-データ概要

-各カラムの分析

-カラムの従属性

-今後の方針

-疑問点

データ概要

データサイズ **3,969,881**

カラムサイズ **12**

列名	データ型	欠損値の数
Unnamed: 0	int64	0
日付	object	0
書店コード	int64	0
ISBN	object	0
出版社	object	6,753
書名	object	6,736
著者名	object	1,331,681
大分類	object	7,017
中分類	object	7,017
小分類	object	7,017
本体価格	float64	6,736
POS販売冊数	int64	0

日付

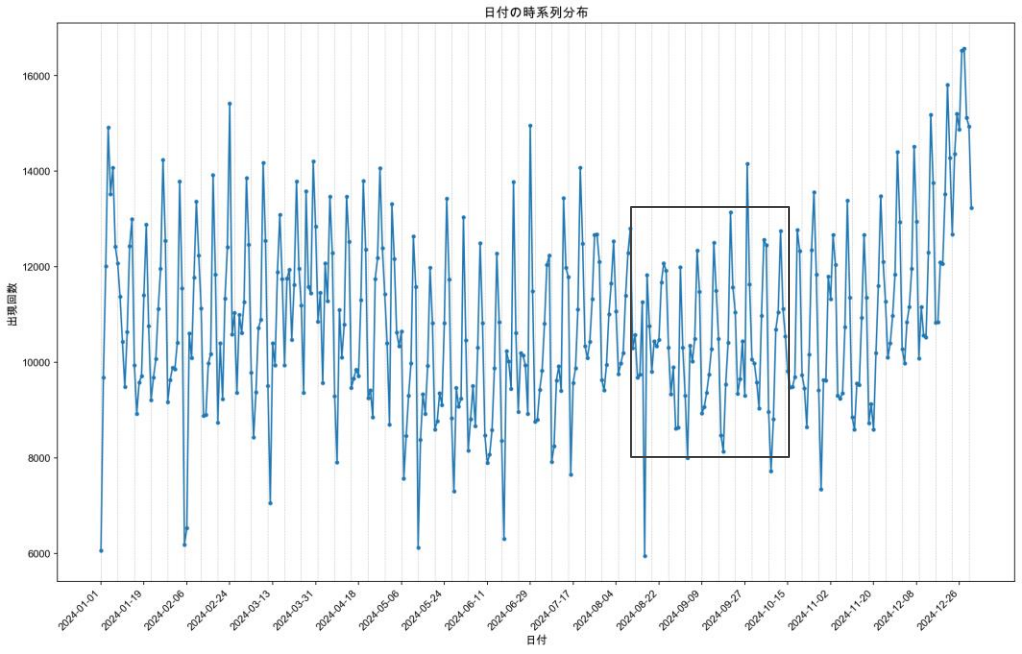

ユニークな数	**366**
欠損値の数	**0**
欠損値の割合	**0%**

- 期間は**2024/1/1~12/31**
- **2024**年はうるう年なので**366**日

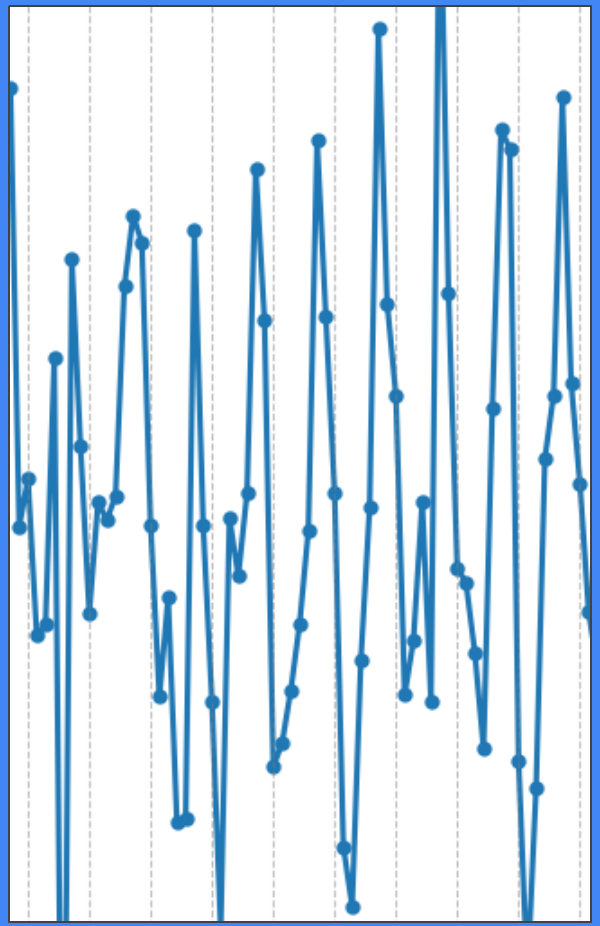

- 1週間毎の周期
- 縦線は月曜日(2024/1/1が月曜日)
- 火曜日に最低
- 土曜日に最高

※週によって誤差はある

- 長期休暇にデータ数がやや減少(GW, 夏季休暇)
- 年末にかけてデータ数が上昇

※12月中に特別な傾向は見られない(現段階では)

ISBN

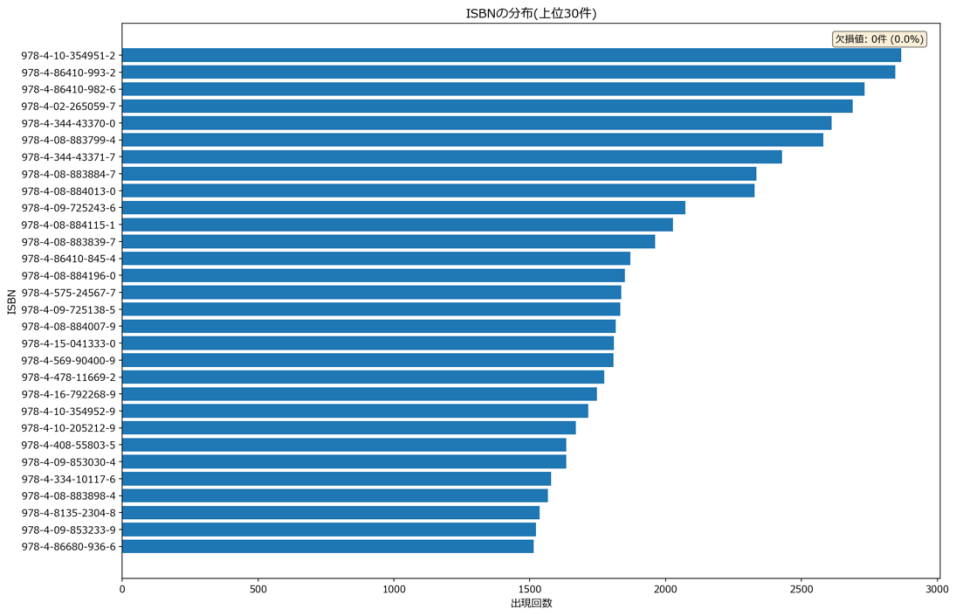

ユニークな数	195,548
欠損値の数	0
欠損値の割合	0.0%

ISBN

- ISBNコード（国際標準図書番号）とは
  →本や書籍を特定する唯一のコード、バーコードなどに使用
- 例）978-4-8069-1902-5
  978 → 接頭記号、「書籍」であることを表す
  4 → 国記号、日本で発行された書籍には「4」が割り当てられる
  8069 → 出版者記号、どの出版社が発行したかを表す
  1902 → 書名記号、書籍出版物の固有番号が割り振られる
  5 → チェックデジット

ISBNに関する分析

出現回数が100回以下が96.09％　187,920件/195,548件
→ロングテール

出現回数上位30件はすべて1500回以上出現
→人気書籍に強い集中がある ＝ 売上集中構造

ISBNに関する今後の分析方針

- 出版社別にISBNの平均出現回数を計算する
  ①少ないISBNで大きな出現回数を稼いでいる場合
  →人気タイトル依存型

  ②多くのISBNを幅広く持っている場合
  →カタログ拡大型

出版社のデータと紐づけて分析するのが面白そう

出版社

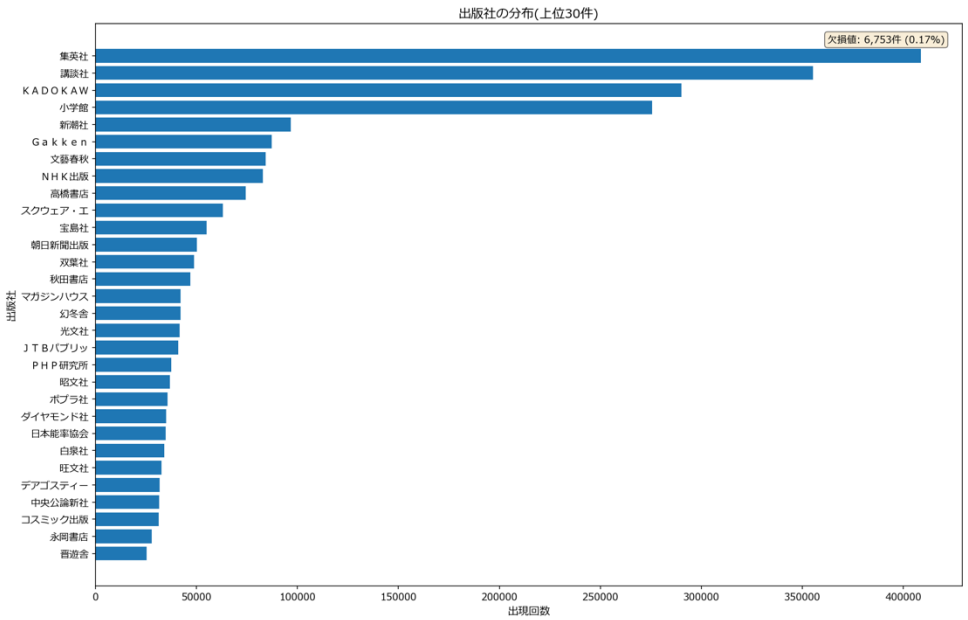

ユニークな出版社数	1,397
欠損値の数	6753
欠損値の割合	0.17%

出版社に関する分析

- ユニークな出版社数を基準
  出現回数が1000回未満　82.61%　1,154件 / 1,397件
  →ロングテール
- データ全体を基準
  回数上位4件グループ　33.50%　1,329,841件 / 3,969,881件
  出現→突出している上位4件だけでデータ全体の1/3を占めている

0.17%の欠損値や表記ゆれを修正して再分析

出版社（正規化後）

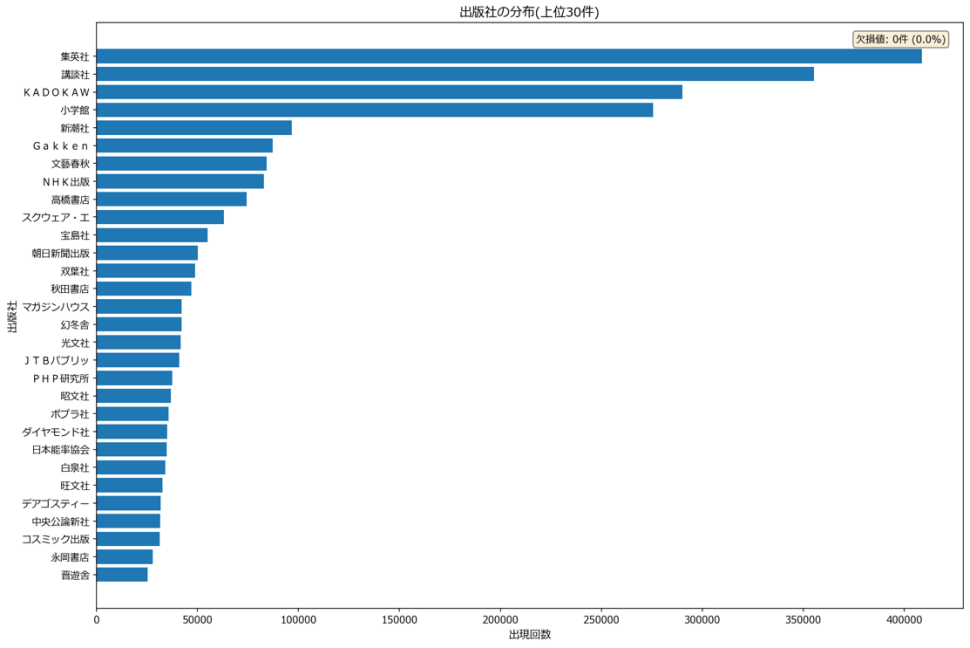

ユニークな出版社数	1,389
欠損値の数	0
欠損値の割合	0.0%

出版社に関する分析（正規化後）

- 欠損値をISBNから補完
  →ISBNコードから出版者名を特定し補完

- 表記ゆれの修正、スペースの削除
  →同一出版者でもスペースの有無や表記ゆれによって
  別出版者としてカウントされてしまう問題を修正

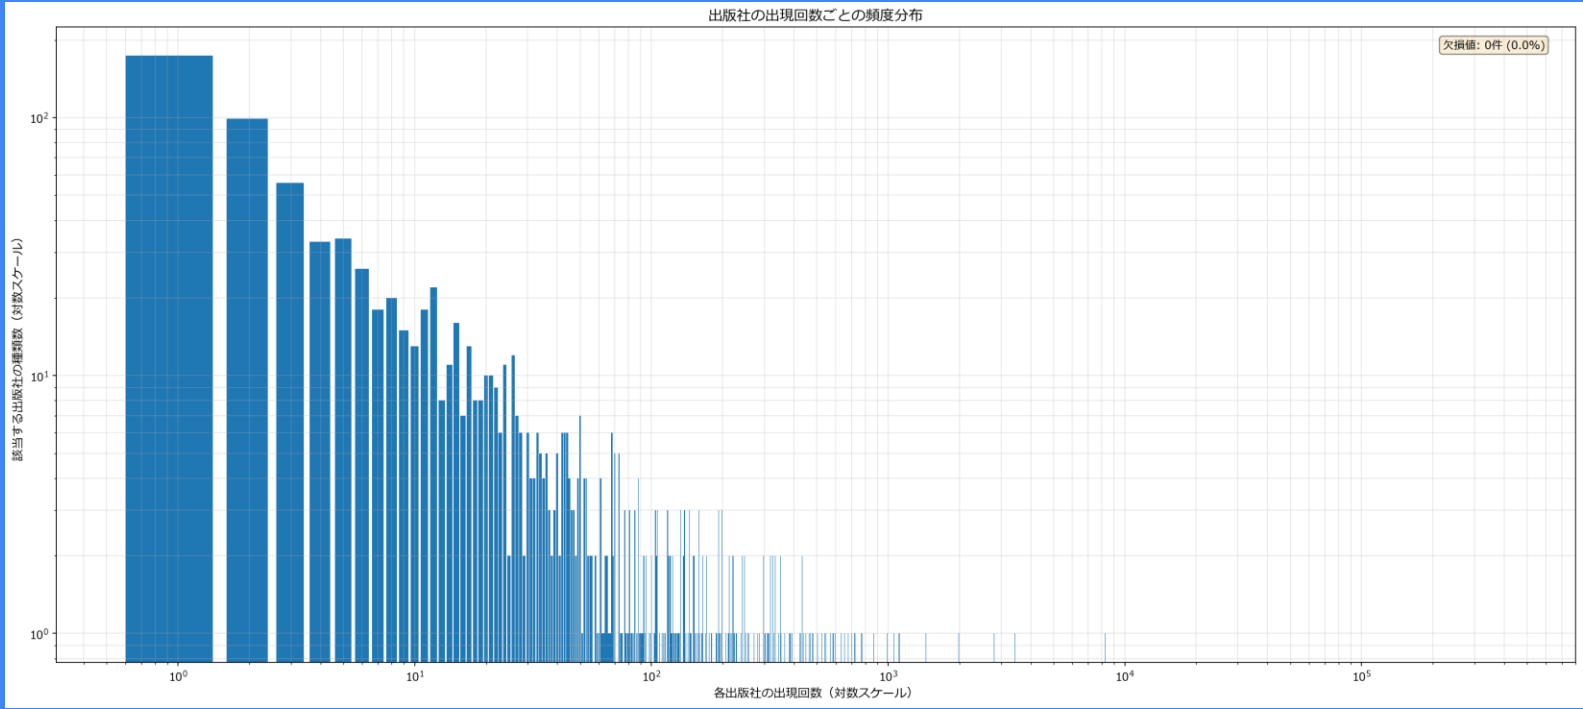

- 対数スケール上でデータが右肩下がりになっている
  べき乗則に従っている
- 出版数が1～10冊程度の出版社が圧倒的多数を占めている
- 出版数が1000冊を超える出版社はごくわずか

書名

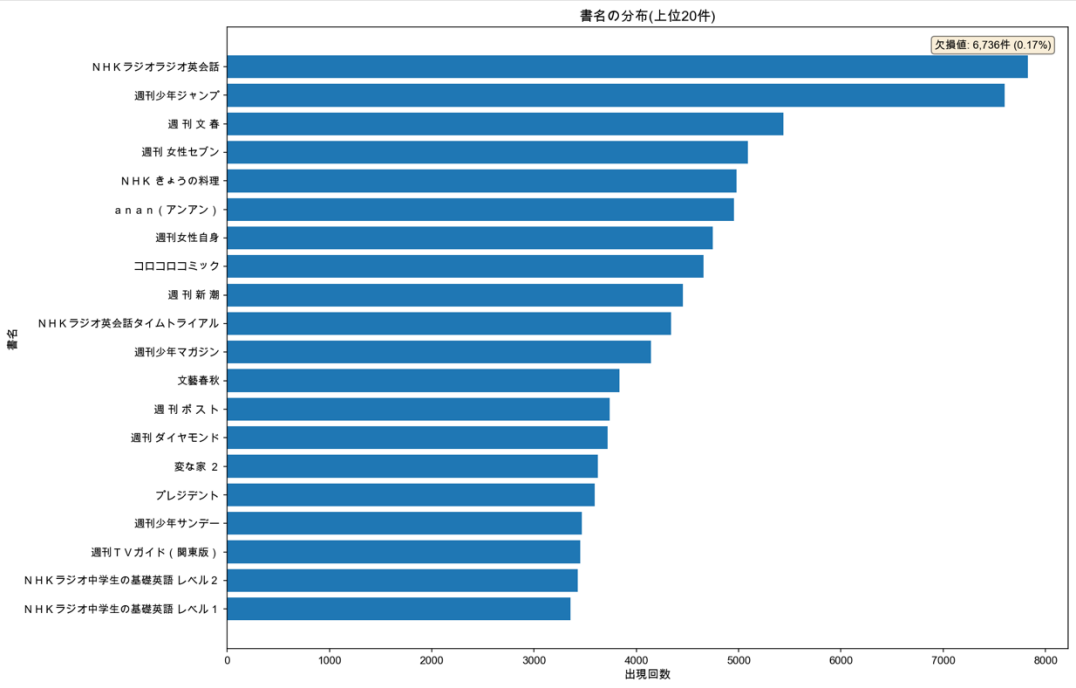

ユニークな数 **177,043**

欠損値の数 **6,736**

欠損値の割合 **0.17%**

書名に関する分析

- 出現回数**1,000回未満が 99.85%（176,783種類/177,043種類）**
- **空白の表記ゆれ**
- **巻数別に区別される**

半角スペース（' '）を含む: 0件
全角スペース（'　'）を含む: 2,842,472件
両方含む: 0件
いずれかのスペースを含む: 2,842,472件

- **()のなかに含まれる「～版」は必要か**
  ※「VOGUE JAPAN（ヴォーグジャパン」など途中で切られ閉じられていないものもある

書名(正規化後)

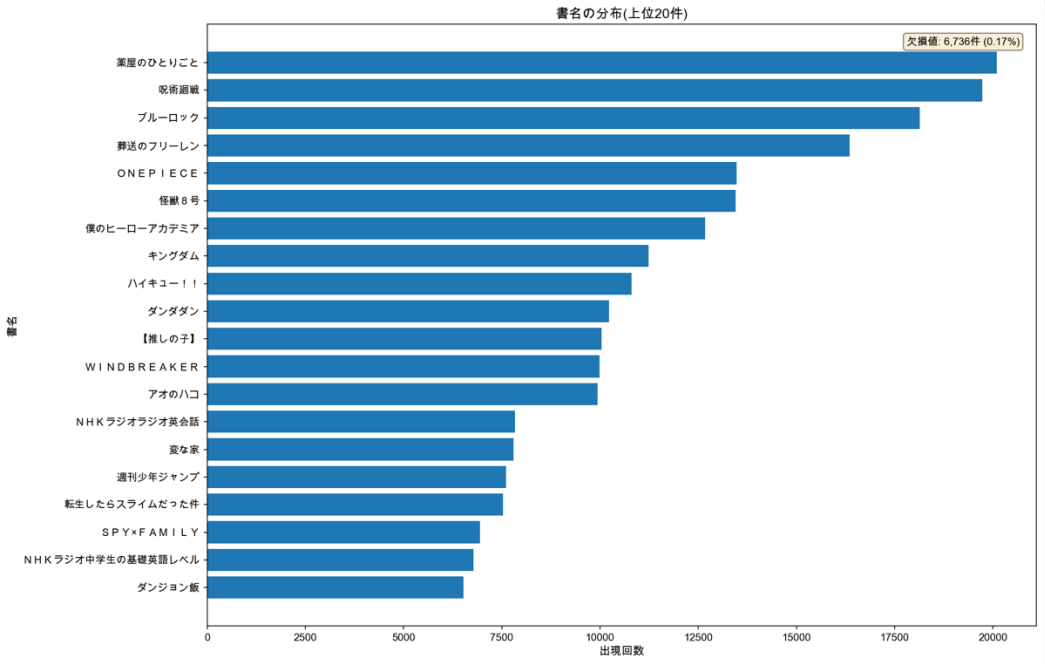

ユニークな数	**136839**
欠損値の数	**6,736**
欠損値の割合	**0.17%**

- **177,043種類 → 136,839種類（22.46%削減）**
- **巻数，サブタイトルは削除**
- **コミック本が上位を占める**

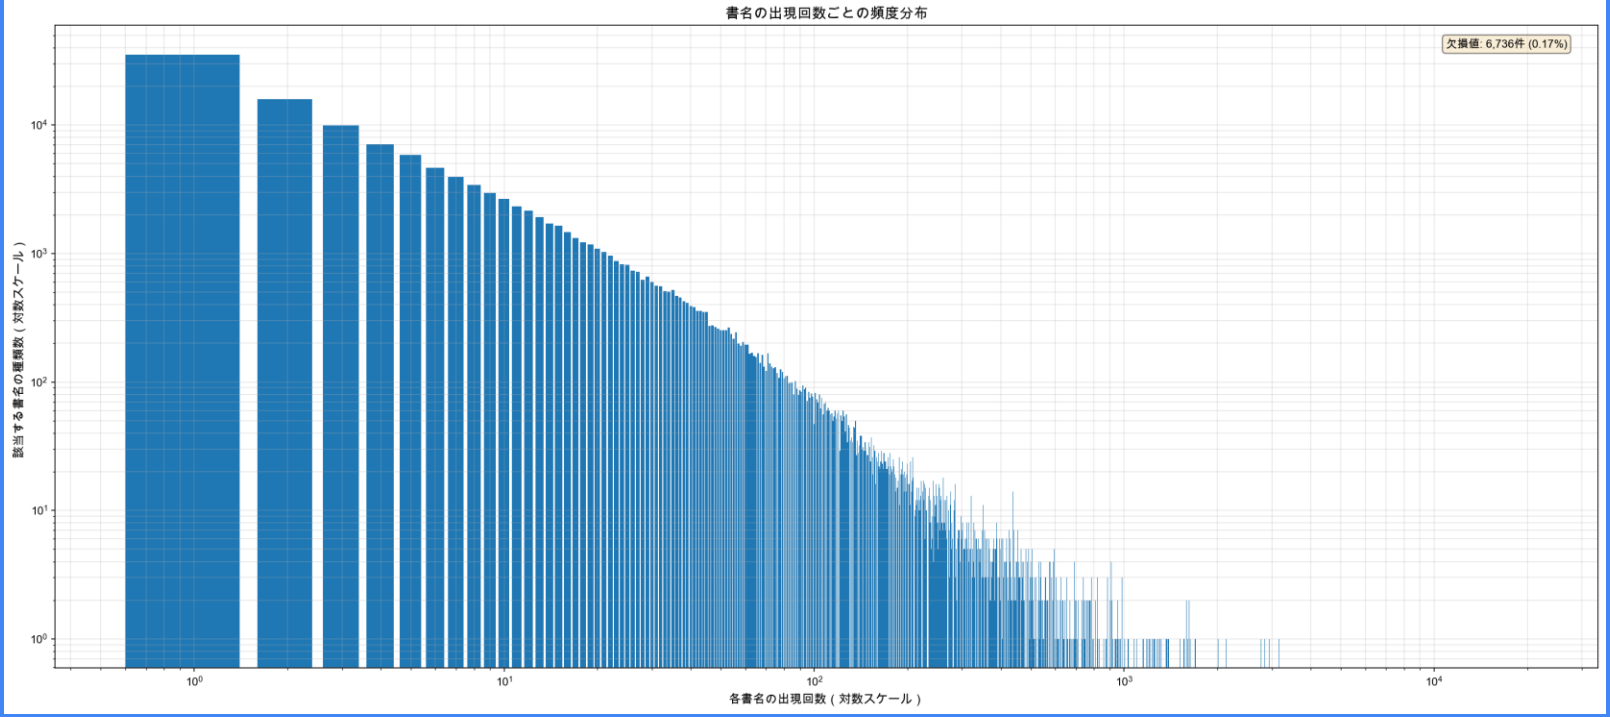

- 対数スケール上でデータが直線上に並んでいる

i.e. べき乗則に従っている

- 機械学習時はCount-Encodingでよさそう
- 対数変換でスケールしても面白いかも

著者名

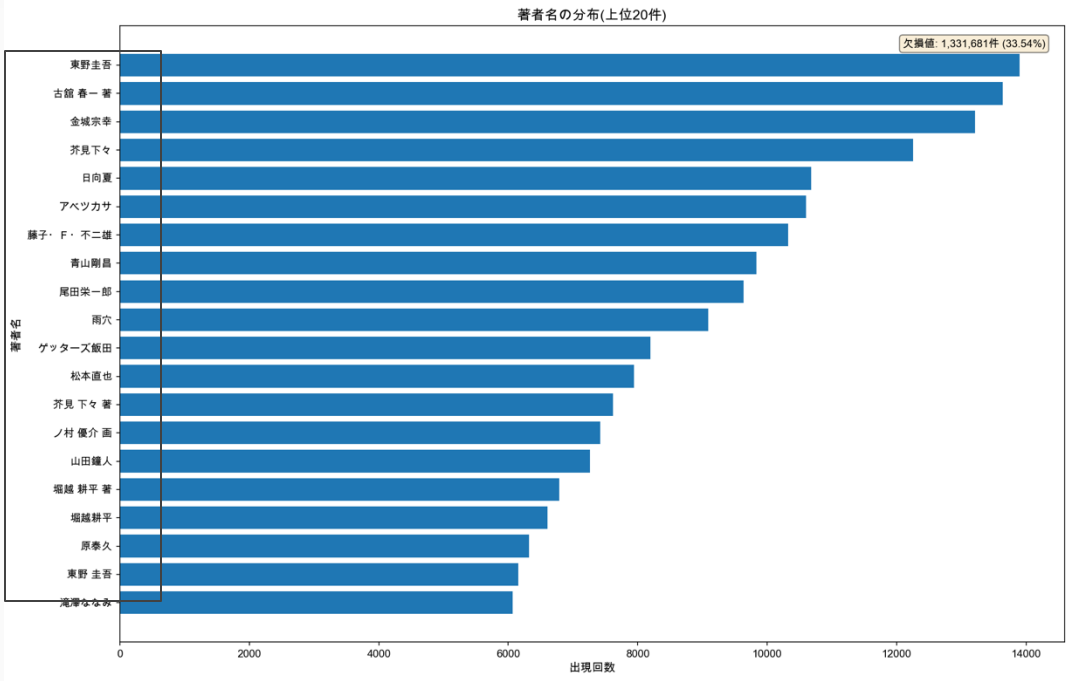

ユニークな数　**64,631**

欠損値の数　**1,331,681**

欠損値の割合　**33.54%**

- **1000回未満が 99.42%（64,257種類/64,631種類）**
- **ロングテール**
- **異常な欠損値の数**

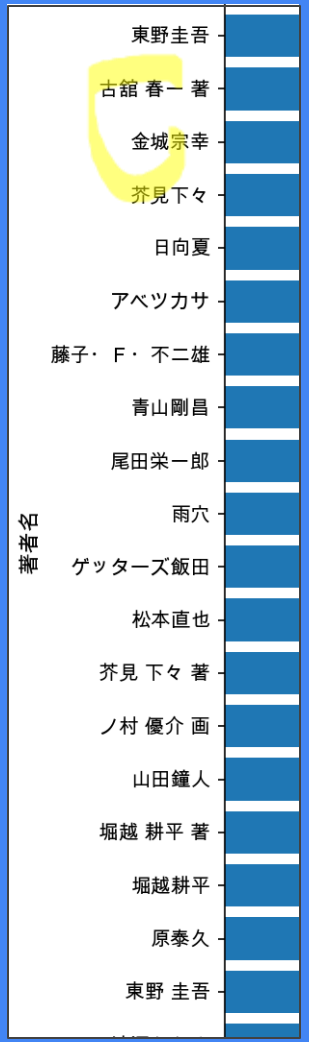

- 空白による表記ゆれ
- ～著などの表記ゆれ

'監修': 53274件
'訳': 1104件
'原作': 16007件
'文': 11510件
'漫画': 10396件
'絵': 7952件
'著': 557326件
'さく': 4124件
'画': 49472件
'マンガ': 1128件
'作': 47322件
'え': 8158件
'編': 12557件
'[著]': 11件

著者名(正規化後)

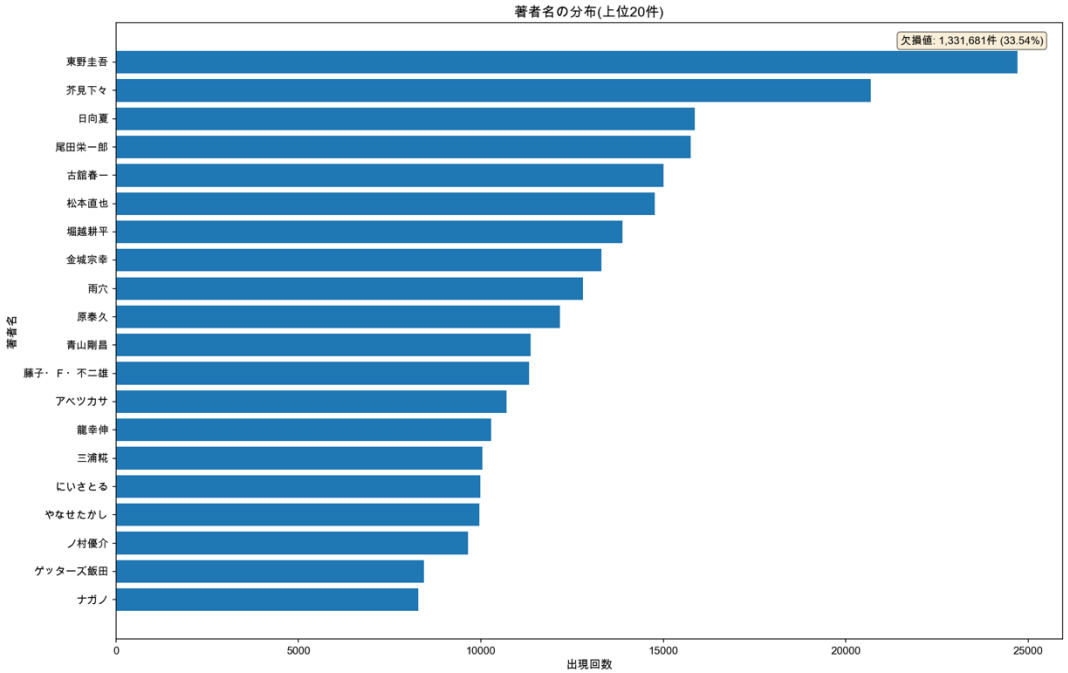

ユニークな数	**48,232**
欠損値の数	**1,331,681**
欠損値の割合	**33.54%**

- **64,631種類 → 48,232種類（19.87%削減）**
- **表記ゆれの改善**
- **書名と綺麗に対応**

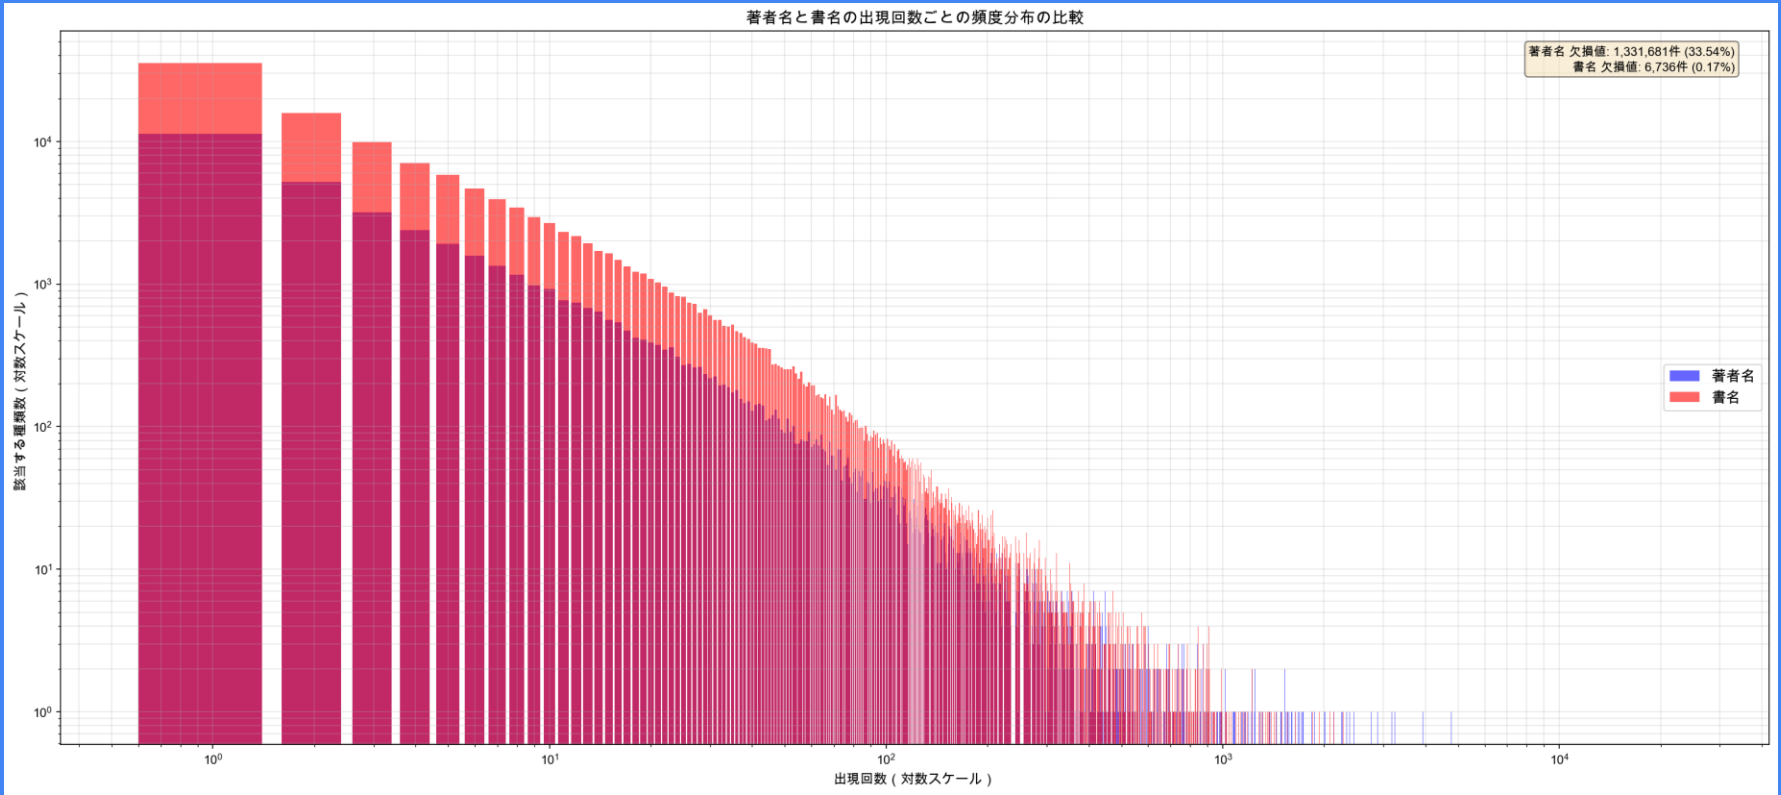

- 著者名の方がやや少ない

↑膨大な数の欠損値が影響しているだけでは

著者名の欠損値に関する分析

- 欠損値の数**1,331,68は2パターンあることを発見**

パターン1- 6,736行: 著者名・出版社・書名・本体価格が全て欠損（多くの情報が抜けている不完全なレコード）

パターン2 - 1,324,945行: 著者名のみが欠損（雑誌や学参など著者名が本来不要なカテゴリ）

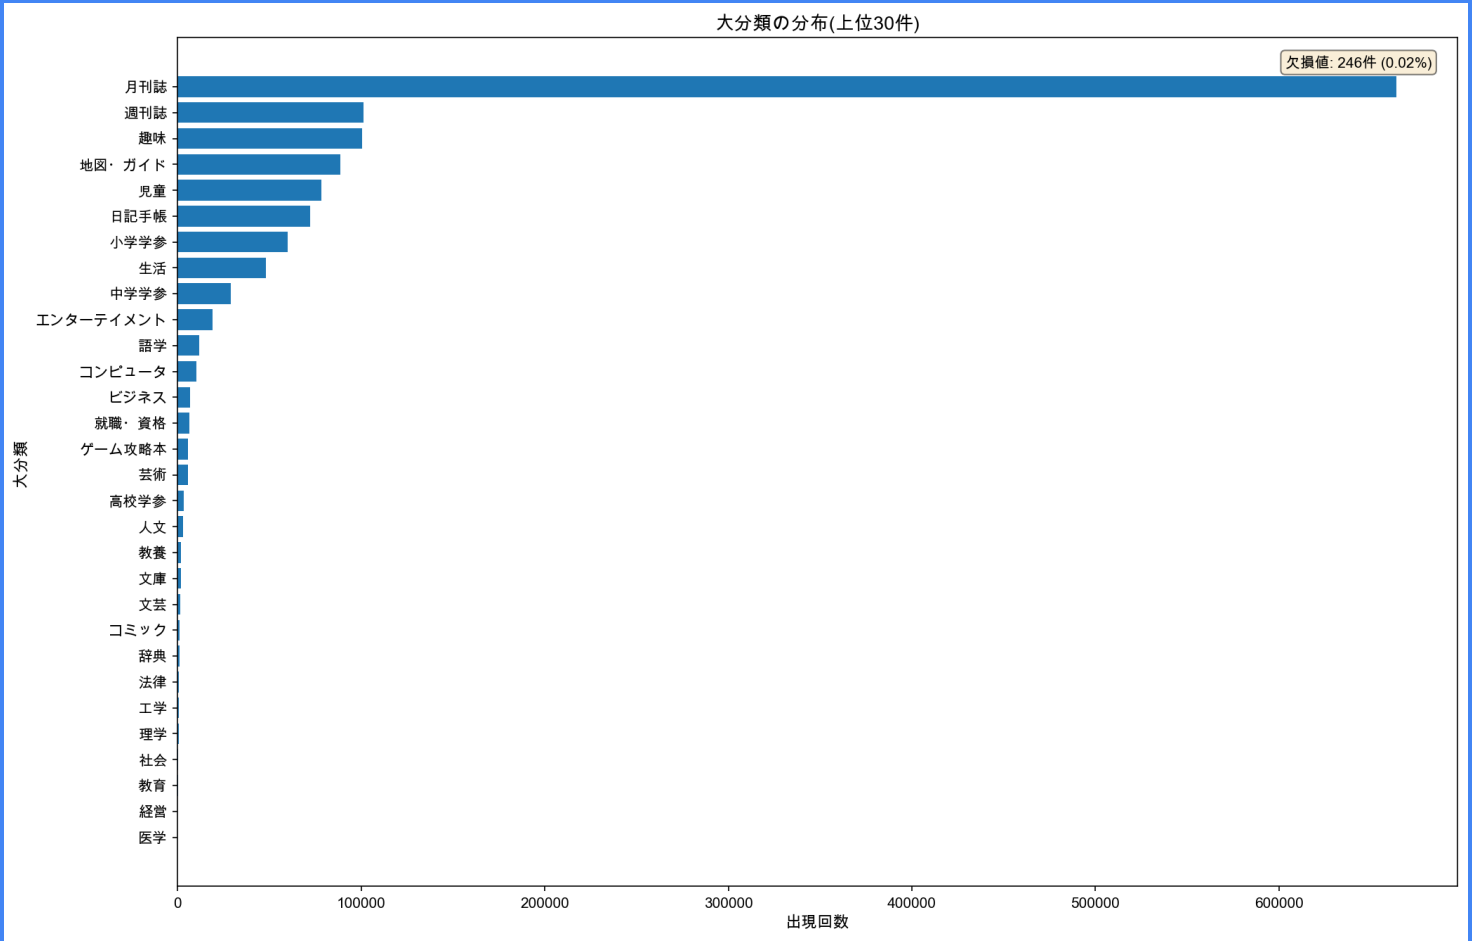

パターン2に限定した大分類の分布

大分類・中分類・小分類

大分類・中分類・小分類の階層構造（サンバーストチャート）

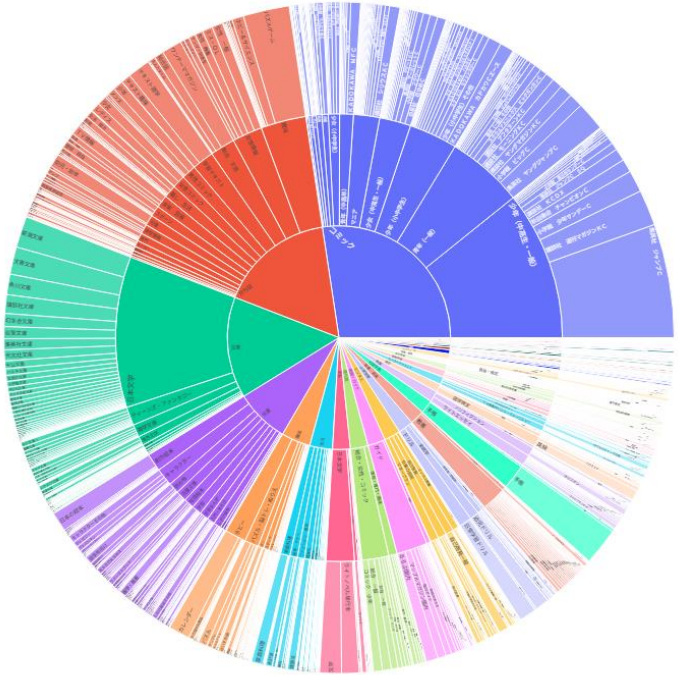

大分類・中分類・小分類の階層構造（サンバーストチャート）

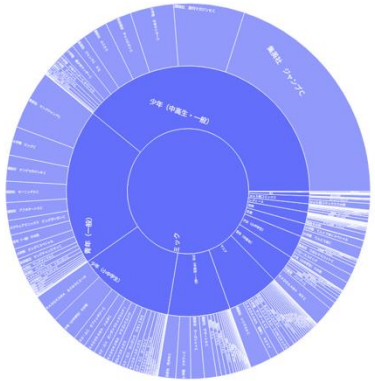

大分類

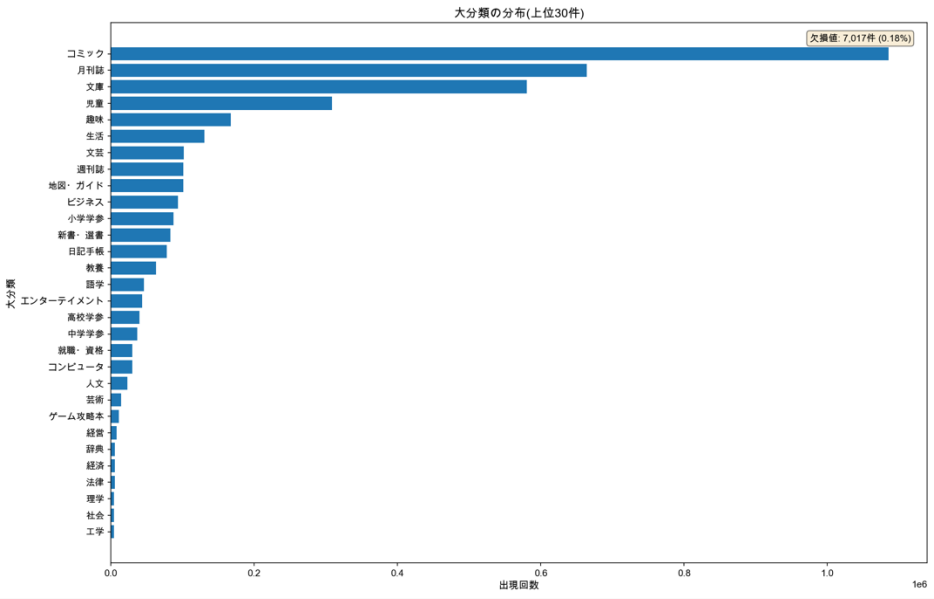

ユニークな数	**34**
欠損値の数	**7017**
欠損値の割合	**0.18%**

大分類に関する分析

- データ全体を基準
  出現回数上位4件で66.45%(2,638,033件/3,969,881件)
  →上位4件でデータ全体の2/3を占めている。
  （特にコミックが多い）

- 機械学習時にはダウンサンプリング（SMOTE）を適用し、データバランスを調整する。

中分類

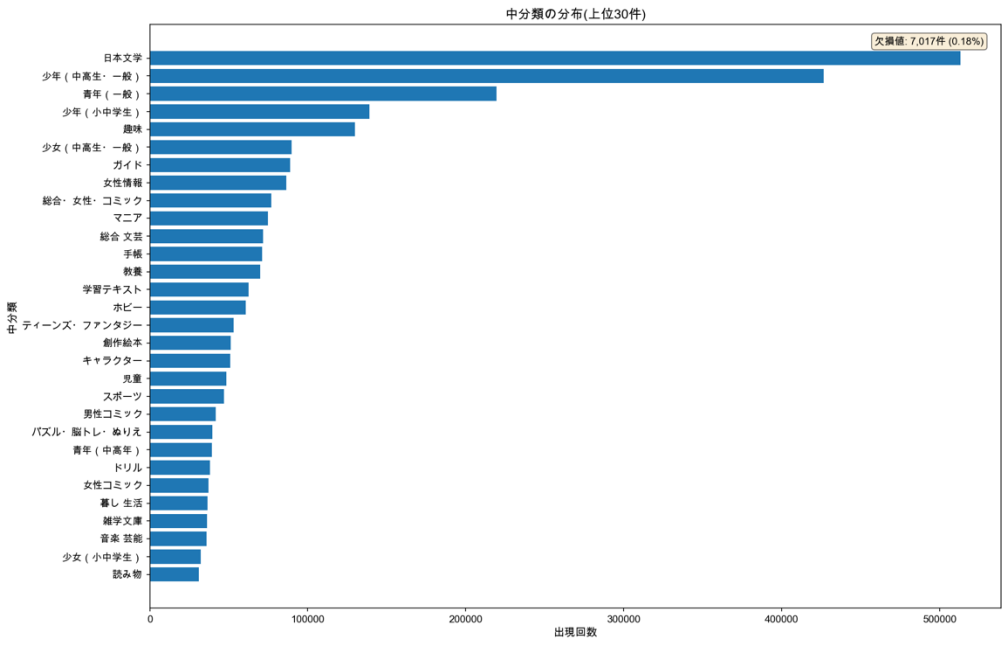

ユニークな数	**299**
欠損値の数	**7017**
欠損値の割合	**0.18%**

中分類に関する分析

- データ全体を基準
  回数上位3件　29.20%　1,159,368件 / 3,969,881件
  →上位3件で全体の3割弱を占めている

- ユニークなデータの上位10件のうち6件がコミック
  →大分類と同様にデータの偏りがみられる。

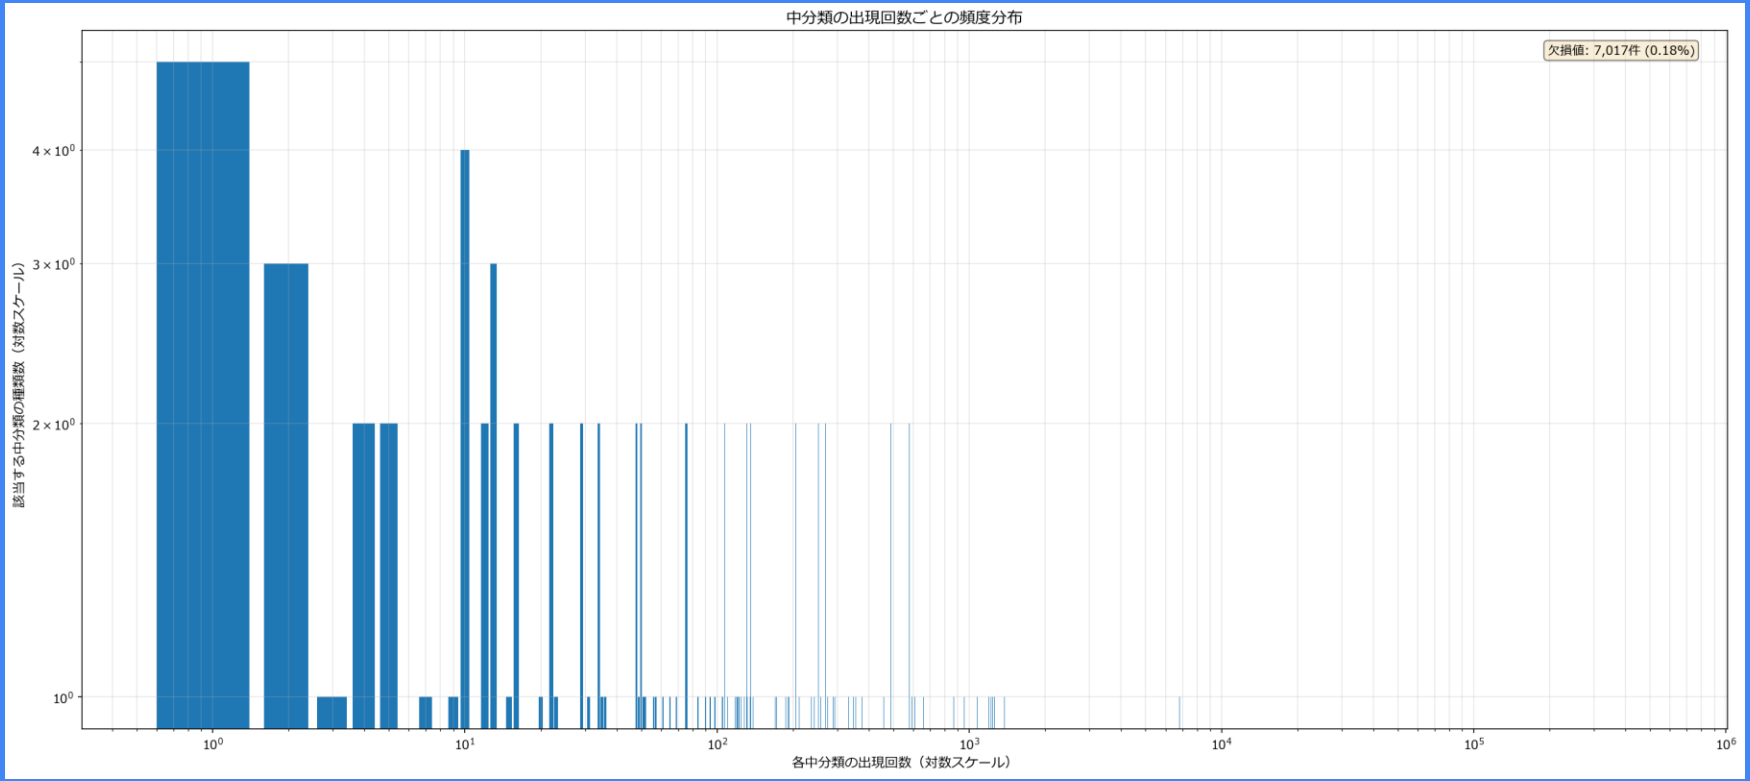

- 他のカラムに比べて離散的
  →ユニークなデータ数が少ないため妥当

小分類

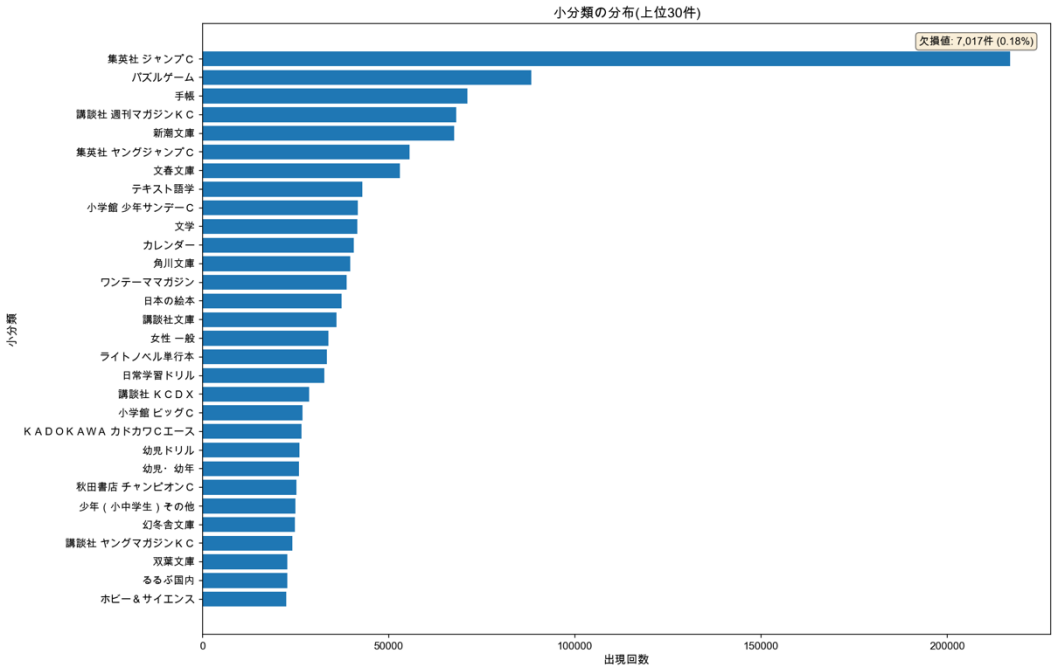

ユニークな数　**2254**

欠損値の数　**7017**

欠損値の割合　**0.18%**

出現回数**1000**回未満
76.62%（1,727件/2254件）

→ロングテール

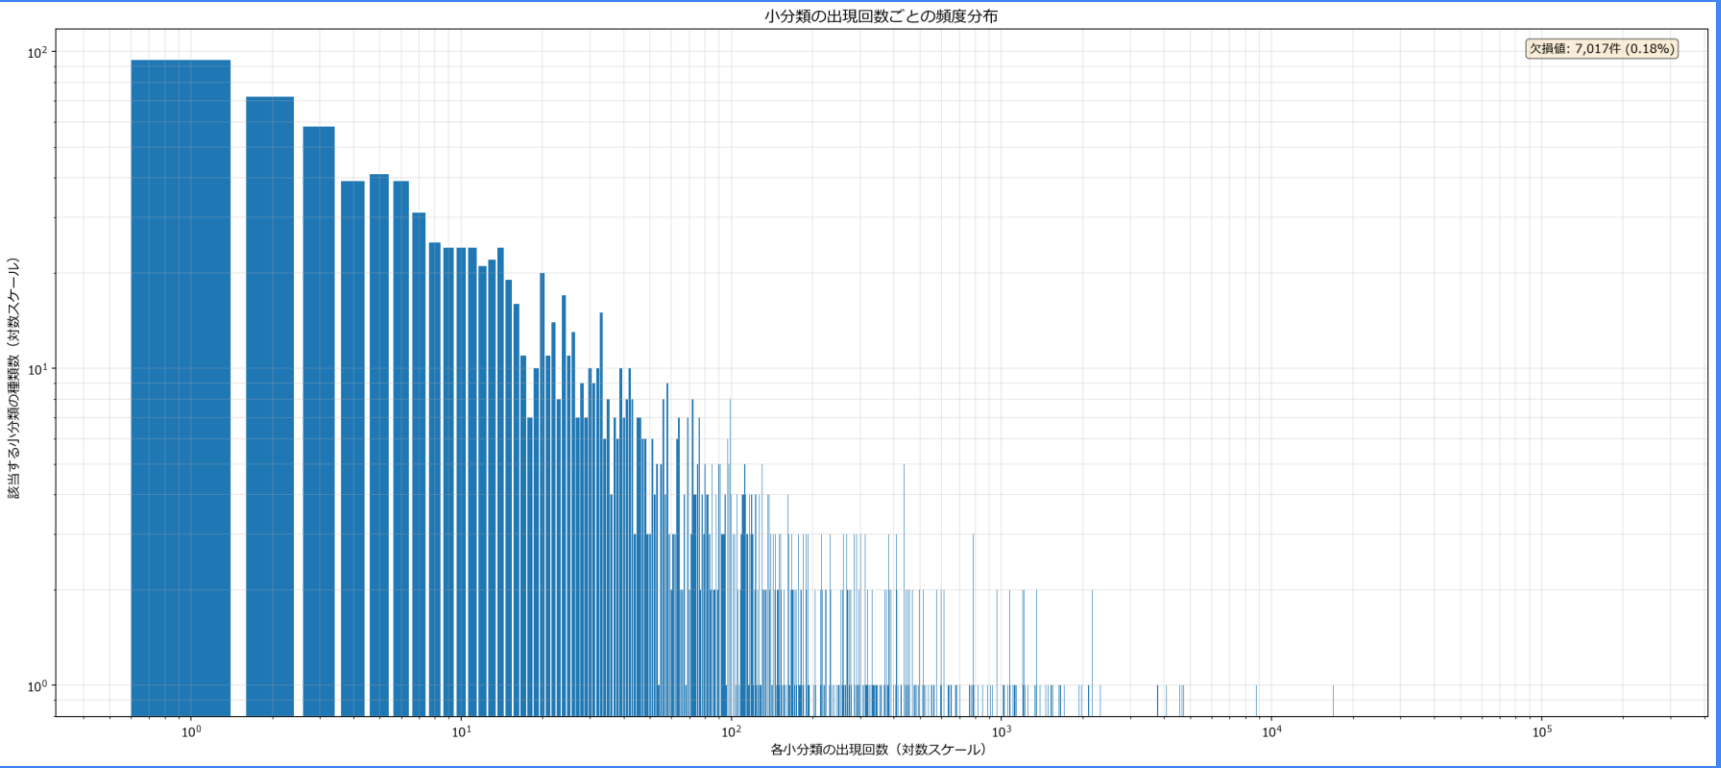
小分類の出現回数ごとの頻度分布
欠損値: 7,017件 (0.18%)
該当する小分類の種類数（対数スケール）
各小分類の出現回数（対数スケール）
10^0
10^1
10^2
10^3
10^4
10^5

- 出版社のグラフと酷似

大分類、中分類、小分類の欠損値の分析

- 欠損値の数**7017**は**2**パターンある
- **パターン1- 6,736行: 著者名・出版社・書名・本体価格が全て欠損（多くの情報が抜けている不完全なレコード）**
- **パターン2 - 281行: 分類がすべて欠損（シールブックや指人形絵本のような子供向けの物が大半）**

本体価格

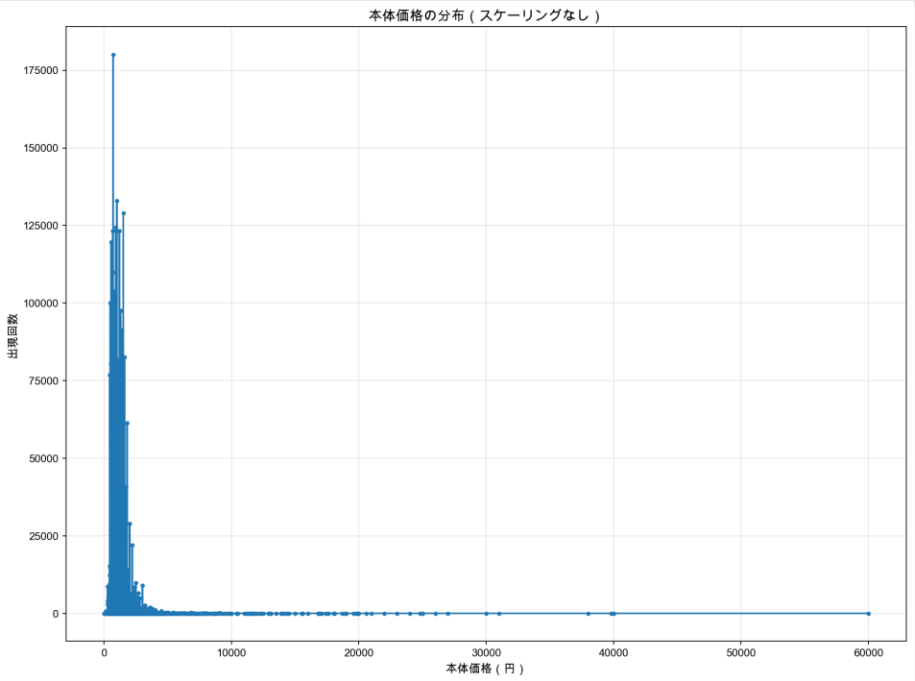

ユニークな数 **1,034**

欠損値の数 **6736**

欠損値の割合 **0.17%**

- データの**96.9%**が**2000**円以下**(3,838,600**件**/3,963,145**件**)**

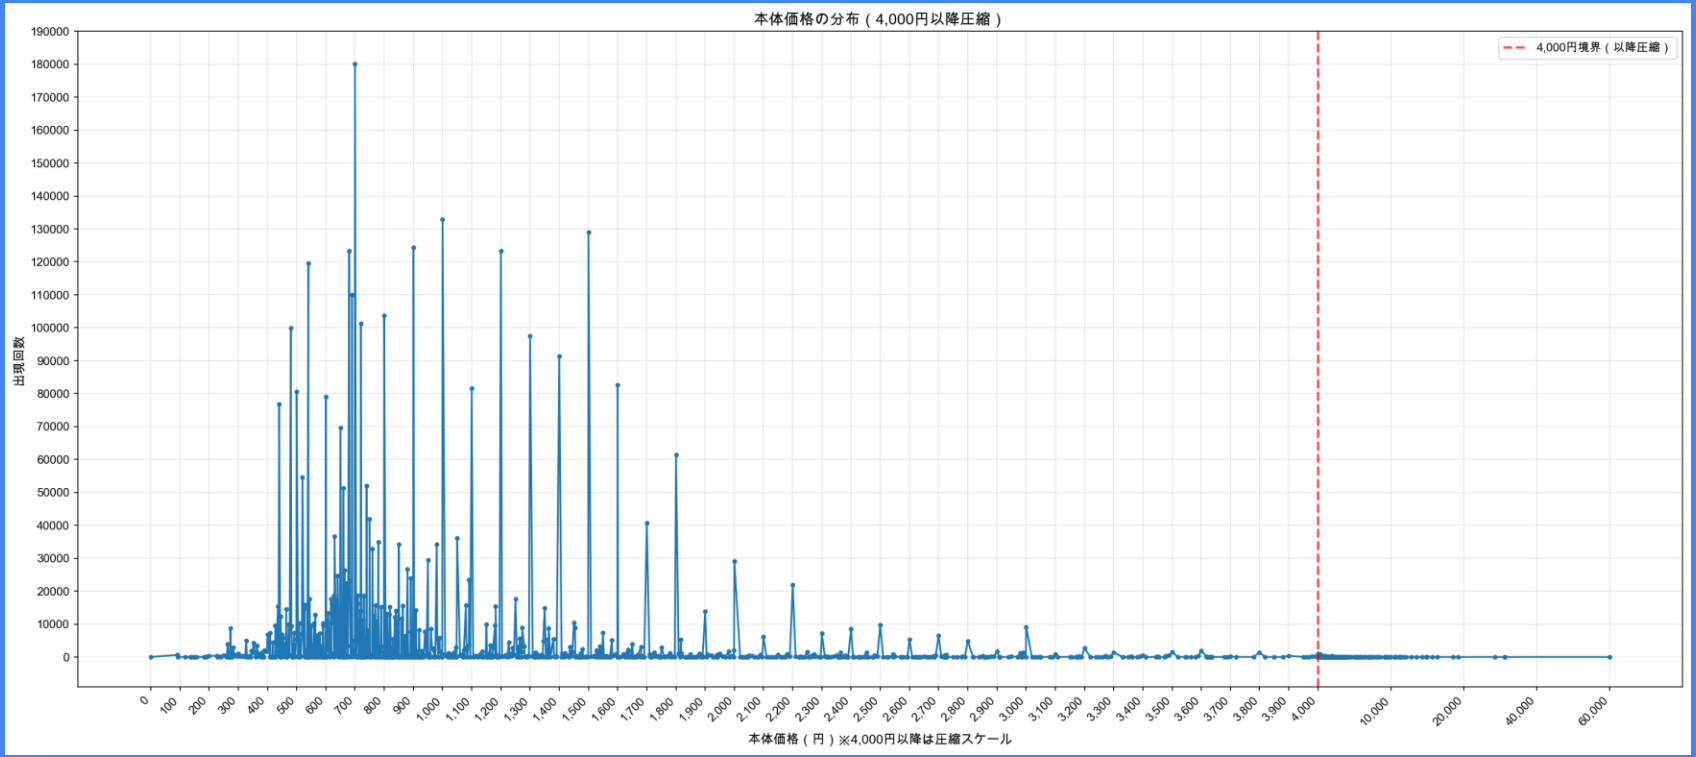

- **デルタ関数のように特定の金額に突出**

e.g. 700円: 180,084件，1000円: 132,948件，1500円: 129,019件

POS販売冊数

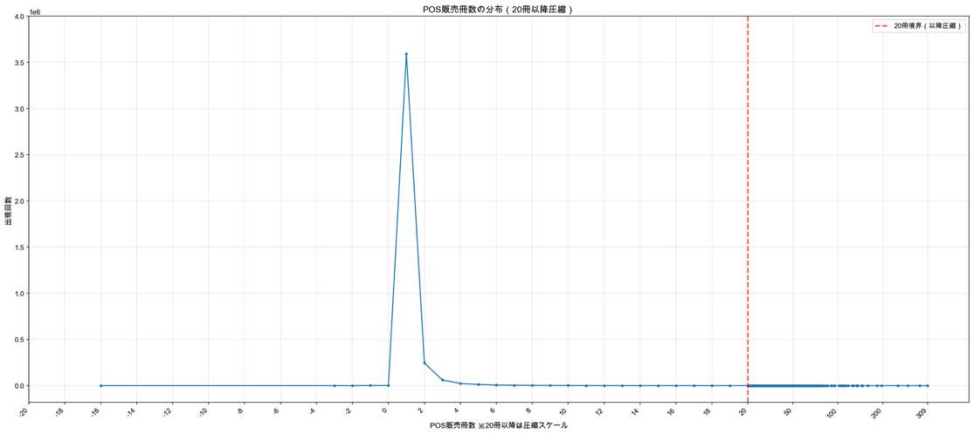

ユニークな署名数	168
欠損値の数	0
欠損値の割合	0.0%

- 最低-16, 最高309
- 全体の90.64%が1冊
- 負のデータが存在(1690件)

※返品処理とのこと

カラムの従属性

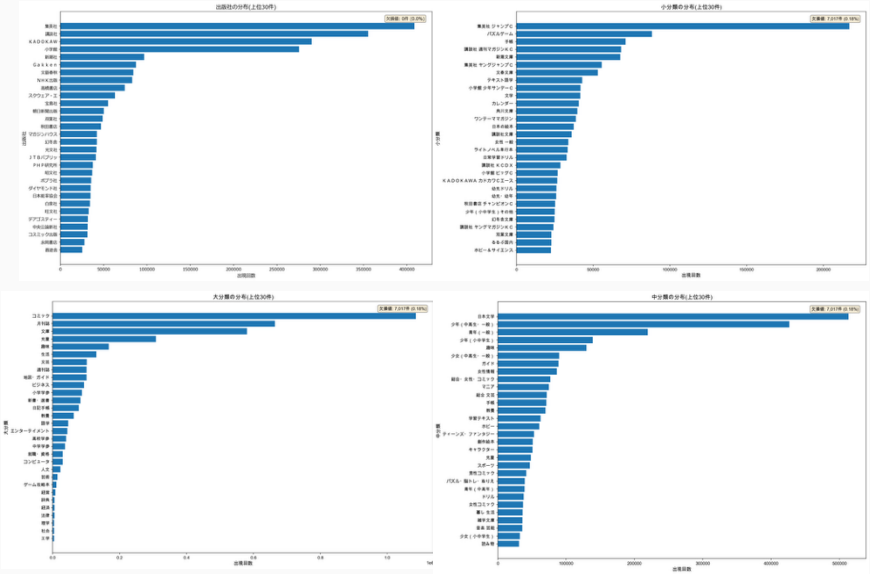

- 明らかに同形
- 相関というか，決定的に決まっているものがある

e.g. 書名→{著者名,本体価格}

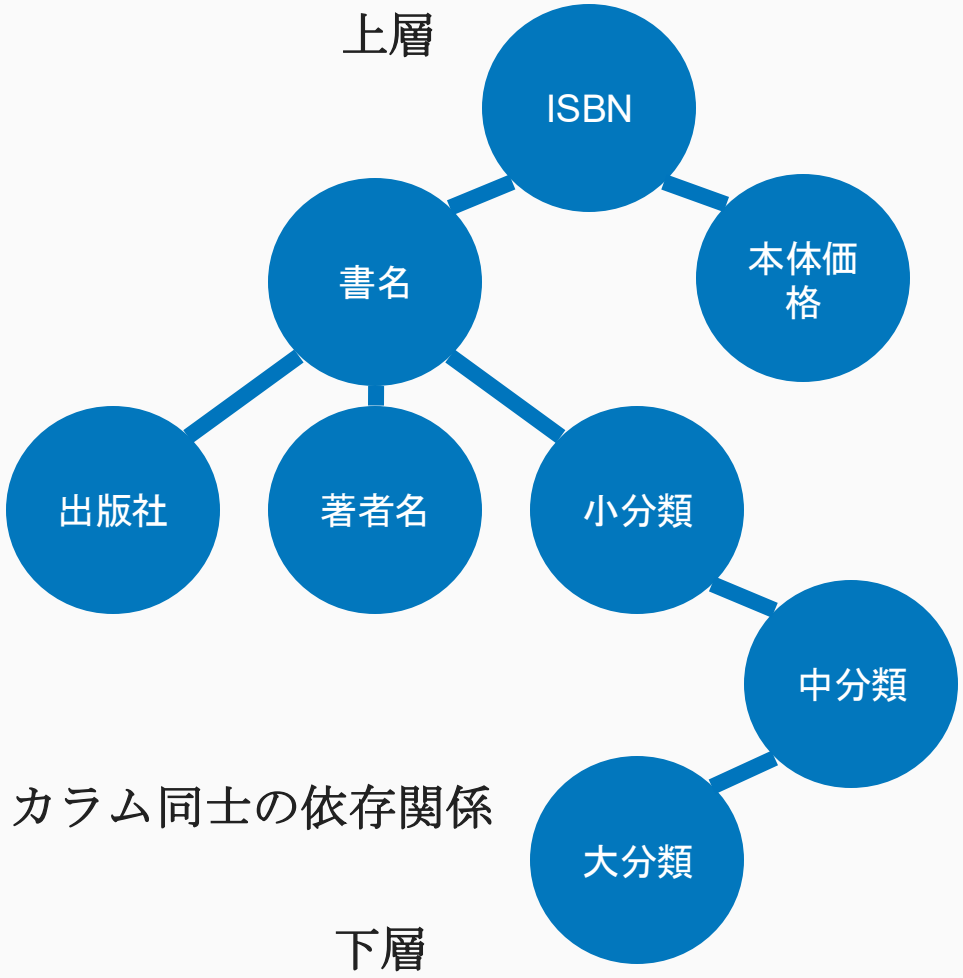

- 上層が決まれば決定的に下層が確定(左の依存関係にあるカラムをISBN郡とする)
- 独立したカラムは「日付」「書店コード」「ISBN郡」「POS販売冊数」の4つ
- 従属したカラムに意味を持たせるには他のレコードを参照するような特徴量エンジニアリングが必要

今後の指針

- カテゴリカルデータの数値化(今週も少し触れた)
- STL分解(周期性のある時系列データ)
- 何らかの手法で機械学習後，LIMEで解釈
- 「書名」，「著作名」をセマンティックに解釈

疑問点

- 機械学習する場合，何を目的変数とするか(1日のデータ数？)
- 最終的な到着地点(何をするために活動するか)

(クラスタリングしてクラスタごとの特徴を分析する？)

Github
https://github.com/dmainf/data_comp