データ解析コンペ経過報告
week 4

2342055　齋藤陽
2342077　奈良原俊誠
2342084　橋本朋樹

目次

前処理
- 欠損値の補完
- 著者名の正規化
- 書名の正規化

統計分析
- 出版直後の売上推移

書店別分析
- 書店別特性と売り上げの相関

予測モデル構築

前处理

欠損値の処理

What are types of missing value?

パターン1：**6,736**件，‘出版社’, ‘書名’, ‘著者名’, ‘本体価格‘が同時に欠損したデータ

パターン2：**1,324,945**件，’著者名’のみが欠損したデータ

パターン3：**281**件，’大分類’, ‘中分類’, ‘小分類’が同時に欠損したデータ(‘著者名’が欠損しているかは考慮しない)

欠損値の処理

・パターン3の281件の関して，’書名’のユニーク数は28

・’小学館’が86%を占めていて偏りがある

<u>→欠損自体に意味があると評価</u>

1. 欠損フラグの作成
2. 特定の値で補間
3. **気合の人力で ’大分類’, ‘中分類’, ‘小分類’を補完**

これで’著者名’以外の欠損値はない状態

書名

Missing:	0 (0%)
Distinct:	28 (10%)
パウ・パトロール　パウっ…	33%
ポケピースの～んびりシール	10%
スプラトゥーン３　イカす…	7%
Other	51%

大分類, 中分類, 小分類が同時に欠損したデータの書名の分布

出版社

Missing:	0 (0%)
Distinct:	7 (2%)
小学館	86%
ＴＴＪたちばな	5%
実教出版	4%
Other	5%

大分類, 中分類, 小分類が同時に欠損したデータの出版社の分布

著者名の正規化

The patterns for author name suffixes are limited.

・'著', '監修'など消したいsuffixはすべて全角空白のあとに出現

・ '著者名' の末尾に全角空白を含むデータは2638パターン

1. 全角空白+suffix
2. 全角空白+人の名前

著者名の末尾のパターン出現回数上位10件

出現回数2回以上を人力ですべて考慮　※出現回数1回から急激に人名が多くなる

書名の正規化

・上位層(どの書店でも20書名くらいまで)にしか季節性や傾向は見られない

＝大半の'書名'は年に数冊売れるだけ

→頻出な'書名'(今回は上位50)をHeuristicに選択し，気合ですべてのパターンを網羅

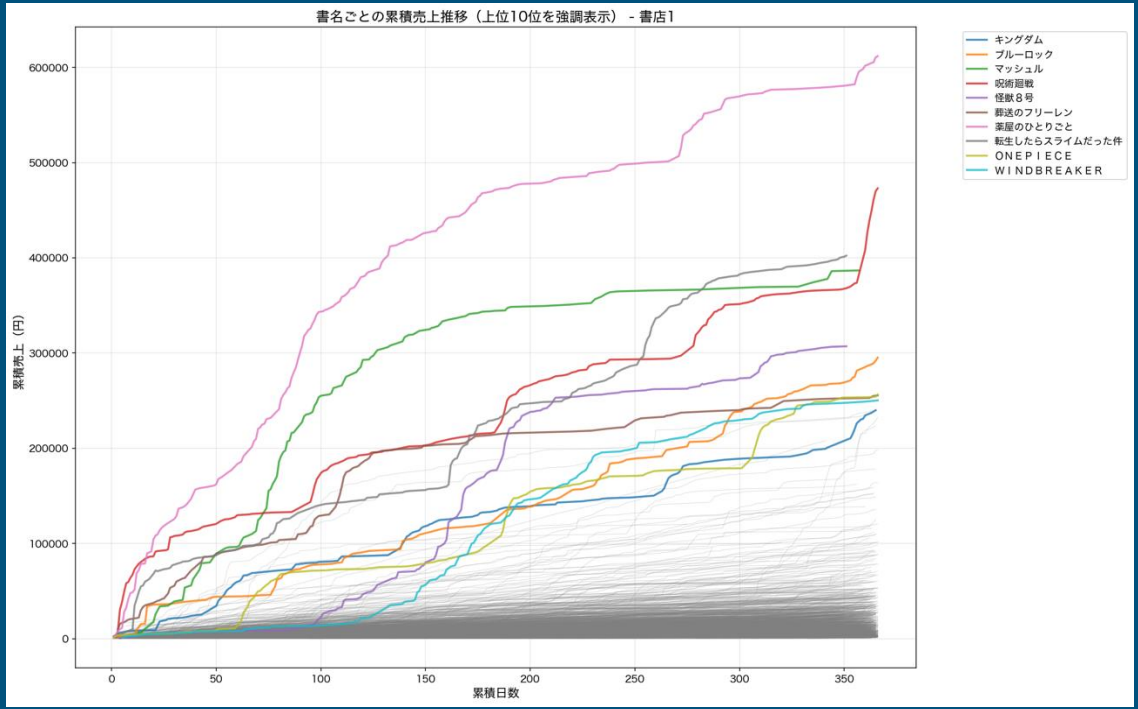

書店コード1における書名別の累計売上の推移(横軸：累積日数，縦軸：書名ごとの累積売上)

書名の正規化

Goal：頻出書名を「作品名_巻数」に正規化する

Concern：作品は同じだがシリーズが異なる場合

e.g. 「薬屋のひとりごと　1」，「薬屋のひとりごと～猫猫の後宮謎解き手　1」

→今回は「 薬屋のひとりごと_猫猫の後宮謎解き手1 」に統一

Positive Thinking：・別シリーズや2次創作と本シリーズは相互に影響している(仮説)

・「_巻数」を消去しなければ区別はできる(巻数と同じレイヤで)

Negative Thinking：データに多様性がなくなる．そもそも本来は別の本

書名の正規化

What is the Long Tail?

・Head

少数の商品が全体の売上の大部分を占める

・Tail

個々の売上は小さい膨大な数の商品

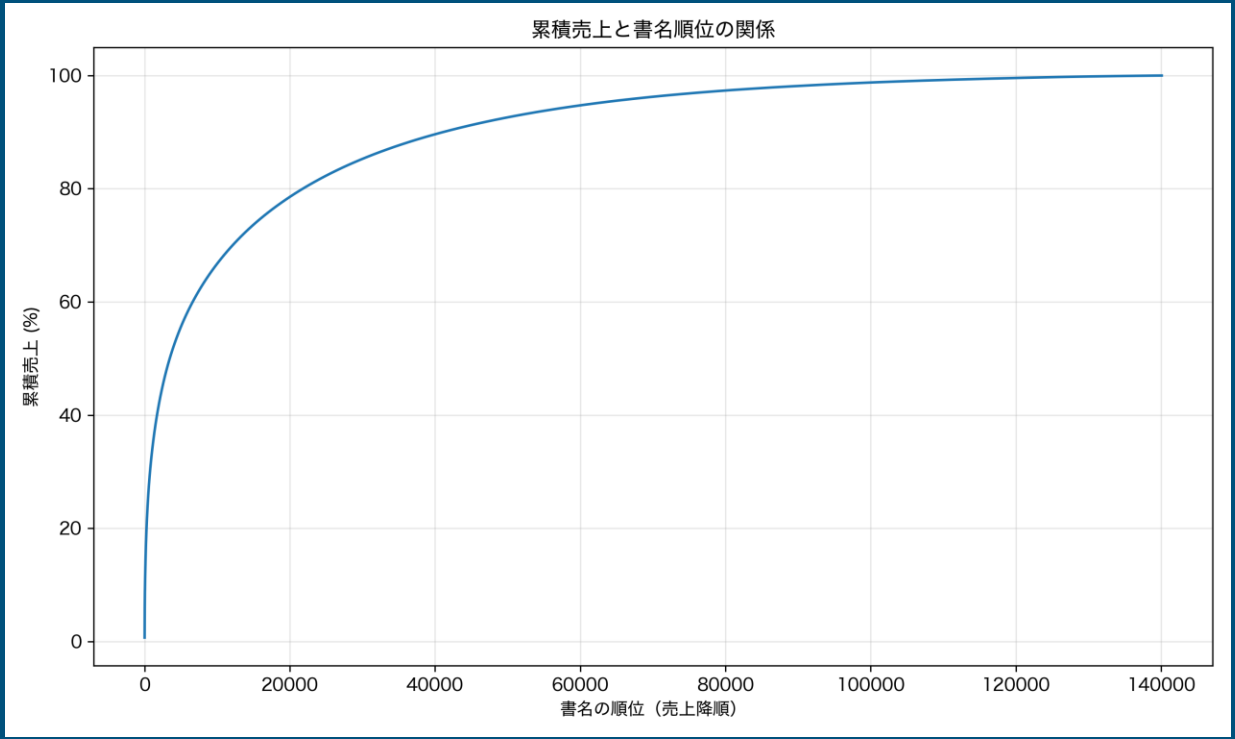

書名順位と累積売上の関係(横軸：書名ごとの累積売上で降順ソートしたものの連番，縦軸：横軸の地点までの累積売上が総累積売上に占める割合)

Headのみに季節性や傾向が存在

Headのみを採用し，Tailを捨てる戦略は本当に良いのか

統計分析

Title:
Book Title

Author:
Wendy Writer

Publisher:
Publisher Name

Copyright Date:
20XX

売上推移

・どの書籍が多く販売されているか調査(巻数は削除し、作品自体の力を評価)

・薬屋のひとりごと
→平均して売上上昇を保っている

・呪術廻戦
→年末で急激に売り上げが増加している

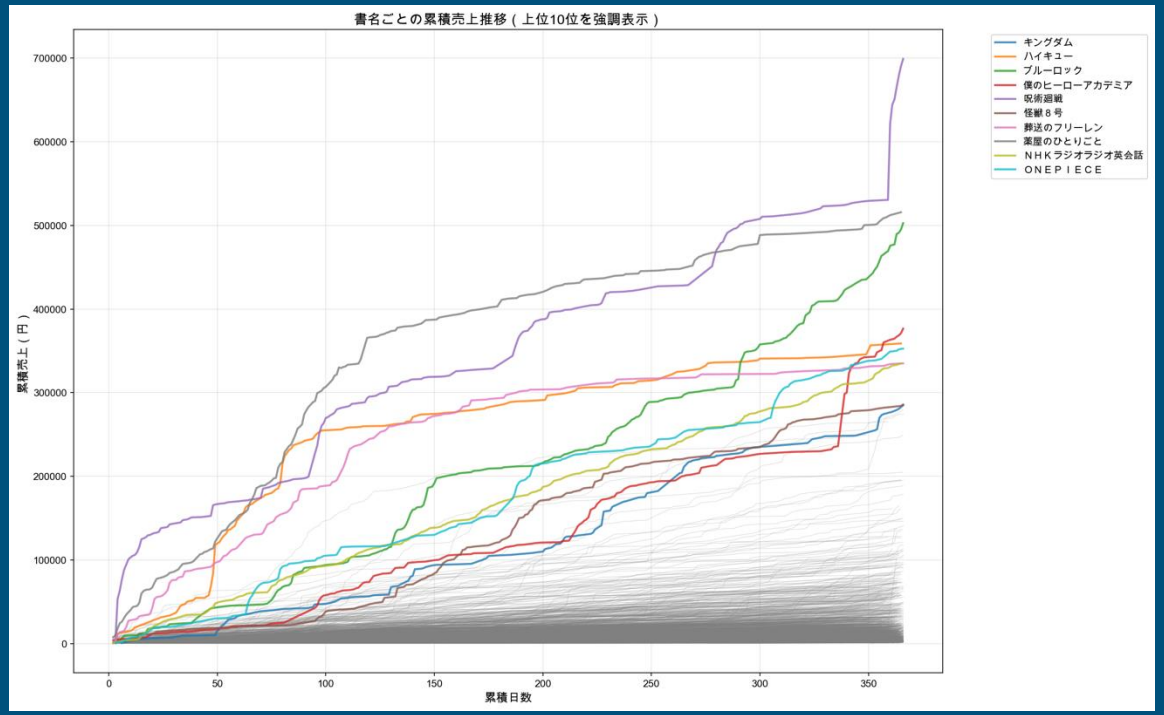

経過日数と累積売上の関係(横軸：累積日数，縦軸：累計の売上, 販売冊数×POS販売価格)

この2作品について出版直後の売り上げ推移を調査

出版直後の売上推移

- 薬屋のひとりごと（例：書店3）出版直後とみられる13巻、14巻の累計売上の上昇率が高い

- 14巻の販売開始日とみられる日以前までに約2万円の売上がある

→何か別の作品が集計されている可能性がある

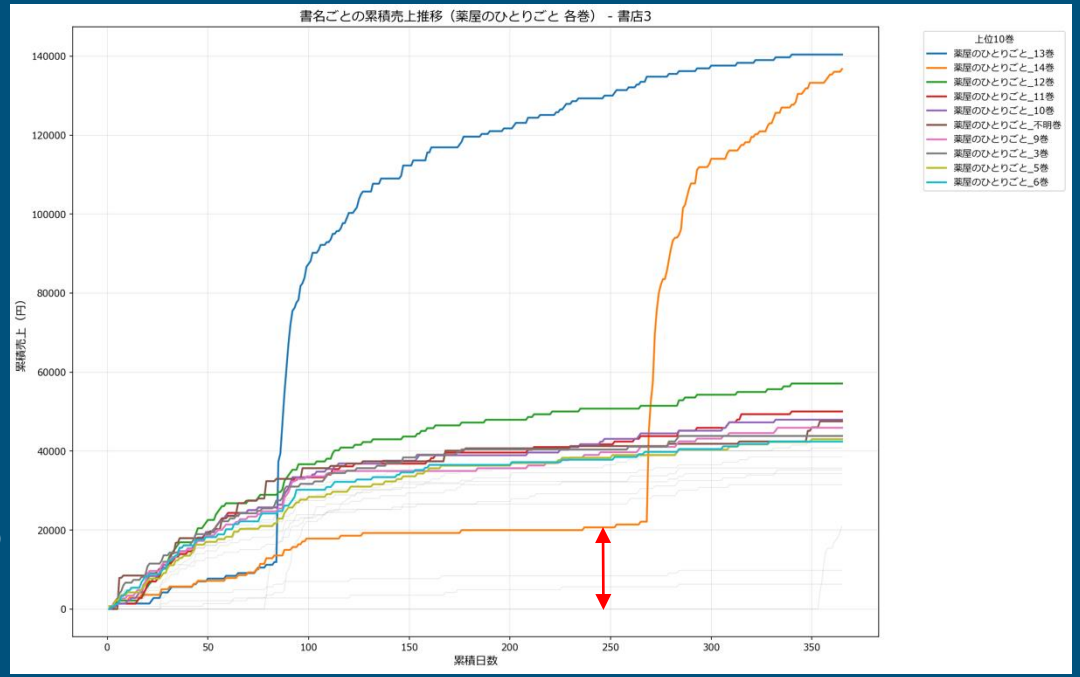

経過日数と巻数別累積売上の関係(横軸：累積日数，縦軸：巻数別累計の売上，販売冊数×POS販売価格)

出版直後の売上推移

・データ内を調査
→文庫とコミック
　が存在する

薬屋のひとりごと_14	日向夏	文庫
薬屋のひとりごと_14	日向夏	コミック
薬屋のひとりごと_14	日向夏	文庫
薬屋のひとりごと_14	日向夏	コミック

・コミックの発売時期前に同一書名の文庫本が販売されていた
　ため、売上推移グラフにずれが生じていた

・今回はコミックに絞って出版直後の売上推移を確認
→データから「大分類」カラムにおいて"コミック"のみ抽出
　再度分析を実行

出版直後の売上推移

- 薬屋のひとりごと（例：書店3）
  先ほどの修正を行い再分析

- 先ほどよりずれは減少したが
  依然としてずれが生じている

→データを見ると販売開始日以前
に「大分類」"コミック"表記で
販売されている書籍があった

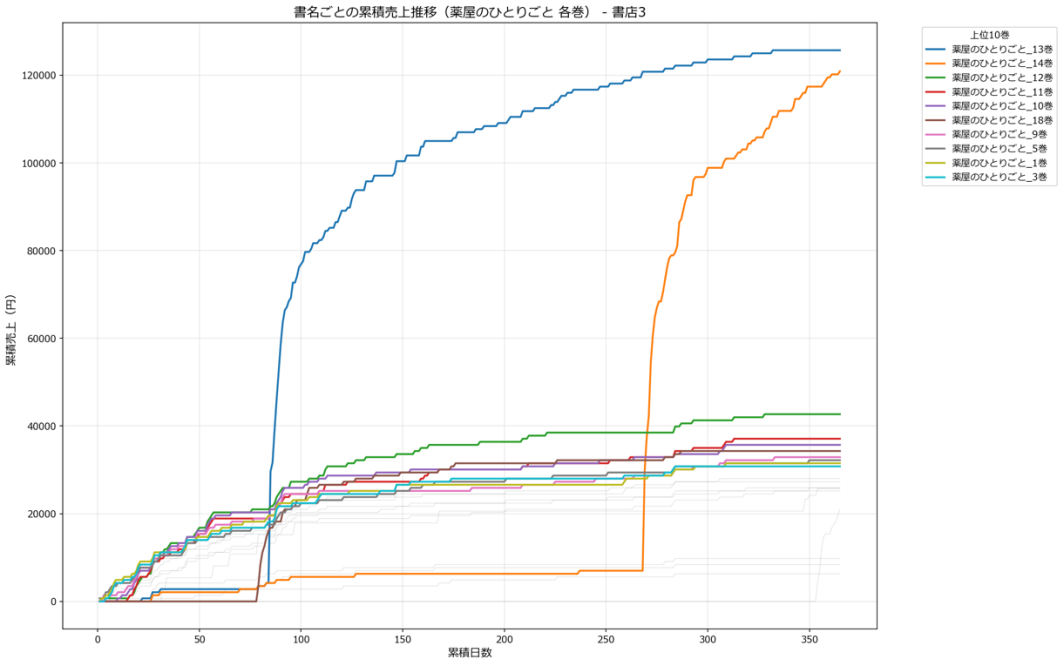

→調査しきれなかったため来週以降の課題としたい

経過日数と巻数別累積売上の関係(横軸：累積日数，縦軸：巻数別累計の売上,販売冊数×POS販売価格)

出版直後の売上推移

- 呪術廻戦（例：書店1）
  書名から巻数を抜き出し、巻数ごとに売上推移を表示
- 2024年以前に出版された巻と比較しても出版直後の伸び率が高い
- 呪術廻戦全体の売上のグラフ中に大きな上り幅ができる理由

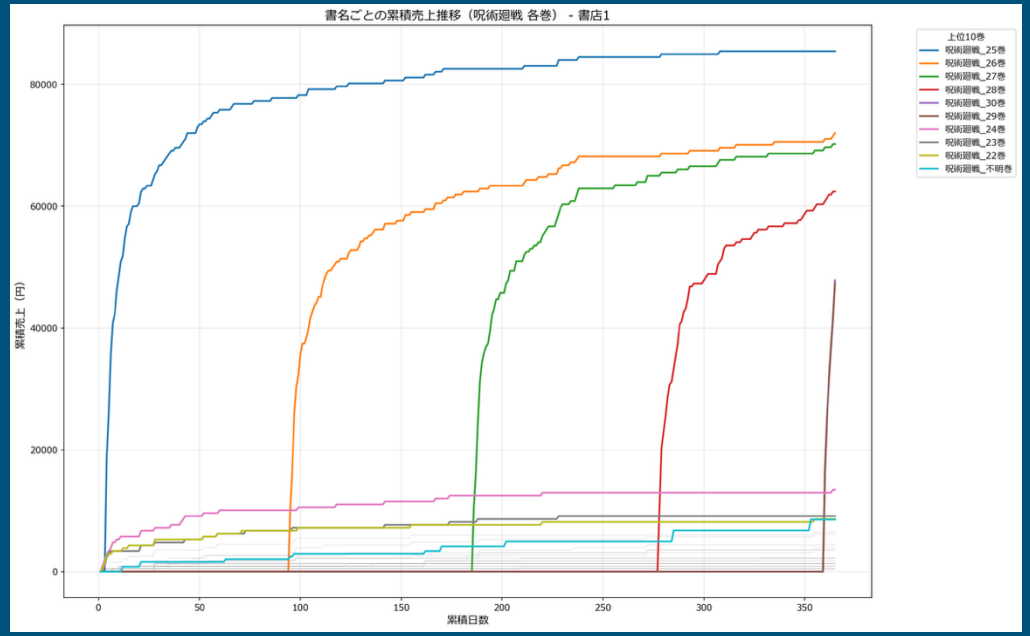

経過日数と巻数別での累積売上の関係
(横軸：累積日数，縦軸：巻数別累計の売り上げ, 販売冊数×POS販売価格)

出版直後の売り上げ推移

・出版直後の
　350日前後
　270日前後
　180日前後
　100日前後
で大きく売り上げが
向上している

350日前後の箇所の上り
幅は異常ではないか？

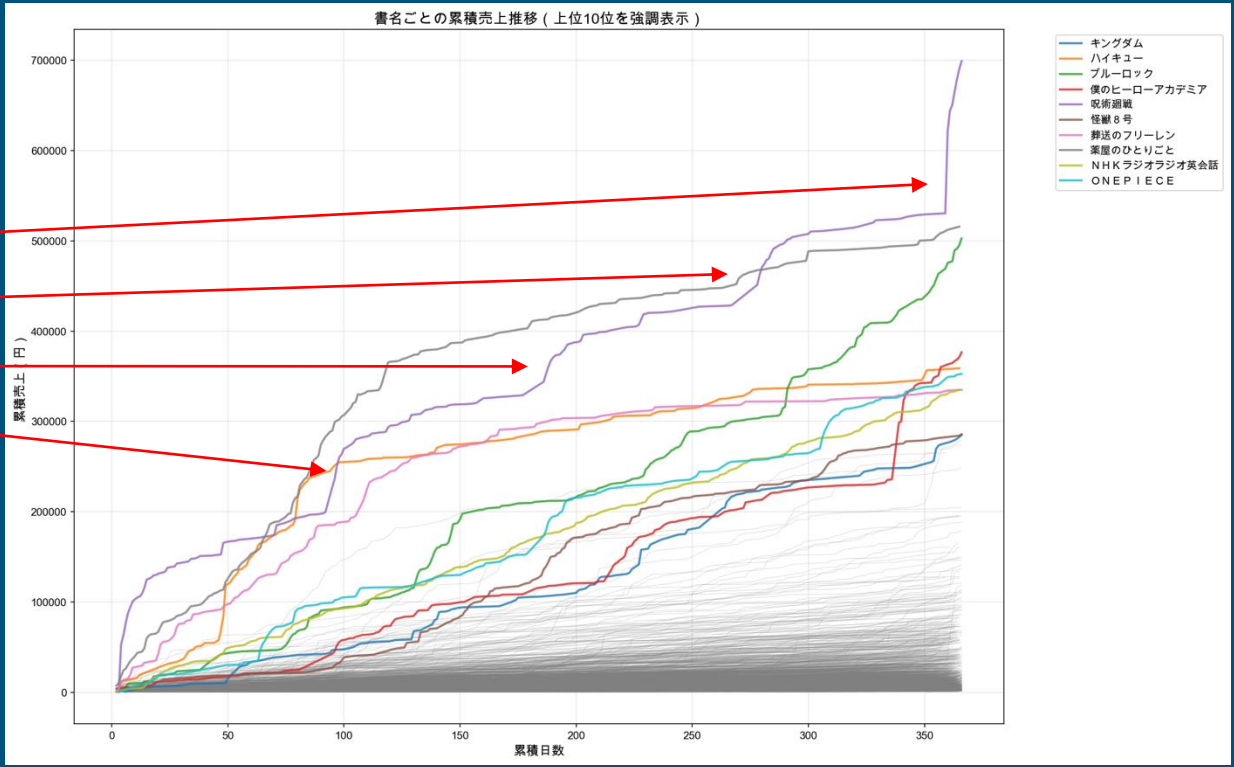

経過日数と累積売上の関係(横軸：累積日数，縦軸：累計の売り上げ, 販売冊数×POS販売価格)

出版直後の売り上げ推移

- 茶色と紫の線が重ねて表示されている
→29巻と30巻は2024/12/25同時発売であった

- 出版直後の巻が2つあるため異常な上り幅のグラフになっていた

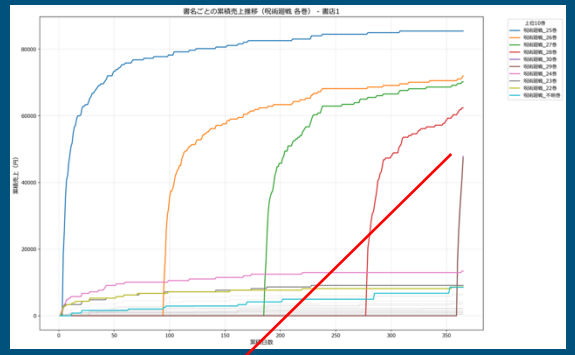

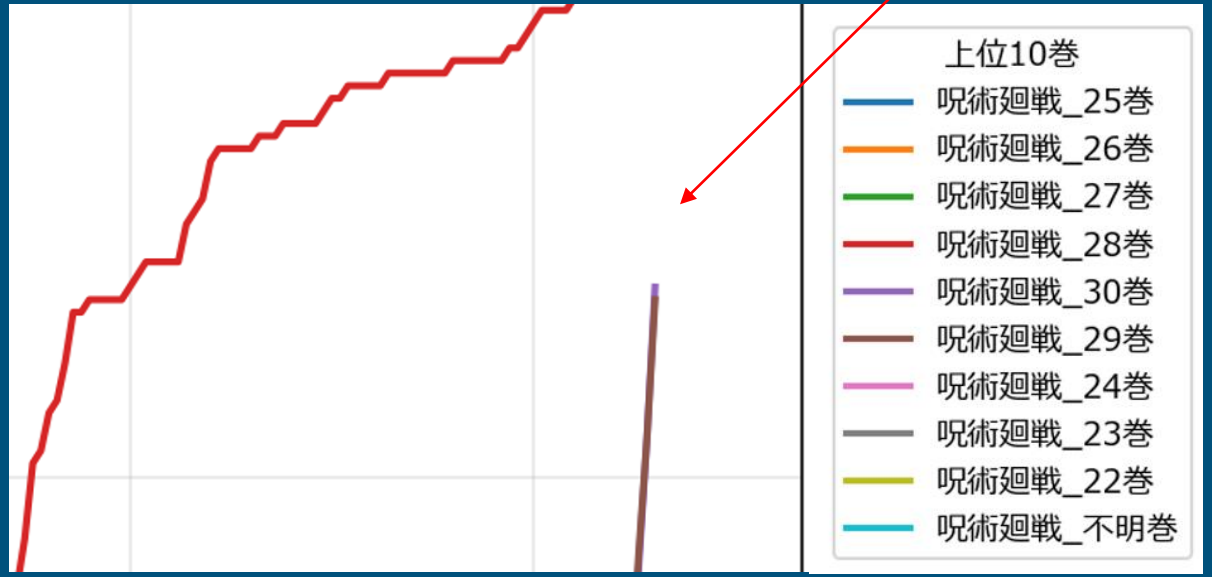

書店別分析

Title:
Book Title

Author:
Wendy Writer

Publisher:
Publisher Name

Copyright Date:
20XX

書店別特性の調査

・書店ごとにそれぞれ立地や特性が存在する
（例：郊外/都市部、単独店舗型/複合施設型 etc...）
→これらの情報が売上との相関をなしているのではないか

・e-honを用いて書店別に新たな情報/カラムを追加
https://www.e-hon.ne.jp/bec/GROUP0315

・e-honに記載されていない"書店コード2"はGoogleMapを使用してデータを追加した

書店別特性の調査

・データ概要
店舗ごとに差が出ると考えた項目を追加

・カラム構成
右図の14項目で構成

①書店コード/書店名
配布ファイル"Store_code.txt"と同一
35店舗それぞれに1-35の書店コード
書店コードと紐づけて各店舗名が記載

書店コード	int64	①
書店名	object	
住所	object	②
駅距離	int64	③
開店時間(平)	int64	
閉店時間(平)	int64	
営業時間(平)	int64	④
開店時間	int64	
閉店時間	int64	
営業時間	int64	
店舗型	object	⑤
人口	int64	
周辺人口	int64	⑥
合算人口	int64	

書店別特性の調査

②住所
e-honより抜粋
複合施設でビル名や階数も記載されている場合はその部分も含み記載

④開店時間・閉店時間・営業時間　各2項目ずつ
②と同じくe-honより抜粋
平日と休日(特殊時間含む)で営業時間が変わる店舗があったため
それぞれのカラムを平日、それ以外の2項目に分割して記載
例：10:00開店→1000と入力しint型で格納
営業時間の単位は分単位で格納
例：11時間営業→660で格納

書店別特性の調査

③駅距離　→　後述あり
GoogleMapを用いて調査
店舗と最寄り駅までの移動経路を徒歩で移動する際の道のりを記載
単位はmで格納

⑤店舗型
GoogleMapのストリートビューを用いて調査
独立店舗型、駅直結型、複合施設型の3パターンに分けて記載
このカラムは個人で判断したため、データの信用性は低い

書店別特性の調査

⑥人口、周辺人口、合算人口

e-statの2020年度国勢調査記録と、jSTAT MAPを用いて調査

https://www.e-stat.go.jp/　（国勢調査）

https://jstatmap.e-stat.go.jp/map.html　（jSTAT MAP）

・人口

jSTATで各書店の店舗があるメッシュを特定し、メッシュコードを取得

国勢調査記録のCSVファイルをもとに人口を算出し格納

書店別特性の調査

・周辺人口
人口カラムと同様に2つのサイトを用いて調査
店舗があるメッシュの周囲8メッシュの合計人口を算出し格納

・合算人口
人口カラムと周辺人口カラムの合計値を格納

※メッシュとは・・・
日本のすべての土地を1km四方で囲んだ範囲のこと（次ページ）
すべての1km四方にかぶらないように割り振られている番号を
メッシュコードと呼ぶ

書店別特性の調査

- 図例
  各四角は一辺1km
  ☆→店舗位置
  ①→人口カラム (1km^2)
  ②→周辺人口カラム (8km^2)
  ①+②→合算人口カラム (9km^2)

- 下部テキストが国勢調査記録の一部
  メッシュコード62406517の人口は
  3193人と分かる

- 手動で繰り返して人口系カラム3項目を設定

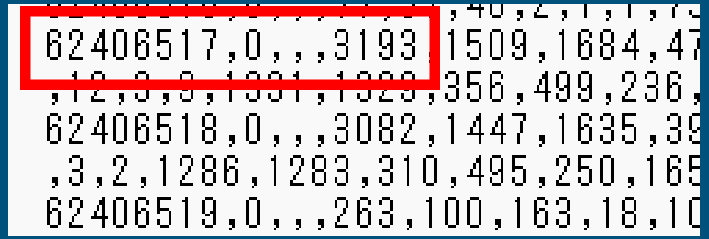

書店別特性の分析

- 駅距離との相関
  先週(10/22)の説明であった通り羽田空港内2店舗と営業日数が極端に少ない2店舗計4店舗を除外した。
  (上：全店舗、下：4店舗を除外)

- 相関は-0.13～-0.15

→店舗～駅間の距離と売上に相関はないといえる

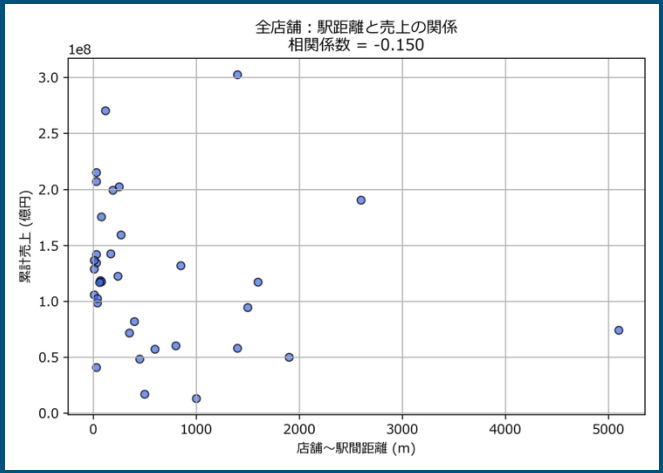

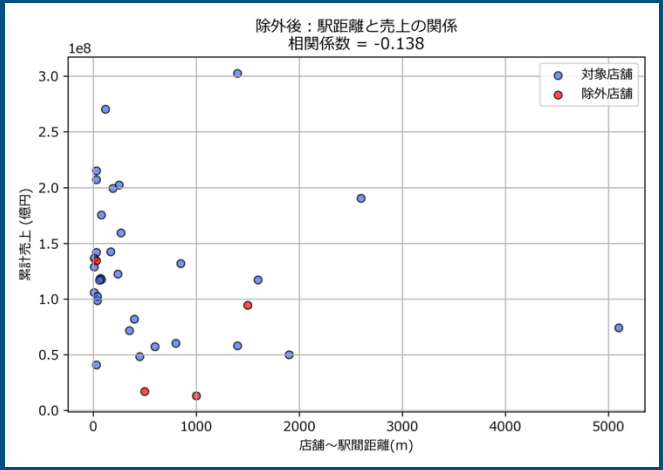

店舗～駅間の道のりと累積売上の関係(横軸：店舗～駅間距離(m)，縦軸：年間累計の売上, 販売冊数×POS販売価格)

書店別特性の分析

・駅距離（後述）

・そもそも店舗～駅間距離でデータを扱うのは正しいのか
上図：駅までの距離があまりにもあるため、通常は
徒歩を想定していない
下図：駅構内での距離が含まれておらず、改札後の
道のりのみ

→他公共交通機関(バスなど)や、駐車場の有無、
高速道路のICまでの時間などでも解釈できる

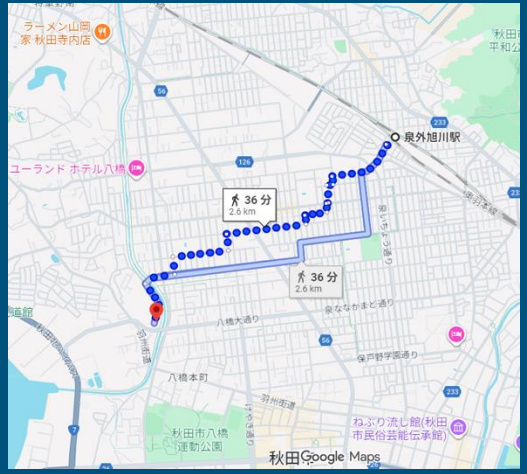

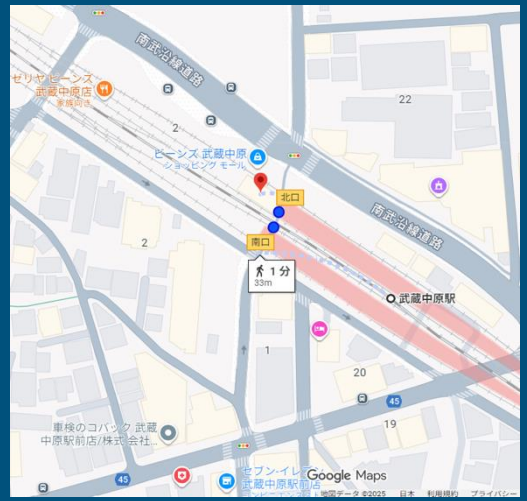

引用元：GoogleMap

書店別特性の分析

- 営業時間との相関
  開店時間や閉店時間にかかわらず店舗が
  オープンしている時間と売上の相関を調査

- 除外について
  前頁と同様に4店舗を除外したパターン

- 相関はみられなかった
→必ずしも除外すればよいのかは不明)

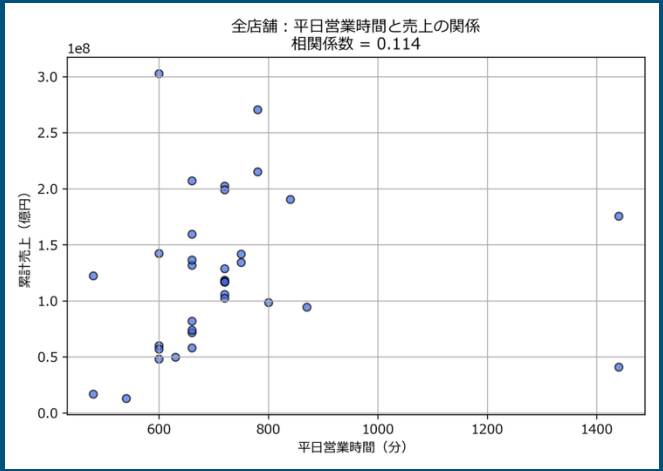

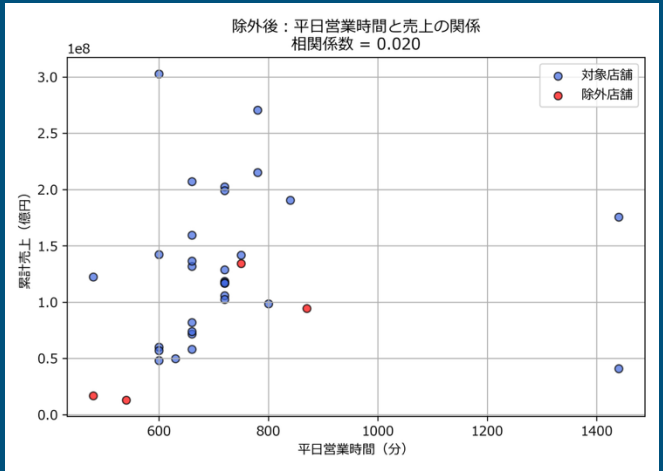

平日の営業時間と累積売上の関係(横軸：平日営業時間(分)，縦軸：年間累計の売上, 販売冊数×POS販売価格)

書店別特性の分析

- 人口との相関
  メッシュを用いて店舗が含まれる1km四方に住んでいる人口と売上で比較

- 除外について
  ①前頁と同様に4店舗を除外して相関を調査
  →人口という項目においては羽田空港内2店舗のみ除外でも相関がみられるのでは
  ②営業日数が少ない2店舗は相関調査に戻し、羽田空港内2店舗のみを除外

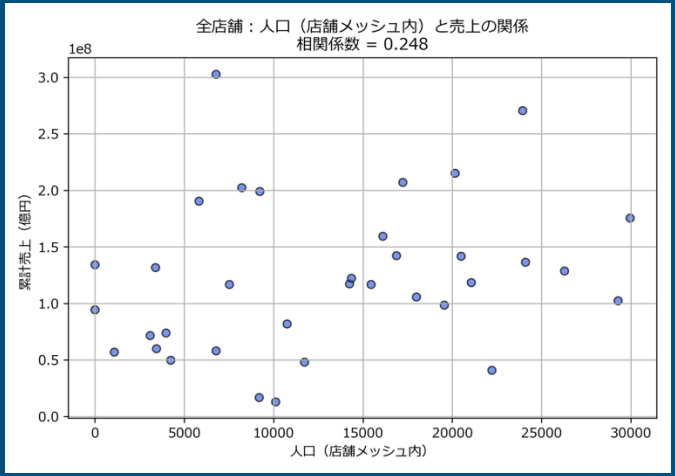

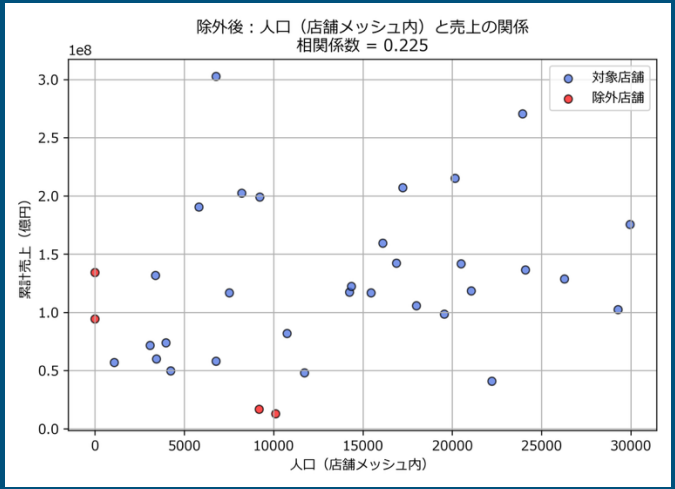

1km四方内の人口と累積売上の関係(横軸：1km四方内人口(人)，縦軸：年間累計の売上, 販売冊数×POS販売価格)

書店別特性の分析

- ②羽田空港内2店舗のみを除外した相関
  各データ数の相関
  - 全体　　：0.248
  - 4店舗除外：0.225
  - 2店舗除外：0.256

→大差は見られなかった

- どのデータ数でも弱いが正の相関がみられた
  →人口をベースに分析を続けていく

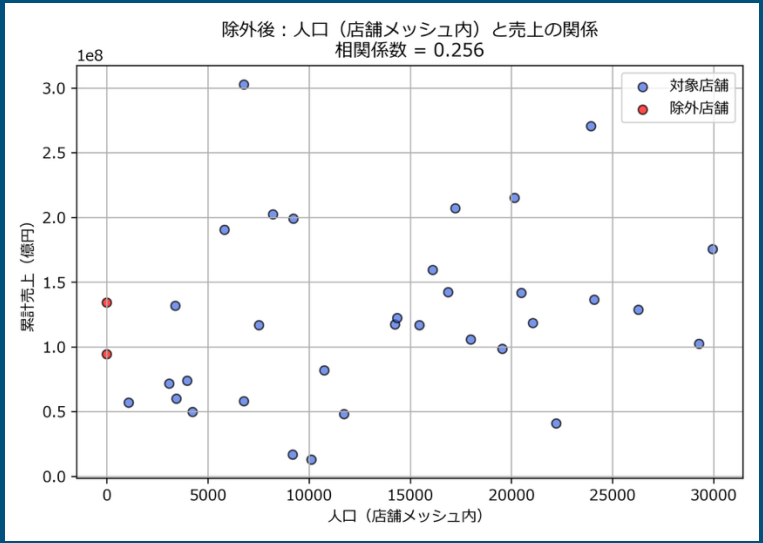

1km四方内の人口と累積売上の関係(横軸：1km四方内人口(人),
縦軸：年間累計の売上, 販売冊数×POS販売価格)

書店別特性の分析

- 合算人口との相関
  前頁の1km四方から3km四方まで範囲を拡大
- 除外について
  先ほどと同様に羽田空港内2店舗のみを除外
- 人口と比較しても相関が弱く、相関はない
  →都市部は書店が密集しているため3km四方
  まで範囲を広げると別店舗に流れている
  人口も含んでしまうのではないか

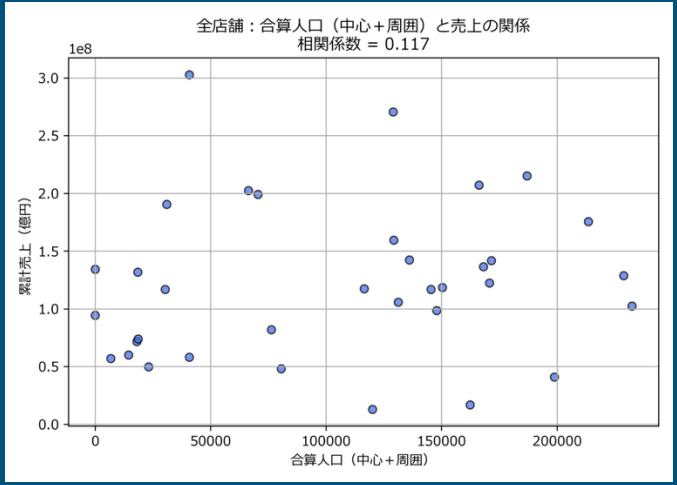

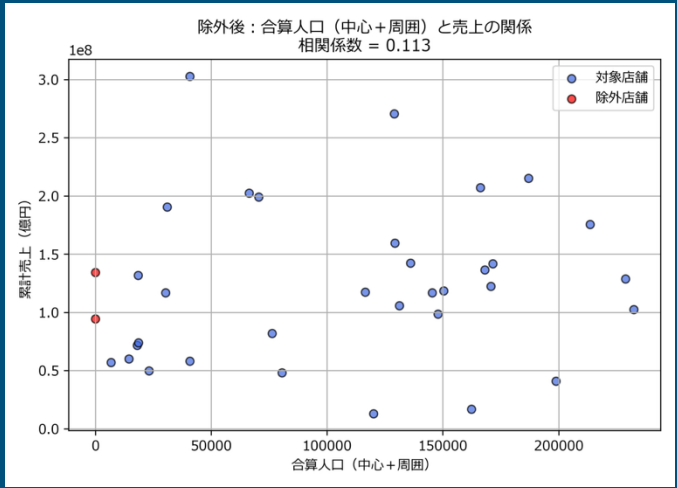

3km四方内の人口と累積売上の関係(横軸：3km四方内人口(人)，縦軸：年間累計の売上, 販売冊数×POS販売価格)

書店別特性の分析

- 店舗型と売上の相関
  駅構内・複合施設・独立店舗の3パターンに分類
  GoogleMapのストリートビューや住所から
  個人の意見で分類したため信頼性は低い

- 駅構内型の売上が一番高い
  →駅構内型は除外後で7店舗、うち5店舗が首都圏
  に位置している
  店舗型よりはやはり人口や都市部/郊外の差が
  大きいと推測した

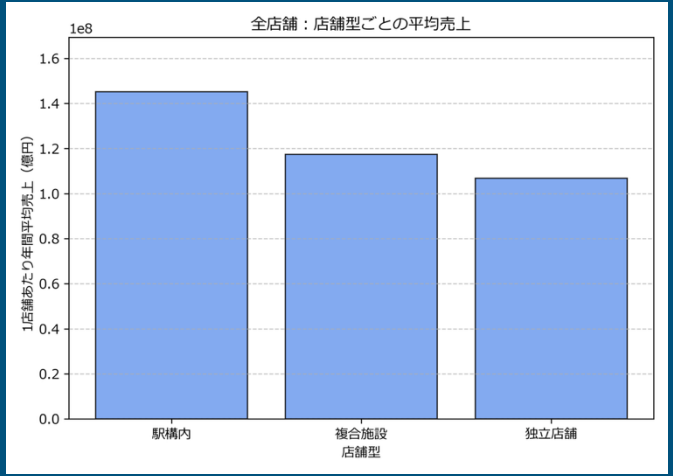

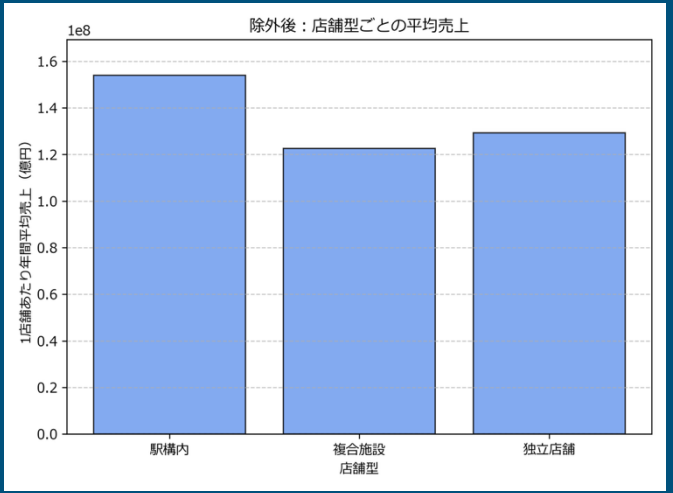

店舗型と1店舗当たりの平均売上の関係(横軸：店舗型，縦軸：年間累計の売上, 販売冊数×POS販売価格)

書店別特性のまとめ

今後の方針

・売り上げと各カラムの相関について
　強い相関があるカラムは見られなかった
　→売上で分析をするのではなく、客数や販売冊数で分析してみる
・人口のカラムで弱い正の相関がみられた
　→今後は人口カラム詳細に分解して分析を続けていく
　　（例：男女別人口比・15歳以下/65歳以上・夜間人口/昼間人口）

課題

・距離や営業時間を絶対的な数値でおいて分析することの是非
・相関を求める際に除外した4店舗をどのように扱うか

書店別特性の分析

- 周辺施設との相関
  jSTAT MAPで人口カラム計算時と
  同様のマス内の地図記号から
  施設数を人力でカウント
  人力のため見逃しの可能性有

- 除外について
  これまでと同様に4店舗を除外したパター

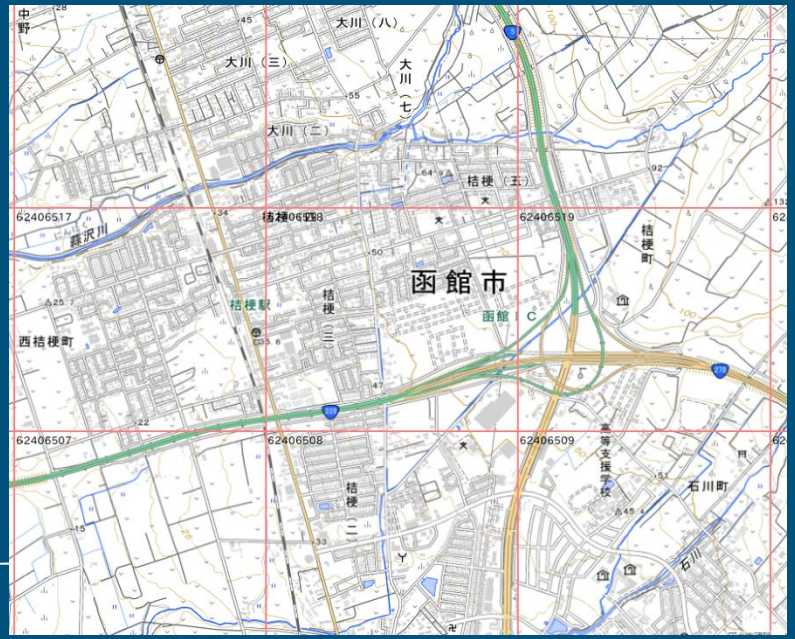

書店別特性の分析

- 周辺施設との相関

  売上全体と周辺施設には
  「小・中学校」
  「老人ホーム」との
  弱い相関のみだった

- 書店毎の大分類別売上と合わせ
  相関を調べる

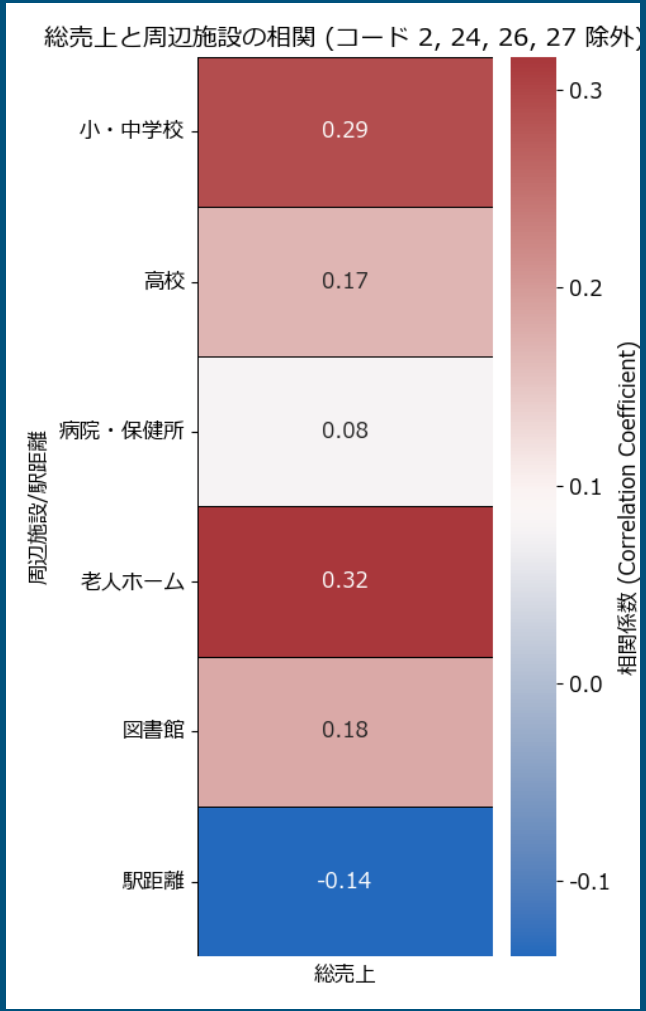

書店別特性の分析

・周辺施設との相関

売上率
＝書店の大分類の合計売上
　÷書店の総売り上げ

　小・中学校
　「ビジネス」「経済」
　と相関がある
　高校
　「経済」と相関がある

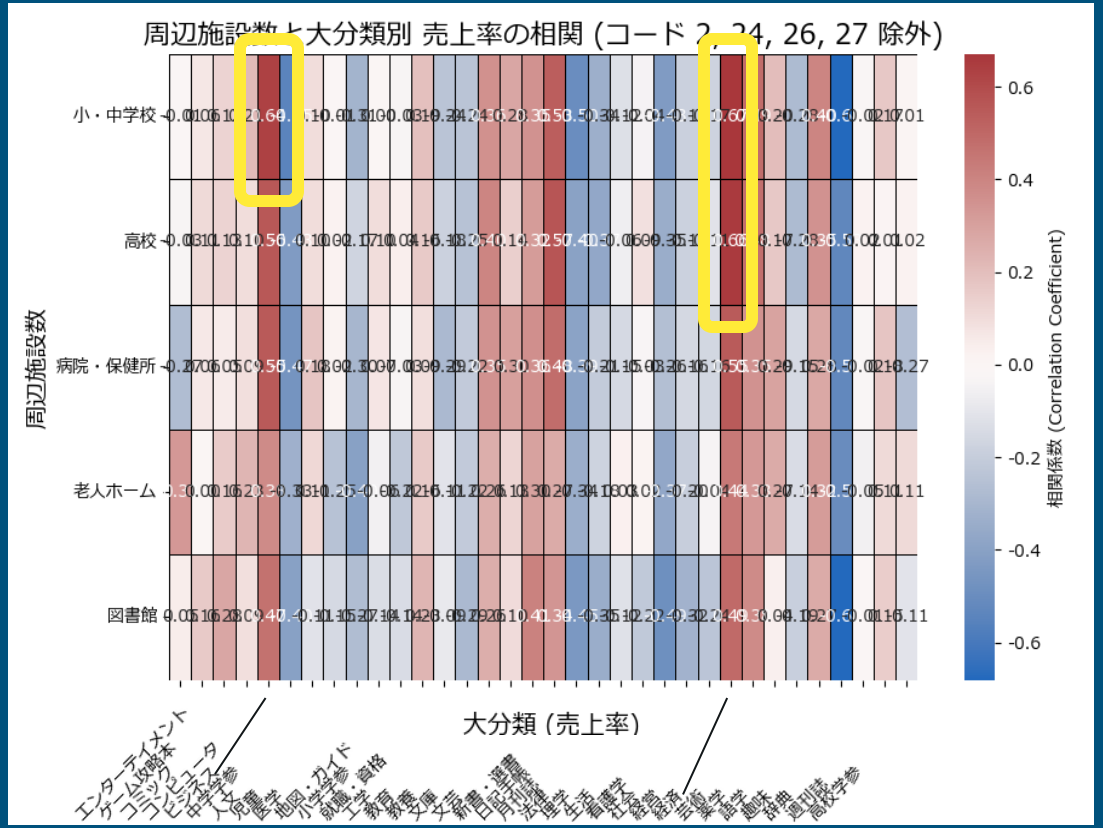

書店別特性の分析

他店舗例：

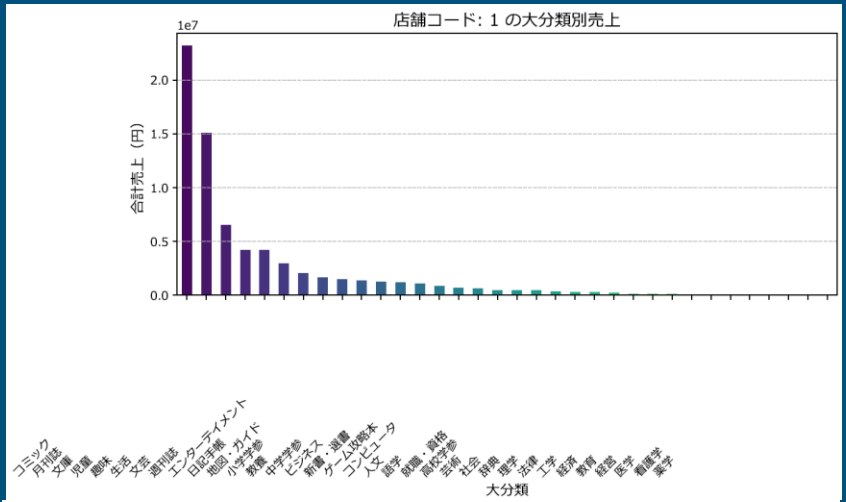

- 店舗21の大分類別売上

  ほかの店舗に比べて、
  コミックの売上が
  極端に高い

店舗21

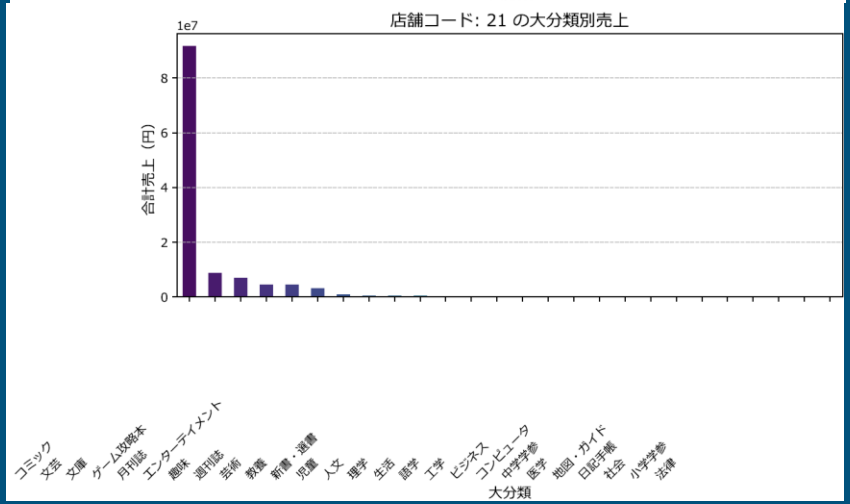

大分類ごとの売上(横軸：大分類，縦軸：年間累計の売上, POS販売冊数×本体価格)

書店別特性の分析

- 書店21除外後の
  周辺施設との相関

  小・中学校、高校で
  「ビジネス」「日記手帳」
  「経済」
  と強い相関

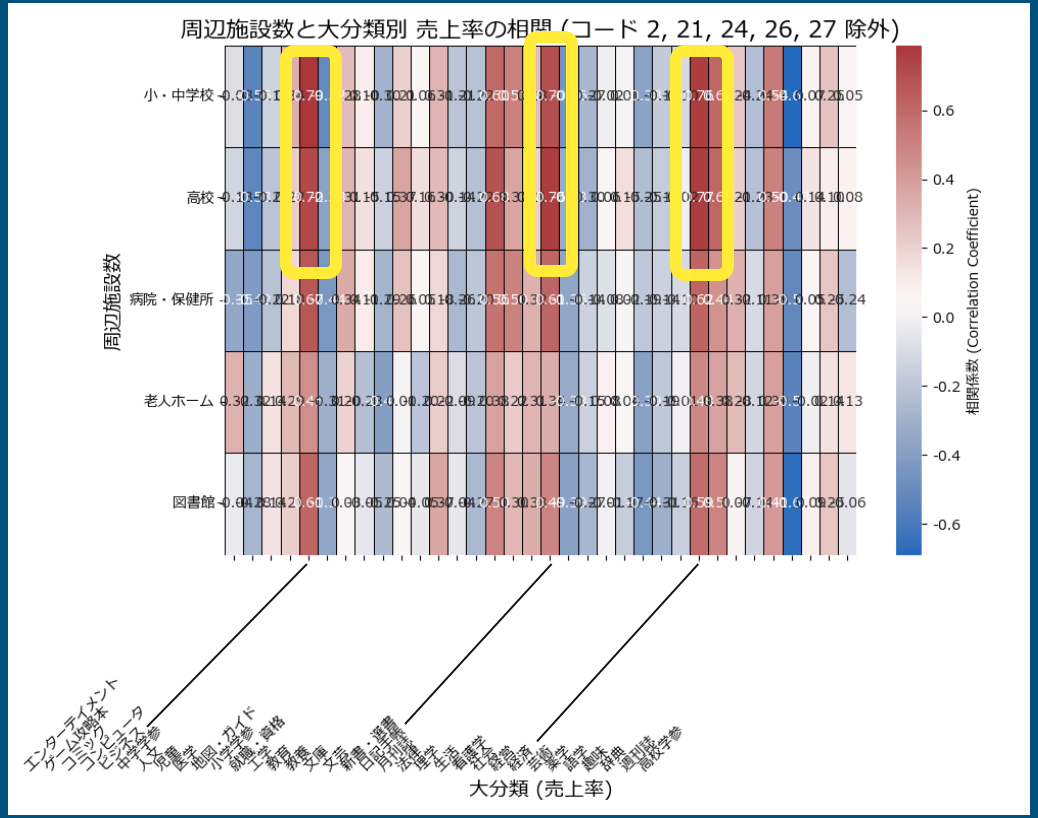

書店別特性のまとめ

・周辺施設との相関について
小・中学校、高校と「ビジネス」「日記手帳」「経済」の強い相関
→分類的に親世代が影響している？

・小・中学校の全体に対する弱い相関は親世代によるものの可能性有
老人ホームは？
→顧客情報がないから何とも言えないがカウントするマスを増やせば
相関の精度を上げられる？

予測モデル構築

Q. なぜ予測モデルを作るのか

Why go to the trouble of building predictive models?

1. 予測モデルを作る過程で，データの理解が深まる
2. 特徴量エンジニアリングの効果を数値で評価できる

   e.g. MASE(Mean Absolute Scaled Error)：ベースラインとの誤差

   ここで検証した特徴量エンジニアリングはクラスタリングでも使える
3. 中間目標の設定

   彷徨うにしても中間地点を決めたい(収束したい)

   だめそうだったら方向を変えれば良い

今わかっていること

・書店ごとで傾向が違う(前週10/22の発表資料を参照)

e.g. ‘書店コード’ [26, 27, 2, 24, 29]には注意

・よく売れる本には季節性や傾向が見られる

・よく売れない本が大半であり，その本に特徴は見られない(数回買われるだけ)

・時系列は日次1年間の366のみ

(3,969,881, 12)

列名	データ型
Unnamed: 0	int64
日付	object
書店コード	int64
ISBN	object
出版社	object
書名	object
著者名	object
大分類	object
中分類	object
小分類	object
本体価格	float64
POS販売冊数	int64

データの概要(データ数，カラム数)

どの視点でデータを見るか

1. 全データを書店ごとに分割する

2. ’日付’, ‘書名’を主キーに .groupbyし, 売上(POS販売冊数*本体価格)の合計を取る

※本体価格はグループ内の平均値

※その他のカラムはグループ内の最頻値で統一(特に’著者名’は表記ゆれが多く分別するのが困難だったから)

＝目的変数：各書店のその日の書籍ごとの売上

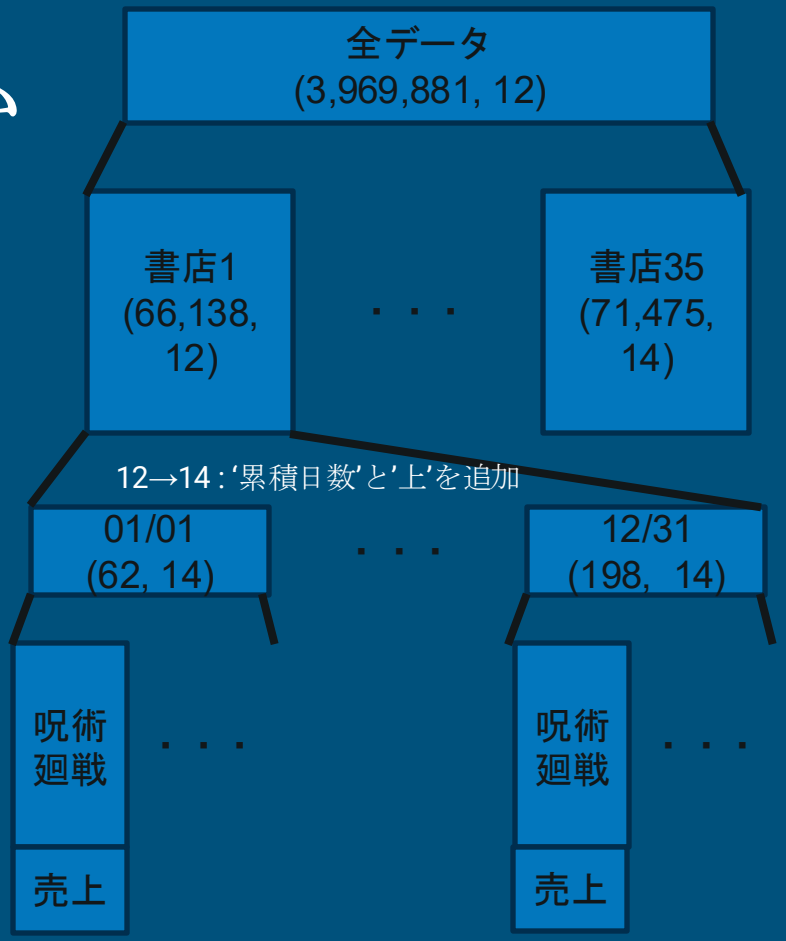

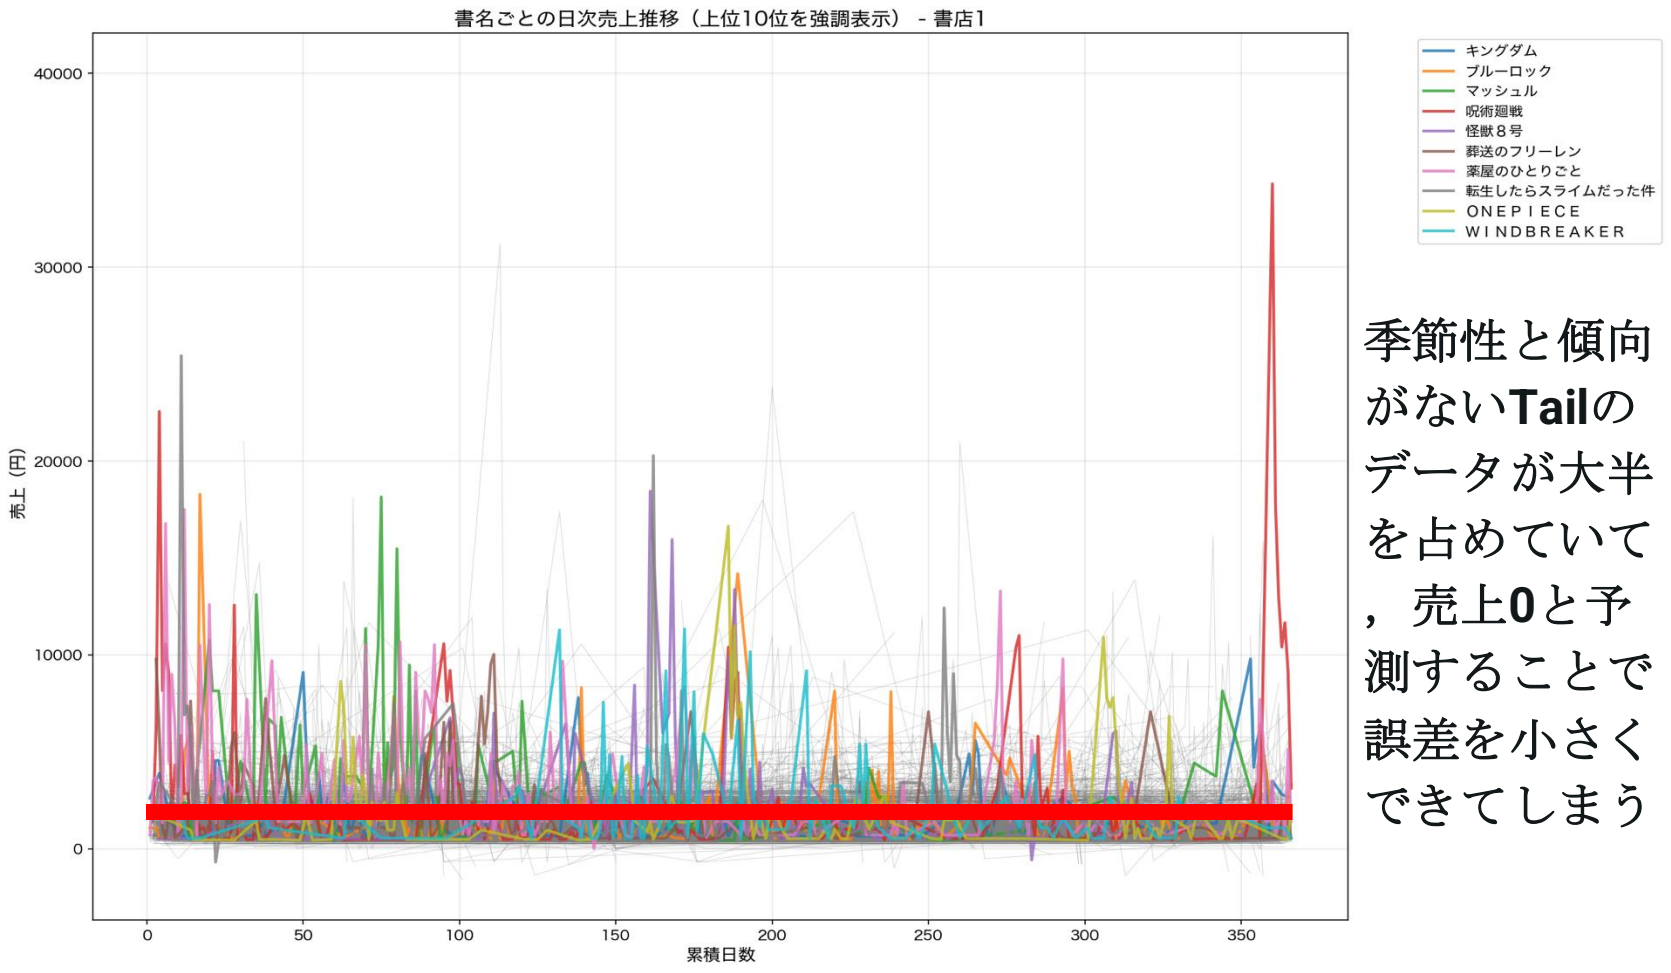

季節性と傾向がないTailのデータが大半を占めていて，売上0と予測することで誤差を小さくできてしまう

書店コード1における書名別の日次売上の推移(横軸：累積日数，縦軸：書名ごとの日次売上)

データの拡張

・季節性を考慮するため，’日付’を’year’, ’month’, ‘day’, ‘is_day’, ‘is_weekend’, ‘week_of_year’, ‘quarter’に分割

・重要なハイパーパラメータ

CONTEXT_LENGTH	予測のために参照する過去のデータの期間
PREDICTION_LENGTH	予測を生成する期間の長さ

→**CONTEXT_LENGTH**と**PREDICTION_LENGTH**を使い，「**Tail**データの排除」と「データ拡張」を同時に行う

データの拡張

1. MIN_LENGTH = CONTEXT + PREDICTION
2. if < MIN_LENGTH
   drop
3. If 売上の合計 < 閾値
   drop
4. データ長とMIN_LENGTHでSLICEを決定
5. for in SLICE
   ランダムにSTARTを決定
   END = START + MIN_LENGTH

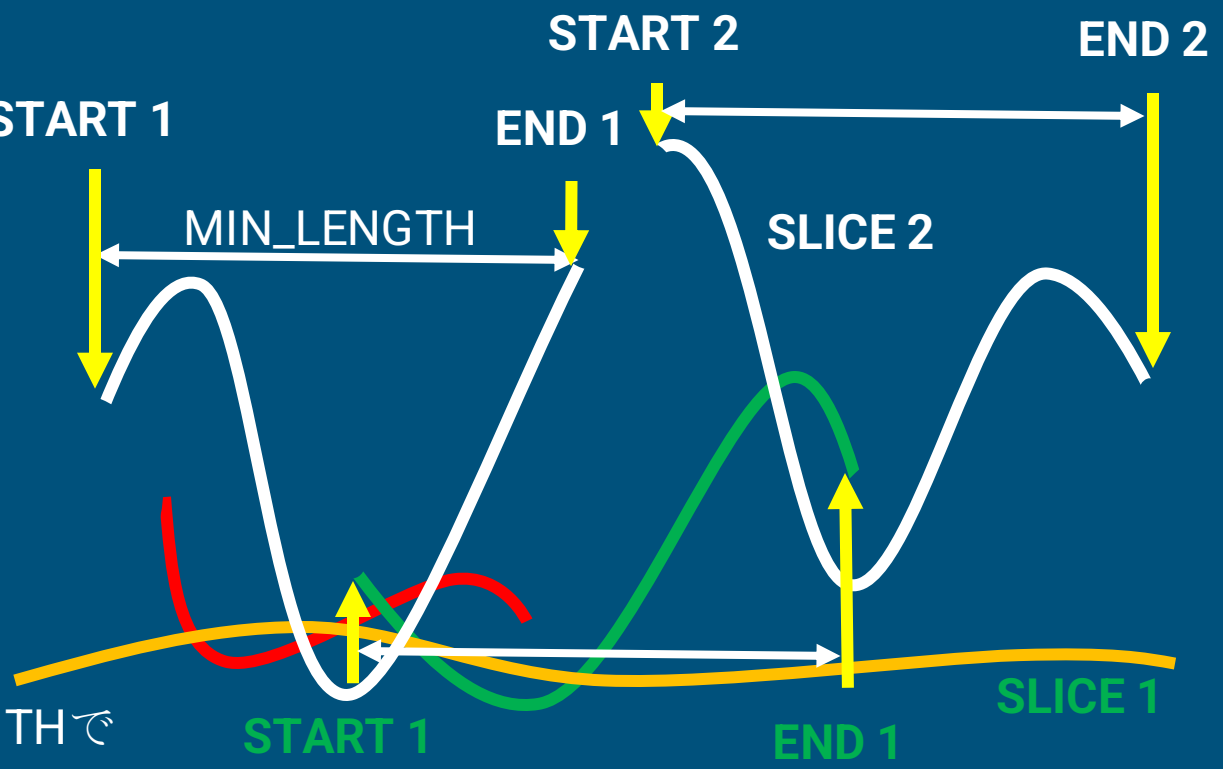

データの拡張

Problem : データの数が一気に絞られる(ロングテールな分布だから)

e.g. CONTEXT = 56, PREDICTION = 28　のとき

データ数	3,504,873	→	321,684
‘書名’のユニーク数	140087	→	339

Solve : ・ウィンドウ・ローリング処理

過去**WINDOW**日分の統計値(平均値・標準偏差など)を追加

※データ数を増やす訳では無いが，新たな特徴量を作る

・時系列を逆にしたデータを追加

時系列を逆にするとは

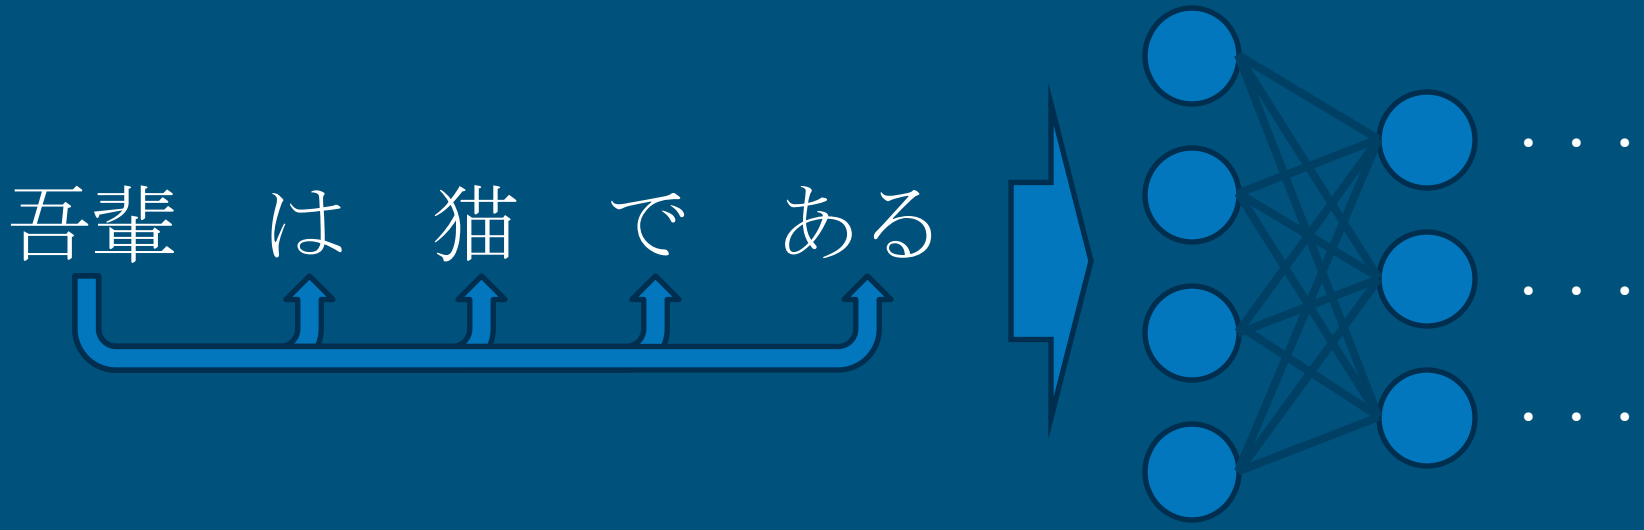

時系列を逆にするとは

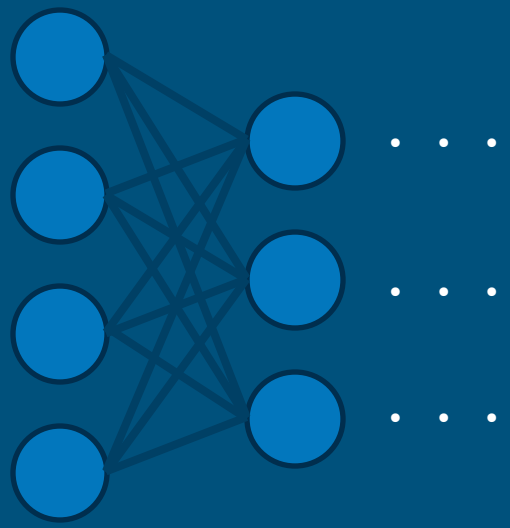

吾輩　は　猫　で　ある

I　am　a　cat

「吾輩」が「I」に変換されるまで「は」「猫」「で」「ある」を経由する
→対応関係のある単語の距離が近くなる
＝勾配がダイレクトに伝わる

※色々話したが今回は使わない(モデルの機構により)

使用するモデル

TFT(Temporal Fusion Transformer)

2019年，Googleから発表されたTransformerをベースにした時系列予測のためのアーキテクチャ

・高い予測精度：短期的なパターンと長期的なパターンの両方を捉えるのが得意，静的特徴量・既知の動的特徴量・過去の動的特徴量を賢くfusionする

既知の動的特徴量	未来で確定している情報
過去の動的特徴量	過去の実績からしかわからない実績値

・解釈可能性：Attentionを可視化することでモデルが注意した箇所を分析できる

・確率的予測：予測の不確実性を定量化できる

※実装にはGluonTS(Amazonが開発した時系列予測のためのPythonライブラリ)を使用

自己教師あり学習

直感で自然言語処理に
似ていると感じたので採用

・Next token prediction
「今日は天気が良いので，」
→「公園に行った．」
・Masked Token Prediction
「私は [MASK] でご飯を食べる．」
[MASK]→箸

自己教師あり学習
(Self-Supervised Learning)

自己教師あり学習：データから自動生成した擬似ラベルで学習する

BERT，GPTのような巨大な事前学習済モデルを支える学習方法

Ex) Next token prediction：続く単語を予測する
Ex) Masked token prediction：一部をマスクし復元する

人工知能実現のために最も重要な要素

6ステップでマスターする機械学習(2.1~2.4) 発表資料(Shunsei NARAHARA)より抜粋

SLICEにより両手法を擬似的に再現している

Next token prediction と Masked Token Prediction

・ミクロな視点で見れば
Next token prediction

・マクロな視点で見れば
Masked Token Prediction

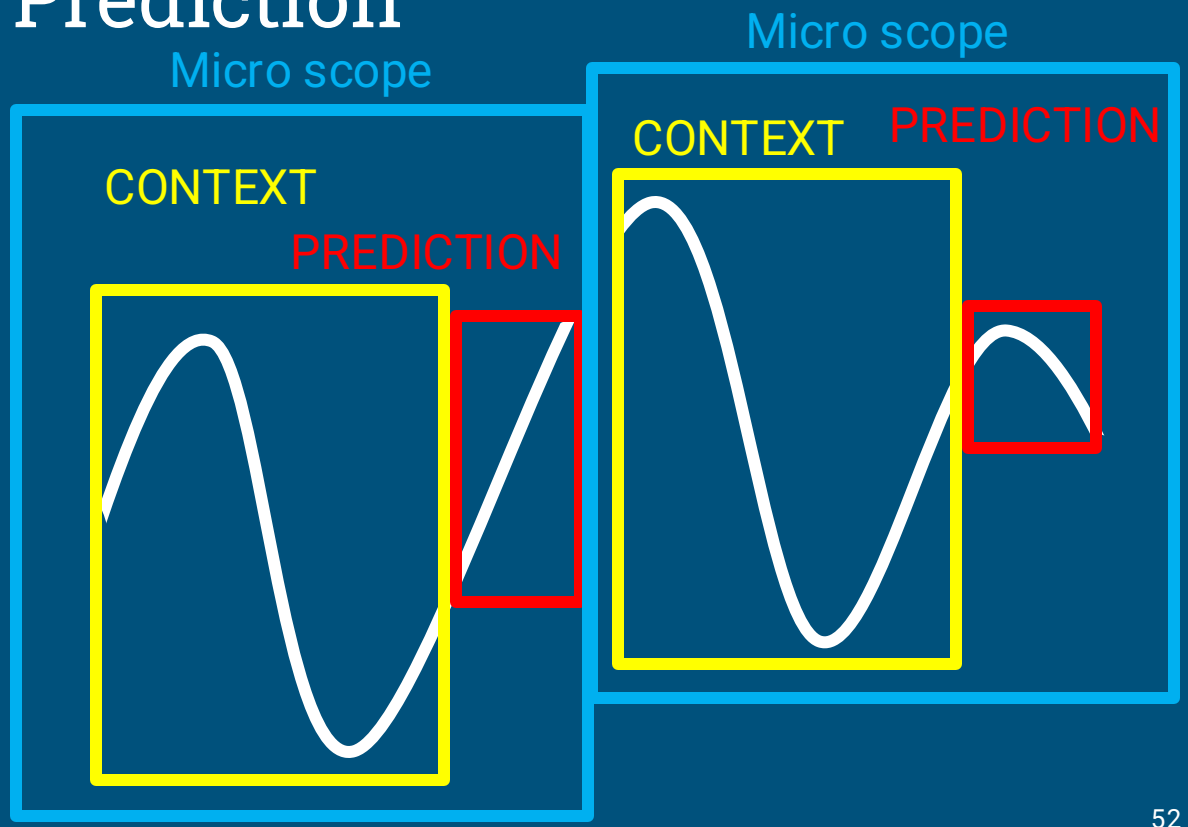

Next token prediction と Masked Token Prediction

・ミクロな視点で見れば
Next token prediction

・マクロな視点で見れば
Masked Token Prediction

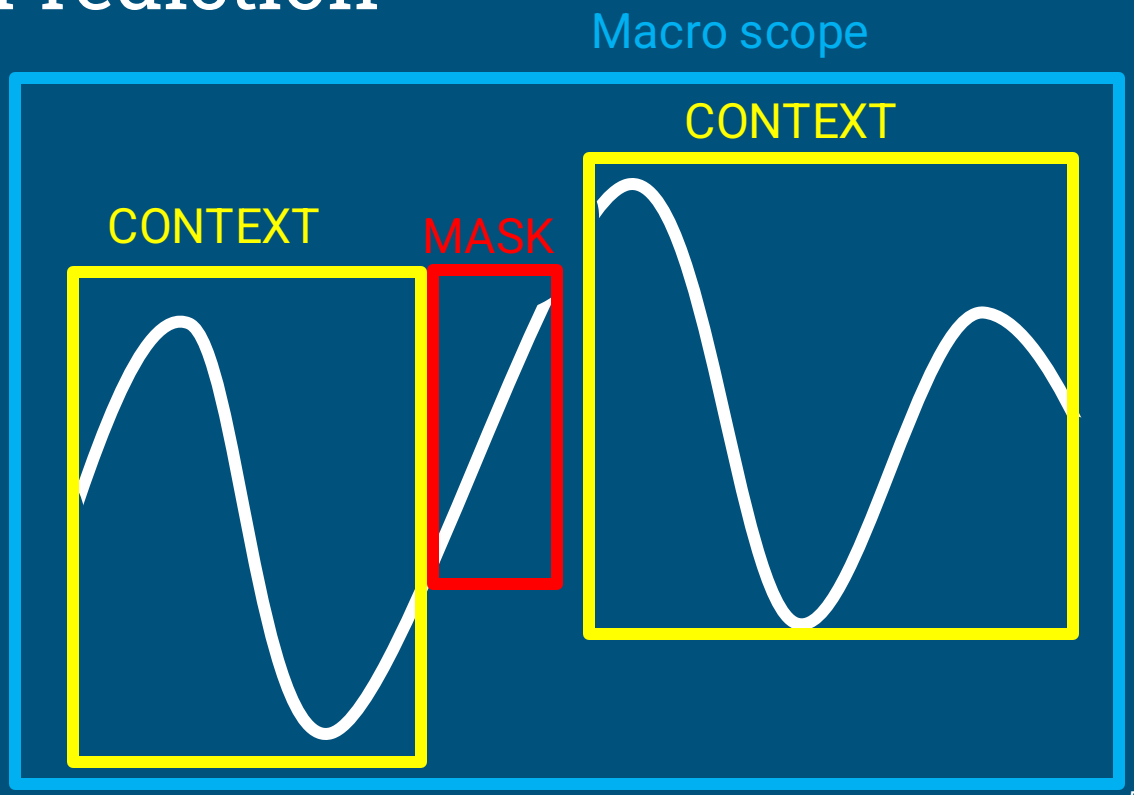

パラメータ

データ(321684, 38)
5,078スライス(train:2666, test:2412)

静的特徴量　　'sample_weight'(長いデータにかけるbias，ほぼSLICE数)
既知の動的特徴量　　'day_of_week', 'is_weekend', 'quarter'
過去の動的特徴量　　'lag{window}', 'mean{window}', 'std{window}', 'max{window}'
※特徴的なものを抽出

etc.. epoc, batch_size, hidden_size, dropout_rate, learning_rate, num_heads …

評価指標

MASE = mean(予測値 − 実測値) /
mean(ナイーブな予測値-実測値)

RMSE(Root Mean Square Error)
予測値と誤差の2乗の平均の平方根
MAPE(Mean Absolute Percentage Error)
誤差の絶対値を実測値で割った百分率
sMAPE(Symmetric Mean Absolute Percentage Error)
MAPEのゼロ除算を防いだもの(分母を実測値+予測値にする)

MASE (Mean Absolute Scaled Error)
ナイーブな予測値と予測値の誤差の絶対値の平均，今回は1日前のデータ
MASE < 1 1日前の値で予測するより優れている
MASE > 1 1日前の値で予測するより劣っている

予測結果

RMSE　1782.67
MAPE　0.4001
sMAPE 0.3908

MASE　0.7064
< 1

※時系列を逆にした場合
MASE　0.7736
RMSE　2267.67

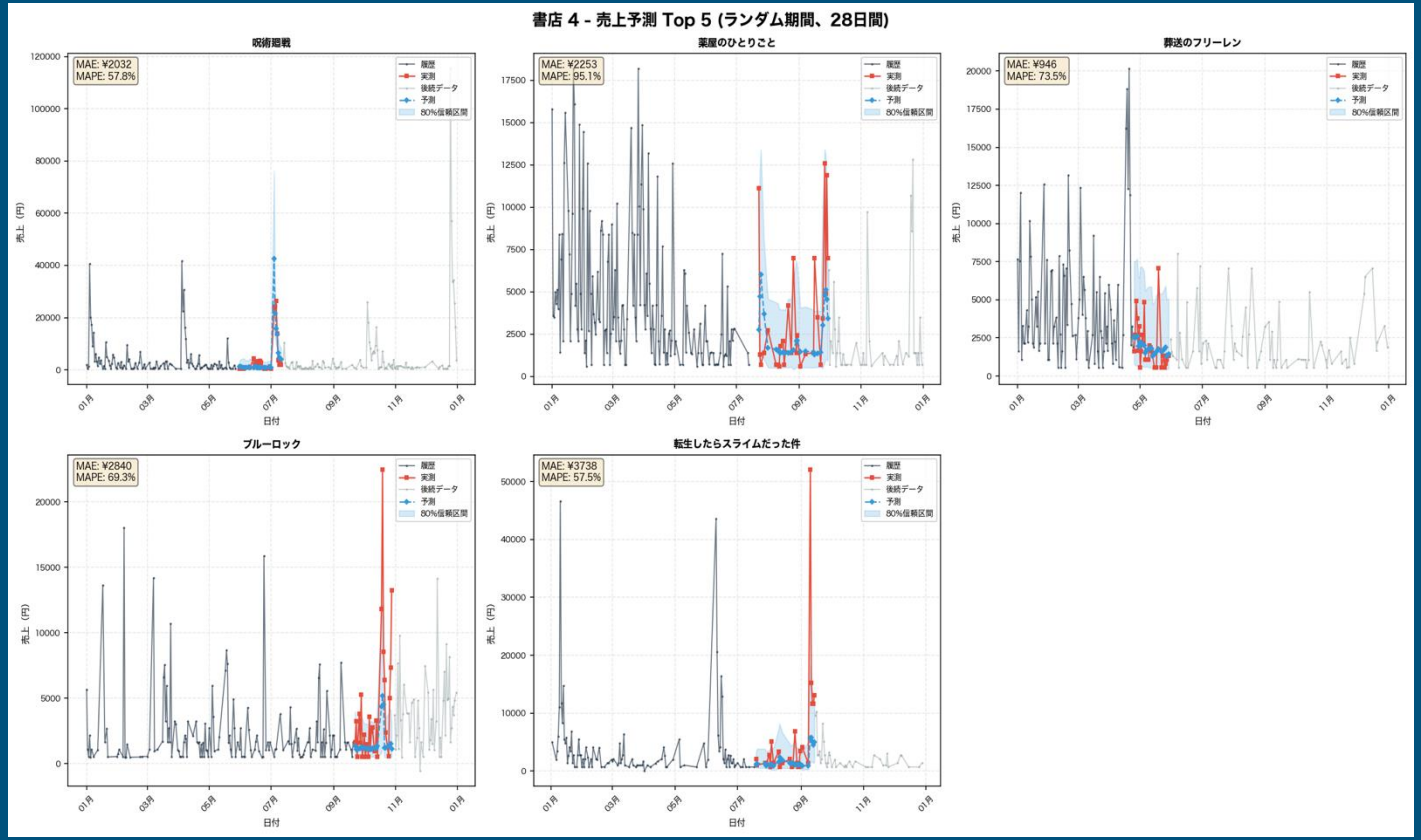

TFTを使った書店コード4の総売上上位5の書名の売上の予測結果(横軸：日付，縦軸：売上)

※ランダムなので結果は毎回変わる

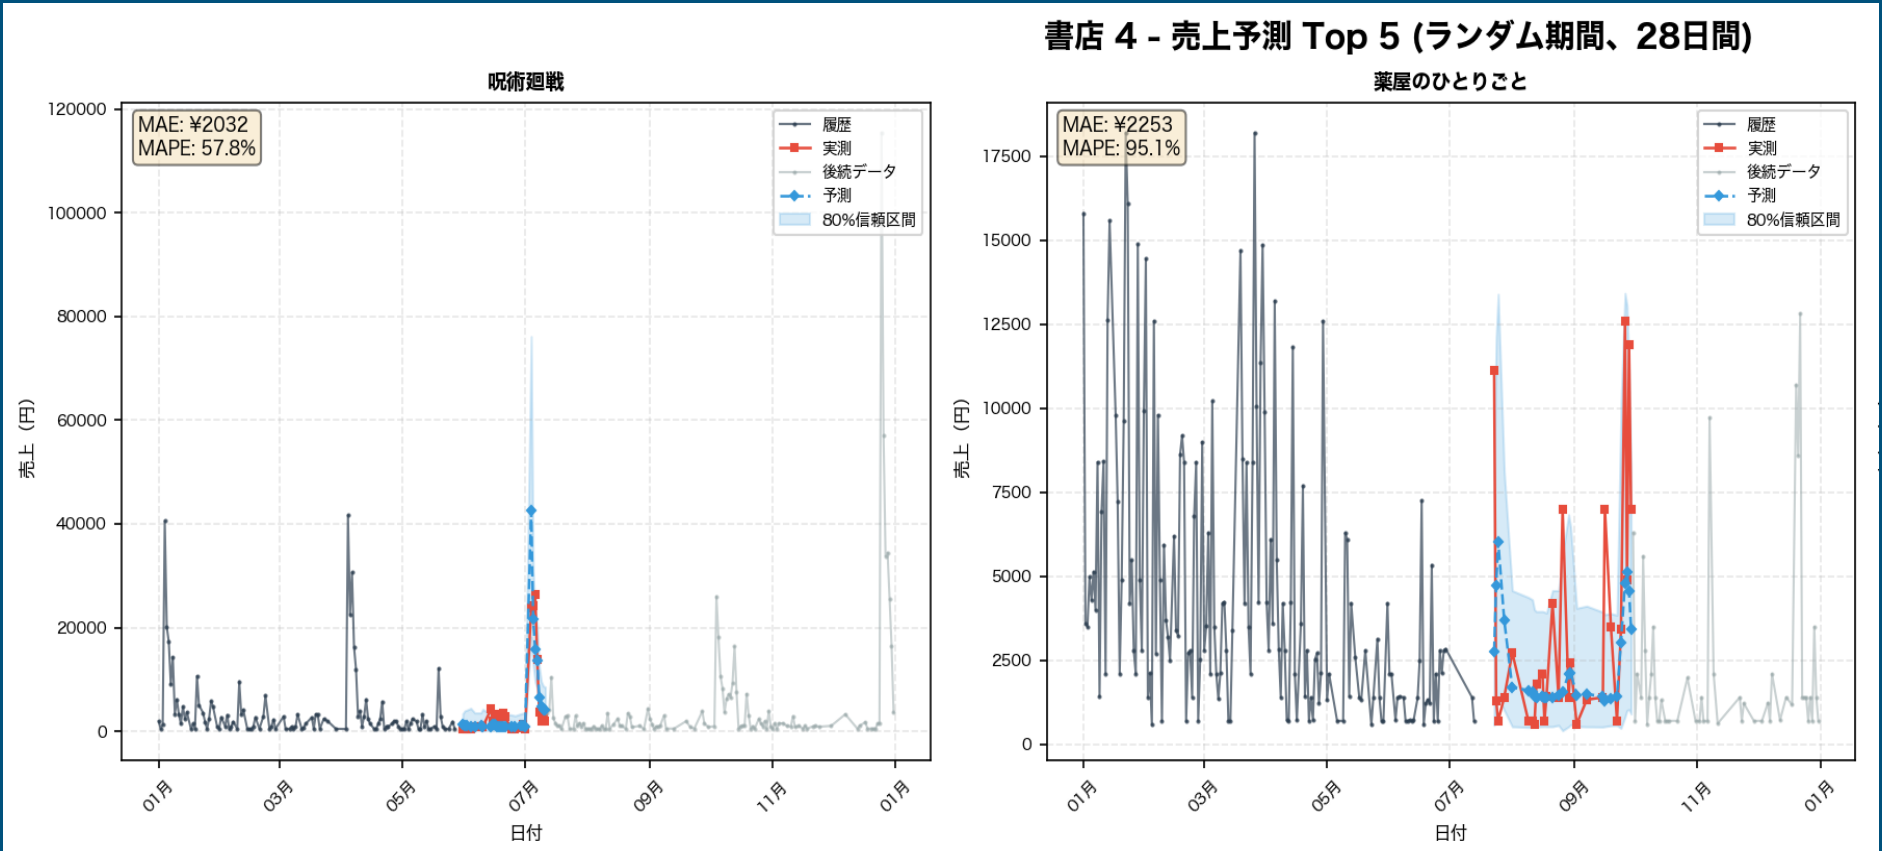

TFTを使った書店コード4の書名「呪術廻戦」「薬屋のひとりごと」の売上の予測結果(横軸：日付，縦軸：売上)

予測結果の評価

・期間が明確に決まっている連載は予測可能

・そうでないものは急激な変化を予測できないものの，過去の実績から80%信頼区間では捉える

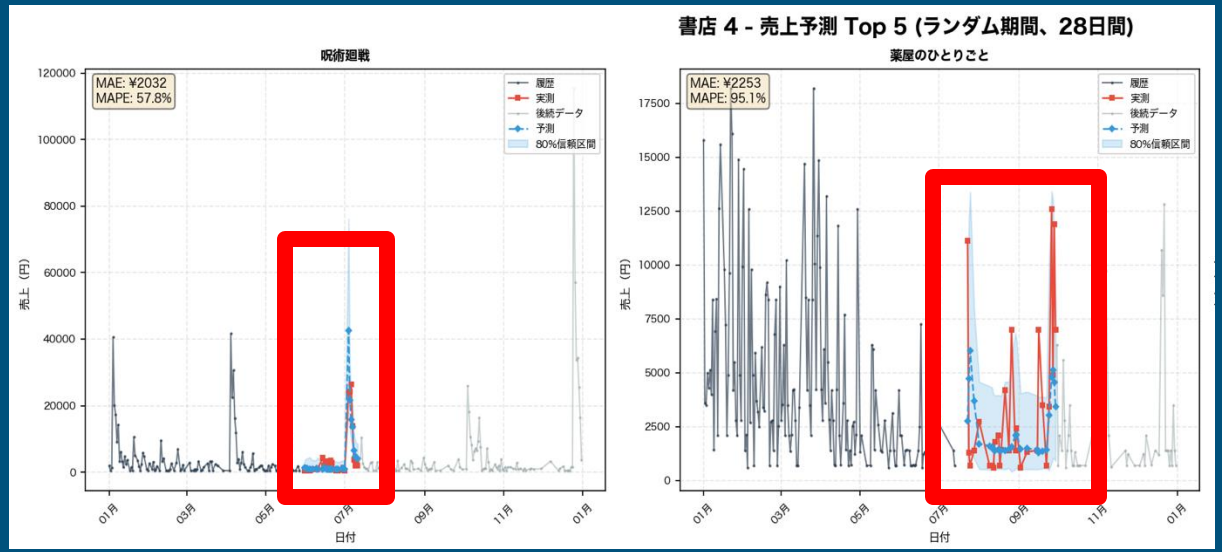

TFTを使った書店コード4の書名「呪術廻戦」「薬屋のひとりごと」の売上の予測結果
(横軸：日付，縦軸：売上)

予測モデルの問題点・課題

Problem: ・データ拡張が弱い，改善の余地あり

・'著者名', 'x分類'を最頻値で潰している

・他のモデルを試してないので良いのかわからない

Task: ・(重要)Attentionの分析

・ハーパーパラメータの調整

※今回は割と適当にやった．調整したのはEpocとBatchくらい

・元のカラムを適度に潰さないようにする

・TFTの構造をもっと理解する

・いままで行った統計分析の結果をもっと活用する　e.g. 書店の位置情報

References

Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International journal of forecasting*, *37*(4), 1748-1764.

Github

https://github.com/dmainf/data_comp

本発表に添付したグラフやグラフを生成するためのコードはすべてここに格納されているので，詳細を知りたい場合は確認することを勧める．