データ解析コンペ経過発表
Week 7

2342077 奈良原俊誠
2342055 齋藤陽
2342084 橋本朋樹

目次

正規化
-書名の正規化

予測モデルの課題
-予測モデルの現状
-季節性を考慮するための静的特徴量
-本データの分布の特徴
-TFTの特徴と適正
-間欠需要を攻略するための戦略
-情報の粒度と多様性
-Law of Scale and Chinchilla

データ拡張
-メッシュデータの拡張

正規化

書名の正規化

「作品_シリーズ | 関数」に正規化する

真の問題点

・異なる販売周期のシリーズが統合される
(＝データに多様性がなくなるだけでない)

・新刊が発売されるとスパイク(一瞬だけ急激に売上が上昇する)が発生するデータでは周期性があまりに重要

→「作品_シリーズ_巻数」に正規化

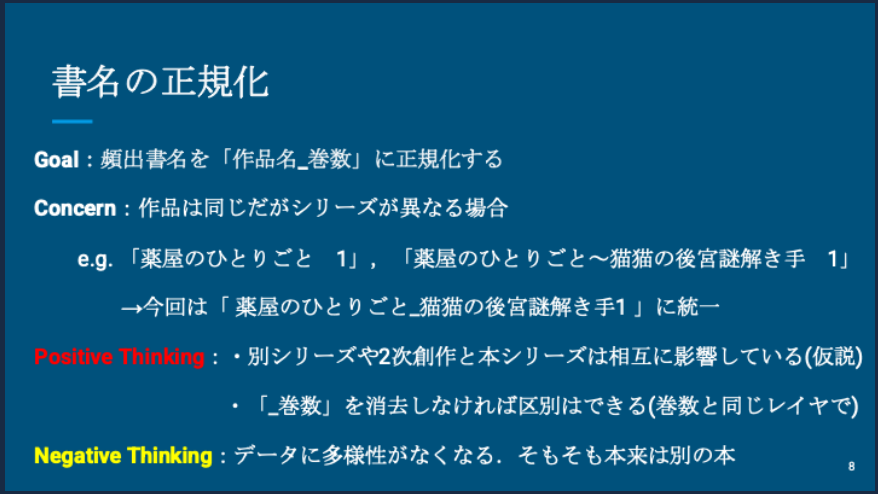

書名の正規化についての考察，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

書名の正規化

「作品_シリーズ | 関数」に正規化する真の問題点

・異なる販売周期のシリーズが統合される

(＝データに多様性がなくなるだけでない)

Q.「コミック」「月刊誌」はなぜ売上が大きい書名が多いのか

A. 連載することで，読者に定期的に購入させているから(仮説)

→周期性が重要

・新刊が発売されるとスパイク(一瞬だけ急激に売上が上昇すること)が発生する

→結局，周期性が重要

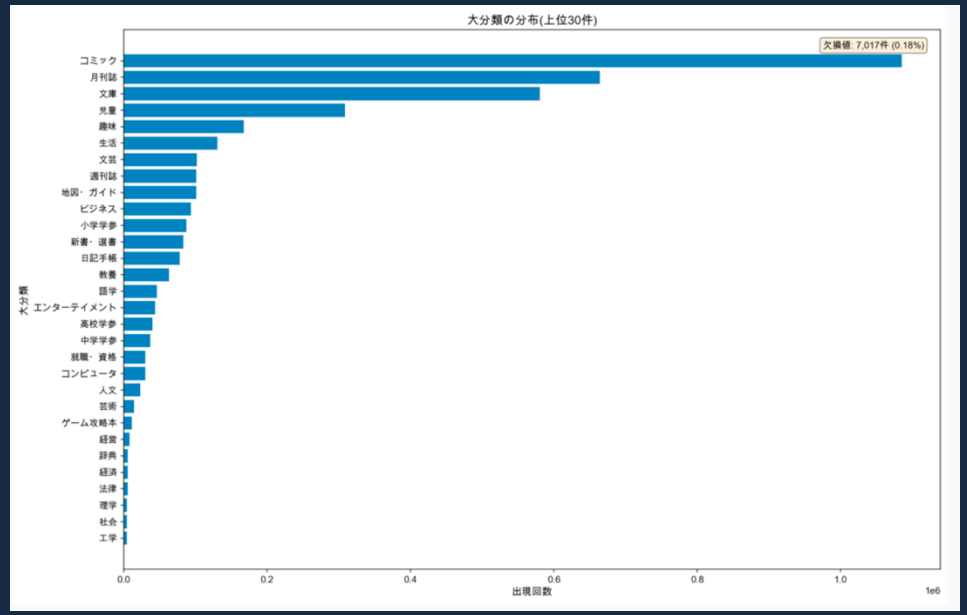

大分類の分布[横軸：出現回数，縦軸：大分類]

<u>→「作品_シリーズ_巻数」に正規化</u>　※異なる周期が混ざるのは危険

書名の正規化

Goal：‘書名’を「作品_シリーズ_巻数」に正規化する
Concern：余りに多くのパターンが存在していて，すべてに一般化した正規化をするのはほぼ不可能

Solve：適度に人力する(正規化できる部分はする)

1. 周期性が出現しそうな，ある程度の出現回数(今回は1000回)が確定した’作品’を抽出する
   ※正規化していない状態で抽出したものなのであくまで目安
2. ’書名’の空白を削除し，’作品’を含む’書名’を抽出(検索と言ってもいいかも)する
   e.g.「会　社　四　季　報」→「会社四季報」
3. 抽出した書名の空白を戻す
   Q. なぜ空白を戻すのか
   A. ほとんどの’巻数’は空白を挟んで存在するから(人力の気休め)
4. 抽出したすべての’書名’について’作品’, ‘シリーズ’, ‘巻数’を抜き出し正規化する
   ※本編(シリーズが明記されていないもの)は’シリーズ’を’original’とする
   ※’シリーズ’, ’巻数’が両方存在しない場合，「作品」のみ

書名の正規化[結果]

・出現回数が多い(重要度が高い)書名はすべてに正規化がされている

・出現回数が1000回付近(重要度か低い)書名は正規化されていない

→すべての書名を正規化することも視野にあるが，現段階では成功

書名	# 出現回数
Missing: 0 (0%)	Missing: 0 (0%)
Distinct: 171691 (100%)	Distinct: 1097 (<1%)
171691 Distinct values	Min 1 / Max 20121

呪術廻戦_original	20121
ブルーロック_original	18833
葬送のフリーレン_original	17064
薬屋のひとりごと_original	15538
ＯＮＥＰＩＥＣＥ_original	13493
怪獣８号_original	13455
僕のヒーローアカデミア_original	12870
キングダム_original	11310
ハイキュー_original	11227
ダンダダン_original	10230

出現回数上位10の書名[正規化済み]とその出現回数

書名	# 出現回数
Missing: 0 (0%)	Missing: 0 (0%)
Distinct: 171691 (100%)	Distinct: 1097 (<1%)
171691 Distinct values	Min 1 / Max 20121

ｋｕ：ｎｅｌ	1024
ＮＨＫラジオ_まいにちドイツ語	1024
来世は他人がいい_original	1023
鵺の陰陽師_original	1022
ラグビーマガジン	1019
ＦＩＮＥＢＯＹＳ	1014
ポケモンパルデア図鑑	1005
レコード・コレクターズ	992
パンどろぼうとりんごかめん	992
方舟	991
僕のヒーローアカデミア_チームアッ	991
母の待つ里	990

出現回数1000回付近の書名[正規化済み]とその出現回数

予測モデルの課題

予測モデルの現状

・季節性を考慮するため'year', 'month', 'day', 'is_day', 'is_weekend', 'week_of_year', 'quarter'に分割

・モデルはTFTを採用

・CONTEXT_LENGTHとPREDICTION_LENGTHを使いTailデータの排除とデータ拡張を同時に行う

・ウィンドウ処理でlag特徴量とrolling特徴量を追加

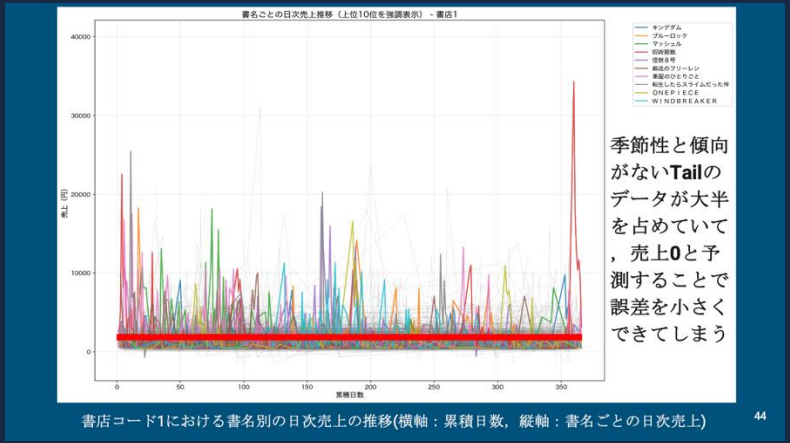

書店コード1における書名別の日次売上の推移(横軸：累積日数，縦軸：書名ごとの日次売上)

Tailデータの問題点，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

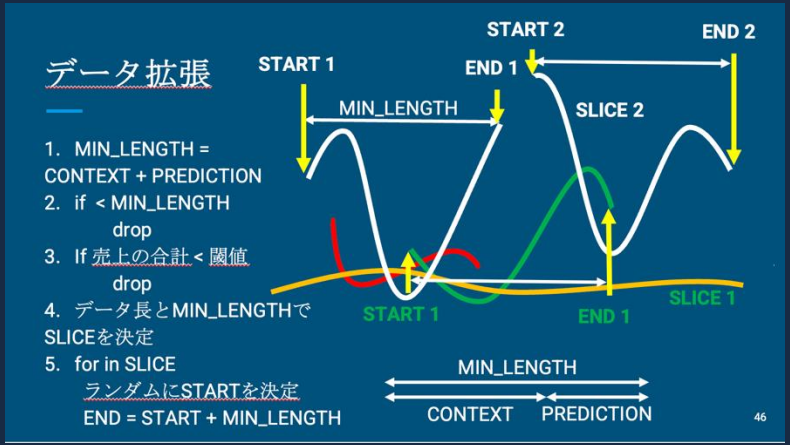

データ拡張のアルゴリズム，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

予測モデルの現状

・季節性を考慮するため’year’, ’month’, ‘day’, ‘is_day’, ‘is_weekend’, ‘week_of_year’, ‘quarter’に分割

・モデルはTFTを採用

・CONTEXT_LENGTHとPREDICTION_LENGTHを使いTailデータの排除とデータ拡張を同時に行う

・ウィンドウ処理でlag特徴量とrolling特徴量を追加

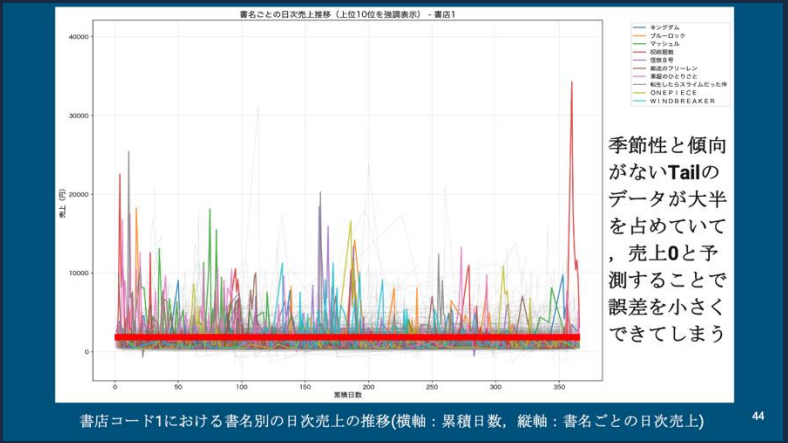

Tailデータの問題点，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

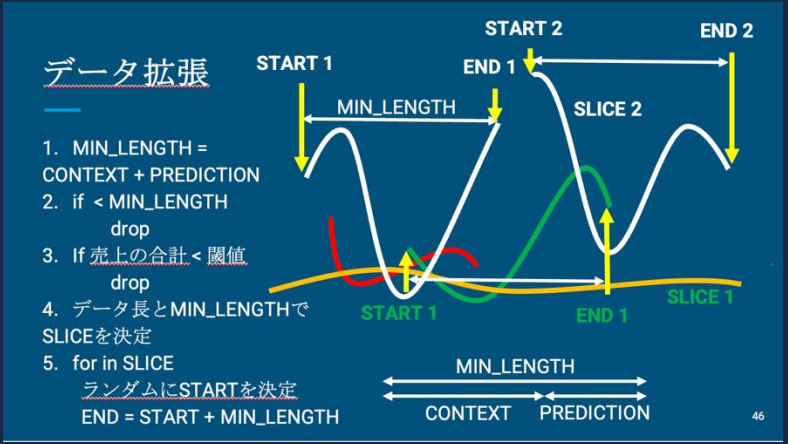

データ拡張のアルゴリズム，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

季節性を考慮するための静的特徴量

季節性を考慮するため'year', 'month', 'day', 'day_of_week', 'day', 'is_day', 'is_weekend', 'week_of_year', 'quarter'に分割

Detail :
'day_of_week' = '日付' mod 7
'is_day' = 'day_of_week' == [0~4]
'is_weekend' = 'day_of_week' == [5~6]
'week_of_year' = '日付' / 7
'quarter' = '日付' * 4 / 366

Problem :
日曜(mod 7 == 6)と月曜(mod 7 == 0)の間に時間の連続が消滅する，標準化がない

Solve :
三角関数を使う(時間経過を角度で表現+時間の連続を維持)

Practice :
'day_of_week_sin' = sin(2 * pi * 'day_of_week' / 'days_in_week')
'day_of_week_cos' = cos(2 * pi * 'day_of_week' / days_in_week)

予測モデルの現状

・季節性を考慮するため'year', 'month', 'day', 'is_day', 'is_weekend', 'week_of_year', 'quarter'に分割

・モデルはTFTを採用

・CONTEXT_LENGTHとPREDICTION_LENGTHを使いTailデータの排除とデータ拡張を同時に行う

・ウィンドウ処理でlag特徴量とrolling特徴量を追加

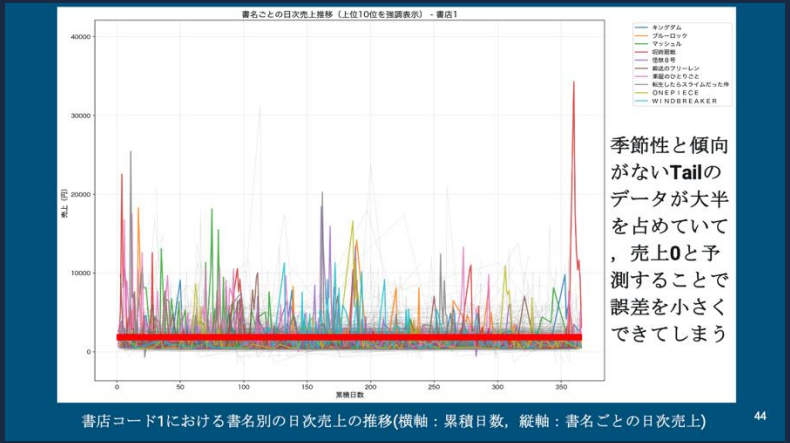

Tailデータの問題点，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

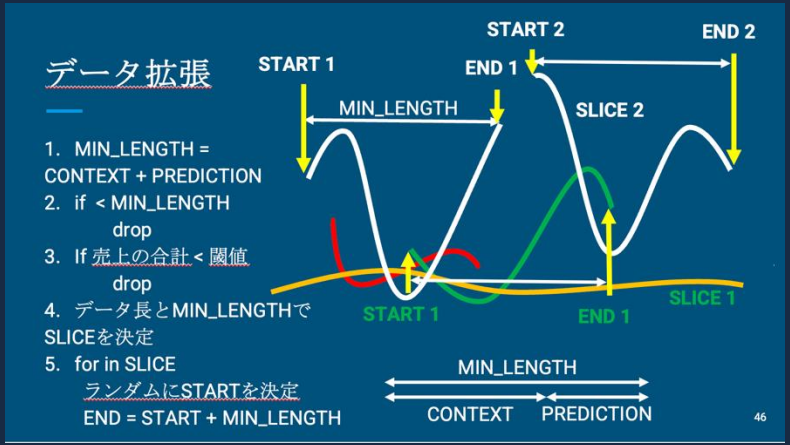

データ拡張のアルゴリズム，データ解析コンペ経過発表 week4より抜粋[Shunsei NARAHARA]

本データの分布の特徴

スパース：ゼロ過剰， データの大半が0である分布
本データは売れたときのみ記録しているため 販売冊数=0 なデータはないが，
実際はスパースな分布

スパイク：突発的な売上
新しく発売された本が瞬間的に売れる

スパース+スパイク = 過分散

ロングテール：膨大な商品が少数しか売れない
数種類の本だけが市場を牛耳る

<u>スパース，スパイク，ロングテールの組み合わせが売上パターンを破壊し，予測を困難にする</u>(別名：間欠需要，予測の難易度が高い)
＝過去の売上パターンだけでは説明できないとされるスパイクの予測を，
予測を0に寄せるスパースの性質と
構造的ゼロと偶然的ゼロを混在させるロングテールの性質が
さらに難易度を上げる

構造的ゼロ：市場に入ってこないTailなデータ
偶然的ゼロ：売れる本のスパイクでない部分

TFTの特徴と適正

Advantage：

・仕掛けられたスパイクの予測に優れる
　　既知の未来を区別して理解する
　　e.g. ‘発売日’があればスパイクを予測できる

・ロングテールな分布にも比較的耐える
　　静的特徴量を区別して理解する
　　e.g. ‘書名’から売上上位かどうか判定できる可能性がある

・予測根拠の解釈性(Attention)

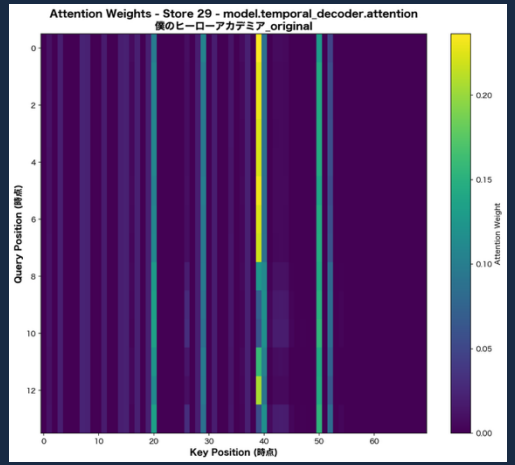

書店コード29，僕のヒーローアカデミアの時間的注意機構の重み[横軸：参照する過去の時点，縦軸：予測する未来の時点]

Problem:

・連続していて規則的なタイムステップをもつ時系列データを前提としている
　　本データは売れたことだけを記録しているので時系列が連続でない

・ゼロ過剰なデータに弱い
　　分位点で計算する損失はゼロ過剰なデータに最適化されていない

・モデルサイズが大きく過学習のリスクがある

間欠需要を攻略するための戦略

戦略0　2段階モデル(少し昔の手法)
STAGE1　売れるか否かの分類
STAGE2　売れた場合何冊かの予測

戦略1　Tweedie損失関数の導入 × LightGBM(簡単)

戦略2　ゼロ過剰系モデル × 深層学習(難しい)
TFTなどの深層学習モデルの出力層をゼロ過剰負の二項分布に改造する．ゲートを設け，実質的に2段階モデルを再現する

負の二項分布：平均値よりも分散が大きい(過分散)
※ポアソン分布は 平均値=分散 を仮定している

間欠需要を攻略するための戦略

戦略1　　Tweedie損失関数の導入 × LightGBM

Tweedie分布　ポアソン分布とガンマ分布の
ハイブリッド

$$Var(\mathrm{X}) = \phi \cdot \mu^p$$

$Var(X)$	確率変数Xの分散
ϕ	定数　※分散σ^2に相当する
μ	平均(=期待値E[X])
p	パラメータ

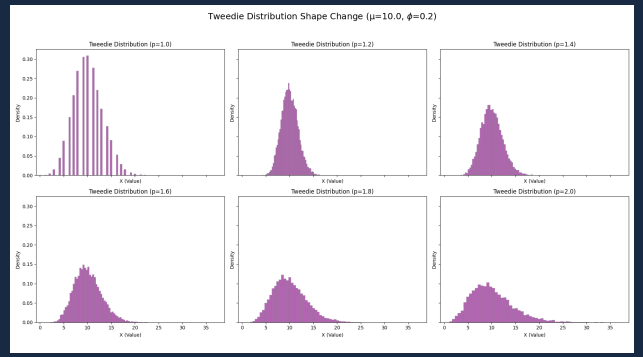

Pの値を1.0から2.0まで変化させたときの
Tweedie分布[横軸：確率変数，縦軸：確率密度]

$case\ p = 0$	正規分布	(＝分散が1)
$case\ p = 1$	ポアソン分布	(＝分散が平均と同じ)
$case\ 1 < p < 2$	ポアソン分布とガンマ分布の複合	
$case\ p = 2$	ガンマ分布	(=分散が平均の2乗)
$case\ 2 < p$	ゼロの確率質量を持たなくなる(不安定)	

間欠需要を攻略するための戦略

pが増加することで，分布の裾が広くなる
＝ゼロの適応とスパイクの適応

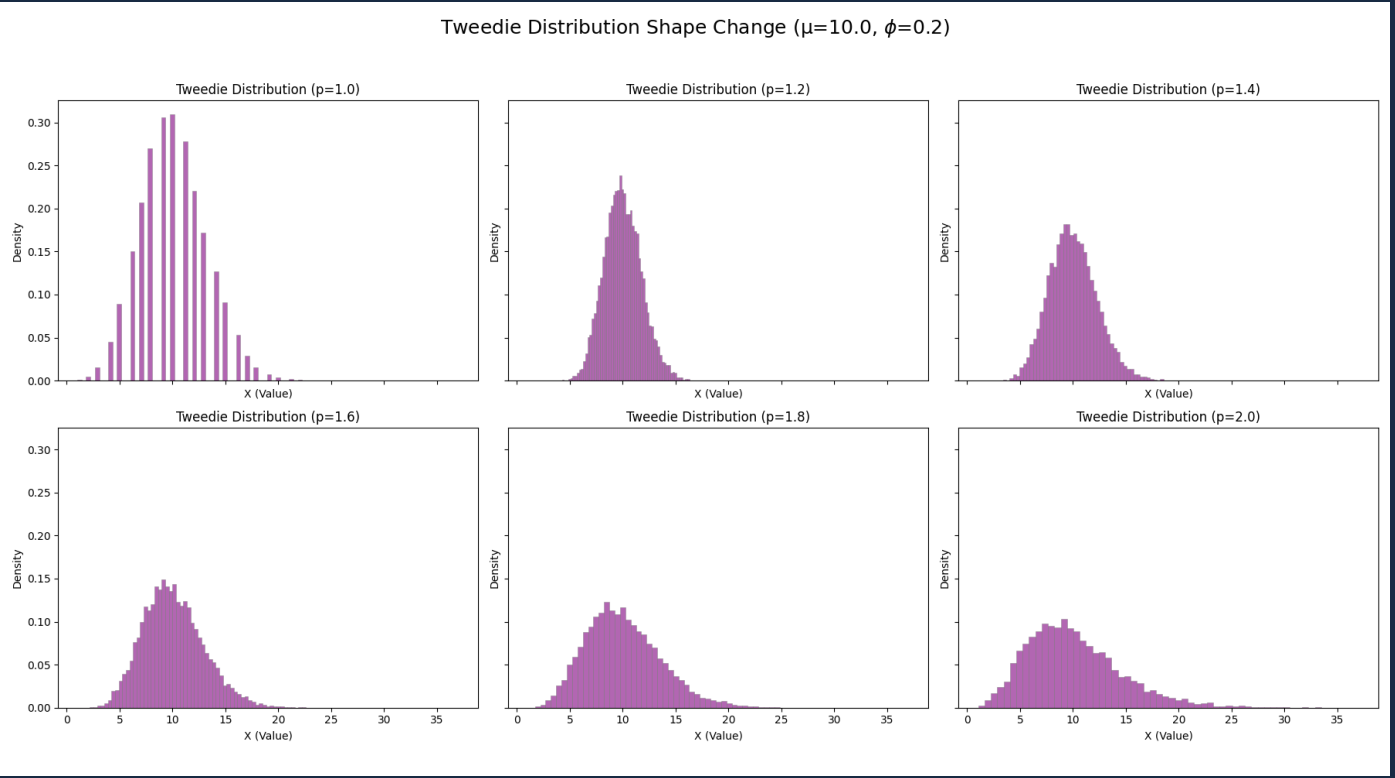

Pの値を1.0から2.0まで変化させたときのTweedie分布[横軸：確率変数，縦軸：確率密度]

間欠需要を攻略するための戦略

・Tweedie損失関数を導入すること自体は簡単
　　ハイパーパラメータpを[1, 2)の間で変化させ，最も誤差が少なくなったpが平均と分散の関係を捉えているとする
・戦略2(ゼロ過剰系モデル × 深層学習)は難易度が高いので戦略1のあとに実施予定(研究のしがいはある)

その他の気付き
・いままでは売上上位の’書名’についてのみ着目してきた(e.g. 売上高い順5つの’書名’についてだけ目視で確認し，それでモデルの評価をしていた)が
スパースでスパイクがあるデータでそのようなデータはほぼ外れ値である
→モデルの評価はRMSEやHeadでもTailでもない中間の’書名’(平均的なデータ)で判断する．対数を予測するのもよさそう
・データを増やすために書店ごとに分けて予測していたが，全体的な特徴をを掴むためにその括りはなくす

情報の粒度と多様性 -sliceの抽出

if 粒度を粗くする:
e.g. CONTEXT_LENGTHを増やす
e.g. 月ごとに予測する

Benefit：
・予測の難易度が下がる
i.e. ノイズ(分散)が減るから

Disadvantage：
・データの多様性が減る
・活用可能性が減る
i.e. 平坦な予測=情報量ない

if 粒度を細かくする:
e.g. CONTEXT_LENGTHを減らす
e.g. 日付ごとに予測する

Benefit：
・データに多様性が増える
・活用可能性が増える

Disadvantage：
・予測の難易度が上がる

情報の粒度と多様性 -sliceの抽出

粒度を細かくする(CONTEXT_LENGTHを増やす)ことでslice数は増える(トークン数は増える)がそれはデータにノイズが増えることも意味する
それに全体のデータ量は変わっていない

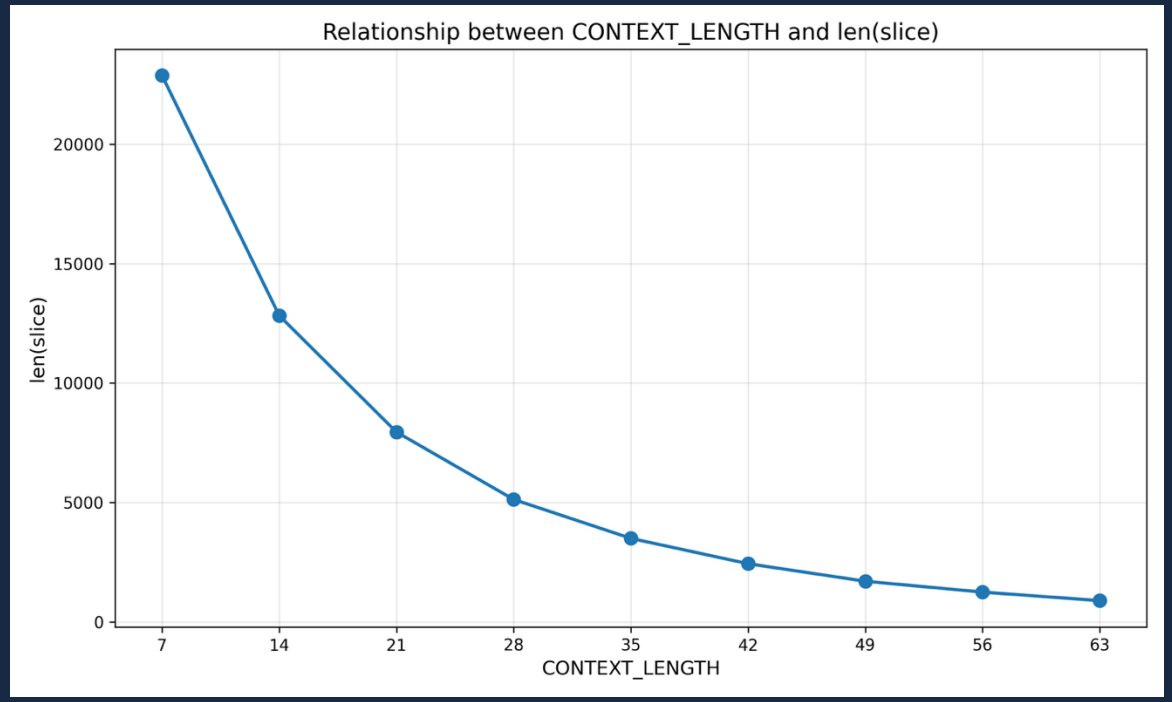

CONTEXT_LENGTHとslice数の関係[横軸：CONTEXT_LENGTH，縦軸：slice数]

Law of Scale and Chinchilla

スケール則
モデルサイズ・データ量・計算量を増やすとパワー則的に性能が向上する

チンチラ則
計算リソースが固定されている場合，モデルサイズとデータ量を比例して増やす必要がある

※パワー則：両対数でグラフが直線になる

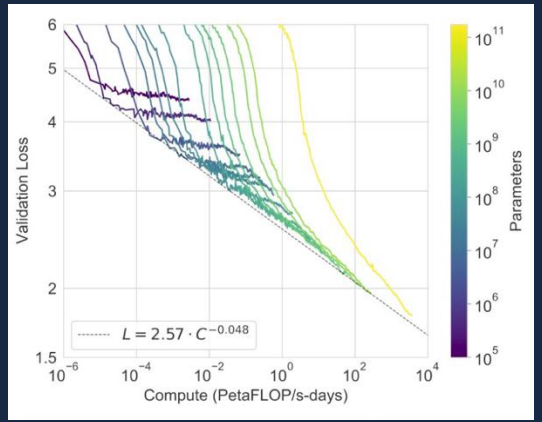

GPT-3でのスケール則[Open AI, 2020]
[横軸：計算量，縦軸：誤差]

データ量 = 20*モデルサイズが適正(と言われている)

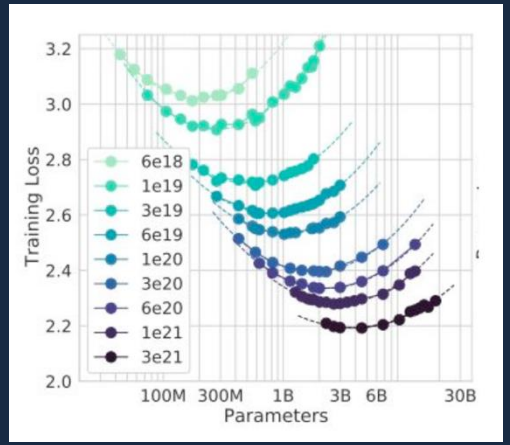

Chinchillaでのチンチラ則[DeepMind, 2022][横軸：モデルサイズ，縦軸：誤差]

Law of Scale and Chinchilla

- Hidden dim: 128
- Variable dim: 64
- Num heads: 4
- Context length: 56
- Prediction length: 14

→データ拡張をし，データ量を増やす必要がある

のときデータ量は

適正データ量: 20*モデルサイズ = 49,143,040　のうち　7%

総パラメータ数(モデルサイズ)：2,457,152

embedding層 –著者名: 1,512,448, 小分類: 121,216 出版社: 61,952 …
LSTM層 - Encoder/Decoder LSTMの重み: 約196,000
Attention層 - Multi-head attention: 約65,536
Variable Selection Networks - Static/Context/Target: 約500,000

データ量：3,515,616

slice数: 1,248
1 slice: 2,817

※TFTによる時系列のデータ拡張済

データ拡張

メッシュデータの修正

・先週のデータ

営業時間系統を
すべてint型で格納

「店舗型」には
・独立店舗型
・複合施設型
・駅構内型

店舗が位置する
メッシュと周辺8つ
で分け人口を算出

書店コード	int64
書店名	object
住所	object
駅距離	int64
開店時間(平)	int64
閉店時間(平)	int64
営業時間(平)	int64
開店時間(特)	int64
閉店時間(特)	int64
営業時間(特)	int64
店舗型	object
人口	int64
周辺人口	int64
合算人口	int64

・修正後

営業時間系統を
date型とint型で格納

「店舗型」を別々に
One-hot形式で格納

店舗が位置する
メッシュと周辺
で分けずにそれぞれ
No.1~No.9とした

書店コード	int64
書店名	object
住所	object
駅距離	int64
開店時間(平)	date
閉店時間(平)	date
営業時間(平)	int64
開店時間(特)	date
閉店時間(特)	date
営業時間(特)	int64
独立店舗型	int64
複合施設型	int64
駅構内型	int64
周辺人口	int64
合算人口	int64

メッシュデータの修正

・営業時間系統のデータの扱い方

Goal：「date型」で格納したい
Concern：24時間営業の店舗の「営業時間(平),(特)」が00:00や23:59:59になる
Solve：「開店時間(平),(特)」と「閉店時間(平),(特)」をdate型、「営業時間(平),(特)」をint型で単位を分として格納する

※(平)は平日または通常日の営業時間を表し
(特)は土日祝または特別に時間を定めている場合の営業時間

書店コード	int64
書店名	object
住所	object
駅距離	int64
開店時間(平)	date
閉店時間(平)	date
営業時間(平)	int64
開店時間(特)	date
閉店時間(特)	date
営業時間(特)	int64
独立店舗型	int64
複合施設型	int64
駅構内型	int64
周辺人口	int64
合算人口	int64

メッシュデータの修正

・メッシュコードの扱い方
（☆が店舗位置であるとした場合）

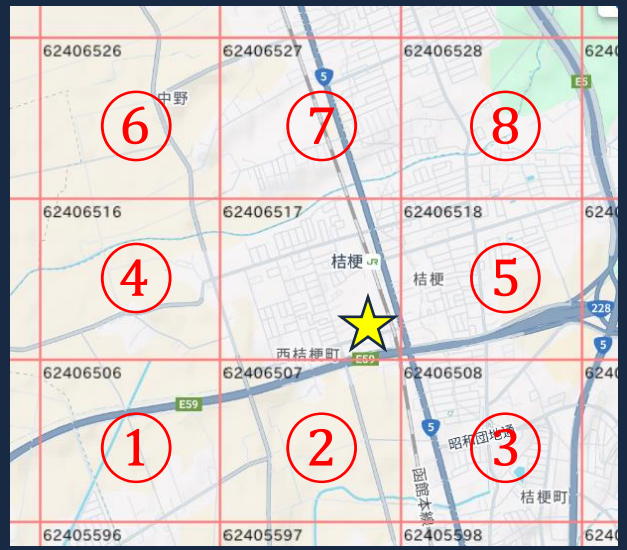

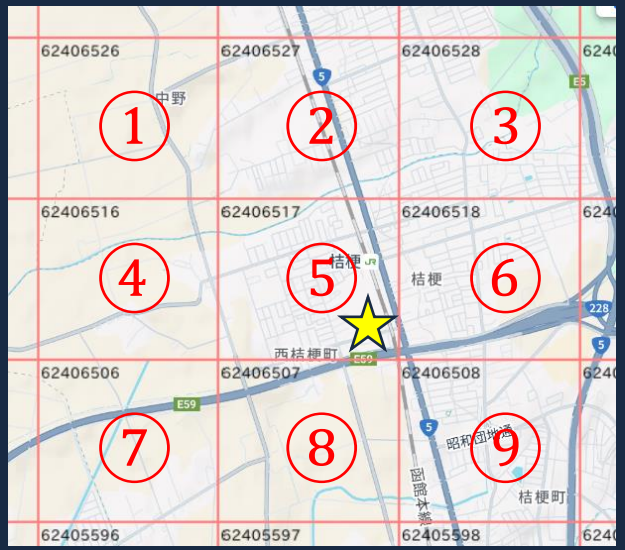

メッシュデータの修正

・メッシュコードの扱い方

① なぜ店舗が位置するメッシュと周辺メッシュで分割しなかったか
→店舗が位置している箇所（前頁では星マーク）がメッシュの中央でない場合が多いため
メッシュを調査した主な要因は人口に関するデータを取得したかった。
そのため、徒歩圏内と考えられる範囲の人口が分かればOK

② 徒歩圏内として挙げた各辺1kmメッシュの3x3圏内は妥当か
→調査を進めると徒歩圏内は一般には「800m」との記述が多かった
現在は3次メッシュ(各辺1km)を、3ｘ3で補っているため、徒歩圏内としては広すぎるのではないか
→新たに4次メッシュのデータを格納することとした

メッシュデータの拡張

・昼間人口及び夜間人口を追加
→メッシュ単位での情報が見つからなかったため、市区別で調査

・メッシュコードを追加
→自動で人口データを取得するために9つのメッシュコードを格納

・４次メッシュの追加
→次ページにて後述

・店舗位置の緯度経度データを追加
→後述

市区別_夜間人口	int64
市区別_昼間人口	int64
昼間フラグ	int64
昼間/夜間割合	int64
緯度	float64
経度	float64
3次メッシュコード(1～9)	int64
4次メッシュコード(1～9)	int64

メッシュデータの拡張

・４次メッシュの追加
現状：3次メッシュを店舗が位置する場所を中心に3x3の範囲で設定
（3次メッシュ→各辺約1kmの四角形の範囲）
拡張：徒歩圏内約「800m」の記述に基づき、4次メッシュとして詳細化
（4次メッシュ→各辺約500mの四角形の範囲）

4次メッシュを設定することに対する期待：
店舗に訪れる可能性の高い徒歩圏内が明確化されたことにより、
人口を用いる分析に、より説得力が増すのではないか

メッシュデータの拡張

・4次メッシュの可視化
　より店舗に近く、徒歩圏内として信頼性が高くなるように拡張した

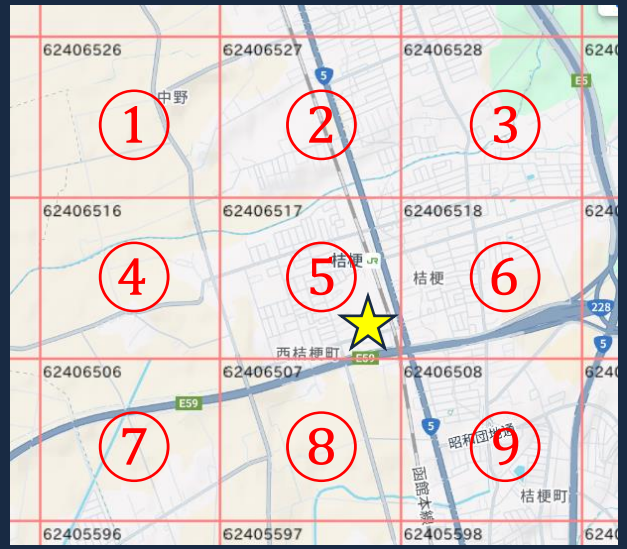

3次メッシュ（各辺約1km）

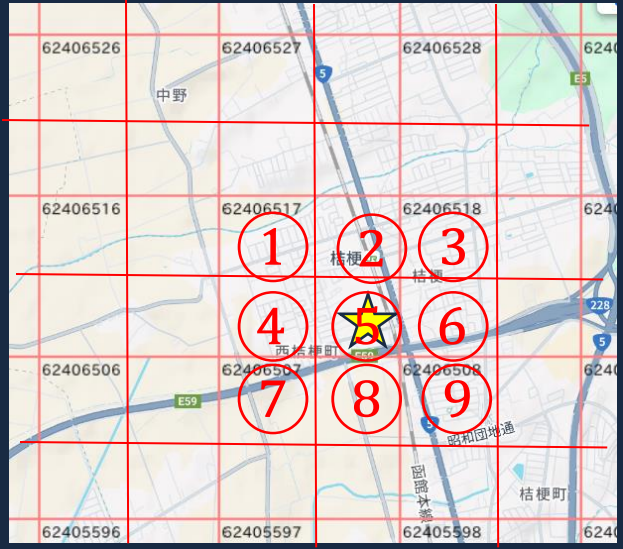

4次メッシュ（各辺約500m）

メッシュデータの拡張

・4次メッシュを扱う際の懸念点
　→より詳細化したことにより、メッシュの境界線を店舗が跨いでいる

Ex)

さらなる懸念点

より詳細化したいため
4次メッシュを調査したが、
またがっている店舗を取捨
選択したら誤差が生まれて
しまい4次メッシュの意味を
なさないのではないか

メッシュデータの拡張

・メッシュを跨いでいる可能性のある店舗の扱い方
→折角4次メッシュで詳細化しているため、扱い方を統一し、誤差を極力少なくしたい

Solve : 店舗型に分けて処理を行う

・独立店舗型　店舗の各頂点から重心の位置を計算しメッシュを特定
・複合施設型　主にフロアマップから施設内の店舗位置を特定
・駅構内型　駅構内図から店舗位置を特定

→特定した後、座標(緯度経度)で保存し、ずれや誤差がないようにした

メッシュデータの拡張

・4次メッシュの特定及び人口データ

JSTAT MAP
https://jstatmap.e-stat.go.jp/map.html

Arc-gis ITARDA WEB マップ

https://www.arcgis.com/apps/MapAndAppGallery/index.html?appid=350c2d2044ea4b9380cc3cb2eb6251ac

使用したフロアマップ及び駅構内図
https://shapo.jrtk.jp/koiwa/shop/floor.jsp?fid=1f
https://www.unicus-sc.jp/kawagoe/floor/

メッシュデータの分析

・昼間人口/夜間人口に関する単体的な分析

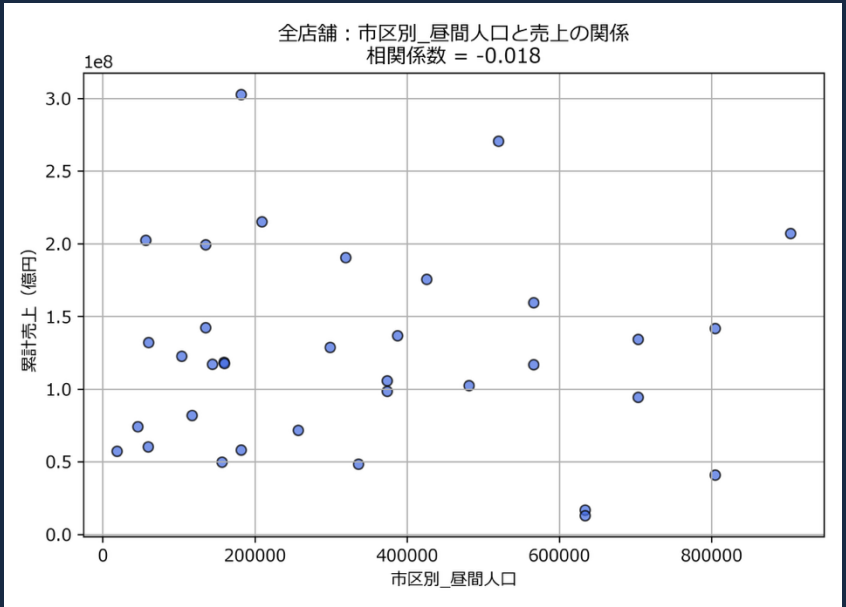

横軸：昼間人口(単位：人)
縦軸：累計売上(単位：億円)

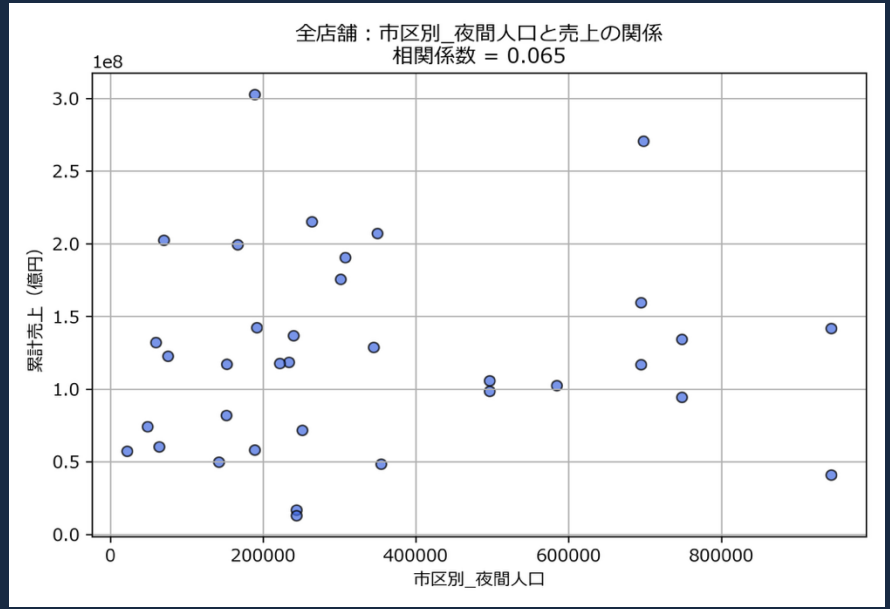

横軸：夜間人口(単位：人)
縦軸：累計売上(単位：億円)

メッシュデータの分析

・昼間人口/夜間人口に関する単体的な分析

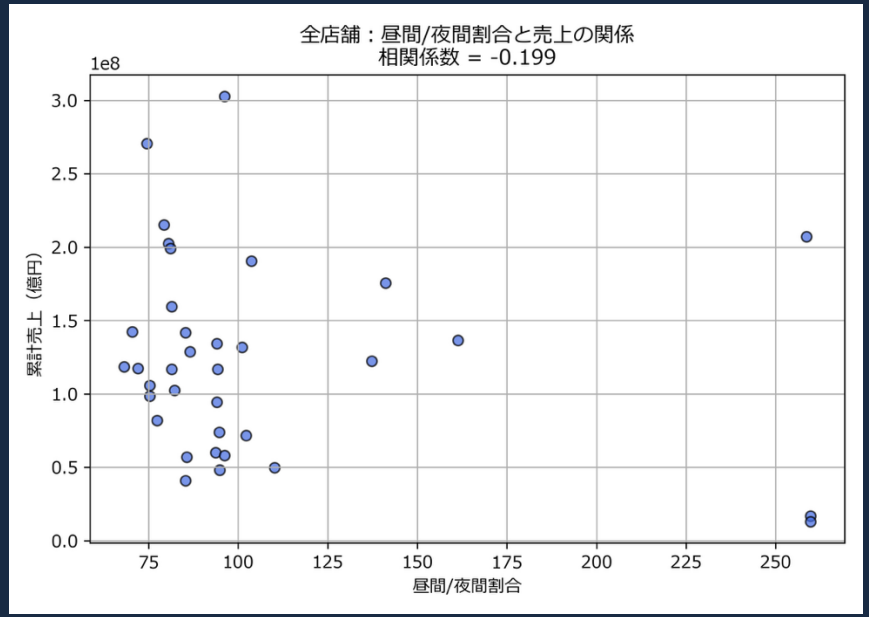

横軸：昼間/夜間割合(100が昼間人口＝夜間人口、単位：%)
縦軸：累計売上(単位：億円)

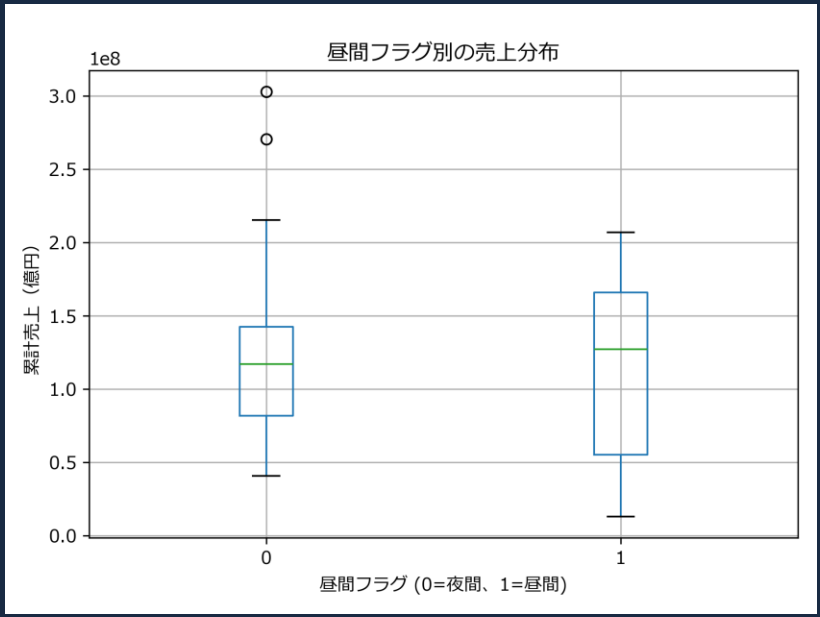

横軸：1：昼間人口＞夜間人口、0：昼間人口＜夜間人口
縦軸：累計売上(単位：億円)

メッシュデータの分析

・昼間人口及び夜間人口の単体分析の結果

・昼間、夜間人口ともに大きな相関は見られなかった
→前回指摘があった通り、相関だけで判断するのは難しい

・昼間フラグ(1:昼間人口＞夜間人口、0:昼間人口＜夜間人口)の有意差
→T値 = -0.615 , p値 = 0.54753
・T値結果より：グループ間の平均の差は小さい
・p値結果より：**0.55（55%）** と非常に大きい
有意差ありとはとても言えない

→多変量解析を行い、人口に関するカラムで売り上げに影響があるか調査する

メッシュデータの分析

・モデル1
目的変数：総売上
説明変数：市区別_昼間人口
市区別_夜間人口
4th_合計人口
昼間/夜間割合
昼間フラグ

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                   売上合計   R-squared:                       0.181
Model:                            OLS   Adj. R-squared:                  0.040
Method:                 Least Squares   F-statistic:                     1.286
Date:                Thu, 20 Nov 2025   Prob (F-statistic):              0.297
Time:                        05:24:49   Log-Likelihood:                -676.52
No. Observations:                  35   AIC:                             1365.
Df Residuals:                      29   BIC:                             1374.
Df Model:                           5
Covariance Type:            nonrobust
==============================================================================================
                     coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------------------
Intercept      2.881e+08   9.19e+07      3.136      0.004       1e+08    4.76e+08
市区別_昼間人口         598.3431    332.642      1.799      0.082     -81.987    1278.673
市区別_夜間人口        -537.8235    296.950     -1.811      0.080   -1145.154      69.507
Q("4th_合計人口")   956.8325    632.908      1.512      0.141    -337.609    2251.274
Q("昼間/夜間割合")  -2.077e+06   1.02e+06     -2.028      0.052   -4.17e+06    1.72e+04
昼間フラグ          2.551e+07   3.72e+07      0.686      0.498   -5.05e+07    1.02e+08
==============================================================================
Omnibus:                       14.712   Durbin-Watson:                   1.873
Prob(Omnibus):                  0.001   Jarque-Bera (JB):               15.940
Skew:                           1.333   Prob(JB):                     0.000346
Kurtosis:                       4.954   Cond. No.                     4.93e+06
==============================================================================
```

結果：
P値(0に近いほど有意)
　すべて0.05を上回っている→どの変数も有意とはいえない
R^2係数(1に近いほど説明できている)
　0.181→人口関連のカラムだけでは売上について18%程度しか説明できていない

メッシュデータの分析

・多重共線性(VIF)
説明変数ごとの相関
5以下であれば妥当な結果

```
--- モデル1：VIF（多重共線性） ---
                 変数        VIF
0          Intercept  67.959083
1           市区別_昼間人口  55.541751
2           市区別_夜間人口  46.913747
3   Q("4th_合計人口")   1.204879
4    Q("昼間/夜間割合")  21.671785
5              昼間フラグ   2.269784
```

結果：
20を超える値が出現
→似ているカラムが多すぎて
正しく計算ができていない

モデルAは意味のある計算ができていない
→総売上を目的変数とするのではなく、夜間人口あたりの売上を
目的変数としてみる
→地元住民による人口が売り上げに起因しているかが分かる

メッシュデータの分析

・モデル2
目的変数：夜間人口あたり売上
説明変数：市区別_昼間人口
昼間/夜間割合
昼間フラグ

```
                            OLS Regression Results
==============================================================================
Dep. Variable:              夜間人口あたり売上   R-squared:                       0.427
Model:                            OLS   Adj. R-squared:                  0.372
Method:                 Least Squares   F-statistic:                     7.700
Date:                Thu, 20 Nov 2025   Prob (F-statistic):           0.000551
Time:                        05:24:49   Log-Likelihood:                -269.91
No. Observations:                  35   AIC:                             547.8
Df Residuals:                      31   BIC:                             554.0
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================================
                   coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------------------
Intercept     1128.2699    256.209      4.404      0.000     605.728    1650.812
Q("昼間/夜間割合")     2.7341      3.115      0.878      0.387      -3.620       9.088
市区別_昼間人口        -0.0020      0.000     -4.551      0.000      -0.003      -0.001
昼間フラグ          -86.8967    318.614     -0.273      0.787    -736.713     562.920
==============================================================================
Omnibus:                       11.187   Durbin-Watson:                   2.265
Prob(Omnibus):                  0.004   Jarque-Bera (JB):               10.381
Skew:                           1.195   Prob(JB):                      0.00557
Kurtosis:                       4.188   Cond. No.                     1.53e+06
==============================================================================
```

結果：
P値(0に近いほど有意)
市区別_昼間人口がp<0.001である→かなり有意
R^2係数(1に近いほど説明できている)
0.427→モデルAと比較するとよくなっているがまだ値としては低い
（目安：R^2>0.5）

メッシュデータの分析

・優位性のある
「市区別_昼間人口」について

昼間人口が1人増えると効率指標が0.002下がる
→昼間人口が１万人増えると、
効率指標が **20ポイント低下** し、
住宅地に比べて効率が悪くなる
（売上が20円下がるのではない）

あくまで相対的な指標

```
                            OLS Regression Results
==============================================================================
Dep. Variable:              夜間人口あたり売上   R-squared:                       0.427
Model:                            OLS   Adj. R-squared:                  0.372
Method:                 Least Squares   F-statistic:                     7.700
Date:                Thu, 20 Nov 2025   Prob (F-statistic):           0.000551
Time:                        05:24:49   Log-Likelihood:                -269.91
No. Observations:                  35   AIC:                             547.8
Df Residuals:                      31   BIC:                             554.0
Df Model:                           3
Covariance Type:            nonrobust
==============================================================================
                    coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     1128.2699    256.209      4.404      0.000     605.728    1650.812
Q("昼間/夜間割合")      2.7341      3.115      0.878      0.387      -3.620       9.088
市区別_昼間人口       -0.0020      0.000     -4.551      0.000      -0.003      -0.001
昼間フラグ          -86.8967    318.614     -0.273      0.787    -736.713     562.920
==============================================================================
Omnibus:                       11.187   Durbin-Watson:                   2.265
Prob(Omnibus):                  0.004   Jarque-Bera (JB):               10.381
Skew:                           1.195   Prob(JB):                      0.00557
Kurtosis:                       4.188   Cond. No.                     1.53e+06
==============================================================================
```

メッシュデータの分析

・多重共線性(VIF)
説明変数ごとの相関
5以下であれば妥当な結果

結果：
1～3程度
→安定しているモデル

```
--- モデル2：VIF（多重共線性） ---
                 変数       VIF
0          Intercept  6.963040
1  Q("昼間/夜間割合")  2.641657
2       市区別_昼間人口  1.331168
3           昼間フラグ  2.197567
```

モデル2は意味のある計算ができている

メッシュデータの分析

・重回帰分析の課題

線形的な状況しかつかむことができない
→売り上げに関する結論は非線形の可能性が高い

・今後の展望

・交通に関連する因子（駅利用者数、複合施設来店者数、駐車場の有無など）と人口データを絡めた分析を行いたい
・この人口データをもとに学習モデルに組み込みたい

メッシュデータの拡張

・3次メッシュの範囲拡大
3×3から5×5に拡大

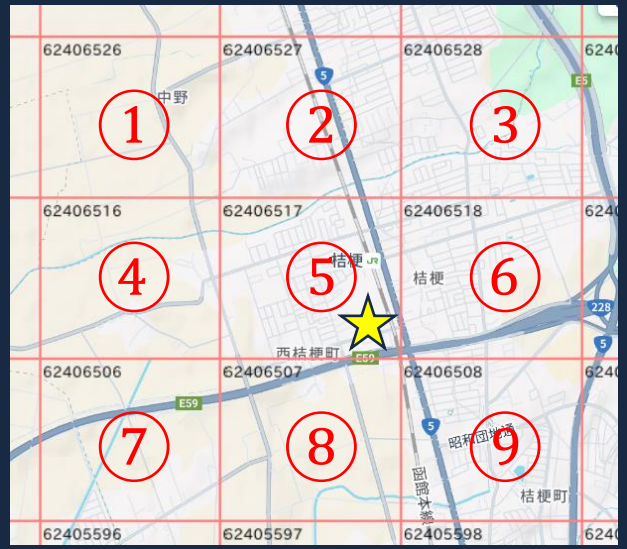

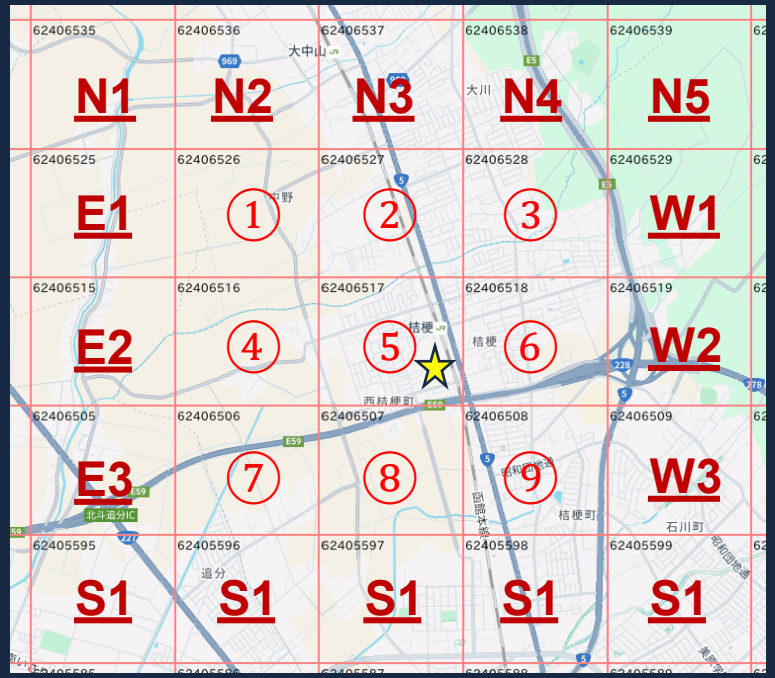

メッシュデータの拡張

・5×5のメッシュの合計人口で相関を調べる

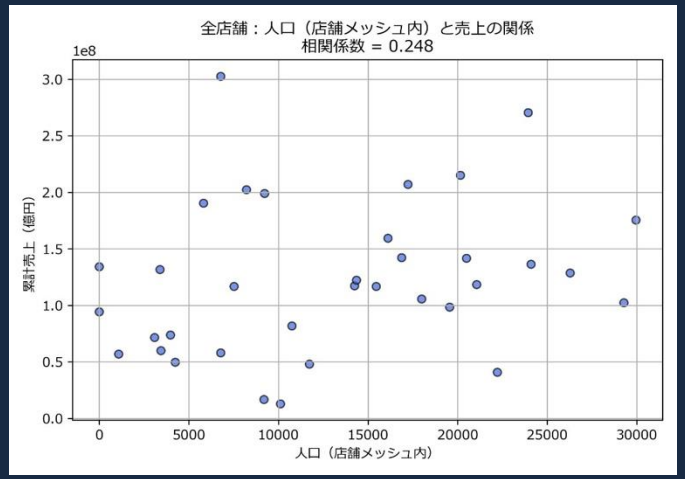

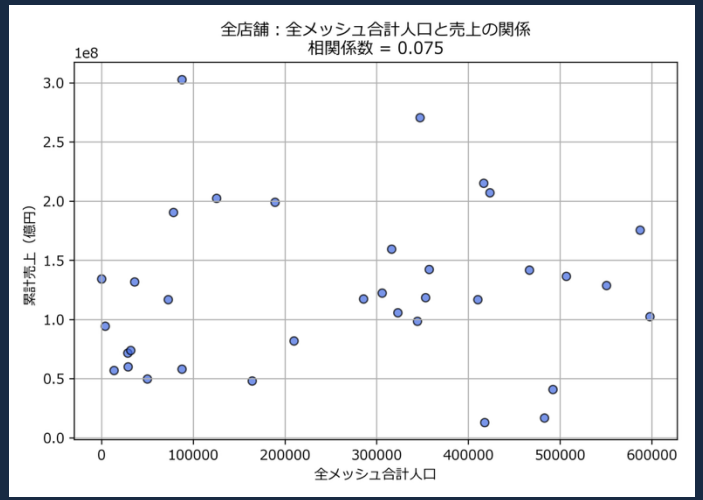

メッシュデータの拡張

・5×5のメッシュの合計人口で相関を調べる

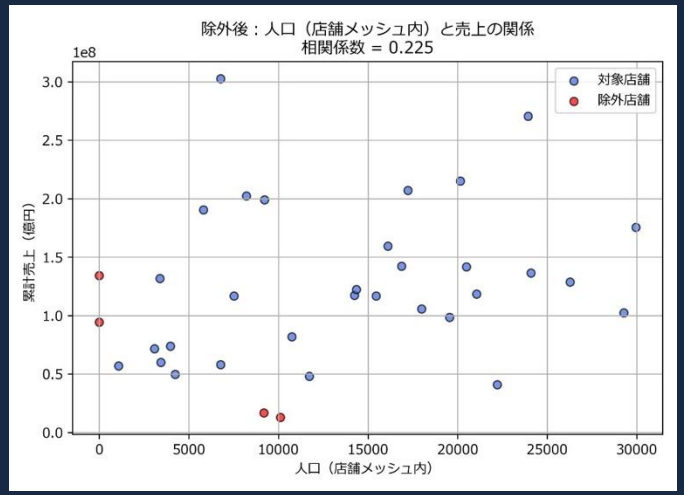

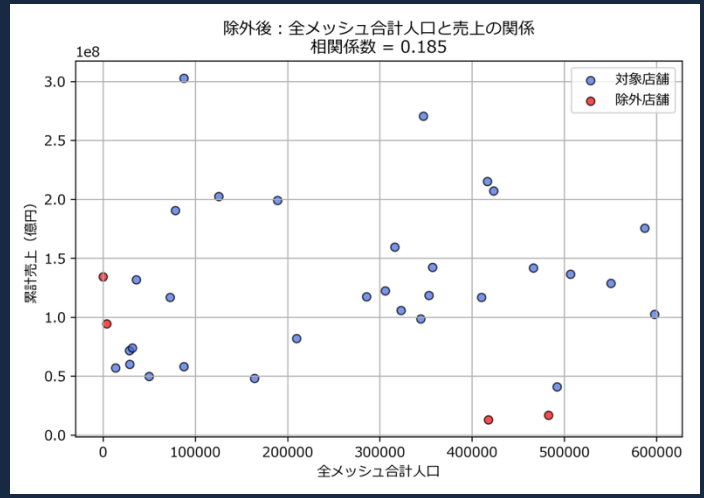

メッシュデータの拡張

・施設のカラムを修正
　→前回相関がありそうだった教育機関系に絞る

小中学校	int
高校	int
図書館	int
老人ホーム	int
病院	int

小学校	int
中学校	int
高校	int
大学	int

メッシュデータの拡張

・教育施設

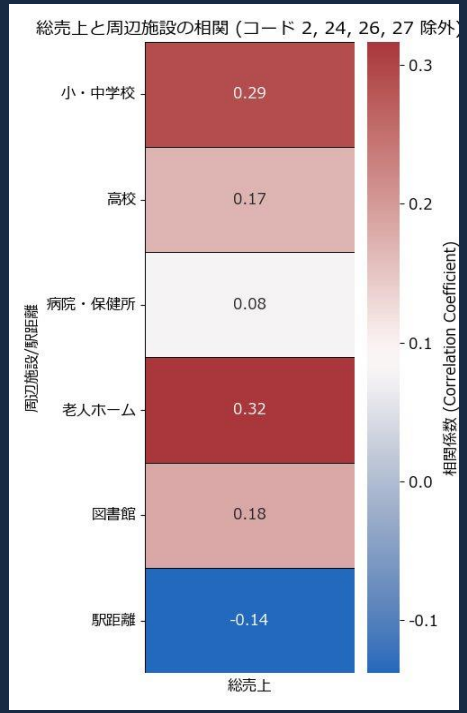

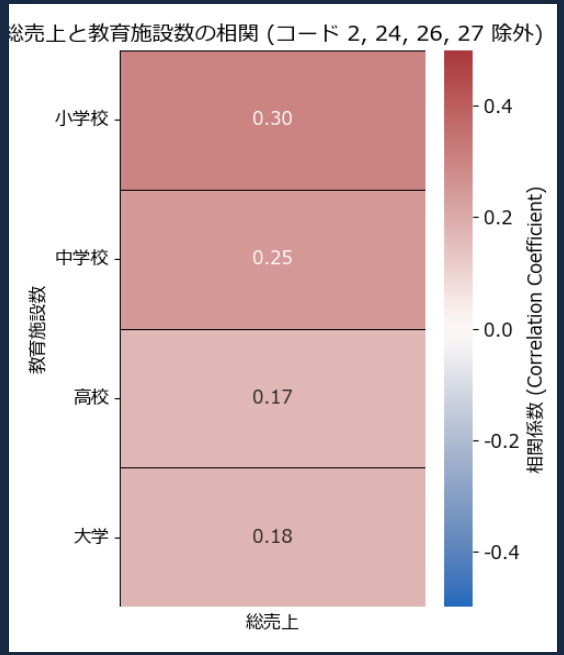

メッシュデータの拡張

・教育施設

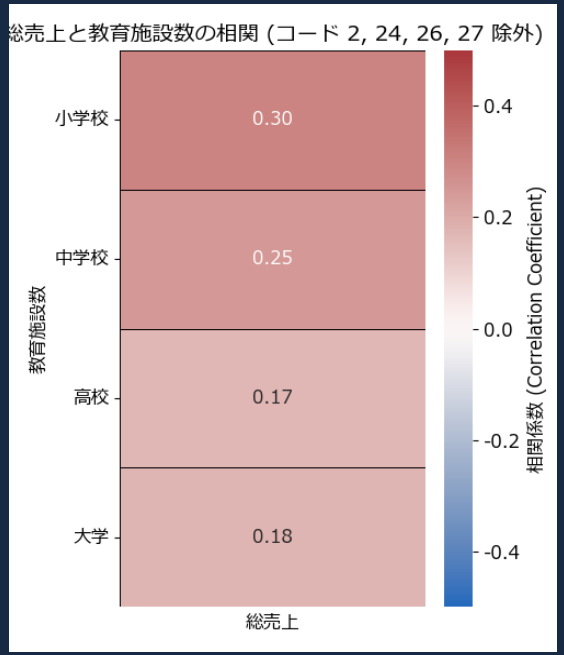

Preferences

Kaplan+. Scaling Laws for Neural Language Models. 2020. In arXiv:2001.08361

Hoffmann+. Training Compute-Optimal Large Language Models. 2022. In NeurIPS2022

Github

https://github.com/dmainf/data_comp.git