データ解析コンペ経過発表 Week 10

奈良原俊誠
斎藤陽
橋本朋樹

目次

TFTと確率分布
- TFTの構築フロー
- TFTのベースモデルの構築
- 最適な確率分布の選定
- TFTと損失関数

偏相関分析と相関分析
- 偏相関分析
- 相関分析

TFTと確率分布

TFTの構築フロー

1. TFTベースモデルを構築する

2. 最適な確率分布を選定する

3. 確率分布を損失関数に組み込む

4. 特徴量エンジニアリング

何が性能を上げているのか確認するためにベースモデルが必要

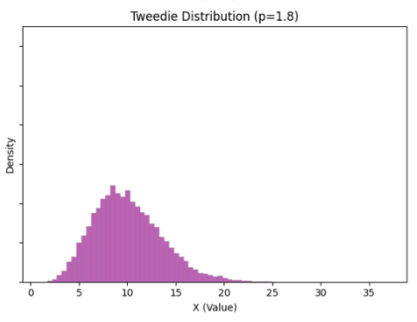

点ではなく確率を予測をする場合
- 対数尤度クラス
- 尤度に基づいたサンプリングクラス

が必要

e.g.
- 正則化，データ拡張
- 書店の詳細特徴量
- Googleトレンド

TFTベースモデルの構築

モデル　　TFT
説明変数　日付，書名，出版社，著者名，[x]分類，本体価格
目的変数　POS販売冊数

- CONTEXT_LENGTH = 180
- PREDICTION_LENGTH = 45
- EPOC = 125

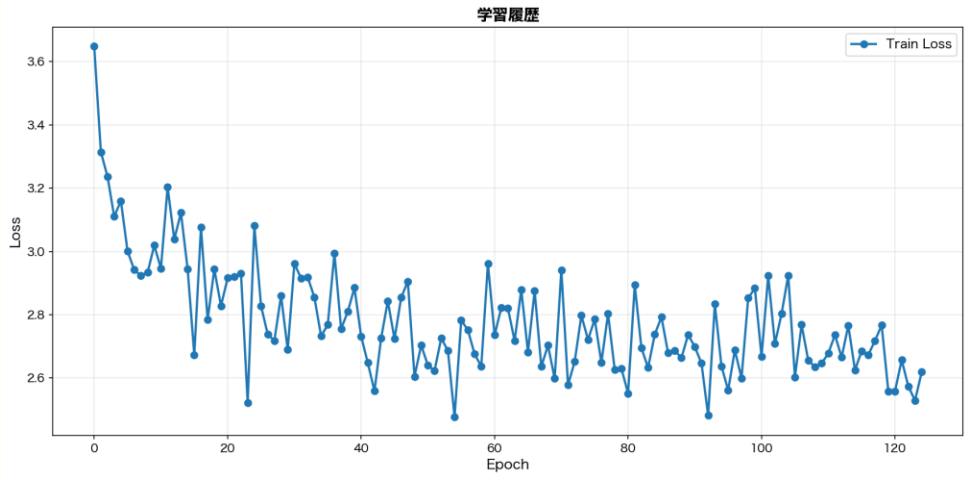

TFTベースモデルのエポックごとの誤差の推移

- 書名は正規化後出現回数>=366の1289種類に限定する
- 混合識別は日付，書名の複合キーとする
- データが存在しない期間のPOS販売冊数は0で補完する
- 著者名の欠損は「UNKNOWN」で補完する
- 出版社，著者名，[x]分類は混合識別ごとの最頻値
- 本体価格は混合識別子ごとの平均値とする

TFTベースモデルの予測結果

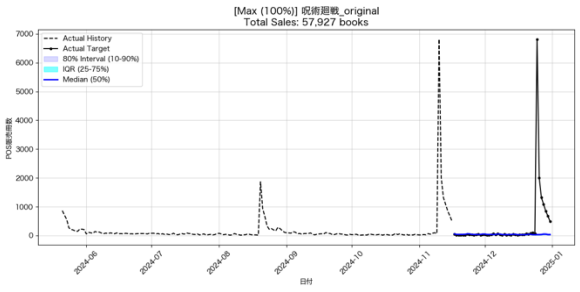

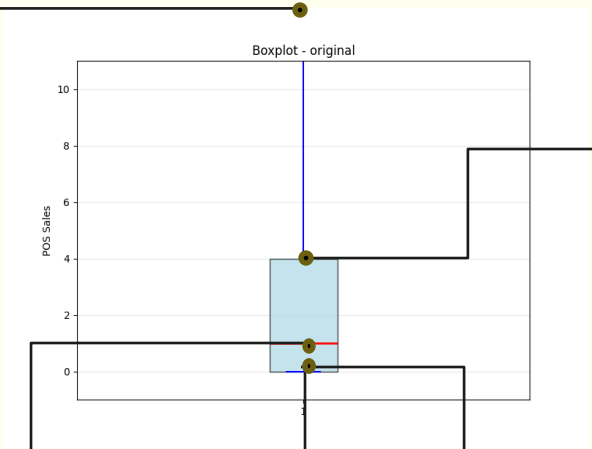

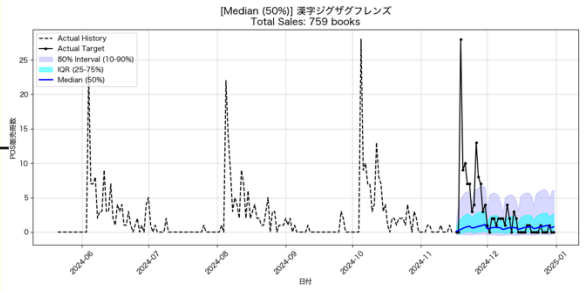

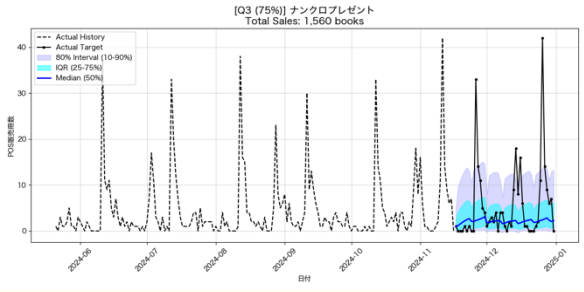

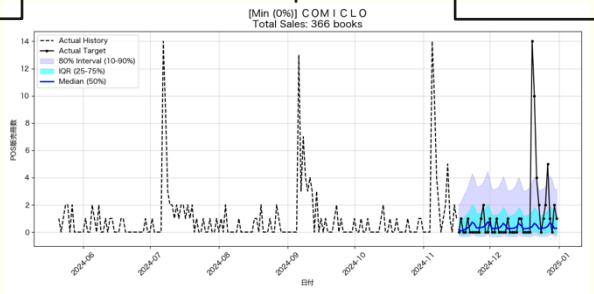

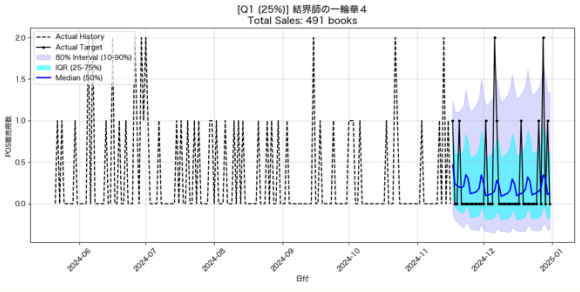

最適な確率分布の選定

目標
書名ごとのPOS販売冊数の分布を近似したい

スケール方法
- original(生データのまま)
- 冪乗変換
- 対数変換(+e)
- シフト(+e)

確率分布
- 正規分布
- ガンマ分布
- Tweedie分布
- パレート分布
- ゼロ過剰負の2項分布(ZINB)

評価指標
- AIC/BIC

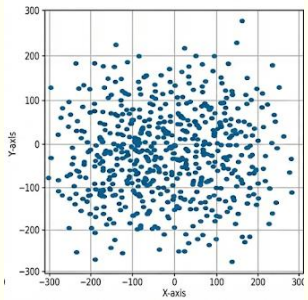

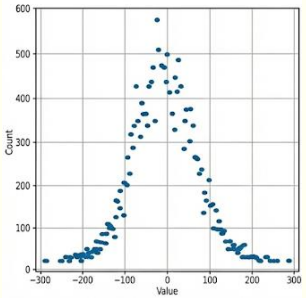

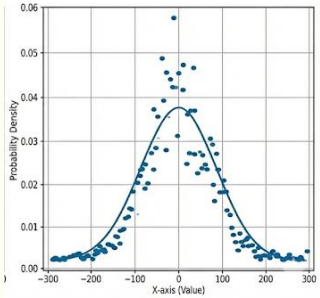

- ガンマ分布とパレート分布は確率変数=0が未定義
- n根号はn=1.5
- 対数変換は底e
- 対数変換はe分正にシフト(対数は真数=0を未定義なため)
- 確率分布は尤度を最大にするパラメータを選択

最適な確率分布の選定

Q. なぜ確率分布を仮定する前にスケールするのか
A. 数学的制約・歪度の解消・分散の安定化・学習の効率化

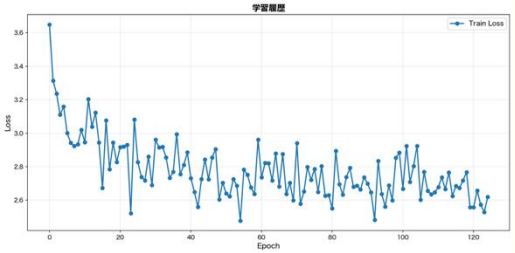

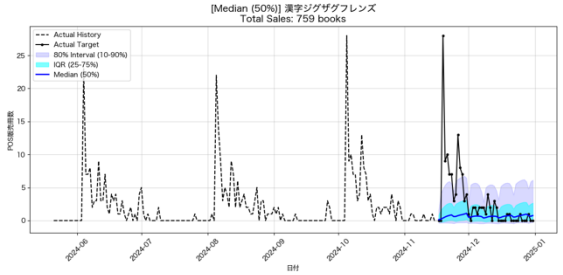

original

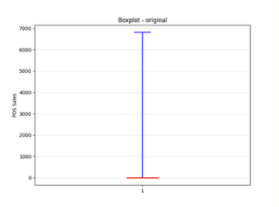

対数変換(+e)

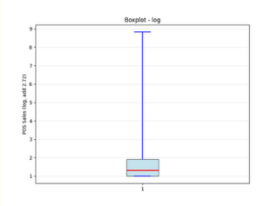

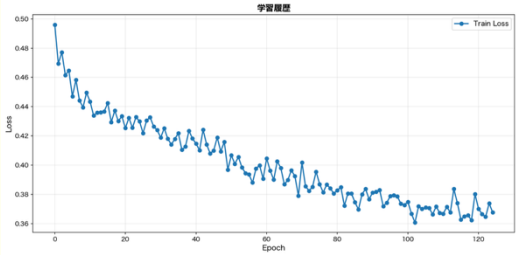

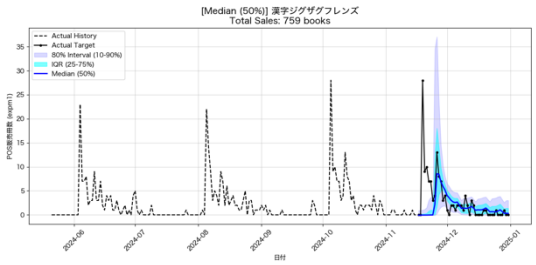

最適な確率分布の選定

originalの
基本統計量

original	
平均値	4.5381
中央値	2.0738
標準偏差	19.5877

original	AIC	BIC
正規分布	4,227,211	4,227,234
ガンマ分布	-	-
Tweedie分布	2,247,841	2,240,786
パレート分布	-	-
ZINB	2,292,950	2,292,984

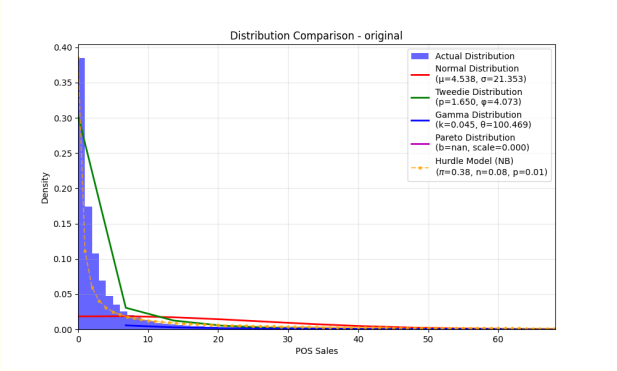

対数変換(+e)の
基本統計量

対数変換(+e)	
平均値	1.5707
中央値	1.4017
標準偏差	0.5461

対数変換(+e)	AIU	BIU
正規分布	1,011,292	1,011,314
ガンマ分布	853,840	853,862
Tweedie分布	925,901	925,923
パレート分布	358,973	358,996
ZINB	928,632	928,666

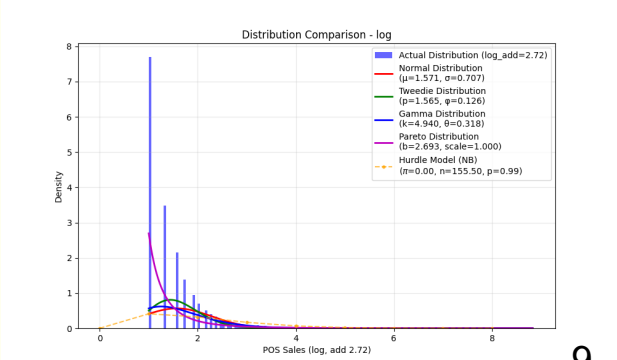

- スケール変換後逆変換をせず評価しているので単位が異なる

最適な確率分布の選定

適応度が高いスケール/確率分布

1. original + Tweedie分布 or ZINB
2. 対数変換 + パレート分布

課題と考察

- Tweedie分布 or ZINBは裾が指数関数的に減少する
- パレート分布はヘッドを捉えられていない印象

→ヘッドをTweedie分布 or ZINB，テールをパレート分布の混合分布が最良？

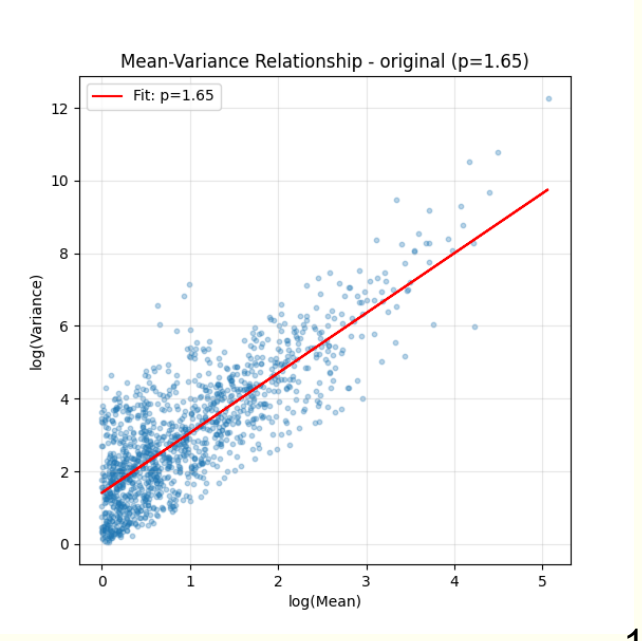

Tweedie分布の尤度を最大にするpとΦの決定

TFTと損失関数

Tweedie分布の組み込み

そもそもTFTにTweedieを組み込むライブラリは存在しない
→PyTorch の `F.tweedie_loss`を利用して負の対数尤度を損失関数として実装

予測の誤差が最小になるようにする

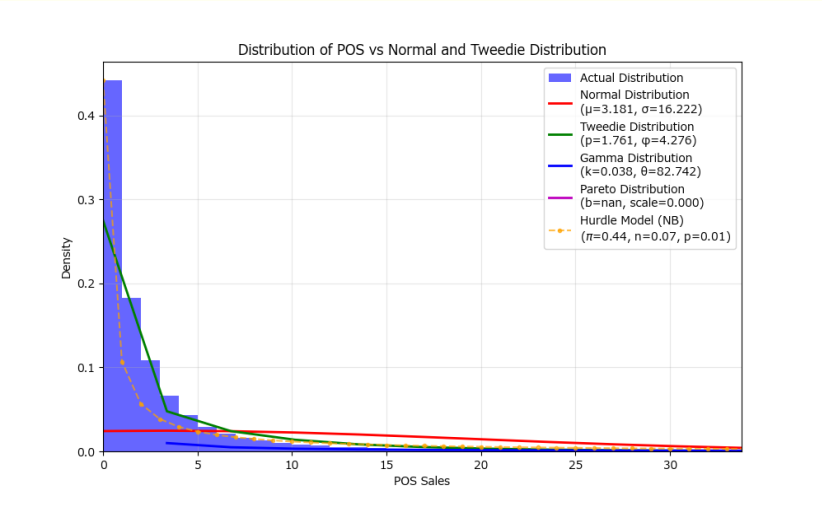

TFTと損失関数

実装結果
0過剰のデータのため、Loss(損失)を最小にするために
データがすべて0で予測

損失関数を組み込む前の
TFTでは予測できていた

損失関数導入により0の
重要度が向上し、予測が
0のみの結果

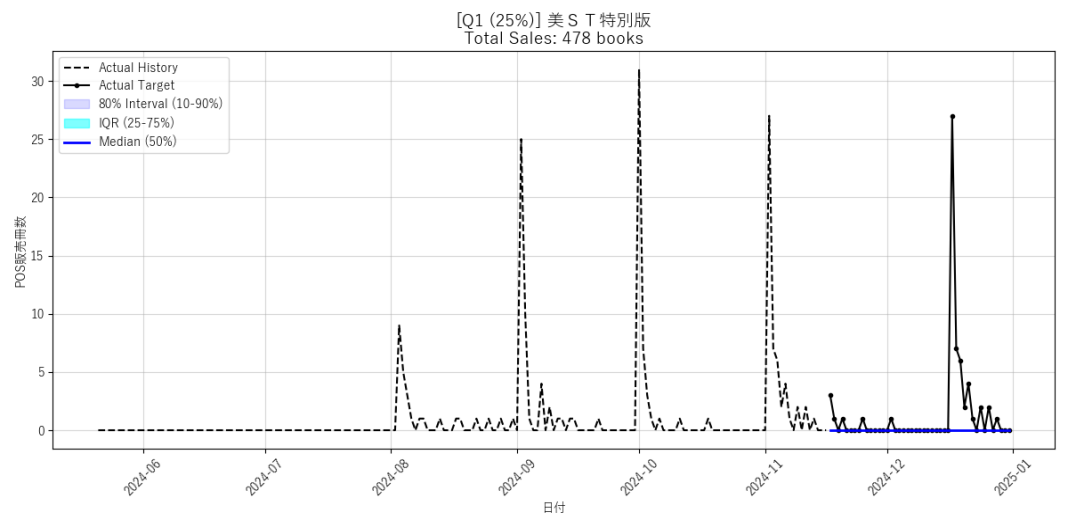

TFTと損失関数

予測データが0になった理由として考えられること

損失関数を求める数式

$$D(y,\mu) = \frac{2}{(1-p)(2-p)}\left[y^{2-p} - (2-p)y\mu^{1-p} + (1-p)\mu^{2-p}\right]$$

ここでy=0が多い(70%-90%)と学習内容が0に引っ張られ、
予測結果として0を算出すれば全体的な損失が少ないと判断された？

Y=（実際の売上）μ=（モデルの予測）p=（分布のパラメータ）

別モデル検証

使用モデル　N-Beats (GrounTS)

現状　書名の周期性が重要
(正規化済み,Week7参照)

特徴　TFTはLightGBM等と比べて
時系列データを保存できる
N-BeatsはTFTよりも時系列
データに強い

結果　N-Beatsは時系列<<<季節性
366日のデータ(1年)では精度が出ない

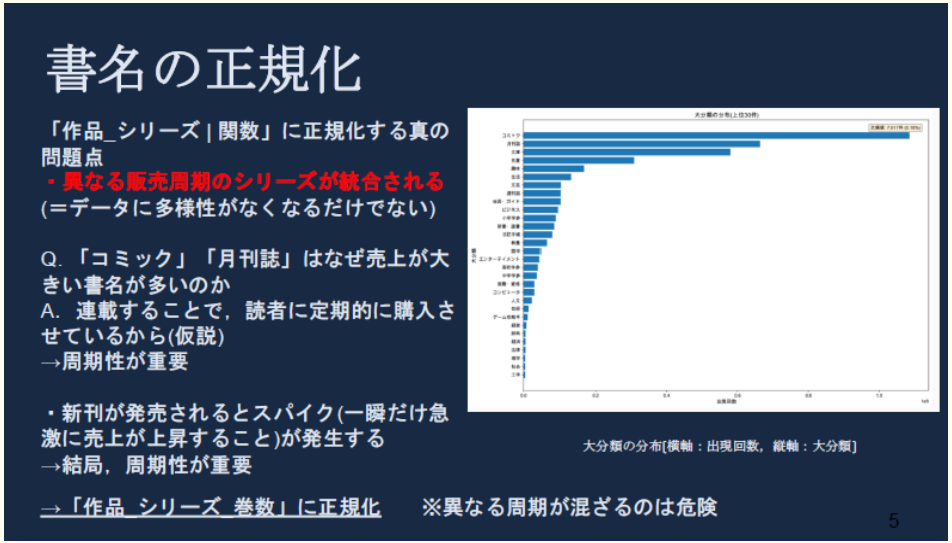

別モデル検証

N-Beatsではmxnetというライブラリを用いる
→mxnetが長期間メンテナンス/アップデートされていない

問題点
　使用している環境のpythonとの整合性がなく、既に存在する別ライブラリとの競合が発生

→競合によりライブラリのnumpyが破損

知見
　N-Beatsに限らず長期的な周期性が重要だと判明
　TFTのContext_Lengthの長さを調整/再確認する重要性が判明

偏相関分析

偏相関分析

TFTの精度向上にデータ拡張が必要

→拡張したデータが有用かどうかの分析

Law of Scale and Chinchilla

- Hidden dim: 128
- Variable dim: 64
- Num heads: 4
- Context length: 56
- Prediction length: 14

→データ拡張をし，データ量を増やす必要がある

のときデータ量は

適正データ量: 20*モデルサイズ = 49,143,040 のうち **7%**

総パラメータ数(モデルサイズ)：2,457,152

embedding層 –著者名: 1,512,448, 小分類: 121,216 出版社: 61,952 …
LSTM層 - Encoder/Decoder LSTMの重み: 約196,000
Attention層 - Multi-head attention: 約65,536
Variable Selection Networks - Static/Context/Target: 約500,000

データ量：3,515,616

slice数: 1,248
1 slice: 2,817

※TFTによる時系列のデータ拡張済

22

偏相関分析

周辺施設数と大分類別売上の相関

小・中学校、高校と「ビジネス」「日記手帳」「経済」の相関あり

→第３の変数が影響しているのではという指摘

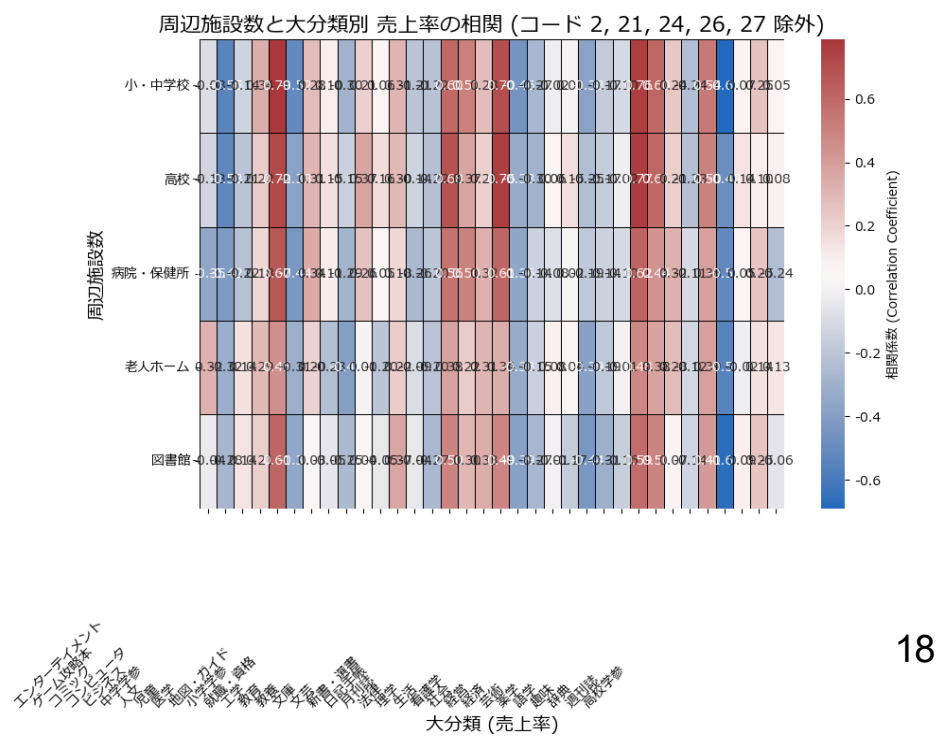

偏相関分析

偏相関係数…第3の変数の影響を除いた相関係数

$$r_{xy\cdot z} = \frac{r_{xy} - r_{xz}r_{yz}}{\sqrt{1-r_{xz}^2}\sqrt{1-r_{yz}^2}}$$

$r_{xy.z}$: 偏相関係数
r_{xy} : xとyの相関係数
r_{yz} : yとzの相関係数 →残差の相関
r_{xz} : xとzの相関係数

偏相関分析

相関があった大分類が「ビジネス」「経済」などであるため、
親世代の数の影響が大きいと仮定

→メッシュ毎の子持ち世帯数のデータを追加
＊国勢調査(核家族世帯数ー2人世帯数)

片親の考慮ができていないため、データ変更の余地あり

偏相関分析

小・中学校に注目

「ビジネス」「日記手帳」「経済」は弱い相関に

「コミック」「ゲーム攻略本」などの相関が多少強まった

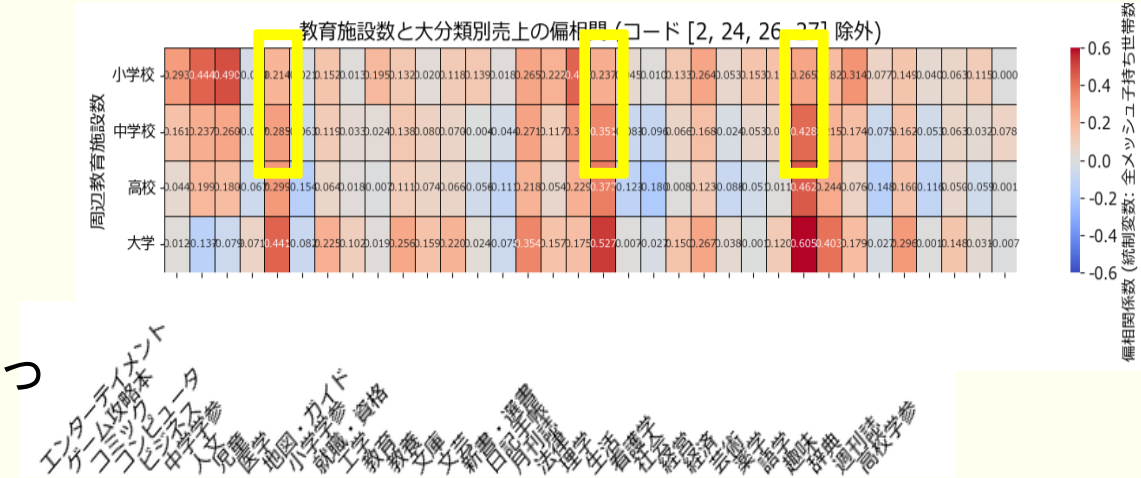

→子持ち世帯数の影響あり

相関分析

交通施設距離と総売り上げの相関

バス距離、駅距離ともに相関が得られなかった。

→ユーザのメインアクセス方法との距離との相関は？

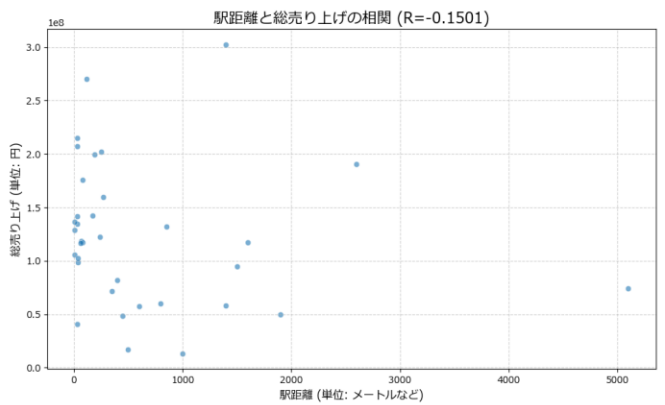

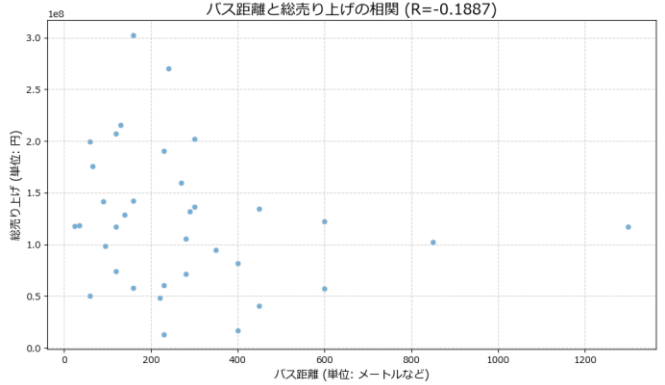

相関分析

バス距離（Googleマップ上徒歩距離）
駐車場の有無のカラム追加（1：有、0：無）

メインアクセス距離カラムを作成

駐車場がある場合…車（1）
ない場合…バス距離と駅距離の小さい値
でデータを作成

相関分析

駐車場のある店舗が多く、
相関が得られなかった。

→東京都内など駅からの距離が近い場合は駅から徒歩で行く人が多いと予想

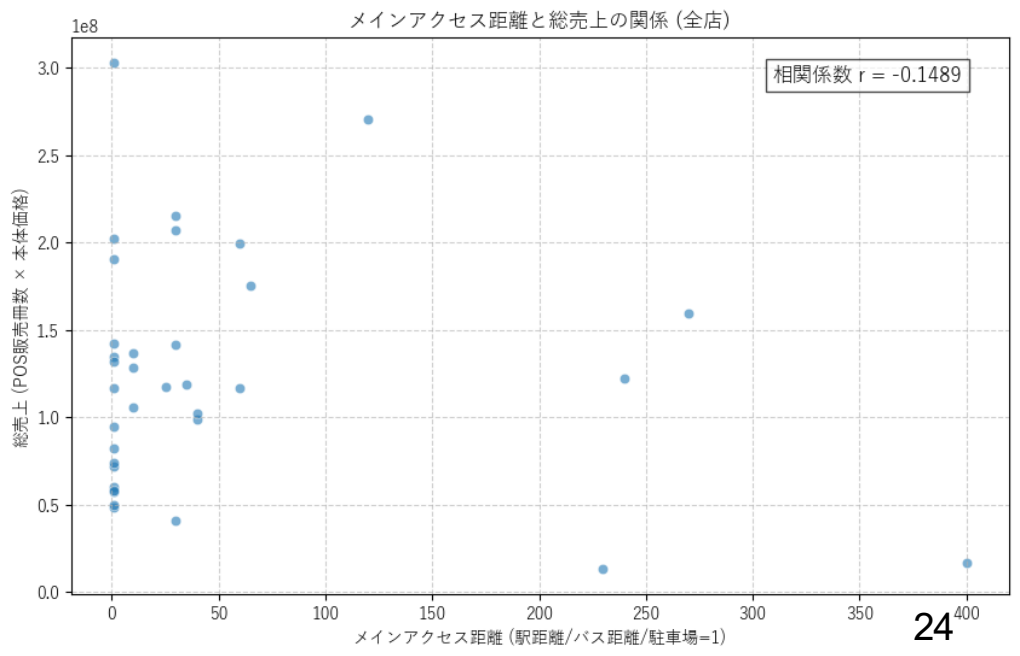

相関分析

メインアクセス距離カラムより
'メインアクセス250'
'メインアクセス500'
'メインアクセス750'　を作成

メインアクセスＮカラム
駅距離がＮ以下の時…駅距離を優先
Ｎより大きいとき…メインアクセス距離と同様

相関分析

メインアクセス250
… r ＝0.0092
メインアクセス500
… r ＝-0.2338
メインアクセス750
… r ＝-0.3084

優先する駅距離の値を大きくするほど相関も強くなった
→値を大きくしすぎると駅距離と変わらなくなってしまう

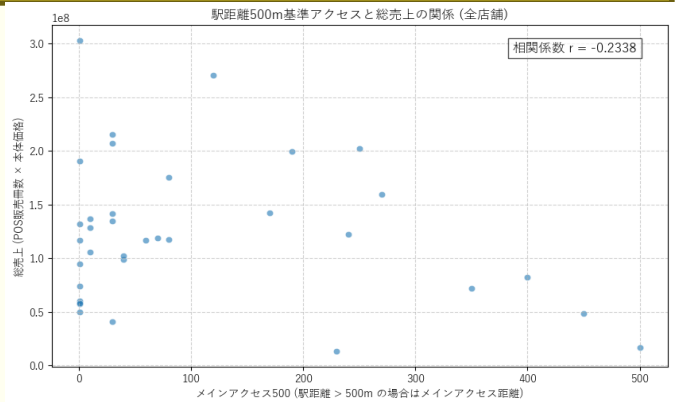

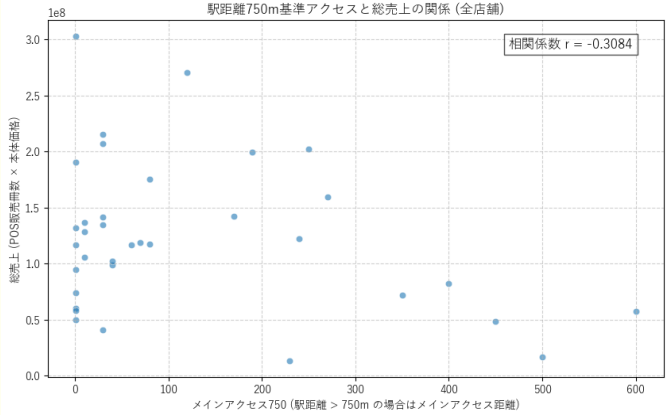

方針

データ拡張の今後の方針

・メインアクセス距離のように今あるデータの新たな活用方法を吟味

・新たな有用そうなデータを検討（Googleトレンドなど）

付録

TFTベースモデルの性能

MSE: 1273.3538
abs_error: 222469.3085
abs_target_sum: 300242.0000
abs_target_mean: 5.1761
seasonal_error: 3.1019
MASE: inf
MAPE: 0.6662
sMAPE: 1.2200
MSIS: inf
num_masked_target_values: 0.0000
QuantileLoss[0.1]: 59135.8522
Coverage[0.1]: 0.1002
QuantileLoss[0.2]: 108422.0868
Coverage[0.2]: 0.1857
QuantileLoss[0.3]: 152245.2899
Coverage[0.3]: 0.2935
QuantileLoss[0.4]: 190740.0818
Coverage[0.4]: 0.3757
QuantileLoss[0.5]: 222469.3087
Coverage[0.5]: 0.4930
QuantileLoss[0.6]: 245536.3308
Coverage[0.6]: 0.5780
QuantileLoss[0.7]: 259461.6109
Coverage[0.7]: 0.6599
QuantileLoss[0.8]: 254524.7909
Coverage[0.8]: 0.7506
QuantileLoss[0.9]: 216690.2208
Coverage[0.9]: 0.8499
RMSE: 35.6841
NRMSE: 6.8940
ND: 0.7410
wQuantileLoss[0.1]: 0.1970
wQuantileLoss[0.2]: 0.3611
wQuantileLoss[0.3]: 0.5071
wQuantileLoss[0.4]: 0.6353
wQuantileLoss[0.5]: 0.7410
wQuantileLoss[0.6]: 0.8178
wQuantileLoss[0.7]: 0.8642
wQuantileLoss[0.8]: 0.8477
wQuantileLoss[0.9]: 0.7217
mean_absolute_QuantileLoss: 189913.9525
mean_wQuantileLoss: 0.6325
MAE_Coverage: 0.3610
OWA: nan

TFT対数変換の性能

MSE: 0.5665
abs_error: 30270.8042
abs_target_sum: 58923.3727
abs_target_mean: 1.0158
seasonal_error: 0.4801
MASE: inf
MAPE: 0.4771
sMAPE: 1.0563
MSIS: inf
num_masked_target_values: 0.0000
QuantileLoss[0.1]: 10739.4286
Coverage[0.1]: 0.1057
QuantileLoss[0.2]: 18419.4137
Coverage[0.2]: 0.2189
QuantileLoss[0.3]: 24198.9619
Coverage[0.3]: 0.3132
QuantileLoss[0.4]: 28195.0255
Coverage[0.4]: 0.3869
QuantileLoss[0.5]: 30270.8041
Coverage[0.5]: 0.5025
QuantileLoss[0.6]: 30506.2312
Coverage[0.6]: 0.6019
QuantileLoss[0.7]: 28687.0630
Coverage[0.7]: 0.6904
QuantileLoss[0.8]: 24616.3711
Coverage[0.8]: 0.7700
QuantileLoss[0.9]: 17219.2771
Coverage[0.9]: 0.8654
RMSE: 0.7527
NRMSE: 0.7409
ND: 0.5137
wQuantileLoss[0.1]: 0.1823
wQuantileLoss[0.2]: 0.3126
wQuantileLoss[0.3]: 0.4107
wQuantileLoss[0.4]: 0.4785
wQuantileLoss[0.5]: 0.5137
wQuantileLoss[0.6]: 0.5177
wQuantileLoss[0.7]: 0.4869
wQuantileLoss[0.8]: 0.4178
wQuantileLoss[0.9]: 0.2922
mean_absolute_QuantileLoss: 23650.2863
mean_wQuantileLoss: 0.4014
MAE_Coverage: 0.3731
OWA: nan

最適な確率分布の選定

original

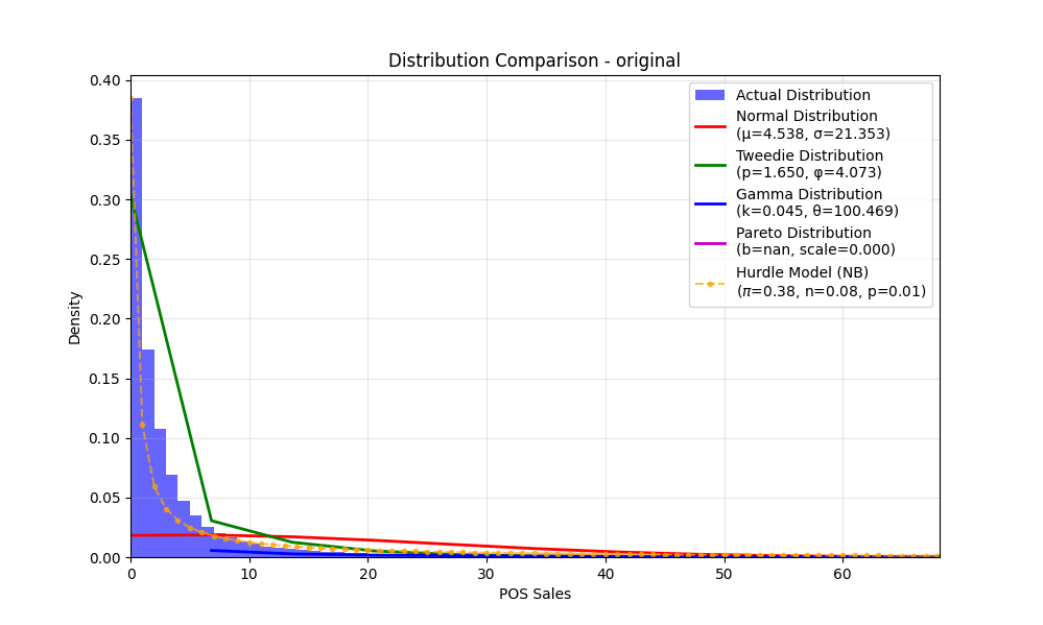

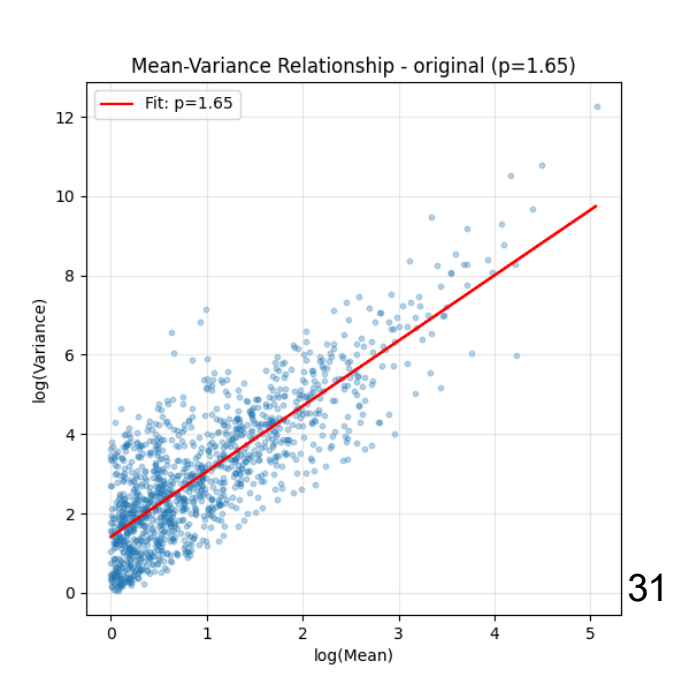

最適な確率分布の選定

冪乗変換

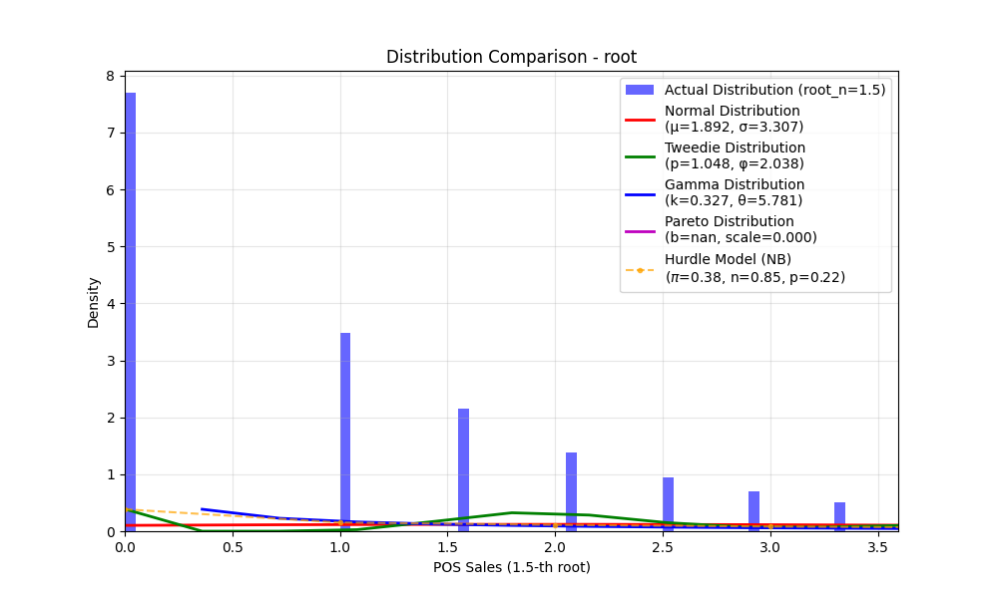

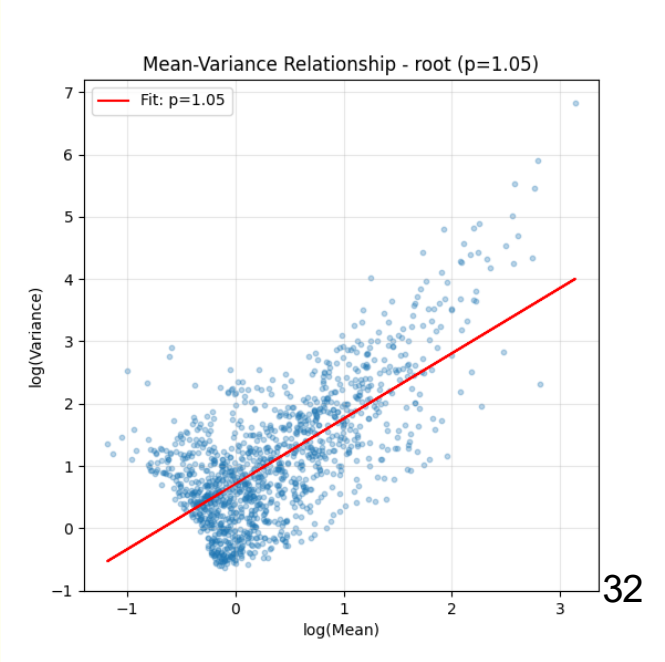

最適な確率分布の選定

シフト(+e)変換

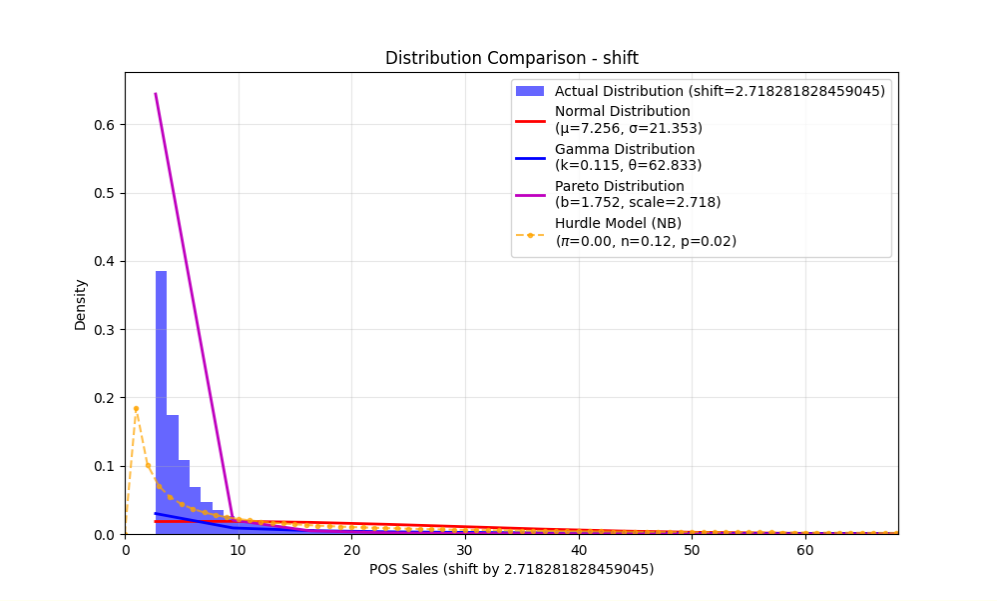

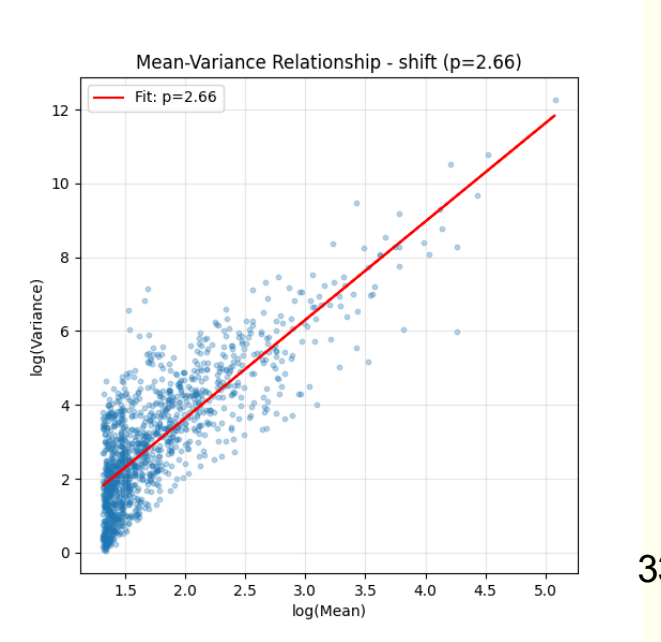

最適な確率分布の選定
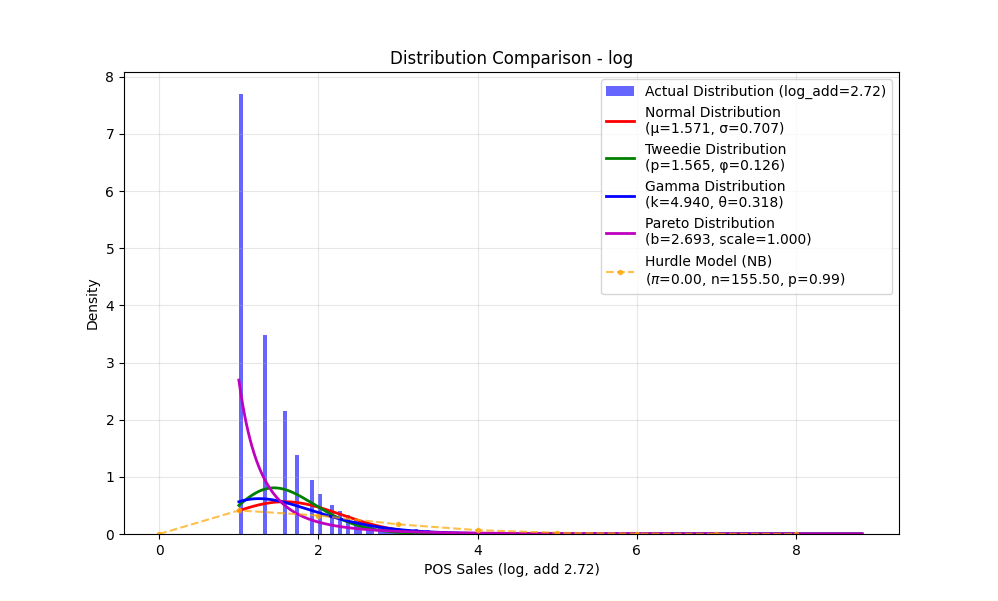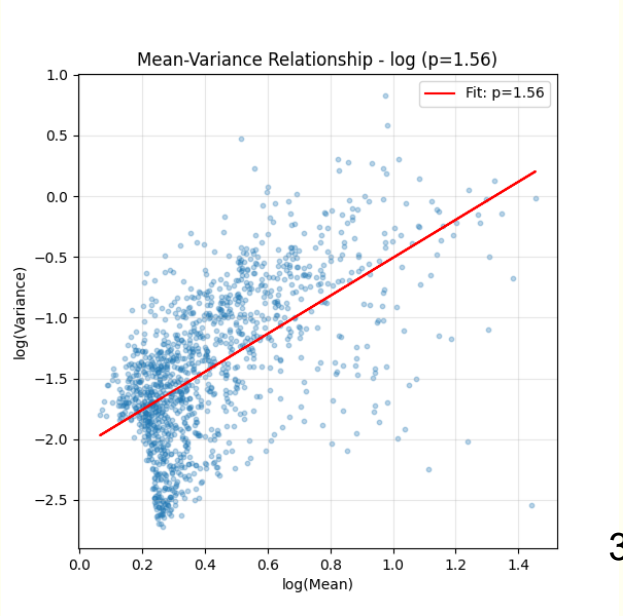
対数変換 (+e)