データ解析コンペ経過発表
Week 15

奈良原俊誠
斎藤陽
橋本朋樹

目的とフロー

目的

間欠需要・ロングテールのデータに適応し，スパイク予測が可能なモデルを作成する

いままでの手法：TFT

1. ベースモデルの作成
2. 確率分布の選定
3. 損失関数に確率分布を組み込む
4. 特徴量エンジニアリング

問題

- モデルサイズに対するデータ不足
- 特徴量エンジニアリングに依存

TFTのモデル

モデル	glounts TFT
データセット	書名ごと総POS販売冊数>=366の1157書名
説明変数	日付, 書名, 著者名, [x]分類, 本体価格, 過去のPOS販売冊数 +特徴量エンジニアリング
目的変数	POS販売冊数
損失関数	分位点損失
CONTEXT_LENGTH	180
PREDICTION_LENGTH	64

- データポイント；group by [書名,日付]
- ゼロ補完：[2024/1/1, 2024/12/31]に存在しないデータポイントを0で補完
- データ数1,157*366= 423,462
- 分位点[0.1, 0.5, 0.75, 0.9, 0.95, 0.99]

TFTの課題

データ不足

- 過学習

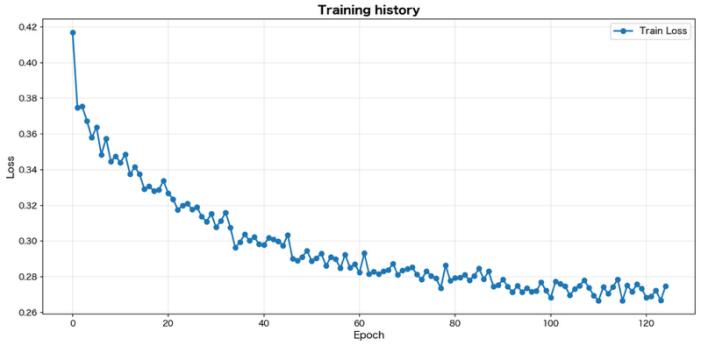

- 深層学習の強みを活かせない

Q. モデルサイズを減らす？

A. であれば決定木系でよい

特徴量エンジニアリング

- 説明変数の増加

→大量の説明変数の解釈は困難

- NNを決定的選択に代替

→深層学習である必要がない

解決策

事前学習済みモデル + ファインチューニング(FT)

LLMアーキテクチャを時系列数値予測に応用する

chronos

Amazonが2024年に開発した時系列基盤モデル．時系列データセット群・ガウス過程を使って生成された人口データ合計84Bトークンで事前学習される

良い点

- モデルサイズの巨大化
- データ不足を解消
- 単一変数

- chronos T5

T5(Encoder-Decoder Transformer)がベース．入力系列を量子化しトークンとして学習・予測する．推論方式は自己回帰

- chronos bolt

入力系列をパッチに分割し量子化．推論方式は直接マルチステップ方式．自己回帰しないためchronos T5より最大250倍高速

Wang et al. (2024). *Fast and accurate zero-shot forecasting…* AWS Machine Learning Blog.[1]

事前学習と事後学習

大量のデータ+合成データ

e.g. Kaggleのデータセット,
Wikipediaの閲覧数

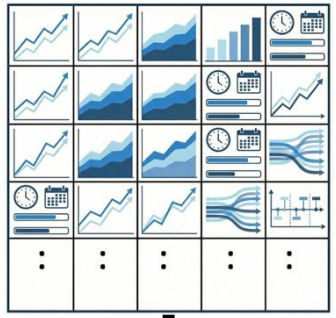

今回のデータセット

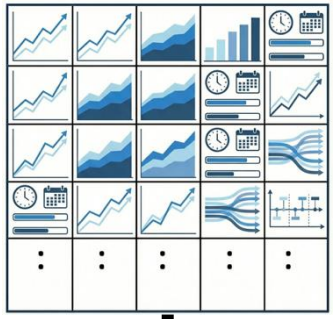

巨大なモデル

事前学習

汎用的なモデル

事後学習

e.g. PEFT, RLHF

特化したモデル

chronosのモデル

モデル	chronos-t5-small / chronos-bolt-base
データセット	書名ごと総POS販売冊数>=366の1157書名
説明変数	過去の POS販売冊数
目的変数	POS販売冊数
CONTEXT_LENGTH	180
PREDICTION_LENGTH	64
FT手法	LoRA
LoRAランク数	16
LoRAバイパス	すべてのAttention層，FeedForwardの入出力層

- FTデータ：(366-64)日を(180+64)日でスライドした59サンプル*1,157書名=68,263スライス
- パラメータ数：chronos-t5-small:46M， chronos-bolt-base:200M
- 「Attention層のすべて」：Attention層にあるQuery, Key, Valueを射影する重み，出力次元に変換・結合する重み

性能評価-MAE, RMSE, Cov(80%)

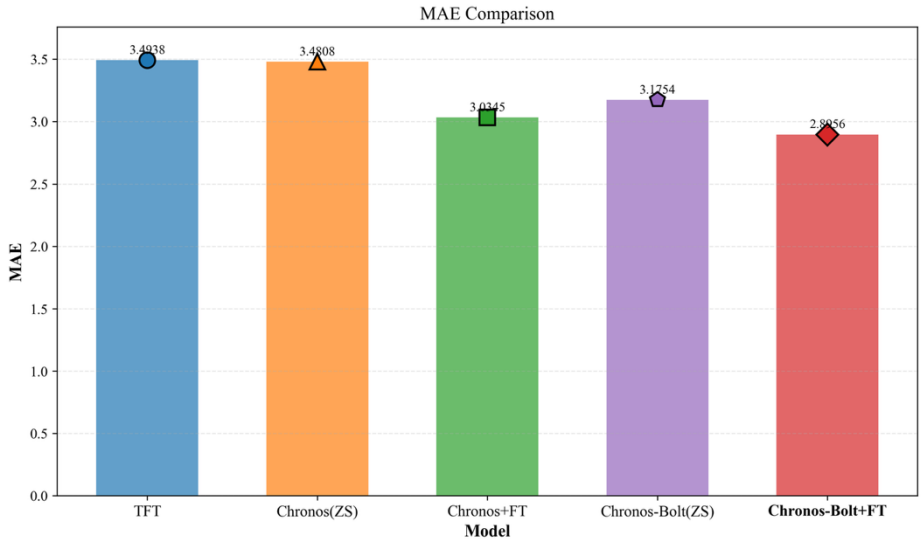

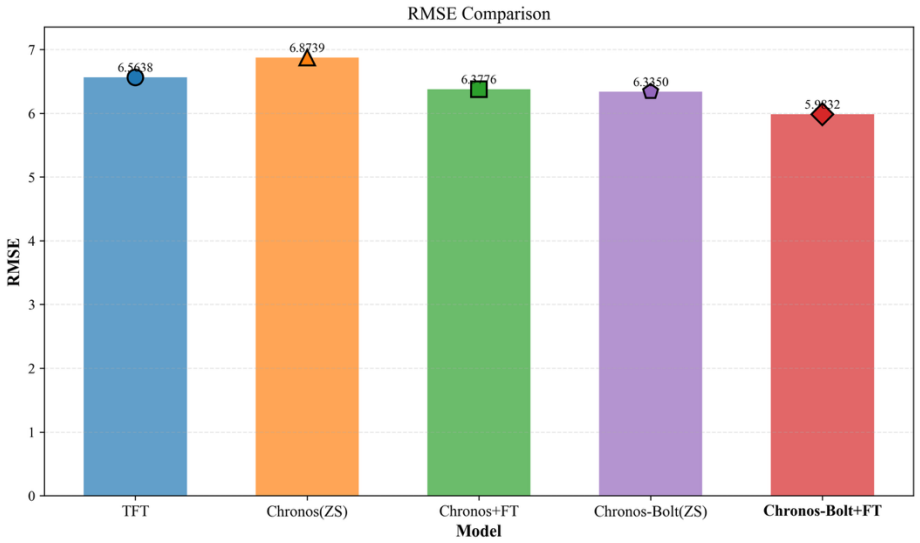

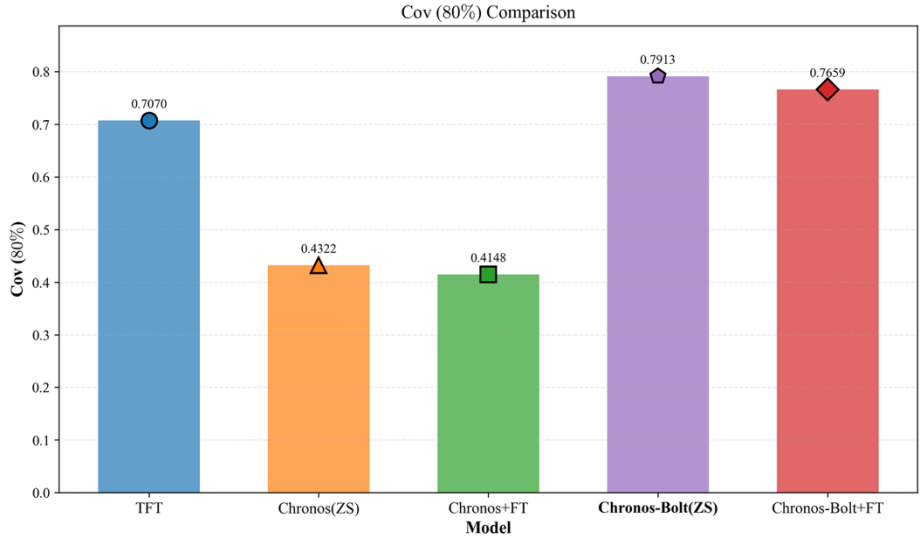

1. **TFT**
2. **chronos(zero-shoto)**
3. **chronos+LoRA**
4. **chronos_bolt(zero-shot)**
5. **chronos_bolt+LoRA**　の5つのモデルを

$MAE, RMSE, Cov(80\%), QL_{0.1}, QL_{0.5}, QL_{0.9}, QL_{mean}$

の7つの指標で評価

性能評価-分位点損失

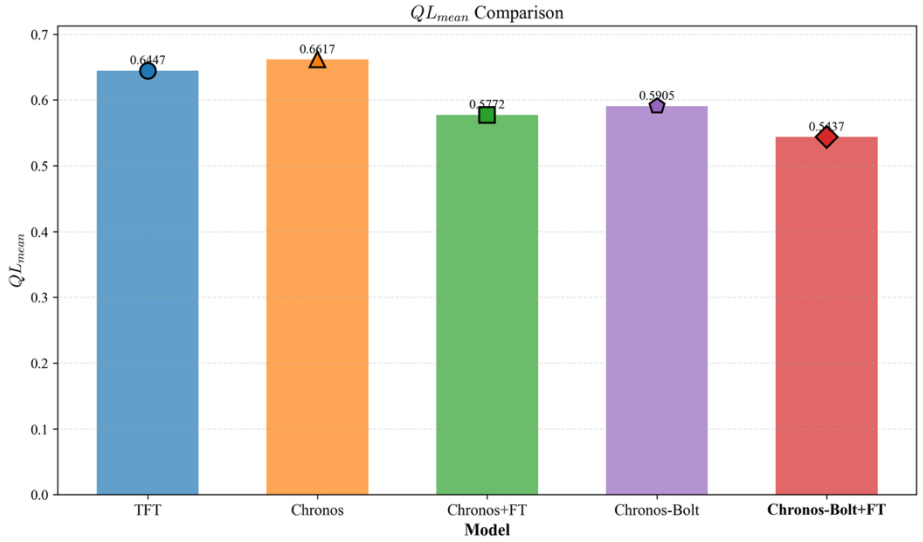
QL_{mean} Comparison
QL_{mean}
0.0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
0.6447
0.6617
0.5772
0.5905
0.5437
TFT
Chronos
Chronos+FT
Chronos-Bolt
Chronos-Bolt+FT
Model

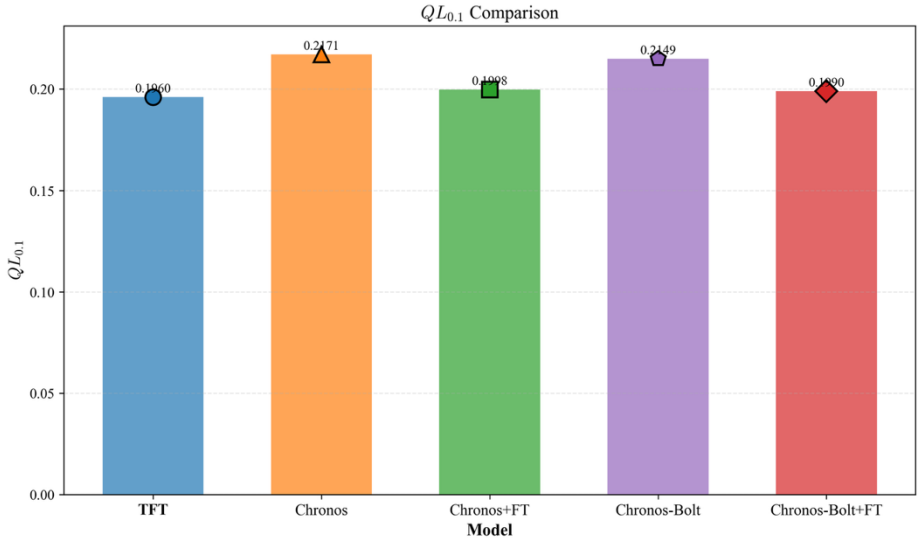
$QL_{0.1}$ Comparison
$QL_{0.1}$
0.00
0.05
0.10
0.15
0.20
0.1960
0.2171
0.1998
0.2149
0.1990
TFT
Chronos
Chronos+FT
Chronos-Bolt
Chronos-Bolt+FT
Model

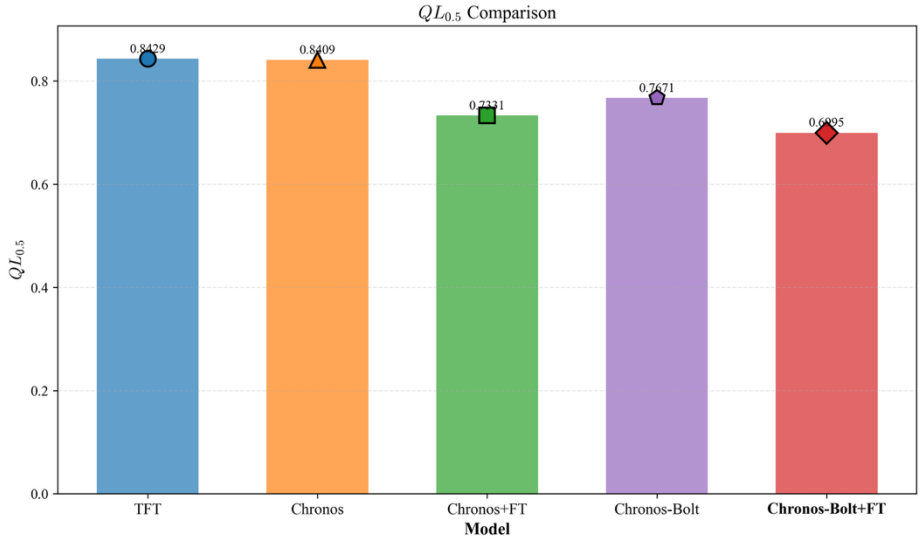
$QL_{0.5}$ Comparison
$QL_{0.5}$
0.0
0.2
0.4
0.6
0.8
0.8429
0.8409
0.7331
0.7671
0.6895
TFT
Chronos
Chronos+FT
Chronos-Bolt
Chronos-Bolt+FT
Model

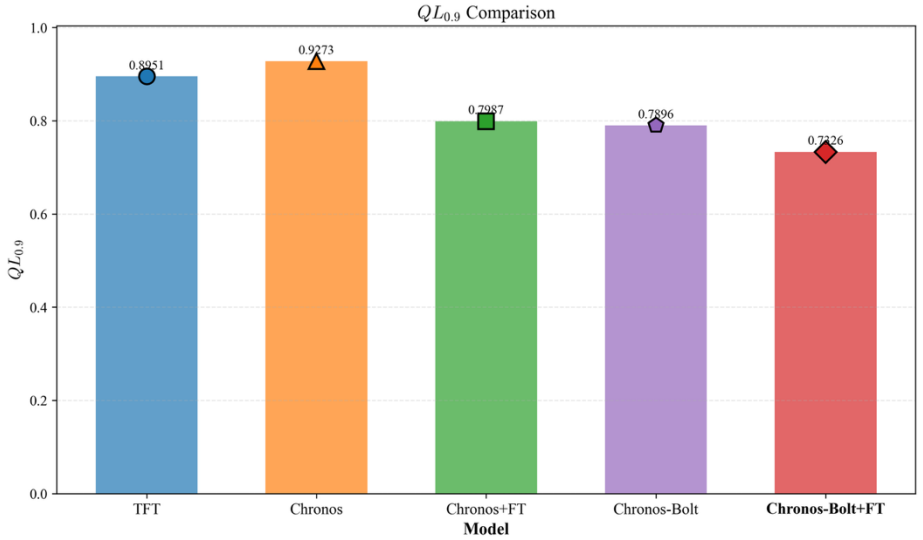
$QL_{0.9}$ Comparison
$QL_{0.9}$
0.0
0.2
0.4
0.6
0.8
1.0
0.8951
0.9273
0.7987
0.7896
0.7326
TFT
Chronos
Chronos+FT
Chronos-Bolt
Chronos-Bolt+FT
Model

性能の考察

- chronos-bolt+LoRAが最良の性能

7のうち5つの評価指標で最良．他2つの評価指標においても上位2

- FTによる性能改善

FT後のモデルは zero-shotと比較しほぼすべての評価指標で改善

- chronos-t5(+LoRA)は予測区間を狭く見積もる

$Cov(80\%)$が他のモデルと比較し著しく低い

- TFTは過小に予測する傾向

TFTの他QLxと比較し$\mathrm{QL}_{0.1}$が小さい

TFT vs chronos

- **TFTの現状**(P4〜5)
  TFTではデータ不足により簡潔需要+スパイクのデータを予測することは難しかった

- **chronosの性能**(P8〜9)
  事前学習済みモデル+FTによってデータ不足が解消され、TFTの特徴量
  エンジニアリングよりも高い精度が出るようになった

⇒売上パターン別に再評価を行いどのような売上パターンで
chronosの性能が評価されているか検証

売上パターン別評価

regime(レジーム)

Regimeとは、時系列がある一定期間に示す振る舞いの型（需要構造、売上パターン）

- **sparse(スパース)**
  - 売上が発生しない日が多い
  - 情報が少なく予測が難しい
    例）ほぼ毎日0冊。たまに1.2冊売れる

- **burst(バースト)**
  - 普段は売れないが、突然大きく売れる
  - スパイクの連鎖
    例）漫画の新刊など急激に何百冊も売れる

- **Periodic(ピリオディック)**
  - どれくらい周期性があるか
    例）月刊誌が1か月に1回のペースで売れる日が決まっている

売上パターン定義

Regimeで分割することによりスパイクに種類を持たせる
（0冊から2.3冊 or 10冊程度からn100冊）

各書名・各期間について以下を算出 (詳細は付録P32参照)

- ADI：売上間隔
- CV^2：規則性
- Hawkes：自己励起性

上記3項目より各regime_scoreを算出 (詳細は付録P34参照)

- Sparse score
- Periodic score
- Burst score

最も高い score をその書名の regime と定義

Regime別性能評価 (sparse)

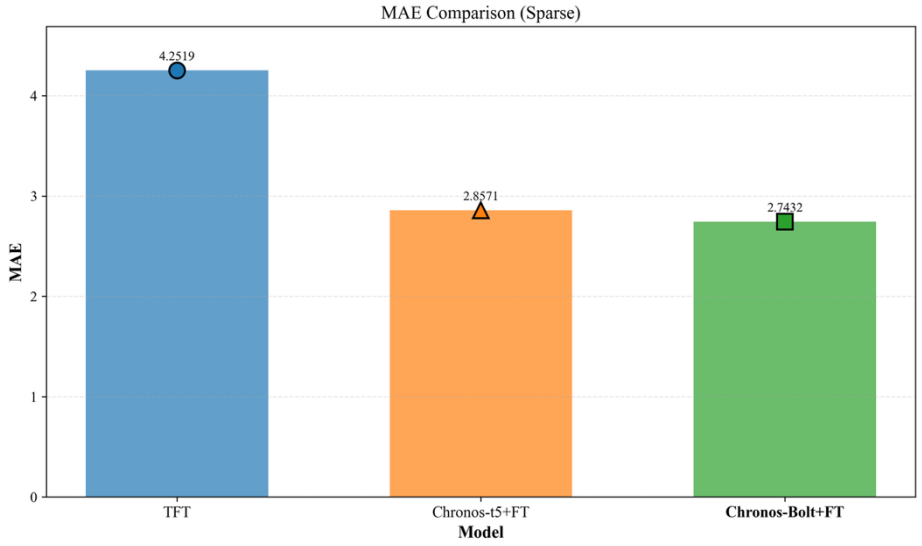

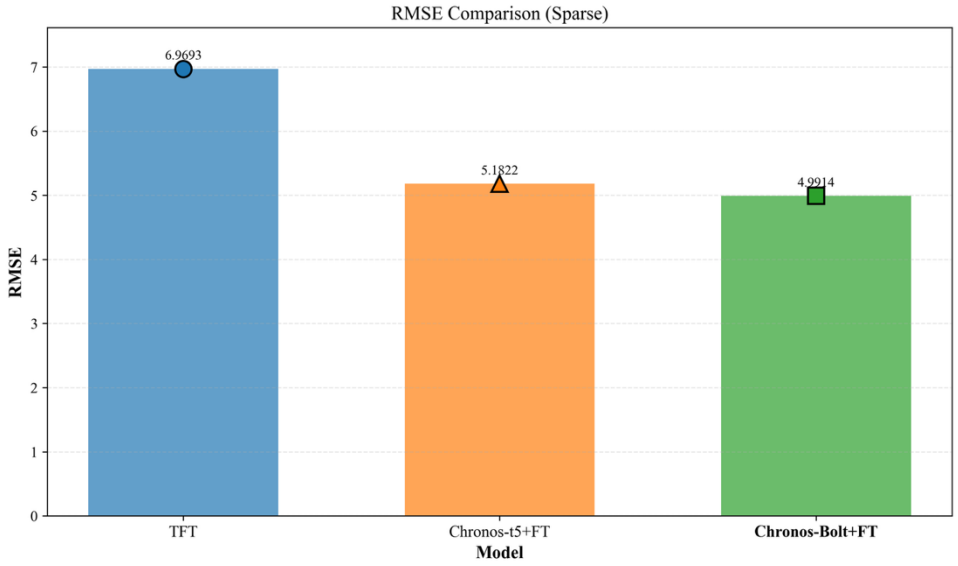

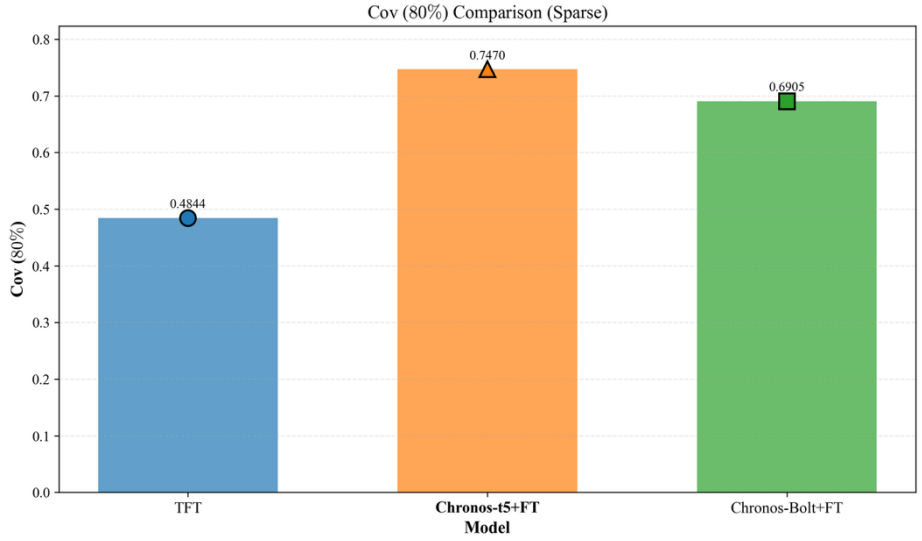

TFT, chronos+LoRA
chronos_bolt+LoRAの3モデルを
MAE, RMSE, Cov(80%), $QL_{0.1}$, $QL_{0.5}$, $QL_{0.9}$,QL_{mean}
の7つの指標で評価

Regime別性能評価 (sparse)

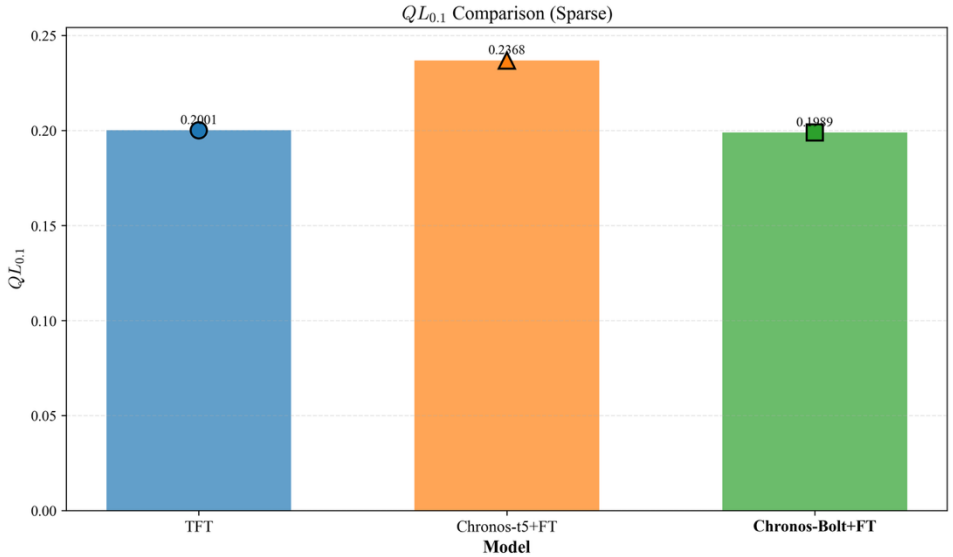

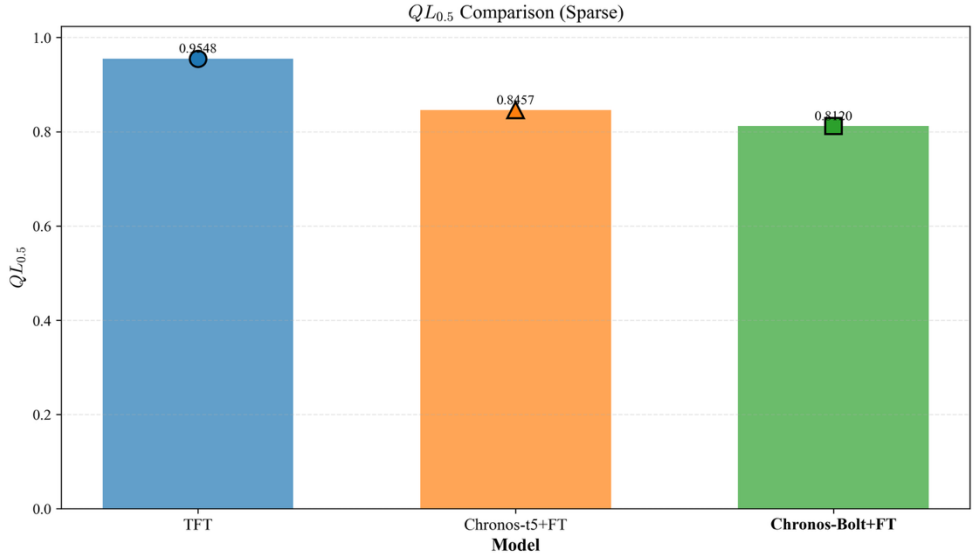

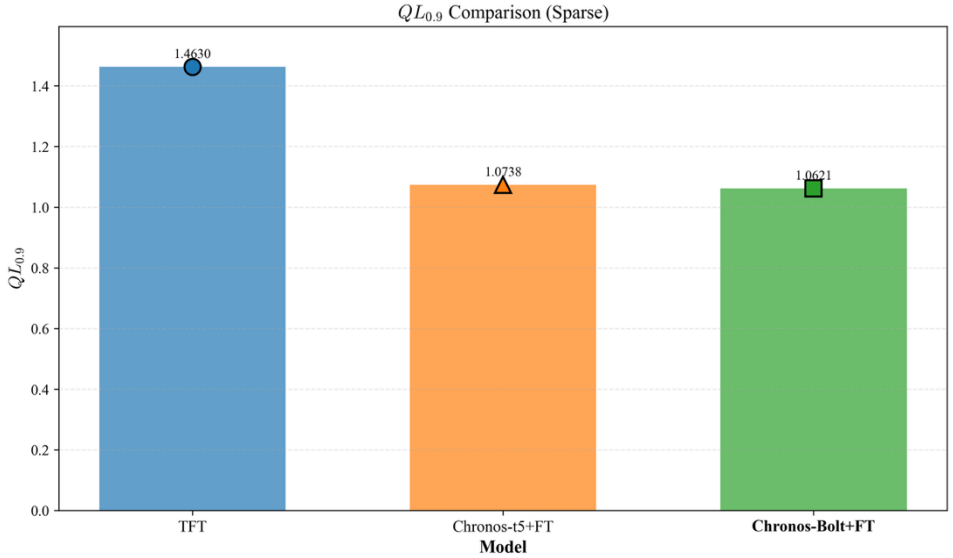

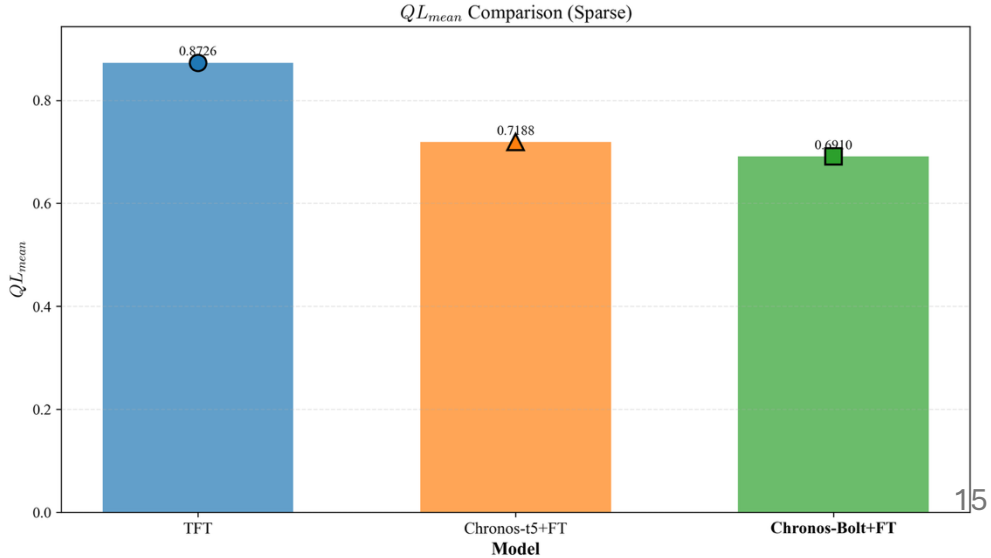

Regime別性能評価 (burst)

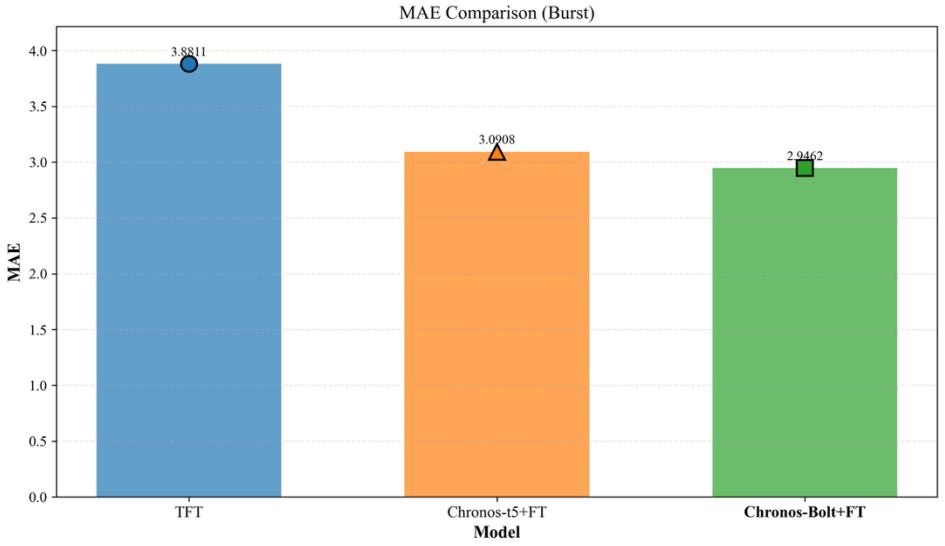

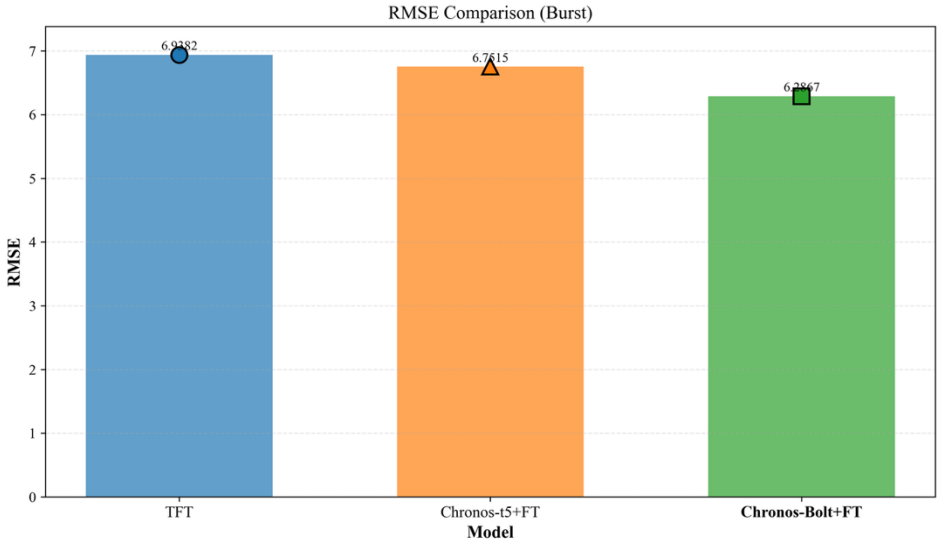

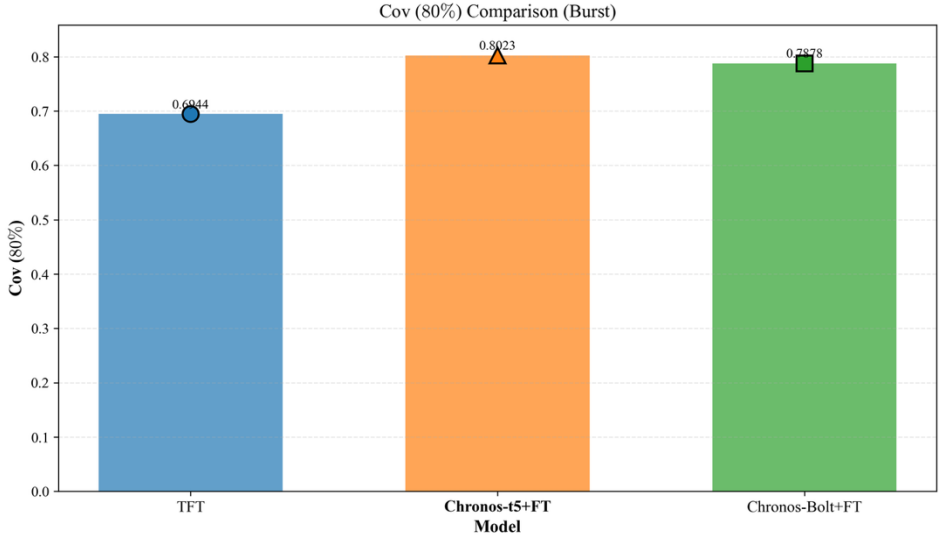

TFT, chronos+LoRA
chronos_bolt+LoRAの3モデルを
MAE, RMSE, Cov(80%), $QL_{0.1}$, $QL_{0.5}$, $QL_{0.9}$,QL_{mean}
の7つの指標で評価

Regime別性能評価 (burst)

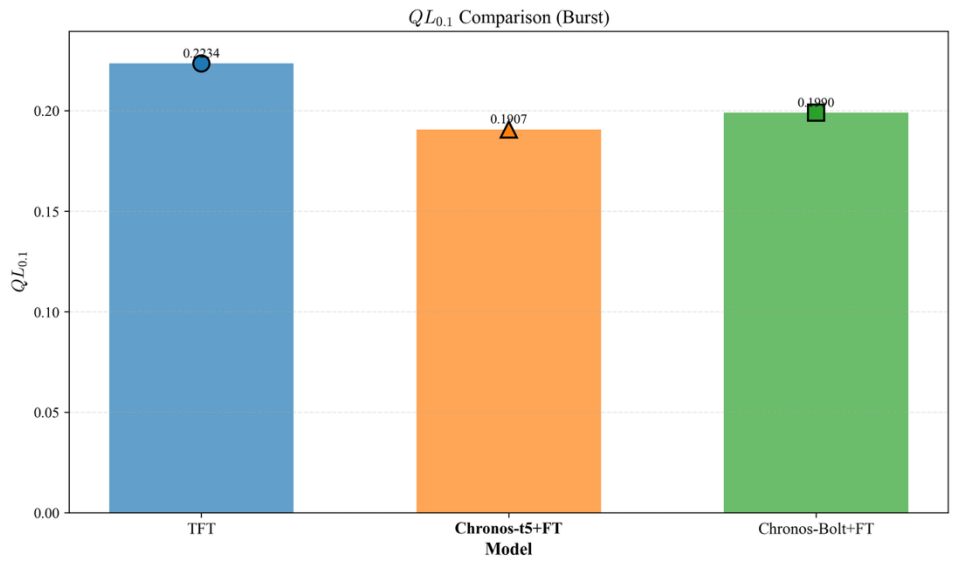

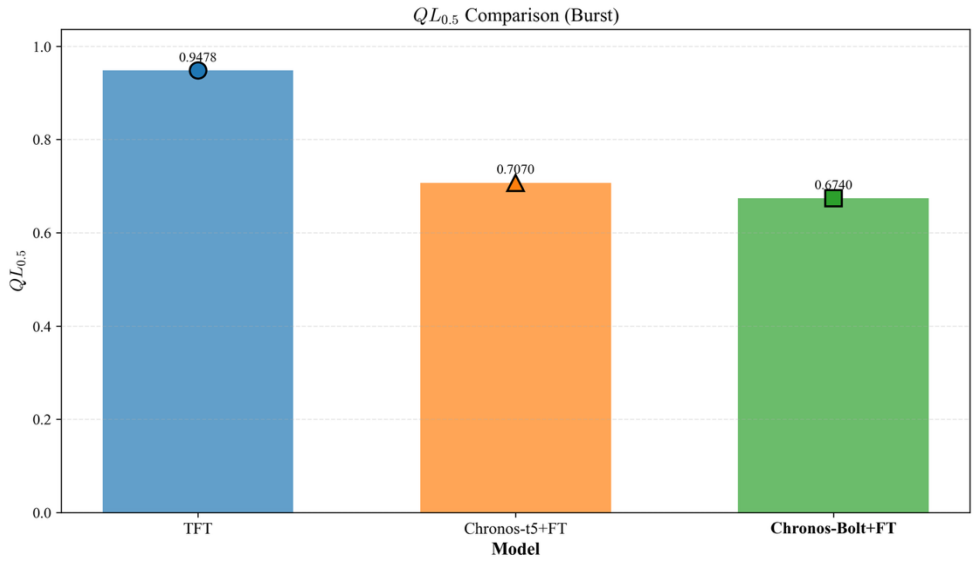

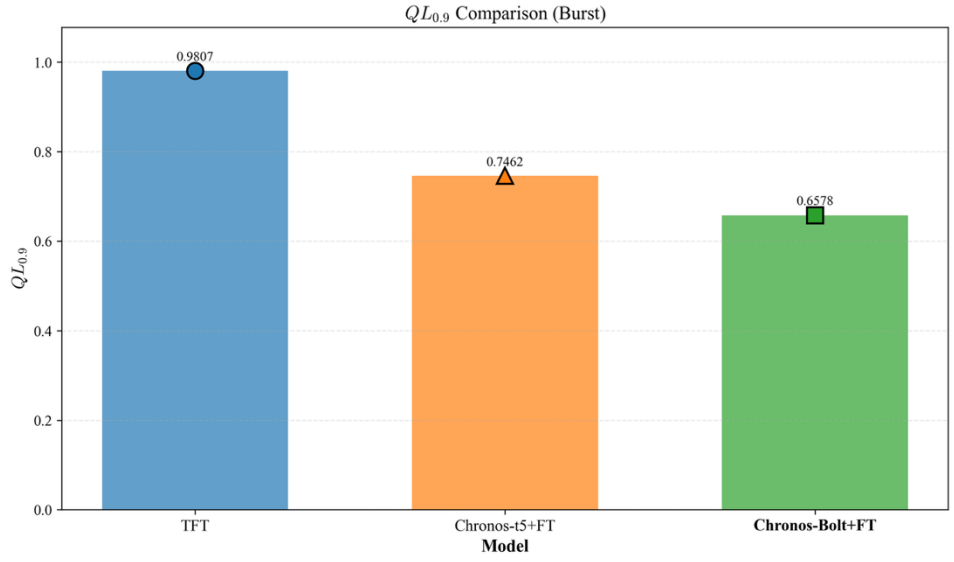

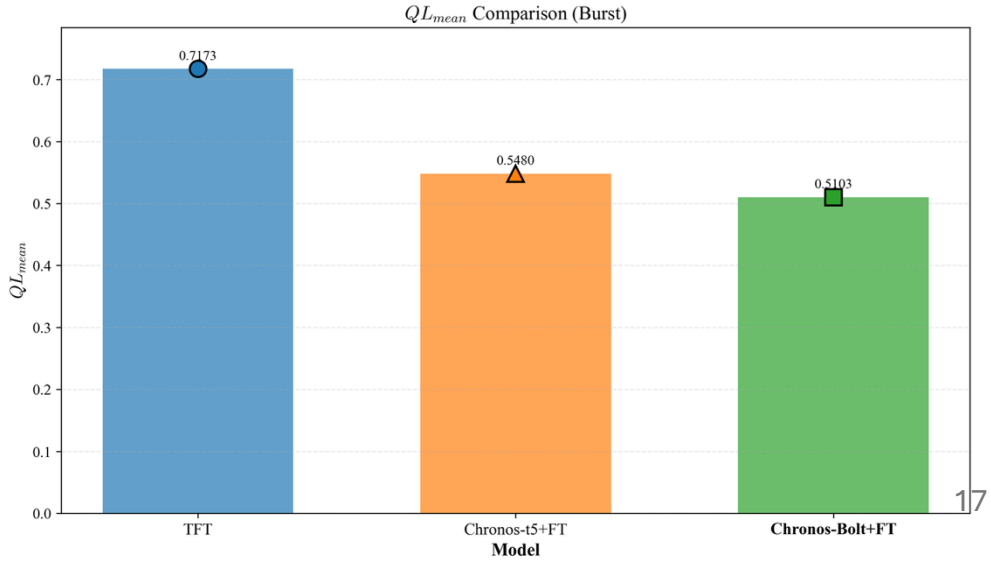

結果

- **sparse-regimeの結果**
  chronosモデル（特に bolt+FT）は**MAE・RMSE・QL のすべてで TFT を上回った**
  Coverage(80%) では
  TFT：0.5 未満
  chronos：0.7 前後

- **burst-regimeの結果**
  MAE は chronos-bolt+FT が最小
  RMSE は全モデルで大きな差はない

売上パターン別に重要な不確実性を捉えられたことが
chronos系モデルがTFTを上回った主な要因であると考えられる

考察

売上のパターンごとに「重要な分位」が異なる

- **sparse 需要**
  → 売れない日の予測が重要
  → 下側分位（$QL_{0.1}$） が本質
- **burst 需要**
  → 急激な需要増への備えが重要
  → 上側分位（$QL_{0.9}$） が本質

  - Sparse × $QL_{0.1}$
  - Burst × $QL_{0.9}$

  の両方で **chronos-bolt が最も良い性能**を示した

※在庫・発注の観点では、sparseでは過小在庫、burstでは欠品を防ぐことが重要であり、 chronos-boltはその両方に対応できる。

典型的な書名の抽出

これまでモデルの予測結果を可視化する書籍を、全書籍を累計販売数でソートし、5%刻みの代表的な書名で行っていた。

→売り上げ規模、売上パターン共に偏りがあったため、網羅できていなかった。

5%刻みの代表的な21書名時

```
=== Calculating Evaluation Metrics ===
----------------------------------------
Metric          | Value
----------------------------------------
MAE             | 11.0322
RMSE            | 189.0880
wQL_0.1         | 0.1928
wQL_0.5         | 0.8593
wQL_0.9         | 1.3457
wQL_Mean        | 0.7993
Coverage_80%    | 0.8021
----------------------------------------
```

5%刻みの代表書名から呪術回線を抜いた時

```
=== Calculating Evaluation Metrics ===
----------------------------------------
Metric          | Value
----------------------------------------
MAE             | 3.7507
RMSE            | 16.6641
wQL_0.1         | 0.2970
wQL_0.5         | 0.6116
wQL_0.9         | 0.5106
wQL_Mean        | 0.4731
Coverage_80%    | 0.7612
----------------------------------------
```

典型的な書名の抽出

売上パターンでクラスタリングし、
代表書名を抽出する。

Davies-Bouldin Scoreでクラスタ数を決定

Davies-Bouldin Score...
クラスタ内がいかに密集しており（コンパクトさ）、
クラスタ同士がいかに離れているか（分離度）

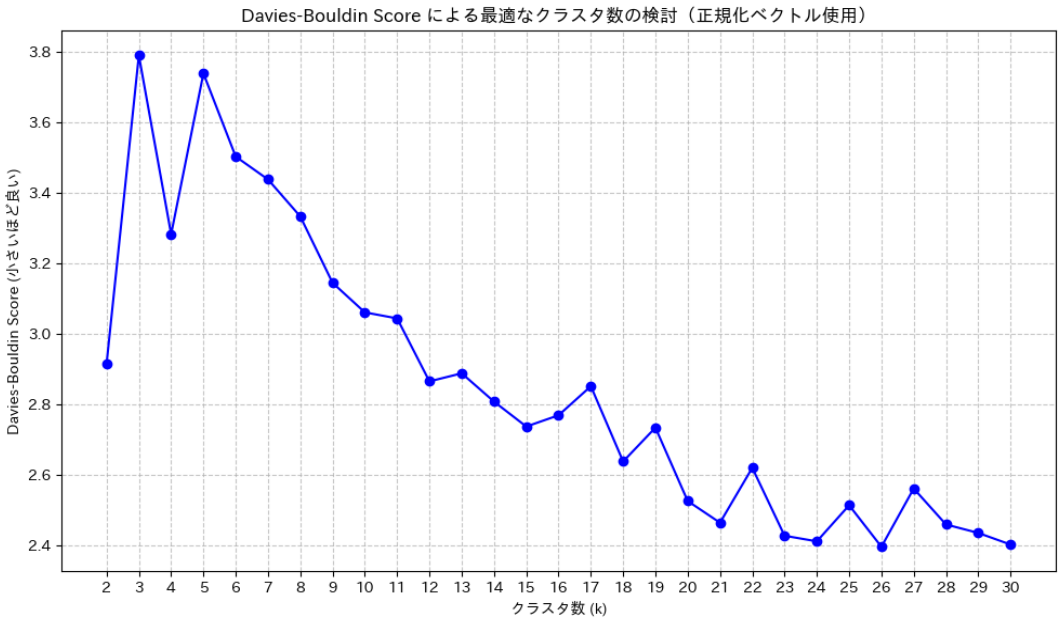

典型的な書名の抽出

```
=== Calculating Evaluation Metrics ===
----------------------------------------
Metric          | Value
----------------------------------------
MAE             | 11.0322
RMSE            | 189.0880
wQL_0.1         | 0.1928
wQL_0.5         | 0.8593
wQL_0.9         | 1.3457
wQL_Mean        | 0.7993
Coverage_80%    | 0.8021
----------------------------------------
```

```
=== Calculating Evaluation Metrics ===
----------------------------------------
Metric          | Value
----------------------------------------
MAE             | 3.7507
RMSE            | 16.6641
wQL_0.1         | 0.2970
wQL_0.5         | 0.6116
wQL_0.9         | 0.5106
wQL_Mean        | 0.4731
Coverage_80%    | 0.7612
----------------------------------------
```

クラスタリングで得た代表書名26件時

```
=== Calculating Evaluation Metrics ===
----------------------------------------
Metric          | Value
----------------------------------------
MAE             | 3.7185
RMSE            | 12.9816
wQL_0.1         | 0.1958
wQL_0.5         | 0.7365
wQL_0.9         | 0.8345
wQL_Mean        | 0.5889
Coverage_80%    | 0.7440
----------------------------------------
```

典型的な書名の抽出

全書名時の
MAE…3.1254
RMSE…6.3350

であり、元の書名に比べ、
代表書名内で偏りに引っ張られない
書名の選出ができている。

→レジームごとに代表書名を抽出する形も検討

クラスタリングで得た代表書名26件時

```
=== Calculating Evaluation Metrics ===
----------------------------------------
Metric          | Value
----------------------------------------
MAE             | 3.7185
RMSE            | 12.9816
wQL_0.1         | 0.1958
wQL_0.5         | 0.7365
wQL_0.9         | 0.8345
wQL_Mean        | 0.5889
Coverage_80%    | 0.7440
----------------------------------------
```

今後進めたいこと

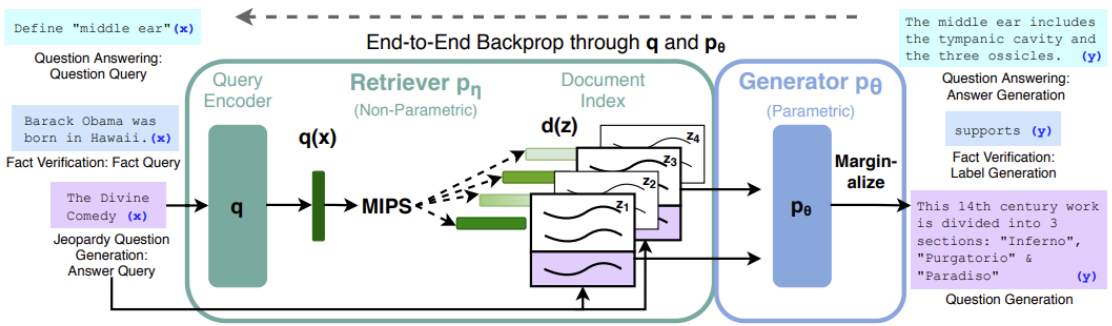

Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[2]

- RAFの実装

RAGの数値予測版．LLMのアーキテクチャに沿って進めていきたい

実装済み(付録参照)で性能改善を見込めた

- 対象書名の増加

巨大なモデルはより間欠な書名データを混ぜてもスパイク予測に対応できる

- 他モデルとアンサンブル

e.g. chronos-bolt + TFT or LightGBM　TFTとchronosは予測傾向が異なる(TFTが下限を意識する)

参照

[1] Wang, S., Ansari, A. F., Stella, L., Hazirbas, C., & Wang, Y. (2024, December 2). Fast and accurate zero-shot forecasting with Chronos-Bolt and AutoGluon. AWS Machine Learning Blog. https://aws.amazon.com/blogs/machine-learning/fast-and-accurate-zero-shot-forecasting-with-chronos-bolt-and-autogluon/

[2] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. *Advances in neural information processing systems*, *33*, 9459-9474.

[3] Hawkes, A. G. (1971). Spectra of some self-exciting and mutually exciting point processes. *Biometrika*, *58*(1), 83-90.

[4] Ogata, Y. (1981). On Lewis' simulation method for point processes. *IEEE transactions on information theory*, *27*(1), 23-31.

[5] Crane, R., & Sornette, D. (2008). Robust dynamic classes revealed by measuring the response function of a social system. *Proceedings of the National Academy of Sciences*, *105*(41), 15649-15653.

Github

https://github.com/dmainf/data_comp

付録

やっていること概略

問題

間欠需要・ロングテールな分布データのスパイク予測は困難

⬇

解決策

巨大なモデルでごり押す

そこに汎用性や効率性を得られれば更によい

TFT-説明変数

- Static features: ['出版社', '著者名', '大分類', '中分類', '小分類', '書名_base']
- Time features (known covariates): ['month_sin', 'month_cos', 'dayofweek_sin', 'dayofweek_cos', '大分類_log_本体価格_relative', '大分類_log_本体価格_z_score', '中分類_log_本体価格_relative', '中分類_log_本体価格_z_score', '小分類_log_本体価格_relative', '小分類_log_本体価格_z_score']
- Past dynamic features (observed covariates): ['大分類_POS販売冊数_relative', '大分類_POS販売冊数_z_score', '中分類_POS販売冊数_relative', '中分類_POS販売冊数_z_score', '小分類_POS販売冊数_relative', '小分類_POS販売冊数_z_score', 'momentum', 'volatility', 'z_score', 'days_since_spike_1.5', 'days_since_spike_2.0', 'days_since_spike_2.5', 'days_since_spike_3.0', 'is_spike_1.5', 'is_spike_2.0', 'is_spike_2.5', 'is_spike_3.0', 'feat_adi', 'feat_cv2', 'feat_hawkes', 'feat_days_since', 'feat_periodicity_score', 'feat_detected_period', 'score_sparse', 'score_periodic', 'score_burst']

性能評価指標

データポイントの区分：書名・日付ごと

誤差 = 予測分布の中央値 - 実測値

QL：Quantile Loss，分位点損失

MAE：データポイントごとの誤差の絶対値，の全データポイントの平均

RMSE：データポイントごとの誤差の2乗，の全データポイントの平均，のルート

QL0.1：データポイントごとの誤差の絶対値，に実測値が予測分布下位10%の値を上回るとき0.1，下回るとき0.9(ペナルティ)を掛けたもの，の合計を全書名総POS販売冊数で割ったもの．予測分布が下限をどれだけ捉えられているか

QL0.5：データポイントごとの誤差の絶対値，の合計，を全書名総POS販売冊数で割ったもの．実質MSEをスケールしたもの

QL0.9：データポイントごとの誤差の絶対値，に実測値が予測分布下位90%の値を上回るとき0.9(ペナルティ)，下回るとき0.1を掛けたもの，の合計を全書名総POS販売冊数で割ったもの．予測分布が上限をどれだけ捉えられているか

QLmean：QL0.1, QL0.5, QL0.9の平均

Cov(80%)：データポイントごとの実測値，が予測区間80%(予測分布下限10%~90%)に収まっている割合，の全データポイントの平均．0.8が適切．ここが0.8より高いとはモデルが予測区間を広げすぎてるということ．

性能評価指標-分位点損失

$L\tau$を

$$L\tau(y, \hat{y}) = \max\big(\tau(y - \hat{y}), (1 - \tau)(y - \hat{y})\big)$$

と定義したとき, QL_τは

$$QL\tau = \frac{2\sum_{i,t} L_\tau(y_{i,t}, \hat{y}_{i,t}{}^{(\tau)})}{\sum_{i,t}|y_{i,t}|}$$

τ: 分位点$[0.1, 0.5, 0.9]$
y: 実測値
$\hat{y}$: 予測値

$$QL_{mean} = mean(QL_{0.1}, QL_{0.5}, QL_{0.9})$$

TFTの性能評価

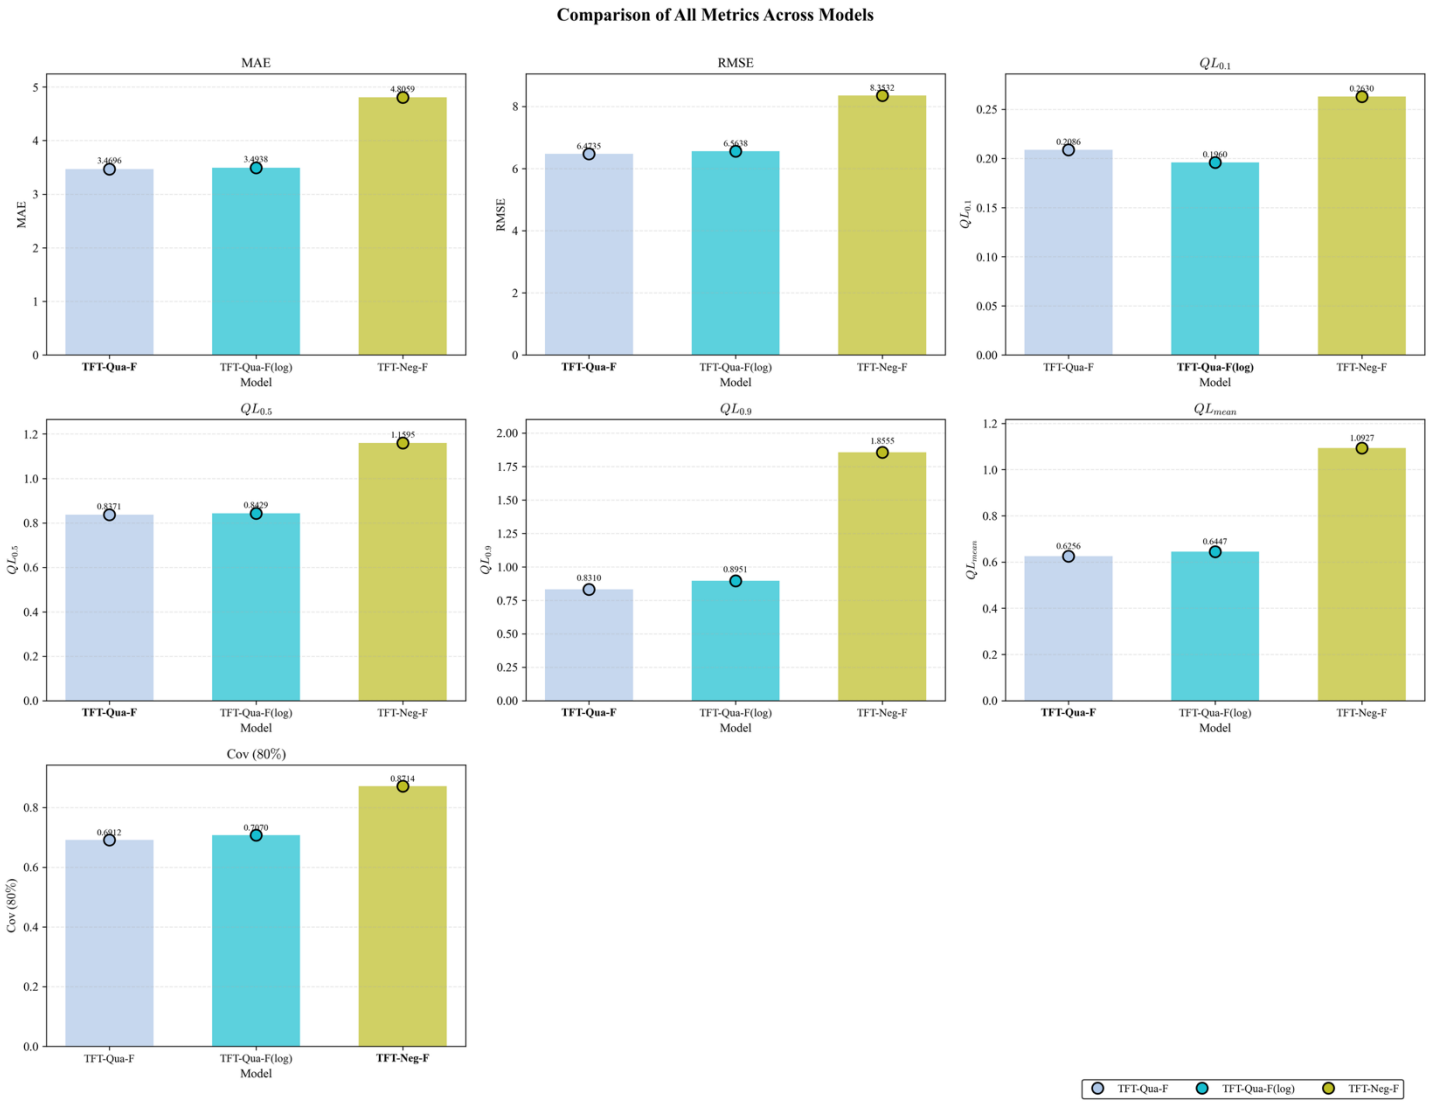

TFTの損失関数を

1. 負の二項分布
2. 分位点損失
3. 分位点損失(+目的変数を対数変換)

した3つのモデルを

$MAE, RMSE, Cov(80\%), QL_{0.1}, QL_{0.5}, QL_{0.9}, QL_{mean}$

の7つの指標で評価

TFT-特徴量エンジニアリング-hazard

目標：スパイクの来やすさ(hazardと定義)をモデル外で決定し，hazardが高いときにスパイクを予測しやすくする挙動を作る

POS販売冊数について

- momentum：1日前から$\max(1, now - PREDICTION_LENGTH)$の平均/ 1日前から$\max(1, now - CONTEXT_LENGTH)$ の平均
- volatility：1日前から$\max(1, now - CONTEXT_LENGTH)$までの標準偏差
- z-score：1日前から$\max(1, now - CONTEXT_LENGTH)$までのz-score
- is_spike_x：z−score $= [1.5, 2.0, 2.5, 3.0]$を超えたかのboolでone-hot
- days_since_spike_x：is_spikeの発火からの経過日数

TFT-特徴量エンジニアリング-hazard

z-score = 2.0 のときのhazard特徴量

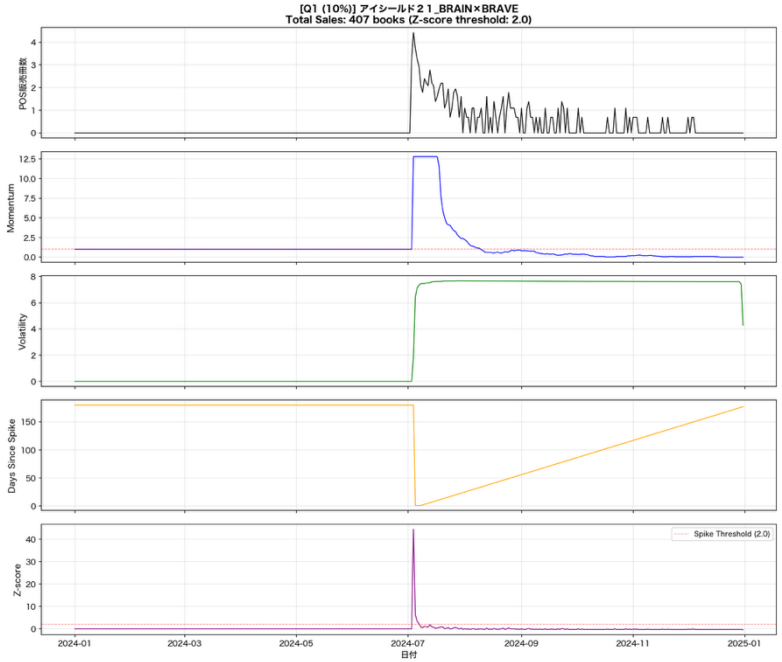

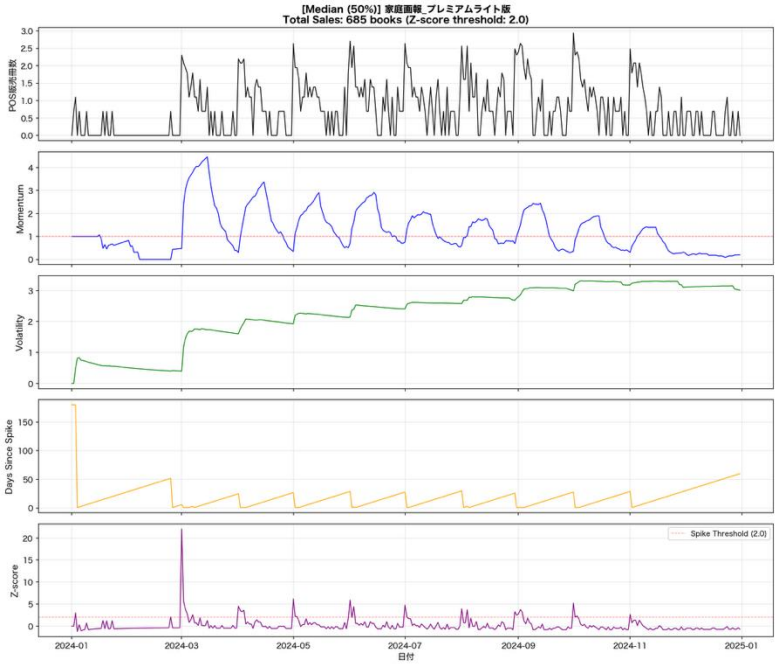

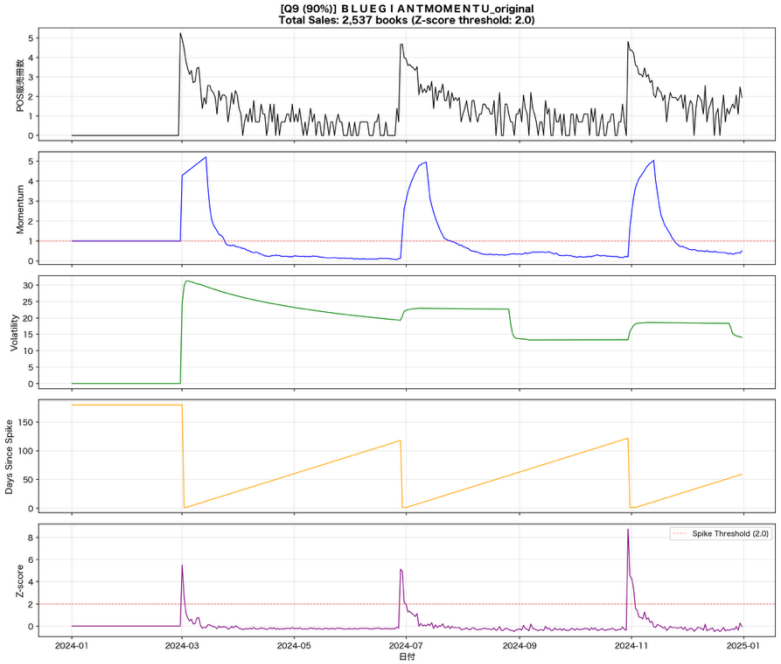

TFT-特徴量エンジニアリング-regime

売上パターンを以下の3パターンに分類できる(hazardの変動から判断)

1. ハザードが「一定」（Constant）
   意味: 「昨日売れなかったこと」は，「今日売れる確率」に何の影響も与えない
   現象: 完全なランダム需要（ポアソン過程）
   例: たまたま通りがかった人が買うような本

2. パターンB：ハザードが「増加」（Increasing）
   意味:「売れない期間が長引けば長引くほど，そろそろ売れる確率が高まる」
   現象: 定期的な補充や，必需品的な需要
   例: 在庫切れしていた人気本が入荷した瞬間.
   「そろそろこのシリーズのファンが買いに来る頃だ」という周期性

3. パターンC：ハザードが「減少」（Decreasing）
   意味:「時間が経てば経つほど，ますます売れなくなる」
   現象: 流行り廃り，鮮度が重要な商品.
   例: 週刊誌やニュース雑誌．発売直後は爆発的に売れるが（ハザードが高い），3日売れ残ったら，もう永遠に売れない可能性が高い
   （ハザードが下がる）
   「初動で売れなかった新刊は，その後も売れない」という現象

TFT-特徴量エンジニアリング-regime

目標： 売上パターンを分けることで周期性があるスパイクと周期性がないスパイクを区別する

- adi(何日ごとに売上が発生するか)
- cv2(売上がどれほど規則的か)
- hawkes(売上が売上をどれほどバーストさせるか)[3][4][5]

を算出しその3つの数値から書名ごとのそれぞれの期間の

- Sparse(どれくらい過疎ってるか)
- Periodic(どれくらい周期的か)
- Burst(どれくらいバズってるか)

を算出

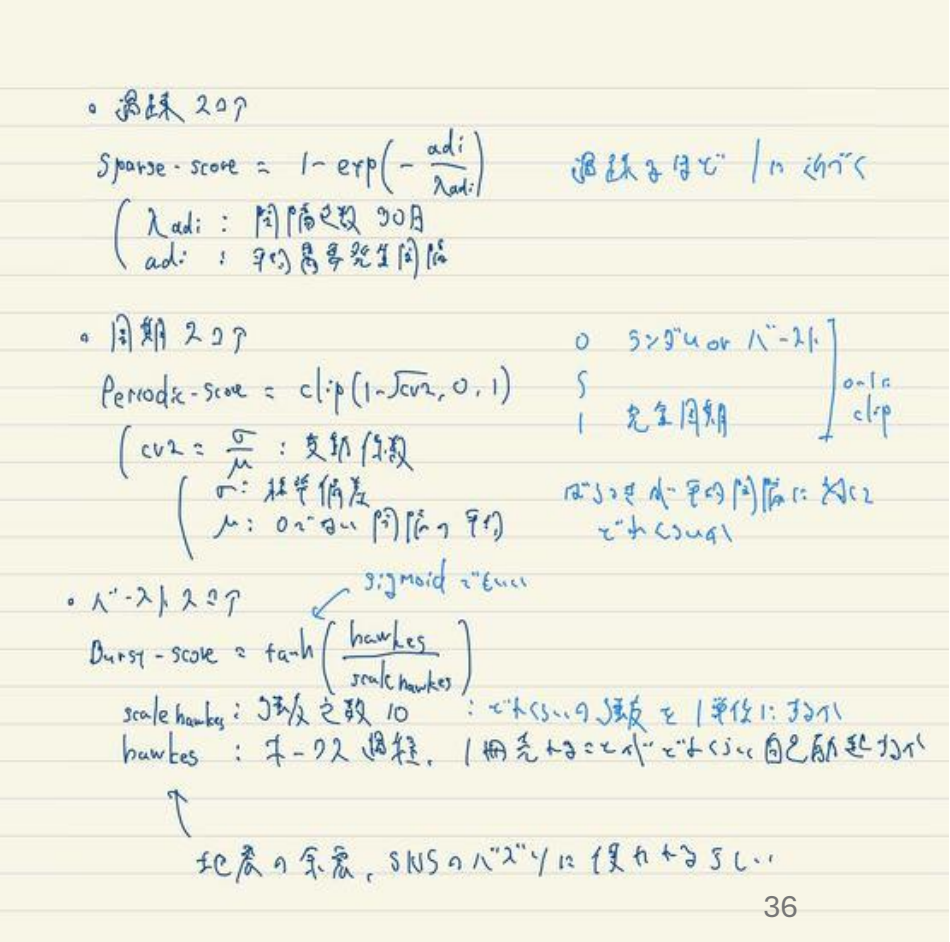

TFT-特徴量エンジニアリング-regime

regime特徴量

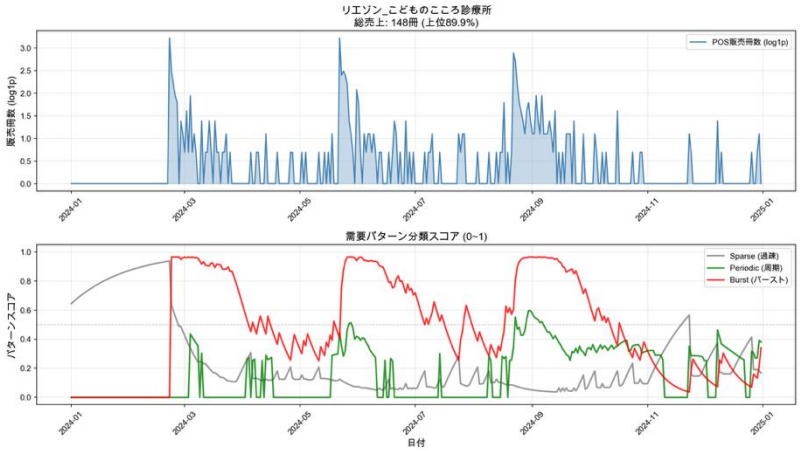

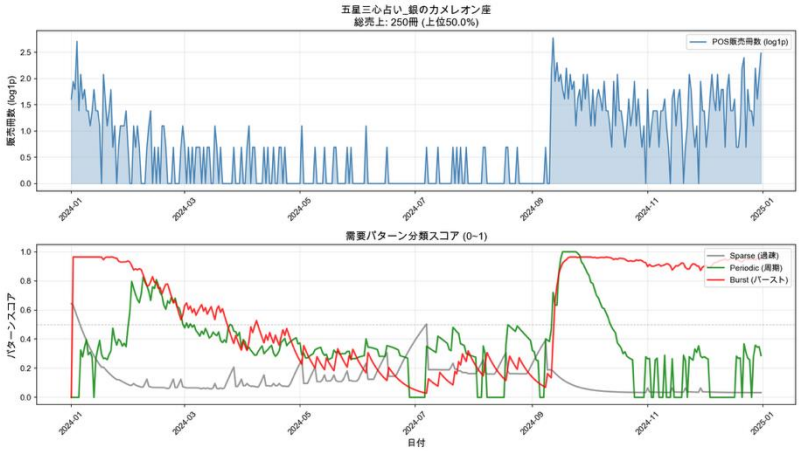

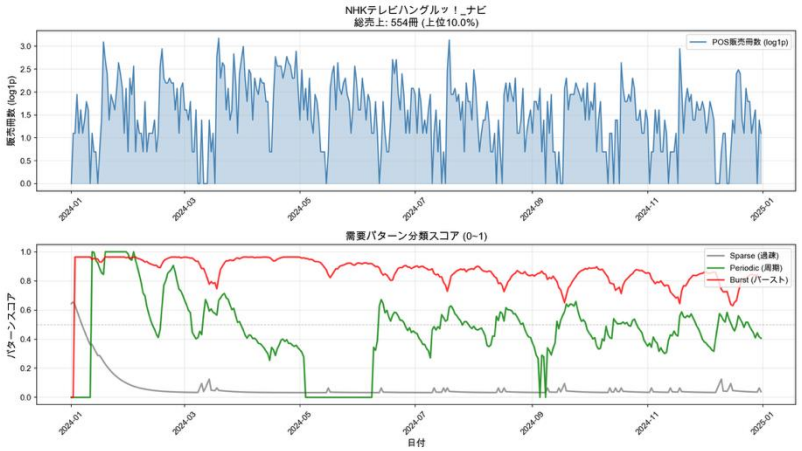

Regime_score

・sparse_score
売上発生の間隔（ADI）と売上の不規則性（CV^2）を組み合わせて算出する。
ADI が大きく、かつ売上が不規則であるほど、sparse_score は高くなる。

・burst_score
売上量のばらつき（CV^2）と自己励起性（Hawkes 強度）を用いて算出する。
大きな売上が突発的に発生し、かつその後の売上を誘発する場合、burst_score は高くなる。

・periodic_score
自己相関に基づく周期性指標を用いて算出する。
一定周期で売上が発生する場合、periodic_score高くなる。
（今回はsparse/burstに焦点を当てたため省略）

各書名・各期間について、Sparse / Periodic / Burst の各 score を算出し、
最も高い score を示した regime をその書名の需要構造として定義した。
今回はルールベース的な分類ではなく、連続的なスコアに基づく相対的なものとした。

現時点のRAFの性能

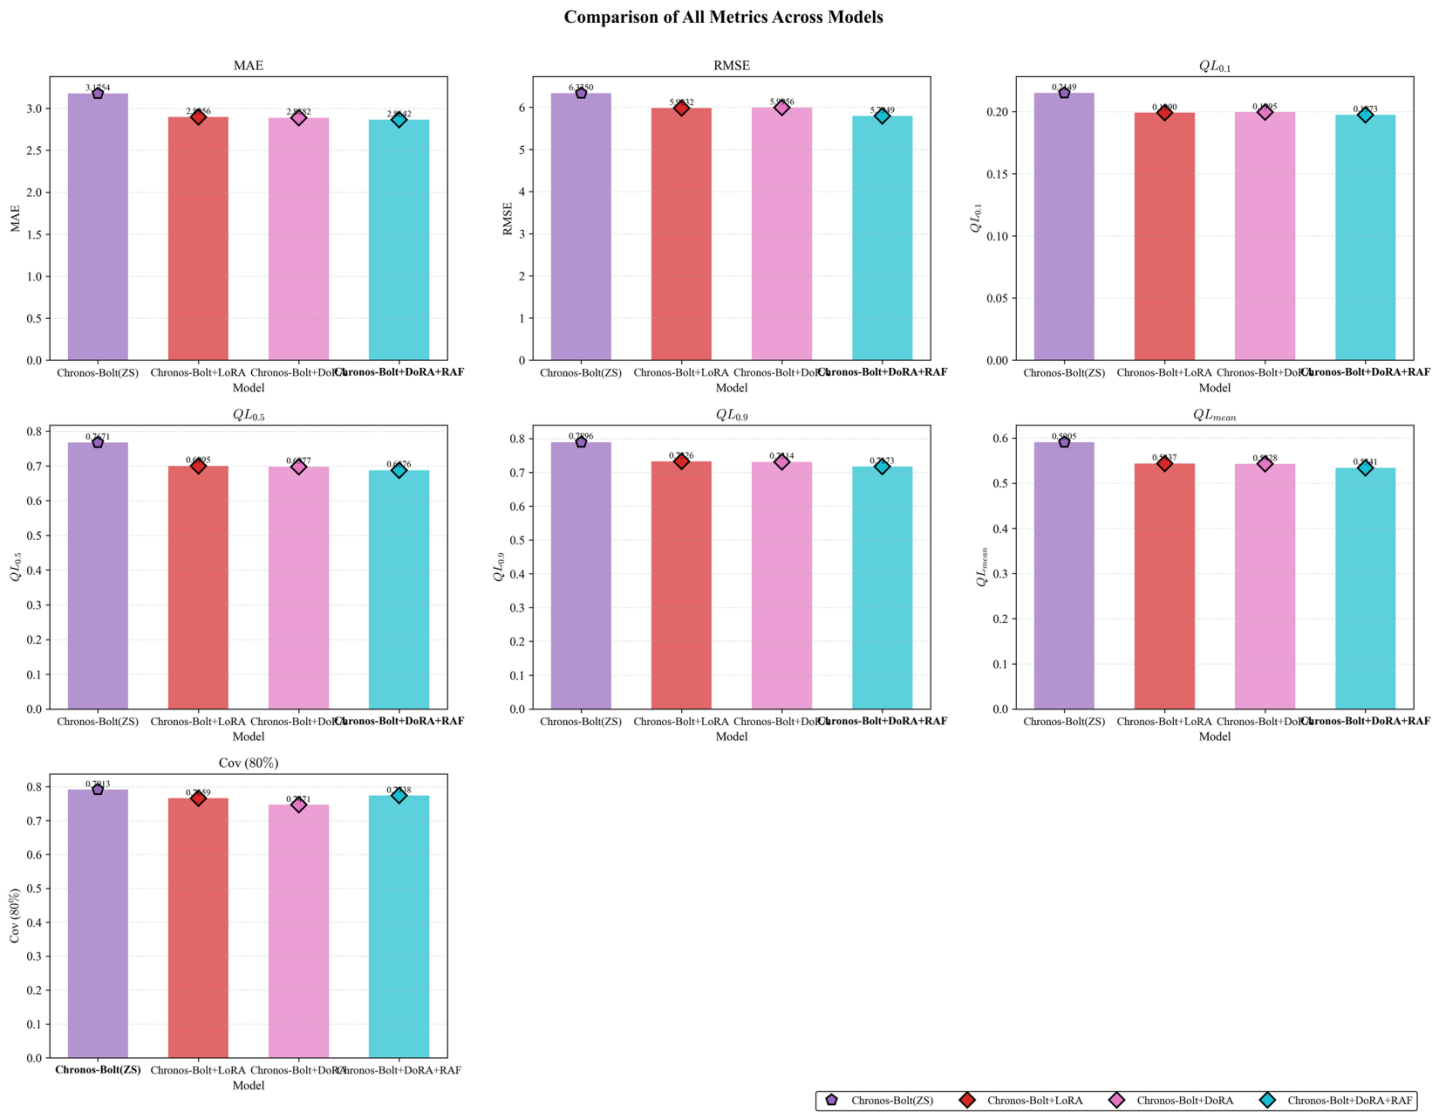
Comparison of All Metrics Across Models
MAE
RMSE
$QL_{0.1}$
$QL_{0.5}$
$QL_{0.9}$
QL_{mean}
Cov (80%)
Chronos-Bolt(ZS)
Chronos-Bolt+LoRA
Chronos-Bolt+DoRA
Chronos-Bolt+DoRA+RAF
Model

Trandformer-Encoder-Decoderモデル

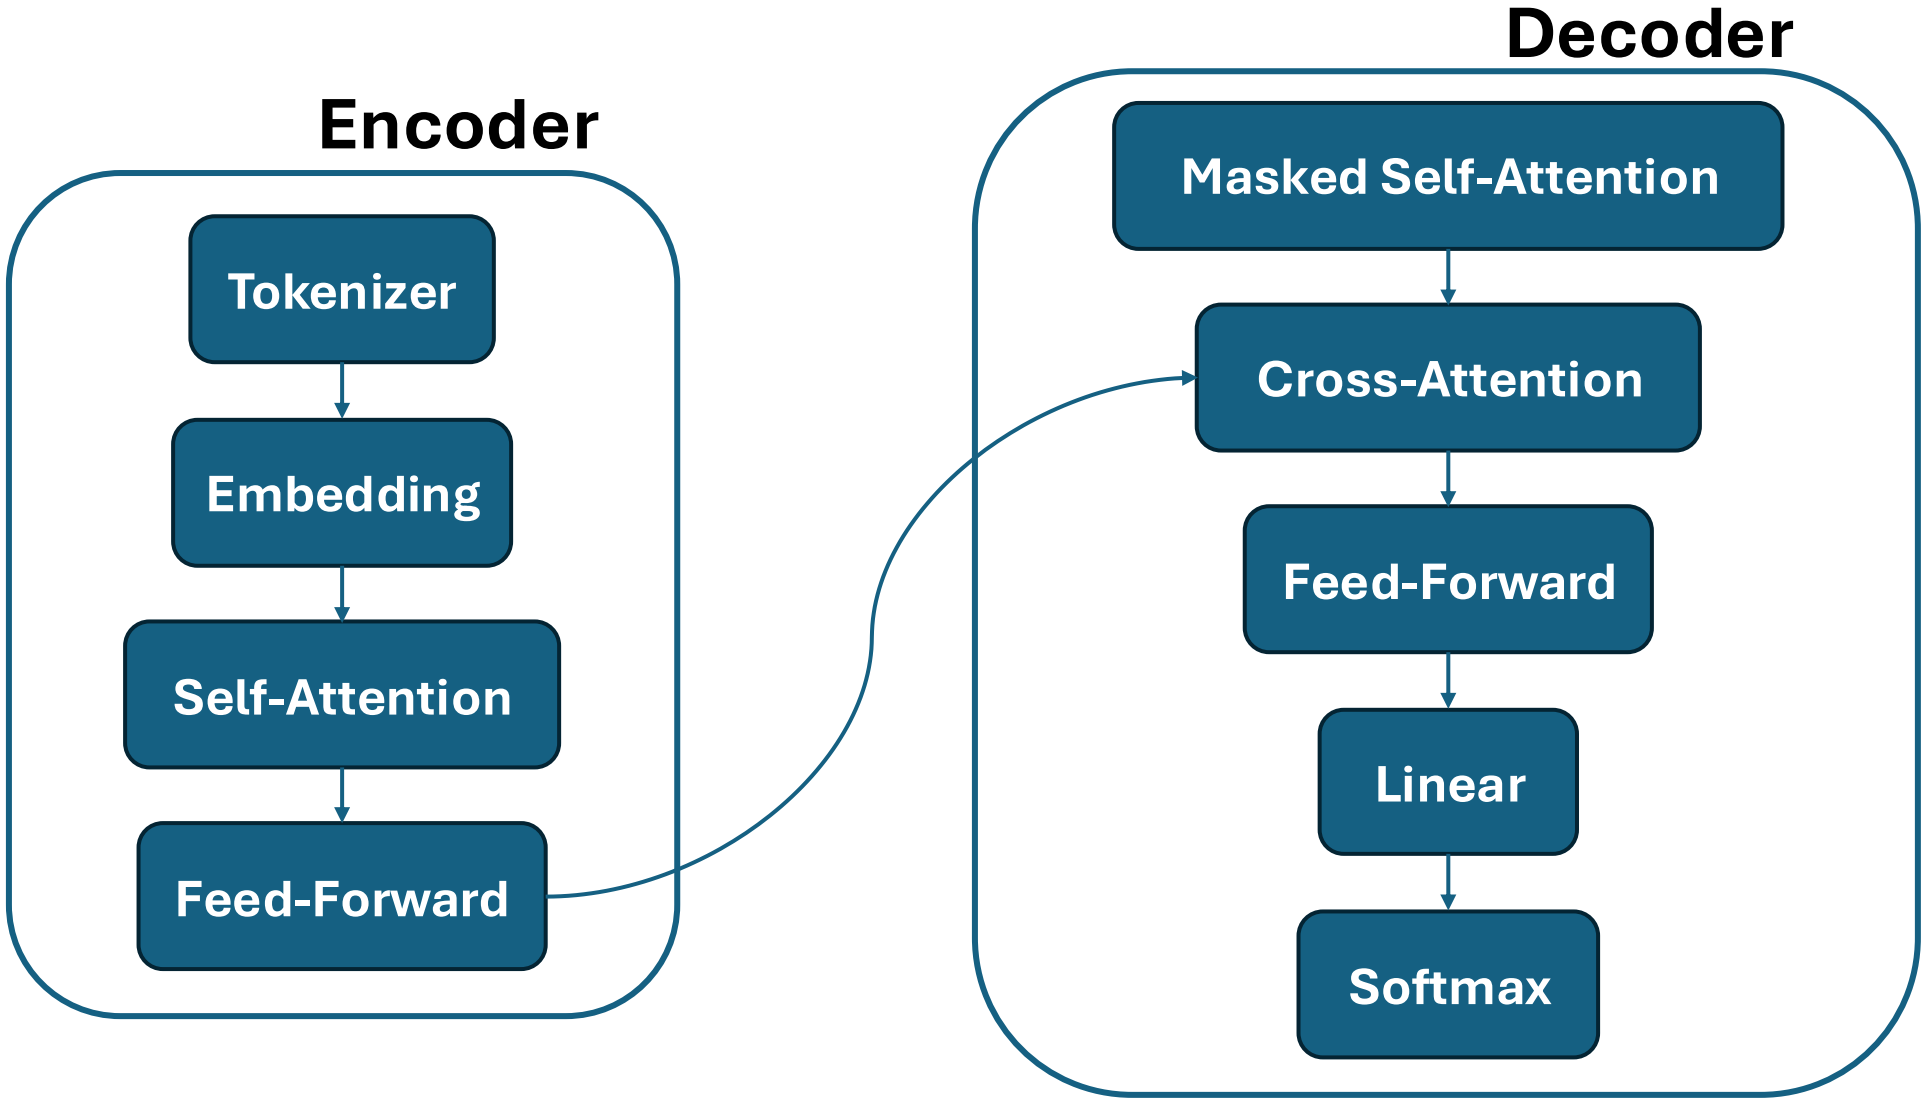

Davies-Bouldin Score

$$R_{ij} = \frac{S_i + S_j}{M_{ij}}$$

Si,Sj…クラスタ内分散
各クラスタ内のデータが中心（重心）にどれだけ集まっているか

Mij…クラスタ間距離
異なるクラスタの中心同士がどれだけ離れているか