間欠需要とロングテール分布を考慮したTFTによる売上予測

データ解析コンペJIMA予選会中間発表会

『TCU_mlab』

奈良原俊誠
斎藤陽
村山 大成
宇治雅貴
橋本朋樹
白川滉
栗山翔伍

1. 背景

2. 前処理

3. データの分布

4. 予測モデル

1. 背景

イントロダクション

背景

- 出版業界は多種少数生産で，在庫管理が難しい
- 人間の経験と勘に頼る予測は，商品の数が増え限界
- 書店員が納得できる根拠を示さなければ現場は動かない

既存の方法

- 決定木系のモデル(LightGBM, XGBoost) + 分布の仮定
- RNN系(LSTM, GRU)の深層学習モデル

問題

- 決定木系のモデルによる『時系列文脈の欠落』

＝静的なラグ特徴量に依存する

- 深層学習モデルによる『判断根拠のブラックボックス化』

実データの

- 表記ゆれによる『情報の分断』
- データの『ゼロ過剰』

私たちのテーマ

実データの不確実性を克服し、予測精度と説明可能性を両立するモデルの構築

- 時系列文脈の統合
- 可視化によって，使用者に考察の余地を残す
- 実データ特有の性質(間欠需要，ロングテール)への適応

2. 前处理

欠損値の処理

予測精度を上げるため，欠損値の処理をする必要がある

- データの「質」の確保　　＝明らかにノイズになりそうなデータを排除する
- データの「量」の確保　　＝安易に削除すると学習データが激減する

欠損値のパターン

	欠損の仕方	データ数	処理方法
パターン1	’著者名’のみが欠損	1,331,681件	欠損値そのままとして扱う
パターン2	‘出版社’, ‘書名’, ‘著者名’, ‘本体価格‘が同時に欠損	6,736件	データとして不完全のため列ごと削除
パターン3	’大分類’, ‘中分類’, ‘小分類’が同時に欠損	281件	他書籍と比較検討しながら人力で補完
パターン4	‘出版社’ のみが欠損	18件	ISBNカラムから出版社情報を特定し人力で補完

- データ数が少ないものは傾向を見ながら1つずつ補完
  - e.g. パターン3はデータ数は多いが，ユニーク数は21
- 欠損自体に意味のあるデータは残したい
  - e.g. パターン1は数が大きすぎる+’月刊誌’が50%を占めている

パターン1の大分類の分布

書名の正規化

『点』から『線』の予測をする

- ‘書名’について「巻数」ごとのデータを「シリーズ」ごとのデータとして見たい

→時系列の結合

課題

- あまりに多くのパターンが混在し，すべてを網羅した正規化はほぼ不可能

対応策

- 出現回数1000回以上の書名に限定

それ以下の書名に周期性は確認できないと判断

正規化ルール

- 「作品_シリーズ_巻数」の形に正規化

「_巻数」を削除することで「作品_シリーズ」ごとの時系列データとして見れる

- 本編は「original」と定義

e.g. 呪術廻戦_original_3

結果

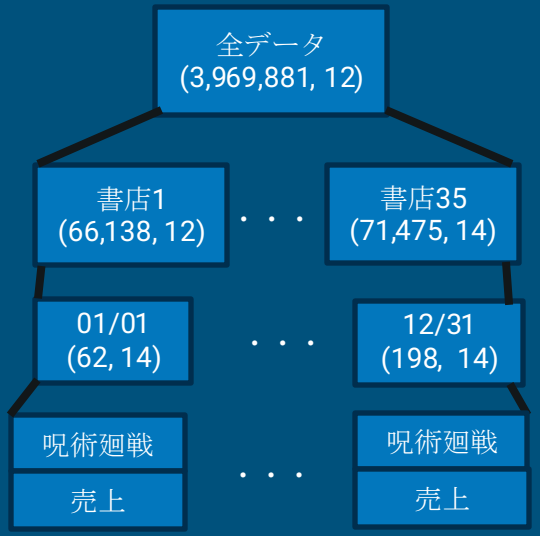

何を予測するか(図解)

呪術廻戦_original	20121
ブルーロック_original	18833
葬送のフリーレン_original	17064
薬屋のひとりごと_original	15538
ＯＮＥＰＩＥＣＥ_original	13493
怪獣８号_original	13455
僕のヒーローアカデミア_original	12870
キングダム_original	11310
ハイキュー_original	11227
ダンダダン_original	10230

書名(「作品_シリーズ」)とその出現回数

3. データの分布

本データの特徴

※ADI, ジニ係数は総POS販売冊数上位500の書名に限定して算出

間欠需要：ゼロ過剰かつ散発的な売上(スパイク)の発生

ADI　8.1925　(大きいほどゼロ需要が大きい)

→常に0を予測する局所解に陥りやすい

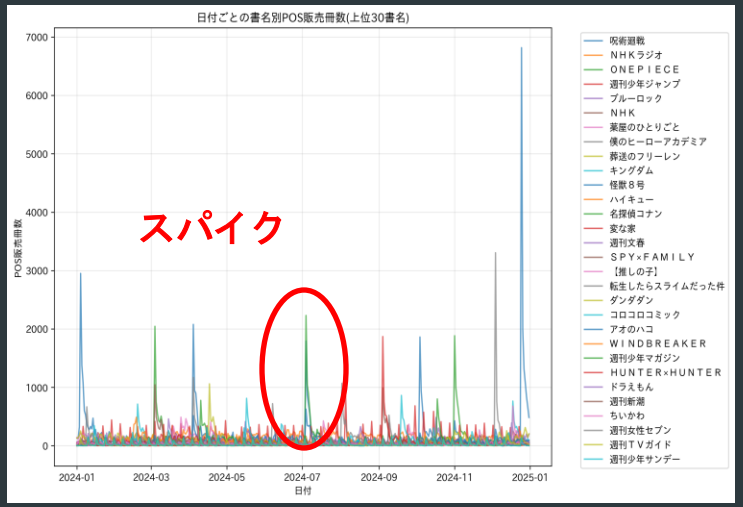

総POS販売冊数上位30書名の日付ごとのPOS販売冊数
(横軸：日付，縦軸：POS販売冊数)

ロングテール：膨大な数の書名でPOS販売冊数が少数

ジニ係数　0.8337　(1に近いほど不均衡が大きい)

→テールの個別パターンの抽出が困難

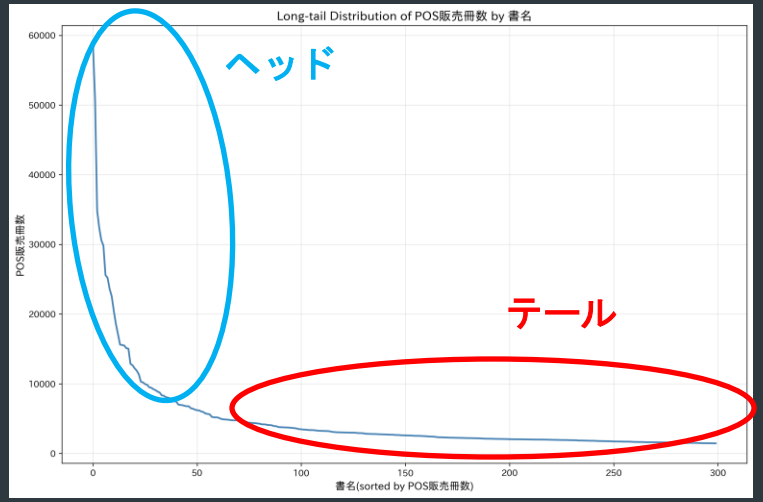

総POS販売冊数上位300書名ごとの分布
横軸：書名(総POS販売冊数の降順)，縦軸：POS販売冊数)

4. 予測モデル

TFT(Temporal Fusion Transformer)

※書店別，日付・書名ごとのPOS販売冊数を予測する

時系列の分断・ブラックボックス・間欠需要・ロングテールに対抗し得るモデル

TFT [1] ：LSTMとTransformerを組み込んだ時系列予測モデル

LSTMの局所的な予測とTransformerの長期的な依存関係を融合する

- 情報の性質で分類して与える入力データ

静的特徴量	時間によって変動しない情報	e.g. 書店コード
既知の動的特徴量	確定している未来の情報	e.g. 曜日
過去の動的特徴量	過去の地点でのみ観測できる情報	e.g. POS販売冊数

良い点

- 間欠需要の予測に優れる

既知の動的特徴量によって突発的な需要を補足できる

- ロングテールな分布の予測に優れる

静的特徴量を使ったCross-learningはヘッドのパターンをテールに適応できる

問題点

- 標準の損失関数がゼロ過剰データに向いていない

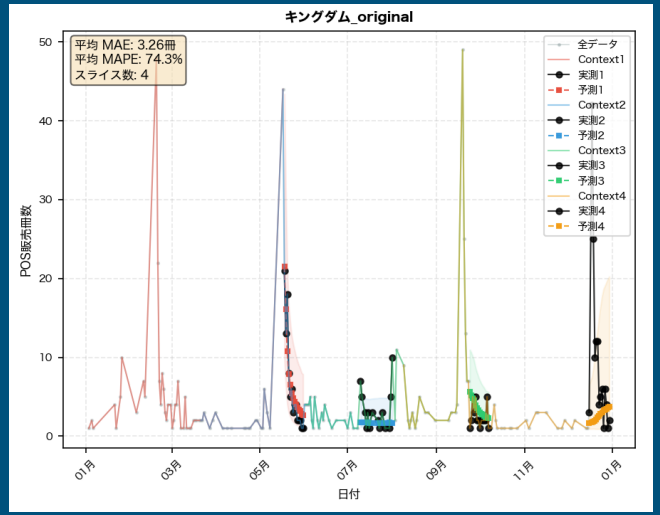

書店コード11'キングダム_originalの予測結果
(横軸：日付，縦軸：POS販売冊数)

間欠需要・ロングテールを克服するために

標準TFTの損失関数の限界

TFTの構造自体は間欠需要・ロングテールな分布に適しているが，損失関数が最適化されていない

解決策

TFTの損失関数にTweedie分布や負の二項分布を仮定し，ゼロ過剰なデータに適応させる

Tweedie分布[2]

$$Var(X) = \phi\mu^p$$

→pを変動させることで適切な分散を仮定できる

ϕ	定数
μ	平均
p	パラメータ

Tweedie損失関数

$$Loss = -y\frac{\hat{y}^{1-p}}{1-p} + \frac{\hat{y}^{2-p}}{2-p} \xrightarrow{\text{微分}} \frac{1}{\hat{y}^p}$$

y	実測値
$\hat{y}$	予測値

※負の二項分布は発散する箇所があり若干危険

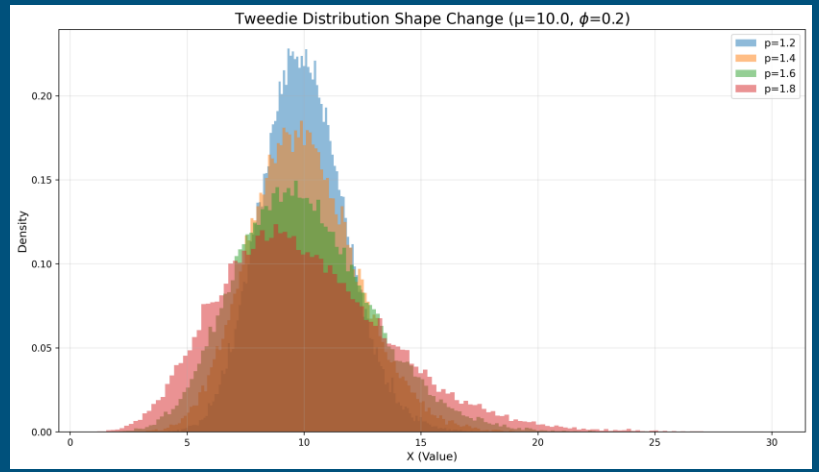

参照

[1] Lim, B., Arık, S. Ö., Loeff, N., & Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. International journal of forecasting, 37(4), 1748-1764.

[2] Tweedie, M. C. (1984, December). An index which distinguishes between some important exponential families. In *Statistics: Applications and new directions: Proc. Indian statistical institute golden Jubilee International conference* (Vol. 579, pp. 579-604).

付録

負の二項分布

成功回数 r とするとき，確率変数 X が値 k を取る確率 $P(X=k)$ が

$$P(X=k)=\binom{k+r-1}{r-1}p^r(1-p)^k$$

で表されるならば，確率変数 X は負の二項分布 $NB(r,p)$に従う．(ただし $0<P(X=k)<1, 1\leq r$)

期待値 $E[X]=\mu=\frac{r(1-p)}{p}$

分散 $\mathrm{Var(X)}=\alpha=\frac{r(1-p)}{p^2}$

モーメント母関数 $M_X(t)=\left(\frac{p}{1-(1-p)e^t}\right)^r$

αが0に近づくとき$\frac{1}{\alpha}$が無限大になる

$$P(X=k|\mu,\alpha)=\frac{\Gamma\left(k+\frac{1}{\alpha}\right)}{\Gamma(k+1)\Gamma\left(\frac{1}{\alpha}\right)}\boxed{\left(\frac{1}{1+\alpha\mu}\right)^{\frac{1}{\alpha}}}\left(\frac{\alpha\mu}{1+\alpha\mu}\right)^k$$

付録

ジニ係数

データの総数 n を第 i 番目のデータの値を x_i，データの値の平均値を $\bar{x}$ とするとき，分布の不均衡度を表すジニ係数 G は以下の式で定義される．

$$G = \frac{\sum_{i=1}^{n}\sum_{j=1}^{n}|x_i - xj|}{2n^2\bar{x}}$$

ADI

$$\boldsymbol{ADI} = \frac{\text{総期間数}}{\text{非ゼロ需要の発生回数}}$$

Head, Tail

ロングテール分布において，出現頻度（売上など）が高く全体の大部分を占める少数の上位領域をヘッド，出現頻度は低いが項目数が膨大でグラフの裾野として長く伸びる下位領域をテールと定義する．

付録

TFTの4つの特徴

- 情報の性質で分類して与える入力データ

静的特徴量	時間によって変動しない情報　e.g. 書店コード
既知の動的特徴量	確定している未来の情報　e.g. 曜日
過去の動的特徴量	過去の地点でのみ観測できる情報　e.g. POS販売冊数

- ゲート付き処理
  ネットワーク全体に配置されたゲート機構が
  深さ制御と変数の選択をする
- 分位点回帰による出力
  点推定ではなく予測区間(確率的な幅)を出力する
- 変数の重要度，時間方向のAttentionを可視化

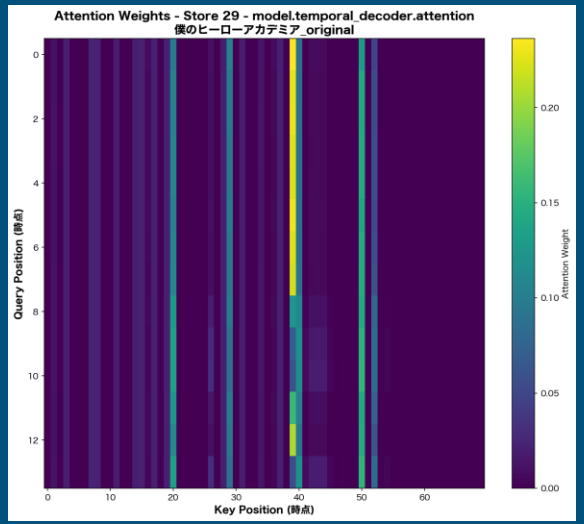

書店コード=29，'僕のヒーローアカデミア'のAttention
(横軸：参照する過去の時点，縦軸：予測する未来の時点)

付録

CONTEXTとPREDICTIONを使った
学習期間・予測期間の決定

1. MIN_LENGTH = CONTEXT + PREDICTION
2. if < MIN_LENGTH
   drop
3. If 売上の合計 < 閾値
   drop
4. データ長とMIN_LENGTHでSLICEを決定
5. for in SLICE
   ランダムにSTARTを決定
   END = START + MIN_LENGTH

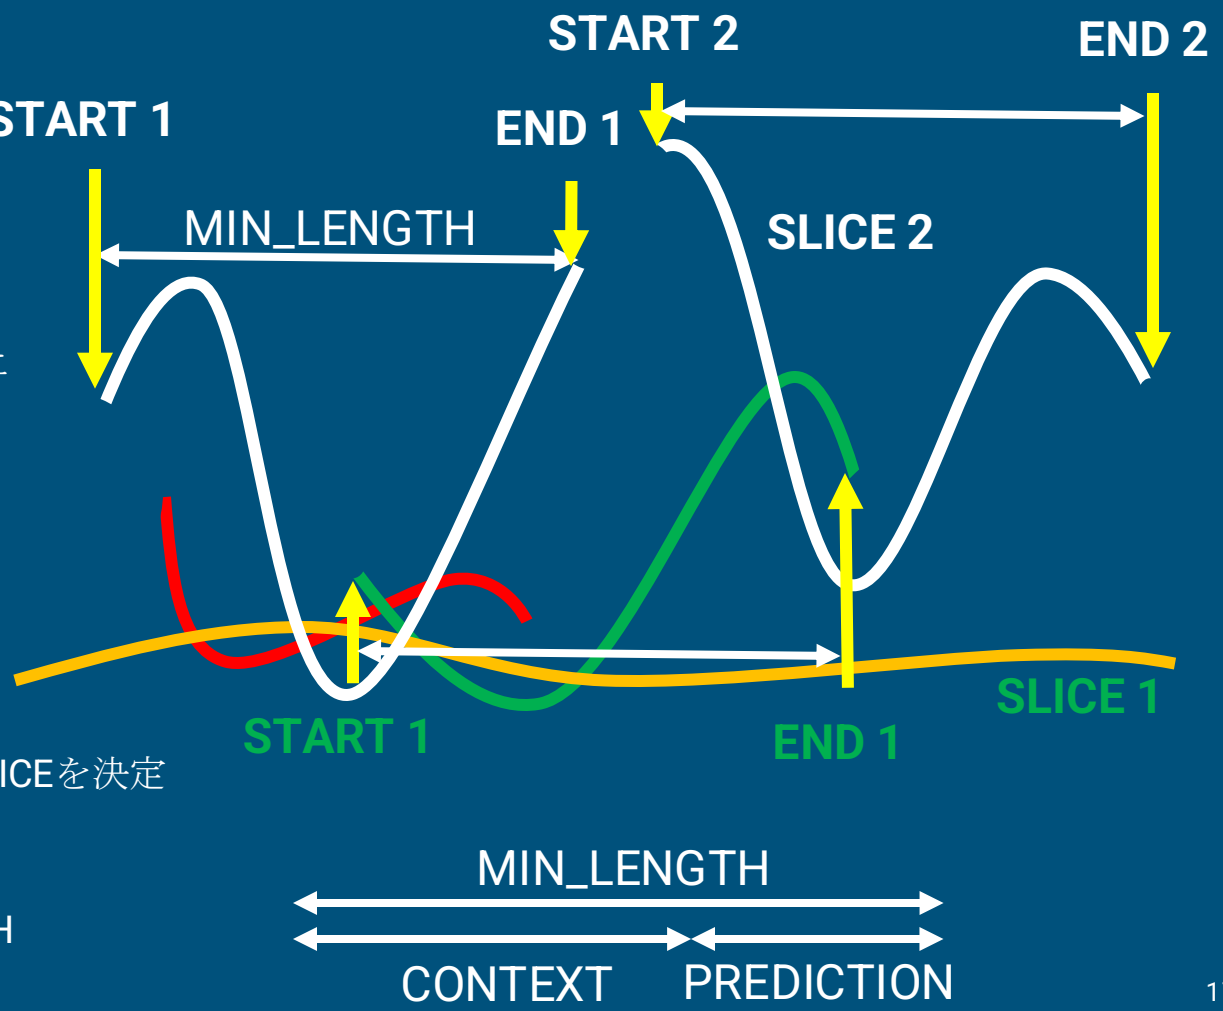

付録

・メッシュを用いたデータ拡張

店舗住所から3次メッシュと4次メッシュのデータを集積し、人口データを格納
店舗を中心として3x3の9マスのデータを取得
※3次メッシュ：各辺約1kmの四角形
※4次メッシュ：各辺約500mの四角形

e.g. 東京駅を中心とした場合
(本データとの店舗位置とは無関係)

3次メッシュ(広範囲)

4次メッシュ(狭範囲)

付録

目的：メッシュデータを扱うことにより、各メッシュ内の人口を調査することが可能
調査した人口をもとに新たな視点でのデータ分析や説明変数として扱う

利点：メッシュ内の人口を割り出すことにより店舗に近い人口（徒歩圏内の人口）を
割り出すことが可能となり、訪れる可能性がある人口数を店舗ごとに確認できる

手法：1. 店舗位置を住所から座標に変換
2. メッシュコード記載の地図より、座標が位置するメッシュを特定
3. 2020年度国勢調査より該当メッシュの人口を抽出
4. 周辺8マスのメッシュでも同様の操作を行う
5. メッシュを北東より1-9の番号を振分各メッシュの人口を別々に格納

e.g. 東京駅を中心とした3次メッシュ

付録

店舗位置を座標で置く際の統一ルール

1. 各店舗に対して「独立店舗型」,「複合施設型」,
   「駅構内型」のデータを与える

2-1. 「独立店舗型」
   地図上で店舗の各頂点の座標から重心をもとめる

2-2. 「複合施設型」
   施設のフロアマップより店舗位置を特定する

2-3. 「駅構内型」
   駅構内図より店舗位置を特定する

3. 2で求めた位置を座標情報として保存し、
   座標が位置するメッシュを店舗が位置するメッシュとする

e.g. 東京駅がメッシュを跨いでいる様子

※2-2, 2-3については一般公開されているオープンデータより引用

付録

・メッシュ及び人口調査に使用したサイト

JSTAT MAP
https://jstatmap.e-stat.go.jp/map.html

Arc-gis ITARDA WEB マップ

https://www.arcgis.com/apps/MapAndAppGallery/index.html?appid=350c2d2044ea4b9380cc3cb2eb6251ac

E-stat 国勢調査
https://www.e-stat.go.jp/